

硕士学位论文

(学术学位论文)

面向航空制造的电连接器机器人自主抓取 与装配系统研究

**RESEARCH ON ROBOTIC AUTONOMOUS
GRASPING AND ASSEMBLY SYSTEM FOR
ELECTRICAL CONNECTORS IN AVIATION
MANUFACTURING**

待填写

哈尔滨工业大学

2026 年 4 月

国内图书分类号：TP242
国际图书分类号：621.8

学校代码：10213
密级：公开

硕士学位论文

面向航空制造的电连接器机器人自主抓取 与装配系统研究

硕士研究生：待填写

导 师：待填写

申 请 学 位：工学硕士

学 科 或 类 别：机械工程

所 在 单 位：机电工程学院

答 辩 日 期：2026 年 4 月

授予学位单位：哈尔滨工业大学

Classified Index: TP242

U.D.C: 621.8

Dissertation for the Master's Degree

**RESEARCH ON ROBOTIC
AUTONOMOUS GRASPING AND
ASSEMBLY SYSTEM FOR ELECTRICAL
CONNECTORS IN AVIATION
MANUFACTURING**

Candidate:	To Be Filled
Supervisor:	To Be Filled
Academic Degree Applied for:	Master of Engineering
Specialty:	Mechanical Engineering
Affiliation:	School of Mechatronics Engineering
Date of Defence:	April, 2026
Degree-Conferring-Institution:	Harbin Institute of Technology

摘 要

本文面向航空制造场景下电连接器机器人自主抓取与装配任务，围绕复杂机舱环境中目标遮挡严重、柔性线缆干扰显著以及狭窄空间运动受限等问题，研究电连接器视觉感知、自主抓取规划与柔顺装配控制方法。论文以电连接器为核心对象，构建由目标识别与位姿估计、候选抓取生成与筛选、引导式避障路径规划以及装配控制组成的技术路线，为形成面向航空非结构化环境的自主装配系统提供方法基础。

在视觉感知方面，论文研究多实例连接器识别、标签身份区分、6D 位姿估计及线缆掩膜提取方法；在自主抓取方面，研究面向装配任务的候选抓取生成、多约束抓取筛选以及避开柔性线缆障碍的运动规划策略；在装配执行方面，进一步为后续柔顺控制与系统集成提供状态输入与轨迹先验。现有内容已迁移至本 LaTeX 工程中，后续可在此基础上继续完善摘要、参考文献、图表与实验结果。

关键词：航空制造；电连接器；自主抓取；柔顺装配；机器人系统

Abstract

This thesis focuses on robotic autonomous grasping and assembly of electrical connectors in aviation manufacturing scenarios. Aiming at severe occlusion, flexible cable interference, and motion constraints in narrow cabin environments, the work investigates visual perception, grasp planning, and compliant assembly methods for electrical connectors. The overall technical route includes target recognition and pose estimation, candidate grasp generation and selection, guided collision-free motion planning, and subsequent assembly-oriented control.

The current LaTeX project has been initialized according to the HIT thesis template, and the existing thesis content has been migrated into chapter files. It can be further refined by completing metadata, references, figures, tables, and experimental results.

Keywords: aviation manufacturing, electrical connector, autonomous grasping, compliant assembly, robotic system

目 录

摘 要	I
Abstract	II
第 1 章 绪论	1
1.1 课题来源	1
1.2 课题研究背景及意义	1
1.3 国内外研究现状	2
1.3.1 目标感知与 6D 位姿估计研究现状	2
1.3.2 复杂受限空间规划与避障研究现状	5
1.3.3 机器人精密力控装配研究现状	7
1.3.4 国内外研究现状分析	9
1.4 本文的主要研究内容	10
第 2 章 基于深度学习的电连接器识别与位姿估计研究	12
2.1 引言	12
2.2 标签识别数据集的制作与分析	12
2.2.1 数据采集与标注方案	13
2.2.2 数据增强	17
2.2.3 数据集特征分析	18
2.3 基于 YOLOv8-seg 的目标检测与实例分割	19
2.3.1 算法选型与总体结构	19
2.3.2 损失函数与训练参数设置	21
2.3.3 动态 ROI 裁剪策略	23
2.4 基于改进 DeepLabV3+ 的关键特征提取与线缆分割	25
2.4.1 网络模型分析	25
2.4.2 高斯热力图建模方法	26
2.4.3 改进输出头与联合损失设计	30
2.5 基于 EPnP 与 RANSAC 的电连接器位姿解算	36
2.5.1 相机投影模型与 EPnP 求解	36
2.5.2 基于 RANSAC 的外点剔除	39

2.5.3 手眼标定与坐标系转换	42
2.6 算法验证实验	43
2.7 本章小结	47
第 3 章 电连接器自主抓取方法研究	48
3.1 引言	48
3.2 端到端 6D 抓取生成网络	48
3.2.1 抓取位姿参数化表示	48
3.2.2 基于局部点云的网络输入构建	49
3.2.3 基于 Contact-GraspNet 的抓取网络结构	52
3.2.4 正负样本判定与损失函数设计	55
3.3 抓取点选择策略研究	58
3.3.1 专用指尖结构设计 with 力封闭性评估	58
3.3.2 基于逆运动学的可达性判别	61
3.3.3 面向线缆障碍的安全间隙评价	63
3.3.4 面向任务的姿态相容性评价	64
3.3.5 综合评分函数与最优抓取确定	65
3.4 GRRT-Connect 运动规划算法研究	67
3.4.1 混合障碍物地图构建	67
3.4.2 引导式采样与双树扩展策略	71
3.4.3 路径生成与后处理优化	75
3.5 实验与结果分析	79
3.6 本章小结	81
第 4 章 电连接器柔顺装配控制方法研究	83
4.1 引言	83
4.2 含线缆干扰的轴孔装配动力学建模与控制器设计	83
4.2.1 轴孔装配误差描述	83
4.2.2 含线缆干扰的装配动力学模型	85
4.2.3 视觉前馈变刚度阻抗控制器设计	89
4.3 面向轴孔对齐插接任务的强化学习环境构建	96
4.3.1 任务形式化与状态空间设计	96
4.3.2 动作空间与下位控制约束	98
4.3.3 稀疏奖励与成功判定机制	99
4.3.4 人在回路交互与数据记录机制	102

4.4 人在回路强化学习装配策略学习与虚实迁移方法	103
4.4.1 人在回路装配策略学习框架	104
4.4.2 装配策略网络结构与在线优化训练方法	105
4.4.3 基于 IsaacSim 的仿真预训练与虚实迁移方法	110
4.5 装配实验与结果分析	113
4.5.1 变刚度阻抗控制器实机验证	113
4.5.2 虚实迁移训练与实机装配实验	114
4.6 本章小结	117
第 5 章 电连接器机器人自主装配系统集成与综合实验研究	119
5.1 引言	119
5.2 实验平台搭建与系统集成	119
5.2.1 航空机舱模拟环境与硬件构成	119
5.2.2 系统标定与精度分析	122
5.2.3 软件体系与数据流闭环	125
5.3 感知—规划子系统联合验证实验	127
5.3.1 三种典型工况设置	127
5.3.2 感知识别与抓取验证	128
5.3.3 规划消融对比实验	130
5.4 面向航空制造的全流程综合验证	133
5.4.1 实验流程设计	133
5.4.2 三种场景下的全流程实验结果与典型失败分析	134
5.5 本章小结	138
结 论	140
参考文献	141

第 1 章 绪论

1.1 课题来源

本课题来源于国家自然科学基金集成项目“面向航空制造的人-机器人协作技术及应用研究”，资助号：92048301。

1.2 课题研究背景及意义

在国家航空装备智能制造升级需求推动下，机舱电气系统的自动化装配已成为提升整机质量与可靠性的重要方向。电连接器作为机舱内信号与能量传输的关键节点，其装配质量直接关系到飞行安全与维护成本。当前该工序仍以人工为主，操作者需在布满管路、线槽与设备舱壁的狭窄空间中借助手持工具完成插接与锁紧，长期高强度作业导致一致性、可重复性和过程可追溯性不足。随着机舱内部系统集成度持续提高，单纯依赖人工已难以满足高可靠、标准化装配的要求，机器人替代或协同人工作业具有迫切的工程需求。

航空机舱装配环境与传统工业产线存在显著差异，可归纳为三方面。第一，空间约束突出：机舱内部结构件、舱壁与管线支架密集，布线区域狭窄且多处于深腔位置，机械臂接近目标时面临典型窄通道问题。第二，光照条件恶劣：金属舱壁强反射、局部照明不均与深阴影并存，严重干扰基于边缘与纹理特征的传统视觉算法。第三，装配对象呈刚柔耦合特性：电连接器尾部整合有柔性线缆，线缆在重力与布线约束作用下呈随机弯曲形态，在视觉层面遮挡壳体、定位孔等关键几何特征，在动力学层面引入随位姿变化的拖拽力与回复力矩，使感知精度与装配可靠性同时受到制约。

上述环境特殊性决定了电连接器机器人自主抓取与装配本质上是一个涉及复杂环境感知、柔性障碍建模、狭窄空间规划和不确定接触控制的跨模块耦合问题。然而现有研究大多针对单一子问题展开，如仅优化 6D 位姿估计精度、仅考虑刚性障碍下的运动规划，或仅围绕标准 *peg-in-hole* 任务进行策略学习，尚未形成针对航空机舱环境中带柔性拖缆电连接器抓取与装配的系统化解决方案。

在此背景下，构建面向航空制造的电连接器机器人自主抓取与装配系统，具有重要的理论价值和工程意义。在理论层面，该研究有助于推动复杂遮挡下目标感知与位姿估计、柔性障碍参与的受限空间规划以及带未知扰动的接触装

配控制等方向的交叉融合，为构建“感知—规划—控制”闭环的机器人装配理论体系提供实践支撑。在工程层面，通过实现电连接器从识别、抓取、避障搬运到柔顺插接的全流程自动化，可显著提升航空机舱装配效率与一致性，降低人工劳动强度，并为后续复杂线缆束装配与人机协作奠定基础。

1.3 国内外研究现状

1.3.1 目标感知与 6D 位姿估计研究现状

目标感知与 6D 位姿估计是机器人自主装配系统的前端关键环节，其任务是从单目、双目或 RGB-D 观测中获取目标类别、实例身份及完整的六自由度姿态信息，为后续抓取规划与装配控制提供几何约束。在航空机舱电连接器装配场景中，该问题因多实例共存、金属壳体纹理贫乏、局部强反光以及柔性线缆遮挡等因素而呈现更高的复杂度，不仅需要完成连接器身份识别与精确位姿估计，还需同步提取线缆延伸形态以服务于后续规划与力控模块。

早期 6D 位姿估计方法以 EPnP^[1] 等几何求解器与 RANSAC 鲁棒估计范式为代表，在已知二维—三维对应关系条件下可高效求解物体位姿，但高度依赖可靠的局部特征提取。在航空机舱环境中，金属壳体弱纹理与强镜面反射使特征检测器频繁失效，柔性线缆的大面积遮挡进一步削弱了可用特征，导致几何方法鲁棒性明显下降。

随着深度学习的快速发展，基于卷积神经网络的目标检测方法成为复杂场景视觉感知的主流方案。以 Faster R-CNN^[2] 为代表的两阶段检测框架（如图1-1所示）与以 YOLO^[3] 为代表的单阶段回归式检测框架（如图1-2所示）分别从精度和速度两个维度推动了目标检测的进步。Wang 等人于 2023 年提出的 YOLOv7^[4] 进一步将实时检测精度推至新高度。




图 1-1
(空白占位图)

图 1-1 Faster R-CNN 模型结构示意图（RPN 区域建议网络与 RoI Pooling 联合检测框架）

在实例分割方面，Mask R-CNN^[5] 通过在检测框架中增加像素级掩膜预测分

图 1-2
(空白占位图)

图 1-2 YOLO 模型结构示意图（单阶段回归式检测框架的端到端预测流程）

支开创了检测—分割联合学习范式；DeepLabV3+^[6] 则以编码器—解码器结构与空洞可分离卷积在语义分割精度与效率之间取得了良好平衡。上述技术的持续进步为复杂遮挡条件下的电连接器多实例识别与线缆掩膜提取奠定了方法基础。

在基于深度学习的 6D 位姿估计方面，研究路线已从 PoseCNN^[7] 等直接回归方法发展为关键点投票、稠密对应和多模态融合等多条技术路径。Peng 等人于 2019 年提出 PVNet^[8]，采用像素级关键点投票策略，通过对目标表面各像素预测指向预定义关键点方向向量并进行投票聚合来定位关键点，有效缓解了遮挡对关键点检测的影响。Wang 等人于 2019 年提出 DenseFusion^[9]，将 RGB 特征与深度点云特征在像素级进行稠密融合，并通过迭代精化网络逐步优化位姿预测，在 YCB-Video 等基准数据集上取得了当时的最优精度。

He 等人于 2020 年提出 PVN3D^[10]，将关键点投票机制拓展至三维点云空间，通过深度逐点投票网络在三维空间中定位关键点，进一步提升了对遮挡和杂乱背景的鲁棒性。Song 等人于 2020 年提出 HybridPose^[11]，引入关键点、边向量和对称对应三种混合中间表示，利用多类型几何特征的互补性增强位姿回归在遮挡工况下的稳定性。上述方法的技术路线对比如图 1-3 所示。

图 1-3
(空白占位图)

图 1-3 典型 6D 位姿估计方法技术路线对比示意图（由直接回归、关键点投票、稠密对应到多模态融合的演进路径）

在多实例场景与面向装配的位姿估计方面，近年来涌现了若干重要进展。He 等人于 2021 年提出 FFB6D^[12]，构建了 RGB 与点云之间的双向全流融合网络，在特征编码阶段实现两种模态信息的深度交互，显著提升了对低纹理与遮挡物体的位姿估计精度。Labbé 等人于 2020 年提出 CosyPose^[13]，面向多视图多物体场景，通过单视图位姿假设生成、跨视图鲁棒匹配以及物体级光束法平差三个阶段的级联处理，实现了对多实例场景中各物体 6D 位姿的一致性估计，并在 BOP Challenge 2020 中获得最佳整体方法与最佳纯 RGB 方法等多项冠军。Su 等人于 2022 年提出 ZebraPose^[14]，采用分层二进制表面编码策略，以由粗到精的方式建立图像像素与模型表面的稠密对应关系，在 LM-O 与 YCB-V 基准上部分指标已超越 RGB-D 方法。上述研究表明，6D 位姿估计技术正从单对象静态识别向面向多实例、多模态融合和装配任务导向的综合感知阶段演进。

在柔性线缆与细长变形物体感知方面，Tang 等人于 2018 年提出基于相干点漂移的柔性线性物体操作框架^[15]，利用 B 样条曲线建模线缆形状并结合点云信息实现三维状态估计，为线缆形态的实时感知提供了方法基础。Caporali 等人于 2023 年提出 DLO3DS 方法^[16]，通过多视图二维图像重建柔性线性物体的三维形状，平均重建误差达到 0.82 mm，验证了在工业级精度要求下利用普通相机实现线缆三维感知的可行性。

Mou 等人于 2022 年在重型工业电缆操作研究中提出基于二维卷积神经网络的电缆耦合效应建模方法^[17]，通过数据驱动方式学习电缆对机器人末端力与力矩的影响规律，耦合效应估计精度超过 85%，表明将柔性电缆的动力学特性纳入系统建模可显著提升对耦合干扰的预测能力。

在国内研究方面，清华大学 Li 等人于 2019 年提出 CDPN^[18]，通过将旋转与平移解耦为坐标预测与位姿回归两个独立子任务，在 LINEMOD 数据集上取得了当时最优的纯 RGB 位姿估计精度，并在 BOP Challenge 2019 中获最佳纯 RGB 方法奖，验证了解耦策略在弱纹理目标位姿估计中的有效性。在工业视觉检测方面，Wu 等人于 2020 年提出基于改进 YOLOv3 的电连接器机器视觉检测方法^[19]，通过 K-means 聚类优化锚框比例、特征图融合与残差结构改进，实现了对电连接器焊点缺陷与旋转缺陷的自动化检测，准确率达 93.5%，表明基于深度学习的目标检测方法已具备在电连接器工业检测场景中落地的可行性。上述国内工作为本文面向航空机舱场景的电连接器多实例检测与线缆精细分割提供了重要的方法借鉴与工程经验。

综合上述研究可以看出，目标感知与 6D 位姿估计技术已在遮挡鲁棒性、多模态融合和多实例处理方面取得显著进展，但针对“柔性线缆严重遮挡条件下

多实例电连接器区分与面向装配的位姿及线缆形态联合估计”这一组合问题仍缺乏针对性解决方案。现有研究通常将柔性线缆视为背景或一般遮挡源，未将其系统建模为后续抓取规划与力控装配所需的重要几何与物理信息载体，这限制了感知结果在整条抓取—装配链路中的可利用程度。

1.3.2 复杂受限空间规划与避障研究现状

在完成目标感知与位姿估计之后，机器人需要在复杂受限空间内规划从当前构型到目标抓取位姿以及从抓取位姿到装配位姿的无碰撞轨迹，运动规划算法的性能直接影响系统的安全性与效率。传统路径规划方法包括基于图搜索的 A* 与 D* 算法，以及基于随机采样的 PRM 和 RRT 系列算法，其中 RRT 类方法因对高维配置空间的良好适应性而被广泛用于机械臂运动规划问题。

Kuffner 与 LaValle 于 2000 年提出 RRT-Connect 算法^[20]，采用双树同步扩展与贪心连接策略使高维配置空间中的规划效率显著提升，已成为机械臂运动规划的经典基线方法，其搜索树扩展过程如图1-4所示。然而后续研究表明，该算法在存在长窄通道的配置空间中仍面临大量无效采样问题，桥接测试等采样策略虽可改善窄通道场景中的可行性，但整体收敛速度仍有提升空间。



图 1-4
(空白占位图)

图 1-4 RRT-Connect 算法双树搜索扩展示意图（起始树 $\mathcal{T}_{init}$ 与目标树 $\mathcal{T}_{goal}$ 交替扩展并贪心连接的过程）

在渐近最优规划方面，Karaman 与 Frazzoli 于 2011 年提出的 RRT*^[21] 通过代价函数与邻域重连机制从理论上证明了路径代价的渐近最优性，Gammell 等人在此基础上先后提出 Informed RRT*^[22] 与 BIT*^[23]，分别通过椭球启发式采样和批量启发式搜索进一步加速了收敛。在轨迹优化方面，CHOMP^[24] 利用协变量哈密顿框架在轨迹平滑性与障碍物代价间进行迭代优化，为受限空间中的路径质量优化提供了有效手段。

在面向特定受限环境的规划改进方面，已有研究针对工业装配场景中的狭

窄空间约束展开工作。相关方法通过引入目标偏置采样、环境势场引导和窄通道检测等启发式策略，在典型窄通道场景中显著缩短规划时间并提高路径成功率。同时，面向多约束环境的规划方法将几何约束、关节极限和末端姿态要求统一纳入采样与校验框架，为航空制造等空间高度受限的应用场景提供了技术参考。上述研究表明，通过引入启发式信息、环境结构特征以及局部优化策略，可显著改善传统 RRT 类算法在受限空间中的性能表现。

在抓取生成方面，近年来基于深度学习的六自由度抓取生成方法取得了快速发展。Mousavian 等人于 2019 年提出 6-DOF GraspNet^[25]，采用变分自编码器从单目深度图像生成六自由度抓取姿态，通过对抓取质量进行评估与精化实现了对未知物体的泛化抓取生成。Fang 等人于 2020 年构建 GraspNet-1Billion 基准数据集^[26]，包含超过 97000 张 RGB-D 图像和十亿量级标注抓取位姿，并提出基于点云的端到端抓取生成网络，通过解耦接近方向与操作参数实现抓取姿态的高效预测，如图1-5所示。Sundermeyer 等人于 2021 年提出 Contact-GraspNet^[27]，利用深度网络从场景点云直接预测接触点和六自由度抓取姿态分布，在复杂遮挡与堆叠场景中展现出良好的泛化性和较高的抓取成功率，为“感知—抓取一体化”的系统设计提供了实践范式。



图 1-5
(空白占位图)

图 1-5 基于点云的 6DoF 抓取生成方法流程示意图（场景/局部点云输入—特征提取—接近方向与夹持参数多分支预测—候选抓取位姿集合输出）

在面向装配任务的抓取规划方面，研究重点逐渐从单纯提升抓取成功率转向考虑抓取姿态与后续任务目标之间的相容性。具体而言，抓取姿态不仅需要保证夹持稳定性，还需满足后续插接操作对末端朝向和接近方向的约束，即任务相容性抓取。近期研究通过将分割模型与抓取网络级联实现对指定目标的选择性抓取，部分工作还将装配方向约束编码至抓取评分函数中，从候选集合中筛选与装配轴线对齐度最高的姿态。

在国内学者的工作中，上海交通大学卢策吾团队在通用抓取感知领域做出

了系统性贡献。在构建 GraspNet-1Billion 大规模基准^[26]的基础上, Wang 等人于 2021 年提出基于 Graspness 先验的抓取检测方法^[28], 通过几何可抓取性度量对场景点云进行快速筛选, 在 GraspNet-1Billion 基准上将检测精度提升超过 30 AP 的同时保持了较高的推理速度。Fang 等人于 2023 年进一步提出 AnyGrasp^[29], 实现了空间与时间域上鲁棒、高效的七自由度稠密抓取感知, 在超过 300 种未知物体的料箱拣选任务中达到 93.3% 的成功率, 接近人类水平, 为复杂杂乱场景中的高精度抓取提供了工业级解决方案。上述国内研究为本文面向航空制造场景的抓取生成与规划提供了技术基础与数据支撑。

然而, 上述研究大多在开放或半结构化桌面环境中验证, 鲜有工作将柔性线缆作为显式障碍纳入抓取可达性分析与路径规划。在电连接器机舱装配场景下, 机器人不仅需要避开舱壁和设备等刚性障碍, 还需避开与目标零件耦合的柔性线缆, 其形态随时间动态变化。现有规划方法通常将柔性障碍等效为静态膨胀后的刚性体, 并未充分利用视觉感知到的线缆形态信息构建动态障碍物地图, 这在狭窄机舱空间内容易导致路径与线缆发生缠绕或近距离擦碰, 影响抓取与装配可靠性。

1.3.3 机器人精密力控装配研究现状

机器人精密装配, 尤其是 peg-in-hole、插拔连接器等接触丰富型任务, 是工业机器人技术的重要应用领域之一。Whitney^[30]建立的柔顺中心理论与 Hogan^[31]提出的阻抗控制理论(其等效模型如图1-6所示)构成了力控装配的经典理论基础, 在此之上衍生出导纳控制、混合力/位置控制等柔顺方法, 广泛应用于处理装配过程中的接触不确定性。

图 1-6
(空白占位图)

图 1-6 阻抗控制等效弹簧—阻尼—质量模型示意图(机器人末端与环境交互的力—位动力学关系)

随着非结构化环境下装配需求的提升, 传统解析模型在应对多源不确定性与复杂干扰力时逐渐显现局限。深度强化学习因此被引入装配领域: Inoue 等

人^[32]率先将 DRL 应用于高精度 peg-in-hole 任务并实现亚毫米级装配，验证了数据驱动策略在精密装配中的可行性。

Vecerik 等人于 2017 年提出利用人工示教数据增强深度强化学习的探索效率^[33]，通过将示教轨迹与智能体交互数据统一存储于优先经验回放缓冲区，在稀疏奖励条件下显著加速了柔性零件插入任务的策略收敛。Beltran-Hernandez 等人于 2020 年提出基于深度强化学习的变柔顺控制方法^[34]，针对位置控制型机器人的 peg-in-hole 任务通过域随机化与迁移学习实现了从仿真到实物的策略迁移，在存在孔位不确定性的条件下完成了高精度插接。

在仿真到真实迁移方面，Tobin 等人^[35]提出的域随机化方法通过在仿真中随机化视觉参数实现了策略的 Sim-to-Real 迁移；Narang 等人^[36]提出的 Factory 仿真框架利用 GPU 加速碰撞检测将接触丰富型场景仿真速度提升超过两万倍，为大规模装配策略学习提供了高效平台。

Schoettler 等人于 2020 年针对工业连接器插入任务，提出基于深度强化学习结合视觉输入与自然奖励信号的方法^[37]，在真实机器人上完成了连接器插入操作，实验表明将强化学习与先验信息相结合可在合理的真实交互次数内求解接触丰富型插入任务。上述仿真到实机迁移的一般流程如图1-7所示。



图 1-7
(空白占位图)

图 1-7 基于深度强化学习的装配策略仿真到实机迁移流程示意图（仿真环境构建—域随机化训练—Sim-to-Real 策略迁移—真实机器人部署）

在多模态策略学习与奖励设计方面，研究者致力于将视觉、力觉和本体感觉信息统一纳入装配策略的学习框架。Luo 等人于 2021 年发表面向工业装配的鲁棒多模态策略大规模研究^[38]，通过系统比较结合示教的 DRL 方法与专业工业集成商的基线方案，在 NIST 标准装配基准上证明 DRL 系统在速度与可靠性方面均优于后者，为 DRL 在真实工业场景中的落地提供了有力证据。Jiang 与 Chen 于 2023 年提出结合 DDPG 与模糊动作生成器的大直径轴孔装配策略^[39]，通过模糊规则补偿强化学习输出的动作偏差，在保持训练收敛速度的同时将装

配接触力降低约 30%，为复杂接触工况下精密装配的奖励函数与动作空间设计提供了参考。

在柔性电缆干扰方面，Mou 等人于 2022 年提出基于学习的电缆耦合效应建模方法^[17]，通过二维卷积神经网络预测重型工业电缆对机器人末端的附加力与力矩，耦合效应估计精度超过 85%，末端定位误差小于 0.01 mm，表明柔性线缆对运动控制及装配过程具有不可忽视的动力学影响，将其显式纳入控制模型可显著提升操作精度。

在国内相关研究方面，Chen 等人于 2023 年提出基于组合强化学习的机器人轴孔装配主动柔顺控制方法^[40]，通过状态判断深度 Q 网络与参数优化深度 Q 网络的级联架构在线调整变阻抗控制器参数，在 0.40 mm 间隙条件下装配成功率达 96%，验证了将强化学习策略分层解耦可有效提高物理机器人装配任务的学习效率与成功率。结合前述 Jiang 与 Chen^[39] 在模糊策略补偿以及 Mou 等人^[17] 在柔性电缆耦合效应建模方面的工作，国内学者在强化学习与力控装配的交叉领域已形成多点布局，但针对带拖缆电连接器这一特殊对象的干扰补偿策略仍有待深入。

然而，现有基于 DRL 的装配策略大多将外部干扰力简化为随机噪声或统计分布，并未显式利用视觉信息估计柔性线缆的方向与形态来构建前馈补偿项。在带拖缆电连接器装配任务中，线缆拖拽力具有明确的方向性且随插接深度非线性变化，仅依靠策略网络的隐式建模难以高效应对此类结构化干扰，限制了现有方法在刚柔耦合装配场景中的适用性。

1.3.4 国内外研究现状分析

综合上述三个方向的研究进展，目标感知与位姿估计、受限空间运动规划以及精密力控装配等领域均已形成较为丰富的方法体系，但现有成果大多围绕单一子问题独立展开，针对航空机舱环境下带柔性拖缆电连接器的多模块紧密耦合工程场景，尚未形成系统性解决方案。在视觉感知方面，基于关键点投票与多模态融合的 6D 位姿估计方法在遮挡鲁棒性上持续提升，但主要面向刚性遮挡工况设计，航空机舱中柔性线缆造成的大面积、形态时变遮挡与之存在本质差异；同时线缆延伸方向与空间形态尚未被纳入感知输出，导致后续规划与力控环节缺乏完整的几何先验。在运动规划与抓取方面，RRT* 系列算法与深度学习抓取生成网络在开放或半结构化场景中表现良好，但柔性线缆构成的动态障碍难以通过传统膨胀策略准确刻画，现有抓取评分体系也较少纳入后续装配方向约束，抓取—装配链路的任务相容性缺乏系统性考量。在力控装配方面，

阻抗控制与深度强化学习的融合已在标准接触丰富型任务中得到验证，但现有策略通常将外部干扰简化为各向同性噪声，未能刻画柔性线缆拖拽力沿特定方向的非线性变化，亟需引入视觉估计的线缆方向信息构建显式前馈补偿项。

针对上述问题，本文将围绕以下三个核心科学与工程问题展开研究：（1）在复杂光照、多实例和柔性线缆严重遮挡条件下，如何构建能够同时输出电连接器身份、6D 位姿以及线缆延伸方向等信息的级联视觉感知系统，为后续抓取与装配提供高质量输入。（2）在狭窄机舱空间中，如何利用视觉感知到的舱壁与线缆形态信息构建动态障碍物地图，并在此基础上设计兼顾搜索效率与安全性的引导式 RRT-Connect 规划策略，实现面向装配的连接器抓取路径规划。（3）在存在柔性拖缆显著干扰的装配过程中，如何利用视觉估计的线缆方向向量构建前馈补偿项，并与深度强化学习策略相结合，形成兼具鲁棒性和安全性的柔顺装配控制框架。

1.4 本文的主要研究内容

针对航空机舱电连接器机器人自主抓取与装配任务中柔性线缆遮挡、狭窄空间约束与刚柔耦合干扰等关键问题，本文从视觉感知、抓取规划、柔顺装配及系统集成四个方面展开研究，构建面向航空制造的电连接器机器人自主抓取与装配系统。课题主要研究内容与全文组织架构如图1-8所示，具体包括以下四个方面。

（1）面向柔性线缆遮挡环境的电连接器级联视觉感知与 6D 位姿估计方法研究。针对多实例混叠、光照复杂及柔性线缆遮挡等问题，设计“由粗到精”的级联视觉感知框架：第一阶段利用 YOLOv8-seg 完成多电连接器的检测、标签识别与实例分割；第二阶段在裁剪后的兴趣区域上采用改进 DeepLabV3+ 进行关键点热力图预测与线缆精细分割；最后结合 EPnP/RANSAC 输出电连接器 6D 位姿及线缆方向向量，为后续模块提供统一感知接口。

（2）面向狭窄机舱空间的电连接器自主抓取与引导式 RRT-Connect 规划策略研究。以视觉感知输出的位姿与线缆掩膜为输入，构建基于点云的端到端抓取生成网络，并通过兼顾抓取质量、线缆安全间隙与装配轴线对齐度的综合评分函数选取最优抓取姿态。在路径规划方面，提出引导式 RRT-Connect 算法，将舱壁与线缆形态映射至配置空间构建混合障碍物地图，规划避开柔性线缆的安全搬运轨迹。

（3）面向柔性拖缆干扰的深度强化学习柔顺装配控制策略研究。针对线缆




图 1-8 课题主要研究内容流程图（级联视觉感知—自主抓取规划—柔顺装配控制—系统集成验证的级联关系与各章对应）

拖拽产生的方向性时变干扰力，构建“视觉前馈 + 导纳控制 + 深度强化学习”的双层装配控制架构：在动力学层面引入视觉估计的线缆方向向量构建前馈补偿项，在策略层面利用 DRL 算法对位置误差、接触力及线缆方向进行联合感知，学习不同干扰工况下的柔顺装配策略。

（4）电连接器机器人自主抓取与装配系统集成及实验验证。搭建包含工业机械臂、视觉传感器和力/力矩传感器的实验平台，完成各模块系统集成，分别开展视觉感知、抓取规划与柔顺装配实验，通过多工况对比测试验证所提方法的有效性与工程应用潜力。

全文共分五章：第一章为绪论，阐述课题背景、研究现状与主要研究内容；第二章研究级联视觉感知与 6D 位姿估计方法；第三章研究自主抓取生成与引导式运动规划策略；第四章研究基于深度强化学习的柔顺装配控制方法；第五章完成系统集成与综合实验验证。

第2章 基于深度学习的电连接器识别与位姿估计研究

2.1 引言

航空机舱内电连接器的视觉感知同时受到多实例混叠、金属反光、深阴影以及柔性线缆遮挡等因素影响，传统依赖边缘、纹理或模板匹配的视觉方法难以在该场景下同时完成目标身份识别、关键结构恢复与高精度位姿求解。为满足后续自主抓取与柔顺装配对目标状态的精确需求，本文构建了一种由粗到精的级联视觉感知方法：首先利用 YOLOv8-seg 在整图中完成连接器实例定位、标签识别与粗分割，其次利用改进 DeepLabV3+ 在局部 ROI 内提取连接器圆柱面上四个矩形平面的角点关键特征并完成线缆精细分割，最后结合 EPnP 与 RANSAC 实现鲁棒 6D 位姿解算。本章围绕数据集构建、网络设计、几何建模与实验验证展开，为第三章抓取规划和第四章线缆干扰补偿提供统一视觉输入。




图 2-1 第二章级联视觉感知系统总体架构图（YOLOv8-seg—ROI 裁剪—改进 DeepLabV3+—EPnP/RANSAC—手眼标定的端到端数据流）

2.2 标签识别数据集的制作与分析

为支撑本章中的目标检测、标签识别、关键点提取、线缆分割和位姿解算任务，本文构建了面向航空电连接器视觉感知的混合数据集。该数据集由真实采集数据与仿真合成数据组成，在样本数量、工况覆盖范围和标注类型上兼顾了工程真实性与网络训练需求。如图 2-2 所示，航空机舱非结构化环境下电连接器视觉观测常同时伴随多实例堆叠、金属反光/阴影与柔性线缆遮挡等复合干扰，因此数据集需在采集覆盖与标注类型上同步支持一级网络的实例定位与标签身份识别，并为二级网络的关键结构提取与线缆掩膜表达提供监督信息。本节从数据采集与标注、数据增强与分布均衡以及数据集特征分析三个方面展开

说明。




图 2-2 航空机舱非结构化环境中电连接器多实例堆叠、金属反光/阴影与柔性线缆遮挡的典型视觉场景对比图

2.2.1 数据采集与标注方案

本文选取中航光电 J599/26FD35PN 型圆形电连接器作为主要研究对象。如图2-3所示，该类连接器具有典型的金属壳体、标签标识区域与柔性线缆尾部结构，能够较好表征航空非结构化环境下电连接器识别、位姿估计与后续自主装配系统集成所面临的视觉干扰特征。



图 2-3 本文研究对象电连接器实物图

在数据采集硬件方面，本文采用机械臂腕部搭载 Intel RealSense D435i 相机的方式获取 RGB 图像，相机与末端执行器固连，可在抓取与装配工作空间内实现多视角、近距离观测。RGB 流分辨率设置为 1920×1080 ，帧率设置为 30 fps，以

尽可能保留连接器标签区域、壳体边缘及线缆细轮廓等细节信息；同时通过机械臂轨迹规划控制相机绕目标进行环绕扫描，使采集到的样本覆盖不同视角、高度与工作姿态下的成像效果。如图2-4所示，相机安装位置与视场范围能够充分覆盖典型航空机舱设备舱段内部的连接器分布区域，为后续在同一硬件平台上完成在线检测、抓取姿态生成以及第四章装配阶段的目标状态感知提供了条件。



图 2-4 电连接器视觉数据采集实物硬件布局图（机械臂腕部安装 RealSense 相机获取多视角 RGB 图像）

在真实数据采集方面，本文围绕航空非结构化环境下中航光电 J599/26FD35PN 型电连接器的典型布置形式与照明条件，构建了包含机舱设备舱段、线槽附近以及模拟工装夹具等多种场景的采集工况。整体共获取约 2500 张真实 RGB 图像，覆盖单连接器与多连接器堆叠、不同背景纹理（舱壁、线槽、线束束缚件等）、不同光照强度以及不同线缆形态（自然下垂、搭靠设备边缘、跨越连接器阵列）等情况，在每类工况下均采集多组不同姿态和距离的样本，以提高后续网络对空间布局变化与成像噪声的适应能力，并为第三章面向抓取规划的目标壳体稳定识别与第四章面向装配阶段的柔性线缆干扰补偿提供统一的视觉样本基础。

在仿真数据集构建方面，本文基于 Blender 建立了包含连接器本体、柔性线缆与机舱局部环境的参数化场景。如图2-5所示，上排展示了真实采集样本在航空机舱局部环境中的成像效果，下排展示了对应的仿真合成样本示例。通过对相机位姿、连接器姿态、线缆形态、背景纹理以及光照条件进行域随机化，并在同一渲染流程中自动输出检测框、实例掩膜、关键点与线缆掩膜等多任务标注，最终生成约 5000 张仿真合成图像。



图 2-5 真实采集样本与仿真合成样本的混合数据集示例图（上：真实采集图像；下：仿真合成图像）

将上述 2500 张真实样本与 5000 张仿真样本统一整理后，按 7:2:1 的比例划分为训练集、验证集和测试集，使整体数据集既保留航空机舱真实成像特性，又在姿态与遮挡分布上具有足够的覆盖度。

在标注策略上，本文采用与两级处理流程一致的层级组织方式组织监督信息。如图2-6所示，上部界面展示了一级数据集的标注组织形式，即在整幅 RGB 图像中对连接器目标进行实例级标注，并同步关联类别身份与标签信息；下部界面展示了二级局部数据集的标注形式，即在裁剪后的单目标 ROI 内进一步标注关键结构区域，用于后续关键点热力图监督与线缆精细表征。具体而言，其一，一级层级以整幅 RGB 图像为输入，对每个连接器目标同时标注边界框、实例掩膜以及标签 ID/类别身份；对应网络输出边界框集合、实例掩膜集合，并得到用于单目标 ROI 裁剪的候选区域。该层级主要用于完成目标锁定与单目标 ROI 提取。其二，二级层级以一级裁剪后的单目标 ROI 图像为输入，在同一 ROI 内对连接器圆柱面上四个矩形平面的 16 个角点进行标注，并同步标注线缆像素级掩膜。其中，每个矩形平面的四个角点均按照固定方向和顺序编码为左上、左下、右上、右下，但网络监督不再为每个角点单独设置通道，而是按角点语义类别构造四通道热力图，即同类角点共享同一热力图通道并在该通道中形成多个响应峰值。该层级输出既保留了用于 2.5 节位姿解算的稳定二维角点观测，也保留了用于第三章线缆障碍建模与第四章力控前馈补偿的线缆形态观测，从而使同一套标签逻辑能够同时服务于刚体位姿求解与柔性干扰表征。




图 2-6 两级标注数据集界面展示图（上：整图实例与标签标注数据集；下：单目标 ROI 关键结构标注数据集）

2.2.2 数据增强

为提升航空非结构化环境中柔性线缆干扰下的识别与位姿估计稳定性，本文将训练期数据增强区分为真实数据增强与仿真数据增强两部分：真实增强校准成像噪声与外观变化，仿真增强扩展极端姿态与遮挡分布。

针对真实采集数据，本文构建与掩膜同步的在线增强流水线，包括按概率 0.5 叠加高斯噪声、随机旋转、色彩抖动、水平/垂直翻转以及随机裁剪缩放。设像素强度为 $I(x, y)$ ，高斯噪声扰动为

$$I_{\text{aug}}(x, y) = \text{clip}(I(x, y) + n(x, y)), \quad n(x, y) \sim \mathcal{N}(0, \sigma^2),$$

其中， $\sigma = 0.1$ 表示噪声标准差， $\text{clip}(\cdot)$ 表示截断到合法强度范围。随机旋转角度 θ 采样于 $[-180^\circ, 180^\circ]$ ，并对图像与掩膜同步进行仿射变换以保持几何一致性；色彩抖动在 HSV 空间对亮度、对比度、饱和度与色相实施随机扰动， $\text{Brightness}=0.5$ 。为覆盖狭窄视野下的局部截断情形，增强流程引入随机翻转与随机裁剪缩放（ $\text{scale} \in [0.8, 1.0]$ 且重采样到 640×640 ）。

针对仿真合成数据，本文将增强转化为渲染域随机化：设渲染参数为 θ ，则

$$I = f(\theta),$$

其中， $f(\cdot)$ 为基于 Blender 的渲染映射函数， I 表示渲染得到的图像。通过对 θ 在工程可行范围内随机采样，并在训练中最小化期望监督损失

$$\min_{\phi} \mathbb{E}_{\theta \sim p(\theta)} \left[\mathcal{L}(g_{\phi}(f(\theta)), y) \right],$$

其中， ϕ 表示网络参数， $g_{\phi}(\cdot)$ 表示从图像到预测结果的网络映射， $\mathcal{L}(\cdot)$ 表示监督损失， y 为对应的自动渲染标签。渲染参数同时扰动相机位姿、连接器姿态、线缆形态与光照纹理等因素，从而扩展线缆掩膜形态与可见性变化的联合分布。




图 2-7 数据增强效果示例图（上：真实采集样本增强结果；下：仿真合成样本增强结果）

如图2-7所示，该图分别给出了真实采集样本与仿真合成样本在多种增强操

作下的视觉变化结果。对于真实样本，高斯噪声、亮度扰动与旋转变换主要改变标签区域、壳体高光与背景明暗分布，从而增强网络对成像噪声、局部反光以及视角变化的适应能力；对于仿真样本，噪声注入、姿态旋转与局部裁切进一步扩展了目标轮廓朝向、线缆弯曲形态及边界截断形式的分布范围。上述增强均在保持图像与掩膜同步变换的前提下进行，使训练输入能够更充分覆盖“柔性线缆干扰+成像退化+视角变化”的联合外观扰动。

2.2.3 数据集特征分析




图 2-8 不同 TagID、目标面积占比与实例形状复杂度样本的分布统计图（增强前后类别覆盖、尺度分布与重叠复杂度对比）

如图2-8所示，增强后不同 TagID 的样本数量更加均衡，目标面积占比的分布范围进一步拓宽，同时高重叠条件下的实例形状复杂样本也得到更充分覆盖，从而降低少样本类别、局部小目标与复杂遮挡组合对训练稳定性的影响。

在数据特征分析中，针对用于 YOLOv8-seg 的整幅图像数据，统计重点对应到图2-8中的三类联合观测变量。左图以柱状形式统计不同 TagID 在增强前后的样本数量，用于衡量目标身份覆盖的均衡性；中图以直方分布形式刻画目标面积占图像面积比例（Object Area Ratio）的变化，用于反映从小目标到较大尺度目标的样本覆盖范围；右图则以散点形式给出了成对边界框重叠程度（Pairwise Bbox IoU）与掩膜多边形顶点数之间的关系，用于描述多实例邻接、轮廓复杂度与分割监督难度之间的耦合变化。上述统计共同表明，在航空非结构化环境中，多实例堆叠、尺度变化与柔性线缆干扰会同时改变检测框重叠程度和实例外轮廓复杂度；增强后，类别分布更均衡、尺度覆盖更充分，且高 IoU 条件下的复杂轮廓样本数量增加，从而为检测与实例分割联合训练提供了更稳定的监督基础。

针对用于 DeepLabV3+ 的 ROI 局部数据，特征分析将统计焦点从整幅身份与尺度覆盖转移到 ROI 内关键结构可见性的空间分布，以及线缆像素级掩膜监

督的有效覆盖范围。结合图2-8 的统计含义，中图所反映的目标面积占比变化可对应理解为 ROI 内连接器主体有效成像尺度的变化，这将直接影响关键点热力图峰值的空间扩散范围；右图所反映的高重叠与高顶点数样本，则对应更复杂的局部轮廓边界和更不规则的线缆遮挡形态，会进一步提高关键结构提取与像素级掩膜分割的难度。由于柔性线缆干扰会造成矩形平面边缘和角点纹理被部分覆盖，ROI 内热力图峰值位置与掩膜覆盖比例将随视角变化、线缆弯曲状态与目标局部尺度共同变化；通过在数据生成与增强阶段保持尺度分布和复杂边界样本的充分覆盖，局部分割监督在强干扰条件下仍能够维持足够的样本多样性与监督有效性。

2.3 基于 YOLOv8-seg 的目标检测与实例分割

在航空机舱电连接器装配场景中，视觉系统首先需要完成目标实例定位与目标对象区分，为后续关键点提取和位姿解算提供稳定的局部输入区域。考虑到该场景中连接器本体、标签区域与柔性线缆通常同时出现，且目标之间存在尺度变化大、遮挡关系复杂和实例间距离较近等特点，本文选用 YOLOv8-seg 作为感知流程的一级网络，用于实现目标检测、标签身份识别与实例分割的联合输出。

该网络输出的边界框、类别信息和实例掩膜共同构成后续 ROI 裁剪与局部精细分析的基础数据，其中 TagID 用于确定目标对象，实例掩膜用于削弱背景干扰，边界框用于确定局部图像范围。

2.3.1 算法选型与总体结构

电连接器的视觉观测需要同时完成实例级定位与像素级轮廓约束。航空机舱非结构化环境中，连接器本体、标签区域与柔性线缆在同一画面内并存，遮挡边界容易出现不完整结构；在此条件下，单纯依赖边界框进行目标锁定难以稳定反映遮挡处的形态变化。YOLOv8-seg 的检测-分割联合输出使得 TagID 关联、边界定位与遮挡边界的像素级约束可以在同一模型预测阶段获得一致监督，从而提升实例可分性与候选区域的几何稳定性。

YOLOv8-seg 采用 Anchor-free 的中心与尺度回归机制，通过直接学习目标中心位置与边界参数完成定位，不依赖预设锚框匹配。在连接器任务中，壳体、标签与拖拽线缆对应的长宽比跨度较大，锚框匹配会引入尺度先验偏差；Anchor-free 回归能够更直接地适应该类尺度变化特征。设网络对第 i 个预测实例给出

边界框参数

$$\hat{\mathbf{b}}_i = (\hat{x}_i, \hat{y}_i, \hat{w}_i, \hat{h}_i),$$

其中, $\hat{x}_i, \hat{y}_i$ 为框中心像素坐标, $\hat{w}_i, \hat{h}_i$ 为宽高尺度, 则该回归过程无需锚框候选匹配即可输出候选定位结果。

同时, YOLOv8-seg 将检测分支与分割分支集成于统一网络框架中, 实现一次前向推理同时输出目标位置与实例掩膜。对于实例分割分支, 其掩膜预测可形式化表示为

$$\hat{M}_i = \sigma(f_{\text{seg}}(F)),$$

其中, $\hat{M}_i$ 为第 i 个实例的像素级掩膜预测, $f_{\text{seg}}(\cdot)$ 为分割预测头, F 为共享多尺度特征, $\sigma(\cdot)$ 表示非线性激活函数。实例掩膜在遮挡边界缺失时仍能够提供像素级拓扑约束, 使得目标锁定不再仅依赖框形状, 从而降低多实例堆叠与柔性线缆遮挡条件下的实例混淆。

如图2-9所示, YOLOv8-seg 由 Backbone、Neck 与 Head 三部分组成: Backbone 提取层级语义特征以表征标签与壳体的判别信息; Neck 完成多尺度特征融合以同时保留细粒度边缘响应与跨尺度上下文一致性; Head 将检测与分割预测集成到统一输出端, 从而实现边界框与实例掩膜的联合推断。




图 2-9 YOLOv8-seg 网络结构图 (Backbone/Neck/Head 与检测-分割联合输出的多尺度特征融合示意)

本文在实现中选用 CSPDarknet53 作为骨干网络，并在 C2f 模块中实现跨阶段特征复用：浅层表征用于保留壳体边缘与标签纹理的局部梯度信息，深层表征用于提供与实例尺度变化相关的语义响应。该特征组织为检测与掩膜分支在遮挡边界处提供共享的判别依据，从而在多实例混叠与柔性线缆遮挡条件下保持实例轮廓的一致性。由检测与分割分支联合输出的目标候选集合可写为

$$\mathcal{D} = \{ID_i, B_i, s_i, M_i\}_{i=1}^N,$$

式中， ID_i 表示标签身份， B_i 表示边界框， s_i 表示检测置信度， M_i 表示实例分割掩膜， N 为候选目标数量。




图 2-10 YOLOv8-seg 在多实例堆叠与线缆遮挡条件下的检测与实例分割效果图（含 TagID 识别结果展示）

如图2-10所示，在多连接器实例堆叠与柔性线缆遮挡条件下，边界框用于给出候选定位的空间范围，而实例掩膜用于补足遮挡边缘的像素级轮廓约束。掩膜输出能够在目标轮廓局部不完整时保持拓扑连贯性，从而降低由局部缺失引发的实例交叉干扰，增强 TagID 与对应实例之间的关联稳定性。

2.3.2 损失函数与训练参数设置

电连接器装配场景中，视觉模型需要同时完成连接器实例的身份判别、目标定位与遮挡边界的像素级轮廓恢复。由于本文在 YOLOv8-seg 的损失函数设计上未引入新的改进项，因此训练阶段直接采用该网络的标准多任务联合优化形式，将分类、目标置信度、边界框回归和实例分割统一到同一目标函数中，其形式为

$$\mathcal{L}_{\text{det}} = \lambda_{\text{cls}} \mathcal{L}_{\text{cls}} + \lambda_{\text{box}} \mathcal{L}_{\text{box}} + \lambda_{\text{obj}} \mathcal{L}_{\text{obj}} + \lambda_{\text{seg}} \mathcal{L}_{\text{seg}},$$

其中, $\mathcal{L}_{\text{cls}}$ 用于约束标签身份与类别预测, $\mathcal{L}_{\text{box}}$ 用于边界框定位回归, $\mathcal{L}_{\text{obj}}$ 用于前景置信度估计, $\mathcal{L}_{\text{seg}}$ 用于实例掩膜预测; 权重系数为 $\lambda_{\text{cls}}, \lambda_{\text{box}}, \lambda_{\text{obj}}, \lambda_{\text{seg}}$ 。分类项与置信度项采用标准交叉熵形式, 本文重点保留与后续 ROI 生成和遮挡轮廓恢复直接相关的框回归损失与分割损失表达。

分割分支采用二值交叉熵与 Dice 项组合监督, 其形式为

$$\mathcal{L}_{\text{seg}} = \mathcal{L}_{\text{bce}} + \lambda_{\text{dice}} \mathcal{L}_{\text{dice}},$$

其中, $\mathcal{L}_{\text{bce}}$ 用于约束像素分类正确性, $\mathcal{L}_{\text{dice}}$ 用于增强预测掩膜与真实掩膜之间的区域重叠一致性。该组合能够在柔性线缆细长、局部遮挡明显的情况下维持轮廓连贯性。

在边界框回归方面, 采用 CIOU 损失进行监督:

$$\mathcal{L}_{\text{box}} = \mathcal{L}_{\text{CIOU}} = 1 - \text{IoU} + \frac{\rho^2(\mathbf{b}, \mathbf{b}^{gt})}{c^2} + \alpha v.$$

其中, IoU 表示预测框与真实框的交并比, $\rho(\mathbf{b}, \mathbf{b}^{gt})$ 表示两框中心距离, c 表示最小外接框对角线长度, v 与 α 分别表示宽高比一致性项及其平衡系数。该损失同时考虑重叠程度、中心偏差与形状一致性, 有利于在遮挡条件下保持候选框定位稳定。

总体而言, 上述联合优化机制保证了不同 TagID 连接器的身份区分、候选区域的稳定生成以及实例轮廓的连续表达, 从而为 2.3.3 节的 ROI 裁剪以及 2.4 节局部关键结构提取提供稳定输入。

在训练实现方面, 输入尺寸设为 640×640 , BatchSize 设为 16, 训练轮数设为 300, 优化器采用 SGD, Momentum 设为 0.937。该参数组合在保证图像细节表达的同时, 降低遮挡样本的梯度方差, 并提升收敛稳定性。

由图2-11可以观察到, 各分项损失随 epoch 的推进呈现整体下降趋势, 分类相关损失首先收敛, 随后定位回归与掩膜分割损失逐步趋于稳定。该现象对应于优化目标的梯度耦合关系: 在初期阶段, 分类与置信度监督为候选目标关联建立基础; 随着候选框的中心与尺度预测逐步稳定, CIOU 中的中心距离与宽高比一致性项开始提供更有效的回归约束; 在后期阶段, 分割损失的下降与掩膜形态连贯性的提升共同作用, 使得遮挡边缘的像素级轮廓能够更稳定地被学习。训练过程中曲线的同步收敛说明了框回归与掩膜监督在遮挡样本上的协同学习是有效的。




图 2-11 YOLOv8-seg 训练过程曲线图（分类/置信度/框回归/分割等损失与关键指标随 epoch 变化）

该协同学习可在检测结果中得到体现：如图2-10所示，多连接器实例堆叠条件下，边界框为实例归属提供空间范围，实例掩膜在遮挡边缘缺失时仍能保持一定拓扑连贯性，从而降低由局部缺失引发的实例混淆概率。该对应关系验证了多任务联合损失对航空非结构化环境下电连接器实例分割的适配性。

2.3.3 动态 ROI 裁剪策略

一级感知网络的输出用于生成局部精细处理的感兴趣区域 ROI。如果裁剪窗口过小，连接器边缘与线缆上下文会被截断，影响遮挡关系的恢复；若裁剪窗口过大，则引入无关背景削弱二级网络的局部聚焦能力。为此本文根据检测框置信度与目标尺度自适应调整 ROI 窗口大小。

设一级检测边界框为 $B = (x, y, w, h)$ ，其检测置信度为 $s \in [0, 1]$ ，则扩展后的裁剪窗口定义为

$$B' = (x, y, \gamma(s)w, \gamma(s)h),$$

其中，动态扩展因子 $\gamma(s)$ 定义为

$$\gamma(s) = \gamma_{\min} + (\gamma_{\max} - \gamma_{\min})(1 - s).$$

当检测置信度较高时，可采用较小扩展因子提高局部聚焦性；当检测置信度较低时，适当扩大裁剪区域可以保留更多上下文信息，降低因一级定位偏差

造成的二级输入截断风险。为保持二级网络输入尺度统一，裁剪后的 ROI 图像被重采样至固定尺寸 $I_{\text{roi}} \in \mathbb{R}^{256 \times 256 \times 3}$ ，并记录从原图到 ROI 的仿射变换矩阵，以便后续将关键点坐标映射回原始图像坐标系。

为给出可逆的几何映射关系，令扩展裁剪窗口中心仍为 B 的中心 (x, y) ，则裁剪窗口左上角可写为

$$x_0 = x - \frac{\gamma(s)w}{2}, \quad y_0 = y - \frac{\gamma(s)h}{2},$$

并定义从裁剪窗口到 ROI 的缩放比例

$$s_x = \frac{256}{\gamma(s)w}, \quad s_y = \frac{256}{\gamma(s)h}.$$

对任意原图坐标 (X, Y) ，其对应的 ROI 坐标 (u, v) 通过齐次坐标仿射变换给出：

$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} s_x & 0 & -s_x x_0 \\ 0 & s_y & -s_y y_0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} X \\ Y \\ 1 \end{bmatrix}.$$

因此，ROI 内关键点预测坐标 (u_j, v_j) 可以通过逆仿射变换映射回原图：

$$\begin{bmatrix} X_j \\ Y_j \\ 1 \end{bmatrix} = \begin{bmatrix} 1/s_x & 0 & x_0 \\ 0 & 1/s_y & y_0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} u_j \\ v_j \\ 1 \end{bmatrix}.$$

同理，线缆像素级掩膜在裁剪与重采样过程中采用相同的几何映射规则，从而保证二级网络的关键点热力图监督与线缆掩膜监督在坐标系层面一致。




图 2-12 基于检测置信度的动态 ROI 裁剪示意图 ($\gamma(s)$ 自适应扩展与仿射回映射关系)

如图2-12所示，动态扩展因子 $\gamma(s)$ 决定裁剪窗口的覆盖范围；仿射映射矩阵将原图坐标 (X, Y) 映射到 ROI 坐标 (u, v) ，逆变换则保证二级网络输出的关键点坐标能够回到原图参考系。该坐标一致性使关键点热力图监督与线缆像素

级掩膜监督在遮挡边界条件下仍保持严格的几何对齐，从而避免标签与预测结果在坐标系层面的偏移误差。

2.4 基于改进 DeepLabV3+ 的关键特征提取与线缆分割

一级检测输出的边界框与粗掩膜可用于锁定目标实例的空间范围，但难以直接刻画连接器圆柱面上矩形平面角点等关键几何结构。为此，本文在 ROI 图像上引入改进 DeepLabV3+ 网络，利用大感受野上下文建模能力实现关键点热力图预测与线缆精细分割，并以统一的像素级监督约束提升遮挡条件下的结构可辨性。本节将从网络选型与空洞卷积原理、高斯热力图建模方法以及改进输出头与联合损失设计三个方面展开说明。

2.4.1 网络模型分析

DeepLabV3+ 的优势在于其对语义与边界的协同建模能力：编码器用于提取具有判别性的高层语义特征，ASPP 模块通过多空洞率分支并行聚合多尺度上下文信息，解码器再引入浅层细节特征对空间边界进行细化恢复。该结构在保证感受野覆盖的同时兼顾局部纹理分辨率，适合处理航空非结构化环境中由金属反光、阴影与柔性线缆遮挡共同引起的外观变化，使得网络能够在局部纹理不稳定时仍保持对矩形平面边缘与角点布局的整体一致性判断。

本文二级视觉感知的目标是：在一级网络生成的单目标 ROI 内，同时预测连接器圆柱面上四个矩形平面的角点关键特征，并输出线缆像素级掩膜，以支撑后续位姿解算与线缆形态先验构建。具体而言，关键点分支并非输出 16 个独立角点通道，而是输出左上、左下、右上、右下四类角点热力图；同一类别通道中可同时出现多个响应峰，对应不同矩形平面的同类角点。为满足该目标，网络需要在 ROI 局部范围内区分“矩形平面边缘纹理—壳体边界—线缆细轮廓”三类高频细节，并在遮挡与反光条件下保持关键点响应峰值的稳定性。然而，原始 DeepLabV3+ 的输出端主要面向单一语义分割任务，难以直接满足“多通道关键点热力图+线缆分割掩膜”的并行输出需求；同时，线缆像素占比通常远小于背景与壳体区域，若仅采用单一分割监督，容易在训练中出现细线缆断裂、边界收缩等现象。为此，有必要对解码端的输出头进行任务化改造，并在损失函数层面对关键点与线缆两类监督进行联合设计，从而为下一节的改进网络结构与优化目标构建提供依据。

DeepLabV3+ 提取多尺度上下文特征的关键在于空洞卷积，其一维形式为

$$y[i] = \sum_{k=1}^K x[i + r \cdot k] w[k],$$

式中, $x[i]$ 表示输入特征, $w[k]$ 表示卷积核参数, r 为空洞率。当 $r = 1$ 时, 该运算退化为普通卷积; 当 $r > 1$ 时, 卷积核在不显著增加参数数量的条件下扩大感受野, 因此网络能够利用更大范围的结构上下文判断遮挡区域内可能存在的关键特征。对于本文研究对象而言, 四个矩形平面角点之间具有稳定的局部拓扑关系, 因此只要网络能够同时观察到足够的壳体上下文, 就有可能在局部遮挡条件下恢复有效的关键点响应。

如图2-13所示, 多空洞率的并行上下文建模与编码器-解码器的特征融合共同决定了模型的输出特性: 一方面, ASPP 的大感受野分支能够在遮挡发生时提供“全局布局一致性”的约束, 避免角点响应被局部线缆边缘牵引; 另一方面, 解码端引入的浅层细节信息能够对矩形平面边缘与线缆细结构进行空间细化。基于该结构特性, 模型能够输出较为稳定的关键点热力图与线缆概率图。然而, 在本文任务中关键点分支需要同时输出四通道角点类别热力图与单通道线缆掩膜, 并对两类输出采用差异化的监督权重; 同时, 线缆遮挡会导致前景/背景像素占比显著不均, 使得仅依赖单一分割损失容易出现边界收缩或细线缆断裂。为此, 需要对原网络的输出头进行任务化改造, 并在损失函数层面对关键点与线缆两类监督实施联合设计, 从而保证关键结构定位与线缆分割在遮挡条件下的同步稳定。

2.4.2 高斯热力图建模方法

为在柔性线缆遮挡与强反光条件下稳定提取连接器局部关键结构, 本文将关键点定位由“直接回归坐标”转化为“回归密集响应图”。与坐标回归仅在单点上提供监督不同, 热力图建模在关键点邻域内构造连续的软标签, 使网络在训练阶段获得更充分的空间梯度信息; 同时, 密集监督与 DeepLabV3+ 的全卷积输出形式一致, 便于将解码端的像素级特征直接映射为关键点响应分布, 从而提高遮挡条件下峰值位置的可辨性与稳定性。

需要说明的是, 本文对 DeepLabV3+ 的修改并非发生在 Backbone 或 ASPP 主体部分, 而是集中在解码端末尾的输出层。原始 DeepLabV3+ 在解码器融合特征后通常接单一语义分割分类头, 用于输出类别概率图; 本文保留编码器、ASPP 和解码器的多尺度特征提取路径不变, 仅将原有单任务分类输出改造为面向角点检测的热力图输出形式。具体而言, 解码端融合后的共享特征图首先保持原




图 2-13 DeepLabV3+ 网络结构示意图（ASPP 多空洞率上下文建模与编码器-解码器融合路径）

有空间分辨率与上下文语义信息，然后不再直接输出单张类别分割图，而是映射为 $N_k = 4$ 个关键点热力图通道，分别对应左上、左下、右上、右下四类角点语义标签。由于连接器圆柱面上存在四个矩形平面，因此同一类别通道中通常包含多个局部峰值，每个峰值对应一个不同平面上的同类角点。这样修改的实质，是将“语义类别判别”转换为“多实例角点类别响应分布预测”，使网络重点学习角点邻域的局部纹理、边缘方向及其相对拓扑关系。

因此，本节所述高斯热力图并不是独立于网络结构之外的附加标签，而是与解码端输出头改造直接对应的监督形式：解码器末端输出多少个关键点通道，就为每个通道构造一个对应的高斯软标签。对于本文任务，四类角点通道与四张目标热力图一一匹配，而每张热力图内部允许出现多个峰值，从而将“网络修改位置”“输出张量定义”和“监督标签构造”统一到同一框架下。这一设计也为下一节的线缆分割分支并行接入提供了共享特征基础。

为对比两类监督形式的差异，设第 j 个关键点的真实坐标为 $\mathbf{p}_j = [x_j, y_j]^\top$ ，坐标回归分支直接输出 $\hat{\mathbf{p}}_j = [\hat{x}_j, \hat{y}_j]^\top$ ，常用的回归损失可写为

$$\mathcal{L}_{\text{reg}} = \frac{1}{N_k} \sum_{j=1}^{N_k} \|\hat{\mathbf{p}}_j - \mathbf{p}_j\|_2^2.$$

该损失在监督层面仅对单点坐标误差进行惩罚，等价于在二维平面上以 Dirac 分布 $\delta(\mathbf{x} - \mathbf{p}_j)$ 作为目标，使得训练梯度主要集中于“坐标偏差”的一阶方向上，难以显式利用关键点邻域内的边缘纹理与几何布局信息。相比之下，热力图建

模将关键点表示为二维连续分布。令 $\mathbf{x} = [x, y]^T$ ，则式 (2-xx) 可写为

$$H_j(\mathbf{x}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{p}_j\|_2^2}{2\sigma^2}\right),$$


并可进一步构造归一化概率分布

$$\tilde{H}_j(\mathbf{x}) = \frac{H_j(\mathbf{x})}{\sum_x \sum_y H_j(x, y)}.$$

在推理阶段，针对第 j 类角点热力图 $\hat{H}_j$ ，本文采用局部极大值检测与阈值筛选提取多个响应峰值，即

$$\mathcal{P}_j = \text{TopK}(\text{NMS}(\hat{H}_j)),$$

其中， $\text{NMS}(\cdot)$ 表示非极大值抑制， $\mathcal{P}_j$ 表示该类别下提取到的候选角点集合， $\text{TopK}(\cdot)$ 表示按响应强度保留前 K 个局部峰值。由于单通道热力图中存在多个同类角点响应，直接采用全局 soft-argmax 会导致多个峰值被平均化，因此本研究采用“多峰值提取 + 后续几何组合”的方式恢复全部二维角点。如图2-14所示，热力图监督将误差从“单点坐标偏差”扩展为“邻域分布匹配”，使得损失函数在关键点邻域内产生连续的空间梯度，从而更有利于在遮挡与反光引起的局部纹理不稳定条件下保持峰值位置的鲁棒性。



(a) 单点坐标回归监督

(b) 高斯热力图软标签监督

图 2-14 关键点监督形式对比示意图 (单点坐标回归/高斯热力图软标签/局部峰值搜索解码)

结合本文任务，二级网络在单目标 ROI 内最终需要恢复四个矩形平面的 16 个角点二维观测。对应到网络实现层面，这意味着解码端末尾的关键点分支不再为每个角点单独设置响应通道，而是输出 4 个彼此独立、语义固定的角点类别通道；再通过多峰值提取与几何一致性组合恢复完整的 16 个角点集合。该关

键点集合一方面用于构造稳定的二维—三维对应关系以支撑位姿解算，另一方面与线缆掩膜共同构成连接器局部刚柔耦合状态的像素级表达，使后续“刚体位姿 + 柔性障碍先验”的联合建模具备统一的数据来源。

在样本预处理阶段，一级网络裁剪得到的 ROI 被统一重采样到固定分辨率输入平面，以消除目标尺度差异对二级网络训练稳定性的影响。对于第 j 类角点热力图，设该类别下共有 M_j 个标注角点，其坐标记为 $(x_{j,m}, y_{j,m})$, $m = 1, \dots, M_j$ 。本文采用二维高斯核叠加的方式构造目标热力图 $H_j(x, y)$ ，其表达式为

$$H_j(x, y) = \max_{m=1, \dots, M_j} \exp \left(-\frac{(x - x_{j,m})^2 + (y - y_{j,m})^2}{2\sigma^2} \right),$$

式中， (x, y) 表示热力图平面上的任意像素位置， $(x_{j,m}, y_{j,m})$ 表示第 j 类角点中第 m 个实例的位置， σ 控制概率峰的扩散范围。采用 $\max(\cdot)$ 形式能够避免相邻高斯峰值在重叠区域过度累加，更适合表达同类角点在单一通道中的多实例响应。




图 2-15 关键点高斯热力图建模示意图（四类角点热力图采用多峰值监督；可视化时将热力图上采样后叠加于 ROI 图像，而非直接以下采样解码特征图为底图）

在参数设置方面，本文取 $\sigma = 2$ 作为热力图扩散系数，以在定位精度与训练稳定性之间取得平衡。当 σ 过小时，监督有效区域过窄，梯度主要集中于极小邻域，遮挡导致的边缘纹理扰动更易引起峰值漂移；当 σ 过大时，响应分布

过于平坦，同类角点之间的局部峰值可分性降低并引入更明显的定位偏差。因此， σ 的选取本质上对应“空间不确定度建模”与“峰值可分性”的折中。图2-15 的目的是展示高斯监督标签与角点响应分布的空间关系，因此可视化时更适合将热力图插值回 ROI 分辨率后叠加在原始 ROI 图像上，而不宜直接以下采样的 decoder 特征图作为底图；后者更适用于说明网络内部特征分辨率，而不利于直观展示角点标签与真实图像结构之间的对应关系。

在监督组织形式上，若角点语义类别数记为 N_k ，则网络输出 N_k 个关键点热力图通道，每个通道对应一个语义明确的角点类别。对于本文研究对象，四个矩形平面内的角点统一按左上、左下、右上、右下四类编码，因此本文取 $N_k = 4$ 。该类别化编码使网络重点学习“角点类型”而非“平面实例编号”，从而减少输出通道数量，提升同类角点在不同平面上的共享表征能力，并与线缆分割分支共享编码与 ASPP 的上下文表示，实现“刚性角点布局 + 柔性线缆形态”的同域特征表达。

在训练目标上，将热力图视为关键点位置的概率型表征，可将预测热力图 $\hat{H}_j(x, y)$ 与目标热力图 $H_j(x, y)$ 的差异转化为像素级能量最小化问题。采用均方误差损失时，优化过程等价于在每个像素位置上对响应幅值进行一致性拟合，其梯度在关键点邻域内连续变化，从而相对降低坐标回归中由单点监督引起的梯度震荡；同时，热力图的峰值幅值可作为关键点置信度的直接度量，为后续在遮挡样本上进行异常点抑制提供可用的质量指标。从结构角度看，该建模方式对应于“将原始单任务分割头替换为 4 通道关键点类别热力图输出头”；从监督角度看，则对应于“为每个输出通道构造同语义、多峰值的高斯软标签”。二者一一配对后，下一节再在同一解码特征上增加线缆分割分支，构成完整的双分支改进网络。

关键点热力图分支采用均方误差损失约束预测热力图与目标热力图的一致性。设第 j 类角点的预测热力图为 $\hat{H}_j(x, y)$ ，则其损失可写为

$$\mathcal{L}_{kp} = \frac{1}{N_k} \sum_{j=1}^{N_k} \sum_x \sum_y (\hat{H}_j(x, y) - H_j(x, y))^2.$$

2.4.3 改进输出头与联合损失设计

根据上一节的建模结果，二级网络的监督信号由关键点高斯热力图和线缆分割掩膜共同构成。为使网络输出形式与构造的标签保持一致，本文对

DeepLabV3+ 解码端的输出层进行改进，构建面向电连接器局部感知任务的双分支输出头。

在经过编码器、ASPP 模块以及解码器特征融合后，设共享特征图记为 F 。在此基础上，分别设置关键点热力图预测分支和线缆分割分支：关键点分支输出四类角点对应的热力图张量 $\hat{H} \in \mathbb{R}^{H \times W \times N_k}$ ；线缆分支输出单通道线缆概率图 $\hat{M}_c \in \mathbb{R}^{H \times W}$ 并经阈值化得到线缆二值掩膜。

为保证输出与热力图软标签幅值定义一致，关键点分支与线缆分割分支均采用逐位置的线性映射并通过非线性函数约束到概率区间。设共享特征在位置 (x, y) 处的向量为 $\mathbf{F}(x, y) \in \mathbb{R}^C$ ，则关键点热力图预测与线缆概率预测可分别表示为

$$\hat{H}_j(x, y) = \sigma(\mathbf{w}_j^\top \mathbf{F}(x, y) + b_j),$$

其中， $\mathbf{w}_j$ 与 b_j 为第 j 类角点的映射参数， $\sigma(\cdot)$ 为将输出压缩到 $[0, 1]$ 的非线性函数；

$$\hat{M}_c(x, y) = \sigma(\mathbf{w}_c^\top \mathbf{F}(x, y) + b_c),$$

其中， $\mathbf{w}_c$ 与 b_c 为线缆分割分支参数。对于关键点热力图输出，本文不采用全局 soft-argmax 直接解码单一坐标，而是在每一类热力图上执行局部极大值检测与峰值筛选，得到候选集合 $\mathcal{P}_{lt}, \mathcal{P}_{lb}, \mathcal{P}_{rt}, \mathcal{P}_{rb}$ ，分别对应左上、左下、右上、右下四类角点。




图 2-16 改进 DeepLabV3+ 双分支输出头示意图（关键点热力图分支 + 线缆分割分支的共享特征与输出通道定义）

如图2-16所示，双分支输出头通过“共享语义上下文+任务专用像素映射”的方式实现并行监督：关键点热力图通道提供左上、左下、右上、右下四类角点的软响应分布，线缆分支提供像素级线缆概率，使两类任务在同一 ROI 内具有一致的监督坐标系。由于关键点通道之间采用按类别共享的输出形式，同类角点能够跨不同平面共享纹理与边缘表征，而异类角点之间又可通过独立通道避免语义竞争；同时，线缆概率图由像素级损失连续约束细长结构的边界连通性，从而在柔性线缆遮挡与局部反光条件下维持可用于后续 EPnP/RANSAC 的二维观测质量。

对于识别出的角点，本文进一步通过几何一致性规则确定其属于同一矩形平面。具体做法为：首先分别在四类角点热力图中提取局部峰值候选集 $\mathcal{P}_{lt}, \mathcal{P}_{lb}, \mathcal{P}_{rt}, \mathcal{P}_{rb}$ ；随后从四个集合中各取一个候选点构造四元组 $Q_k = (\mathbf{p}_{lt}^k, \mathbf{p}_{lb}^k, \mathbf{p}_{rt}^k, \mathbf{p}_{rb}^k)$ ，并要求其满足基本方向约束

$$x_{lt}^k < x_{rt}^k, \quad x_{lb}^k < x_{rb}^k, \quad y_{lt}^k < y_{lb}^k, \quad y_{rt}^k < y_{rb}^k.$$

在此基础上，以两条对角线中点的一致性衡量该四元组是否来自同一平面：

$$e_{\text{pair}}^{(k)} = \left\| \frac{\mathbf{p}_{lt}^k + \mathbf{p}_{rb}^k}{2} - \frac{\mathbf{p}_{lb}^k + \mathbf{p}_{rt}^k}{2} \right\|_2.$$

若 $e_{\text{pair}}^{(k)}$ 足够小，且该四边形面积落在由 CAD 尺寸投影得到的合理范围内，则认为四个角点属于同一矩形平面。最后，对每个平面的四点中心 $\mathbf{c}_k$ 按其相对于连接器壳体中心的极角进行排序，完成 Plane-1 至 Plane-4 的编号，使二维角点集合能够与 CAD 中四个矩形平面的三维角点建立稳定对应关系。

在损失函数设计方面，针对两类输出采用分项约束并进行加权求和。线缆分割分支采用加权二值交叉熵损失与 Dice 损失相结合的方式监督，其表达式分别为

$$\mathcal{L}_{\text{wbce}} = -\frac{1}{HW} \sum_x \sum_y (\beta M(x, y) \log \hat{M}_c(x, y) + (1 - M(x, y)) \log (1 - \hat{M}_c(x, y))),$$

$$\beta = \frac{|\Omega_-|}{|\Omega_+|},$$

其中， Ω_+ 表示线缆像素集合， Ω_- 表示非线缆像素集合； β 为正负样本权重系数，用于缓解类别不均衡对细长线缆分割的梯度抑制。

$$\mathcal{L}_{\text{dice}} = 1 - \frac{2 \sum_x \sum_y \hat{M}_c(x, y) M(x, y) + \epsilon}{\sum_x \sum_y \hat{M}_c(x, y) + \sum_x \sum_y M(x, y) + \epsilon},$$

式中, $M(x, y)$ 表示线缆分割真值标签, $\hat{M}_c(x, y)$ 表示预测概率, ϵ 为平滑项。由此, 线缆分支的损失可写为

$$\mathcal{L}_{\text{cable}} = \mathcal{L}_{\text{wbce}} + \lambda_{\text{dice}} \mathcal{L}_{\text{dice}},$$

其中, λ_{dice} 为 Dice 损失权重系数。

最终, 二级网络的总损失函数定义为

$$\mathcal{L}_{\text{seg}} = \lambda_{\text{kp}} \mathcal{L}_{\text{kp}} + \lambda_{\text{cable}} \mathcal{L}_{\text{cable}},$$

式中, λ_{kp} 和 λ_{cable} 分别表示关键点热力图任务与线缆分割任务的权重系数。关键点损失函数采用均方误差形式, 其表达为

$$\mathcal{L}_{\text{kp}} = \frac{1}{N_k} \sum_{j=1}^{N_k} \sum_x \sum_y (\hat{H}_j(x, y) - H_j(x, y))^2,$$

其中, $H_j(x, y)$ 为目标高斯热力图, $\hat{H}_j(x, y)$ 为预测热力图。

联合损失的梯度耦合关系可写为

$$\nabla_{\theta} \mathcal{L}_{\text{seg}} = \lambda_{\text{kp}} \nabla_{\theta} \mathcal{L}_{\text{kp}} + \lambda_{\text{cable}} \nabla_{\theta} \mathcal{L}_{\text{cable}},$$

其中, θ 表示二级网络参数。该形式说明关键点与线缆两类监督在共享解码特征上共同影响梯度方向, 从而实现并行收敛。




图 2-17 二级网络训练与推理效果示意图

在训练实现方面, 二级网络输入来自一级检测得到的单目标 ROI, 并将 ROI

重采样到固定尺度 $I_{\text{roi}} \in \mathbb{R}^{256 \times 256 \times 3}$ 。网络前向获得关键点热力图 $\{\hat{H}_j\}$ 与线缆概率图 $\hat{M}_c$ 后，按上述损失定义计算 $\mathcal{L}_{\text{kp}}$ 与 $\mathcal{L}_{\text{cable}}$ ，再由权重系数形成 $\mathcal{L}_{\text{seg}}$ ，并通过反向传播更新参数。参数迭代满足

$$\theta_{t+1} = \theta_t - \eta_t \nabla_{\theta} \mathcal{L}_{\text{seg}},$$

其中， η_t 为迭代学习率。由于线缆分支采用加权 BCE 以及 Dice 项，细长线缆在遮挡条件下仍可保持足够的正类梯度贡献；由于关键点分支采用连续高斯软标签监督，热力图峰值在训练过程中趋于稳定，从而提高后续局部峰值提取与几何组合的可靠性。

如图2-17所示，二级网络在连接器局部 ROI 上同时输出关键点热力图与线缆分割结果。图中上排给出了不同姿态下的关键点响应可视化，四类角点在圆柱壳体局部矩形平面附近形成较为集中的高响应区域，说明热力图监督能够在存在反光与纹理重复的条件下保持较清晰的类别区分；下排给出了线缆分割结果示例，预测掩膜能够沿柔性线缆走向保持连续覆盖，并在连接器尾部与背景结构邻接区域维持较好的边界一致性。该结果表明，改进后的双分支网络能够在同一共享特征表示上同时完成关键点定位与线缆像素级解析，从而为后续基于角点组合的 EPnP/RANSAC 位姿解算以及抓取避障约束建模提供稳定输入。

进一步观察可见，关键点热力图在连接器壳体矩形特征较明显的区域呈现出较强峰值，而在线缆遮挡、视角倾斜与局部亮度变化条件下仍未出现大面积错位响应；这说明按类别组织的多峰值监督方式具有较好的空间鲁棒性。与此同时，线缆分割结果在两组示例中均较好覆盖了柔性线缆主体区域，尽管在线缆尾端细边界处仍可能存在局部厚度偏差，但整体走向与连通关系能够被稳定恢复。综上，改进 DeepLabV3+ 能够在航空非结构化环境与柔性线缆干扰条件下实现“关键点定位+线缆分割”的同步感知，并为第 2.5 节 EPnP/RANSAC 位姿解算提供可靠的二维观测输入。

为了便于量化训练效果，关键点定位误差可定义为

$$d_i = \sqrt{(\hat{x}_i - x_i)^2 + (\hat{y}_i - y_i)^2},$$

其中， (x_i, y_i) 为标注关键点坐标， $(\hat{x}_i, \hat{y}_i)$ 为由预测热力图提取并经平面组合后得到的对应角点坐标。若有效角点总数记为 N_p ，则平均关键点误差写为

$$\text{MAE}_{\text{kp}} = \frac{1}{N_p} \sum_{i=1}^{N_p} d_i.$$

线缆分割质量可用 Dice 系数表征为

$$\text{Dice} = \frac{2 \sum_x \sum_y \hat{M}_c(x, y) M(x, y)}{\sum_x \sum_y \hat{M}_c(x, y) + \sum_x \sum_y M(x, y) + \epsilon}.$$

当 MAE_{kp} 随迭代降低且 Dice 随迭代提升时, 说明输出头改造与联合损失设计能够在遮挡工况下同时提升关键点峰值定位精度与线缆边界一致性, 从而满足后续位姿解算与干扰补偿对观测质量的要求。




图 2-18 二级网络训练曲线图 (总损失、关键点热力图损失、线缆分割损失、线缆分割 mIoU、关键点像素误差与学习率调度随 epoch 变化)

如图 2-18 所示, 二级网络在训练集与验证集上的 loss/total 均随迭代持续下降, 且两条曲线整体保持较小间距, 说明共享特征上的关键点分支与线缆分支能够在联合监督下稳定收敛, 验证集上未出现明显反弹, 表明模型未表现出显著过拟合。进一步观察分项损失可见, loss/keypoint_mse 在前期下降较快, 说明四类角点热力图的峰值结构能够较早建立; $\text{loss/cable_wbce_dice}$ 的下降过程相对更平缓, 反映出柔性线缆细长边界、遮挡区域与背景相邻区域的学习难度更高, 但其训练与验证曲线后期仍能同步收敛, 说明双分支输出头与联合损失设计在刚性关键点和柔性线缆两类任务之间取得了较好的梯度平衡。

从验证指标变化看, $\text{metrics/cable_mIoU}$ 随训练推进由初始较低水平持续提升并在后期趋于稳定, 说明线缆分割分支逐步恢复了柔性线缆的主体覆盖范围与边界连通性; $\text{metrics/kp_error_px}$ 则由初期较大的像素误差持续下降至较低水平, 表明由热力图峰值恢复得到的角点位置不断逼近真实标注。右下角学习率调度曲线表明, 训练初期采用较高学习率以加快共享特征与任务分支的建立, 随后逐步衰减以减小参数振荡并增强后期收敛稳定性。结合前述推理效果图可以认为, 经过约 500 个 epoch 的联合训练后, 改进 DeepLabV3+ 已能够在航

空非结构化环境与柔性线缆干扰条件下稳定输出可用于第 2.5 节 EPnP/RANSAC 位姿解算的关键点观测与线缆掩膜结果。

2.5 基于 EPnP 与 RANSAC 的电连接器位姿解算

经过二级网络处理后，系统已经获得由四类角点热力图解析得到的 16 个角点观测以及线缆掩膜等局部精细视觉结果。为实现从图像特征到机器人可执行状态的转换，必须进一步结合相机模型和连接器 CAD 几何先验，将二维关键点映射为三维刚体位姿参数。本文根据连接器 CAD 模型的物理尺寸参数预先确定各角点在物体系下的三维坐标，其中单个矩形平面的宽度为 6.5 mm，长度为 8 mm，并将其四个角点坐标统一表达在连接器物体系 $\{O\}$ 下；再将由“四类热力图峰值提取 + 平面几何组合”恢复出的二维角点与上述 CAD 三维角点一一对应，从而构成后续 PnP 解算所需的 2D-3D 对应集合。航空机舱场景中的线缆遮挡、局部反光与分割偏差会使少量关键点观测发生明显漂移，若采用普通 PnP 求解，异常点会显著拉偏最终位姿结果。本文采用 EPnP 进行高效初值求解，并利用 RANSAC 基于重投影误差剔除外点，以在保证解算效率的同时增强对遮挡干扰的鲁棒性。

2.5.1 相机投影模型与 EPnP 求解

位姿解算基于针孔相机模型。设物体系下第 i 个三维关键点为 $\mathbf{P}_i^O = [X_i, Y_i, Z_i]^T$ ，相机系下为 $\mathbf{P}_i^C = \mathbf{R}\mathbf{P}_i^O + \mathbf{t}$ ，像素观测为 $\mathbf{p}_i = [u_i, v_i]^T$ ，则

$$s_i \begin{bmatrix} u_i \\ v_i \\ 1 \end{bmatrix} = \mathbf{K}\mathbf{P}_i^C, \quad \mathbf{K} = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix},$$

其中， s_i 为深度尺度， $\mathbf{R} \in SO(3)$ 、 $\mathbf{t} \in \mathbb{R}^3$ 为待求位姿， f_x, f_y 为焦距， c_x, c_y 为主点。

如图2-19所示，物方点经 $\mathbf{R}, \mathbf{t}$ 变换至相机系后由 $\mathbf{K}$ 投影为像素，二级网络提供的二维关键点即 $\mathbf{p}_i$ ，与 CAD 三维点 $\mathbf{P}_i^O$ 构成 2D-3D 对应；EPnP 在该对应下通过控制点参数化将位姿求解转化为线性方程组。

本文采用 EPnP 在给定 2D-3D 对应下求 $\mathbf{R}, \mathbf{t}$ 。在物体系中取四个非共面控制点 $\mathbf{C}_j^O$ ($j = 1, \dots, 4$)，由 CAD 与选点规则确定。物方任意关键点用控制点仿射组合表示：




图 2-19 相机模型与 PnP 位姿解算统一示意图（光心 O 、图像平面、物体系 $\{O\}$ 与相机系 $\{C\}$ 、三维点 $\mathbf{P}_i^O/\mathbf{P}_i^C$ 、像素 $\mathbf{p}_i$ 、控制点 $\mathbf{C}_j$ 及位姿 $\mathbf{R}, \mathbf{t}$ 的几何与解算流程）

$$\mathbf{P}_i^O = \sum_{j=1}^4 \alpha_{ij} \mathbf{C}_j^O, \quad \sum_{j=1}^4 \alpha_{ij} = 1,$$

α_{ij} 仅与物体几何有关，由 $\mathbf{P}_i^O$ 与 $\mathbf{C}_j^O$ 预先算得。记控制点在相机系下坐标为 $\mathbf{c}_j^C = (x_j, y_j, z_j)^\top$ ，则相机系下关键点为

$$\mathbf{P}_i^C = \mathbf{R} \mathbf{P}_i^O + \mathbf{t} = \sum_{j=1}^4 \alpha_{ij} \mathbf{c}_j^C.$$

将投影方程写为归一化像面形式。记 $\tilde{u}_i = (u_i - c_x)/f_x$ ， $\tilde{v}_i = (v_i - c_y)/f_y$ ，则有 $X_i^C = \tilde{u}_i Z_i^C$ ， $Y_i^C = \tilde{v}_i Z_i^C$ ，其中 $\mathbf{P}_i^C = (X_i^C, Y_i^C, Z_i^C)^\top$ 。代入 $\mathbf{P}_i^C = \sum_j \alpha_{ij} \mathbf{c}_j^C$ 得

$$\sum_{j=1}^4 \alpha_{ij} x_j = \tilde{u}_i \sum_{j=1}^4 \alpha_{ij} z_j, \quad \sum_{j=1}^4 \alpha_{ij} y_j = \tilde{v}_i \sum_{j=1}^4 \alpha_{ij} z_j.$$

对每个关键点 i 得到关于 12 个未知量 $\mathbf{x} = [x_1, y_1, z_1, \dots, x_4, y_4, z_4]^\top$ 的两个线性方程。设共有 n 组 2D-3D 对应，本文在完整解算时使用 16 个角点对应，即 $n = 16$ ；在 RANSAC 采样阶段采用四点最小子集构造候选位姿。于是可得到 $2n$ 个方程组成的线性方程组 $\mathbf{A}\mathbf{x} = \mathbf{0}$ （或齐次形式下求 $\mathbf{x}$ 的非零解再尺度化）。解出 $\mathbf{c}_j^C$ 后，由物体系与相机系下控制点对应 $\mathbf{c}_j^C = \mathbf{R} \mathbf{C}_j^O + \mathbf{t}$ 通过最小二乘或 SVD 恢复 $\mathbf{R}$ 与 $\mathbf{t}$ ，并施以正交化保证 $\mathbf{R} \in SO(3)$ 。

综上，在当前任务下 EPnP 的输入为二级网络恢复得到的 16 个二维角点 $\mathbf{p}_i$

与依据 CAD 物理尺寸预先确定的三维角点 $\mathbf{P}_i^O$ 。通过控制点参数化建立线性方程组 $\mathbf{Ax} = \mathbf{0}$ 后, 可先求得控制点在相机系下的位置, 再恢复目标位姿 $(\mathbf{R}, \mathbf{t})$ 。完整的 16 组对应提高了位姿估计的冗余度与稳定性, 而后续 2.5.2 节的 RANSAC 仍采用四点最小子集生成候选解, 以增强对局部遮挡和异常角点的鲁棒性。



图 2-20 EPnP 位姿解算实物检测效果图 (左: 二维关键点检测结果; 右: EPnP 位姿估计与三维包围框投影结果)

如图2-20所示, 左图给出了连接器局部区域内的二维关键点检测结果, 右图给出了基于相同 2D-3D 对应关系求得的 EPnP 位姿及其三维包围框投影。可以看出, 投影框的空间方向与连接器实际姿态基本一致, 局部结构框架也能够较好贴合壳体轮廓, 说明图像侧恢复得到的二维角点与 CAD 几何先验之间具有较高一致性。该实物结果表明, EPnP 求得的位姿初值已具备较好的几何可信度, 可作为后续 RANSAC 外点剔除和系统级抓取装配位姿对准的基础输入。

进一步地, 在系统连续运行过程中, 单帧位姿估计结果还会受到瞬时漏检的影响。当某一图像帧中一级检测未能稳定锁定目标, 或二级角点恢复因强反光、遮挡而失败时, 该帧的 ${}^C\mathbf{T}_O$ 将无法直接输出, 进而造成位姿序列出现短时缺失。若不对这类缺失帧进行补偿, 机器人在连续跟踪或在线装配过程中将出现目标位姿突跳、控制输入不连续等问题。为减轻这一影响, 本文在逐帧 EPnP 位姿估计之后引入卡尔曼滤波, 对连续时序下的目标位姿序列进行预测与更新, 从而在个别帧漏检时仍可维持目标状态的连续跟踪。

在实现上, 将目标位姿统一表示到机器人基座坐标系下并作为滤波状态进行时序建模; 其与手眼变换和基座系统一的关系将在 2.5.3 节进一步给出。设离散时刻 k 的状态向量为

$$\mathbf{x}_k = [x_k, y_k, z_k, \phi_k, \theta_k, \psi_k, \dot{x}_k, \dot{y}_k, \dot{z}_k, \dot{\phi}_k, \dot{\theta}_k, \dot{\psi}_k]^\top,$$

其中, (x_k, y_k, z_k) 表示目标在机器人基座系下的位置, $(\phi_k, \theta_k, \psi_k)$ 表示姿态角参数, 带点变量表示对应速度项。采用常速度模型时, 系统状态方程可写为

$$\mathbf{x}_k = \mathbf{A}\mathbf{x}_{k-1} + \mathbf{w}_k,$$

其中, $\mathbf{A}$ 为状态转移矩阵, $\mathbf{w}_k \sim \mathcal{N}(0, \mathbf{Q})$ 为过程噪声。由当前视觉帧得到的位姿观测记为

$$\mathbf{z}_k = \mathbf{H}\mathbf{x}_k + \mathbf{v}_k,$$

其中, $\mathbf{z}_k$ 由当帧 EPnP 估计结果经手眼变换后得到, $\mathbf{H}$ 为观测矩阵, $\mathbf{v}_k \sim \mathcal{N}(0, \mathbf{R})$ 为观测噪声。正常检测到目标时, 滤波器执行标准预测-更新过程; 当某一帧发生漏检或位姿求解失败时, 则跳过观测更新, 仅利用预测方程输出 $\hat{\mathbf{x}}_{k|k-1}$ 作为该时刻的目标位姿估计。这样可以在短时间视觉信息不完整的情况下维持位姿轨迹的连续性, 并抑制由单帧异常造成的瞬时跳变。

因此, 从系统层面看, 本文的在线位姿估计链路可概括为“单帧角点恢复与 EPnP 几何求解提供测量值, 卡尔曼滤波在时间维度上提供状态延拓与平滑约束”。前者保证位姿估计具备明确的几何物理含义, 后者保证估计结果在连续帧运行中具备更好的稳定性与跟踪性。该机制尤其适用于航空非结构化环境下因柔性线缆遮挡和反光干扰引起的短时漏检场景, 可为后续 2.5.2 节的多帧 RANSAC 稳健筛选以及机器人末端连续控制提供更稳定的位姿输入。

2.5.2 基于 RANSAC 的外点剔除

在完成单帧 EPnP 求解和时序卡尔曼滤波之后, 还需要进一步利用多视角观测提高位姿结果的整体鲁棒性。为此, 本文在观测阶段预先设置机械臂末端的 4 个固定观测点位, 使腕部相机从不同视角对同一连接器目标进行成像。机械臂依次运动到这 4 个固定点位后, 在每个位姿下采集若干帧 RGB 图像, 并分别完成一级检测、二级角点恢复以及 EPnP 位姿求解, 由此形成同一目标在多视角条件下的多帧视觉观测集合。由于不同视角下的遮挡程度、反光强度和角点恢复质量并不完全一致, 若直接对全部观测结果进行平均, 异常帧会对最终位姿造成明显拉偏, 因此有必要通过 RANSAC 在多帧观测中剔除外点。其优化目标可表示为

$$(\hat{\mathbf{R}}, \hat{\mathbf{t}}) = \arg \min_{\mathbf{R}, \mathbf{t}} \sum_{i \in \mathcal{I}} \|\mathbf{p}_i - \pi(\mathbf{P}_i, \mathbf{K}, \mathbf{R}, \mathbf{t})\|_2^2,$$

式中, $\mathcal{I}$ 表示内点集合, $\pi(\cdot)$ 表示相机投影函数。

在本文任务中, RANSAC 的“模型”即由 2.5.1 节 EPnP 基于 2D-3D 对应求得的位姿 $(\mathbf{R}, \mathbf{t})$; “模型假设”指某一帧观测对应的位姿在当前多帧集合中能够代表同一目标的真实空间状态。对于单帧内部, EPnP 至少需要四组 2D-3D 对应方可求解, 因此最小子集规模可取为 4; 若某些角点受到线缆遮挡、局部反光或热力图峰值漂移影响, 则该帧估计得到的位姿会偏离真实值。进一步地, 对第 m 帧观测, 先由 2.5.1 节求得相机系下位姿 ${}^C\mathbf{T}_O^{(m)}$, 再结合机械臂当前末端位姿 ${}^B\mathbf{T}_E^{(m)}$ 与手眼矩阵 ${}^E\mathbf{T}_C$, 将其统一转换到机器人基坐标系:

$${}^B\mathbf{T}_O^{(m)} = {}^B\mathbf{T}_E^{(m)} {}^E\mathbf{T}_C {}^C\mathbf{T}_O^{(m)}.$$

其中, m 表示由 4 个固定观测点位采集得到的多帧样本编号。经过该变换后, 原本位于不同相机视角下的观测结果被统一到同一机器人基座系下, 因而可直接比较其空间一致性。设基座系下候选位姿的平移分量为 $\mathbf{t}_B^{(m)}$, 旋转分量为 $\mathbf{R}_B^{(m)}$, 则可进一步定义相对于当前候选参考位姿的帧间一致性误差为

$$e_m^B = \left\| \mathbf{t}_B^{(m)} - \hat{\mathbf{t}}_B \right\|_2^2 + \lambda_R \theta \left(\mathbf{R}_B^{(m)}, \hat{\mathbf{R}}_B \right)^2,$$

其中, $\hat{\mathbf{t}}_B$ 与 $\hat{\mathbf{R}}_B$ 表示由当前采样假设得到的基座系候选位姿, λ_R 为旋转误差权重, $\theta(\cdot, \cdot)$ 表示两姿态之间的旋转夹角。若某一帧的 e_m^B 超过设定阈值, 则说明该帧与大多数观测的空间结果不一致, 可判为外点。由此, RANSAC 通过多帧基座系位姿集合中反复采样并统计内点数, 保留一致性最高的观测子集, 从而在多视角观测条件下获得更稳定的连接器位姿估计。

设第 i 个关键点的关键点重投影误差为

$$e_i = \|\mathbf{p}_i - \pi(\mathbf{P}_i, \mathbf{K}, \mathbf{R}, \mathbf{t})\|_2^2,$$

则其内点判据为 $e_i < \tau$; 当前方案中取 $\tau = 3$ 像素, 以兼顾高精度装配要求与遮挡条件下的鲁棒性。算法 2-1 给出基于 EPnP 的 RANSAC 位姿估计流程。

上述算法给出了单帧图像内基于关键点重投影误差的 EPnP-RANSAC 求解

算法 2-1 基于 EPnP 的 RANSAC 位姿估计

Input: 二维关键点 $\{\mathbf{p}_i\}$, 对应三维点 $\{\mathbf{P}_i^O\}$, 内参 $\mathbf{K}$, 重投影阈值 τ , 最大迭代次数 $N_{\max}$

Output: 位姿 $(\hat{\mathbf{R}}, \hat{\mathbf{t}})$ 及内点集合 $\mathcal{I}^*$

```

1 for  $k = 1$  to  $N_{\max}$  do
2     从当前对应中随机抽取 4 组 2D-3D 对;
3     用 EPnP 求解得候选位姿  $(\mathbf{R}_k, \mathbf{t}_k)$ ;
4     对全部关键点计算  $e_i = \|\mathbf{p}_i - \pi(\mathbf{P}_i^O, \mathbf{K}, \mathbf{R}_k, \mathbf{t}_k)\|_2$ ;
5     统计内点集合  $\mathcal{I}_k = \{i : e_i < \tau\}$  的规模  $|\mathcal{I}_k|$ ;
6     if  $|\mathcal{I}_k| > |\mathcal{I}^*|$  then
7         更新  $\mathcal{I}^* := \mathcal{I}_k$ , 并记录  $(\mathbf{R}^*, \mathbf{t}^*) := (\mathbf{R}_k, \mathbf{t}_k)$ ;
8     end
9 end
10 以  $\mathcal{I}^*$  为内点, 用全部内点重新运行 EPnP (或最小二乘) 得到最终
     $(\hat{\mathbf{R}}, \hat{\mathbf{t}})$ ;
11 return  $(\hat{\mathbf{R}}, \hat{\mathbf{t}})$  与  $\mathcal{I}^*$ 
    
```

流程; 在系统级实现中, 还需将各固定观测点位采集到的多帧单帧位姿进一步经式中的坐标变换统一到机器人基坐标系下, 再依据帧间位姿一致性实施二次外点筛选与融合, 从而得到更稳定的最终位姿输出。




图 2-21 RANSAC 外点剔除效果图 (剔除前后重投影误差分布与内点集合可视化)

如图2-21所示, RANSAC 外点剔除后, 重投影误差主要集中在阈值以下的低误差区间, 而剔除前的异常对应则分布在较大误差范围内。右侧散点图同样

表明，内点整体稳定落在阈值线下方，外点集中出现在高误差区域。该结果说明 RANSAC 能够有效识别由遮挡、反光和热力图峰值漂移引起的异常对应，避免少量失真角点拉偏 EPnP 位姿估计；经外点剔除后，参与重估的对应集合一致性更高，从而为后续手眼标定、抓取规划与装配位姿对准提供更稳定的位姿输入。

2.5.3 手眼标定与坐标系转换

为将 2.5.1 与 2.5.2 节得到的相机系下连接器位姿转换为机器人可执行目标，本文采用 Eye-in-Hand 模式完成手眼标定。首先对涉及的各坐标系及变换符号做统一约定。

坐标系定义与符号约定。记机器人基坐标系为 $\{B\}$ ，原点固连于基座，用于描述机械臂各连杆与末端在基座下的位姿；末端法兰坐标系为 $\{E\}$ ，原点位于法兰中心，随机械臂运动；相机坐标系为 $\{C\}$ ，原点为相机光心， z 轴指前、 x, y 与像面轴一致；目标物体坐标系为 $\{O\}$ ，与连接器 CAD 或位姿解算所用物体一致。变换矩阵采用左上标“目标系”、右下标“源系”的记法： ${}^B\mathbf{T}_E \in SE(3)$ 表示将 $\{E\}$ 下的点或位姿变换到 $\{B\}$ 下，即 $\mathbf{p}^B = {}^B\mathbf{T}_E \mathbf{p}^E$ 。同理， ${}^E\mathbf{T}_C$ 为相机在末端系下的外参（手眼矩阵）， ${}^C\mathbf{T}_O$ 为 2.5 节 PnP 输出的目标在相机系下的位姿。则目标在基座系下的位姿为

$${}^B\mathbf{T}_O = {}^B\mathbf{T}_E {}^E\mathbf{T}_C {}^C\mathbf{T}_O. \quad (2-1)$$

其中， ${}^B\mathbf{T}_E$ 由机械臂正运动学实时给出， ${}^C\mathbf{T}_O$ 由本章级联感知与 EPnP/RANSAC 输出； ${}^E\mathbf{T}_C$ 为标定未知量，不随机械臂运动改变。

手眼标定原理与 Tsai-Lenz 两步法。在 Eye-in-Hand 下，相机固连于末端，故 ${}^E\mathbf{T}_C$ 为常值。令机械臂依次运动到 $i = 1, \dots, N$ 个不同姿态，在每一姿态下由正解得到 ${}^B\mathbf{T}_E^{(i)}$ ，由视觉得到 ${}^C\mathbf{T}_O^{(i)}$ 。记相邻两帧间末端在基座系下的相对运动为 $\mathbf{A}_i = ({}^B\mathbf{T}_E^{(i)})^{-1} {}^B\mathbf{T}_E^{(i+1)}$ ，目标在相机系下的相对运动（等价于相机相对目标的反向运动）为 $\mathbf{B}_i = ({}^C\mathbf{T}_O^{(i)})^{-1} {}^C\mathbf{T}_O^{(i+1)}$ ，则手眼约束可写为 $\mathbf{A}_i \mathbf{X} = \mathbf{X} \mathbf{B}_i$ ，其中 $\mathbf{X} = {}^E\mathbf{T}_C$ 为待求手眼矩阵。将该式按旋转与平移拆开，记 $\mathbf{A}_i = (\mathbf{R}_{A_i}, \mathbf{t}_{A_i})$ 、 $\mathbf{B}_i = (\mathbf{R}_{B_i}, \mathbf{t}_{B_i})$ 、 $\mathbf{X} = (\mathbf{R}_X, \mathbf{t}_X)$ ，有

$$\mathbf{R}_{A_i} \mathbf{R}_X = \mathbf{R}_X \mathbf{R}_{B_i}, \quad \mathbf{R}_{A_i} \mathbf{t}_X + \mathbf{t}_{A_i} = \mathbf{R}_X \mathbf{t}_{B_i} + \mathbf{t}_X.$$

Tsai-Lenz 两步法先由多组 $\mathbf{R}_{A_i}, \mathbf{R}_{B_i}$ 通过旋转方程求解 $\mathbf{R}_X$ （可转化为线性方

程组或 SVD)，再代入平移方程求 $\mathbf{t}_x$ 。本文通过多姿态采样（如 20 组标定图像）构建多组 $(\mathbf{A}_i, \mathbf{B}_i)$ ，求解 $\mathbf{X}$ 并对残差进行评估；依据已有记录，标定后重投影误差可控制在约 0.42 pixels，对应空间位置误差约 0.35 mm，能够满足后续连接器抓取与装配的精度需求。




图 2-22 Eye-in-Hand 手眼标定过程与坐标系关系图（ $\{B\}, \{E\}, \{C\}, \{O\}$ 及 ${}^B\mathbf{T}_O$ 链式变换）

如图2-22所示， $\{B\}$ 、 $\{E\}$ 、 $\{C\}$ 、 $\{O\}$ 的几何关系与式 (2-1) 的链式相乘顺序一致：基座下的目标位姿由末端位姿、手眼矩阵与相机系下目标位姿依次右乘得到。在航空非结构化环境中，该位姿在基座系下可直接用于机器人执行。

2.6 算法验证实验

本节面向航空制造场景中“多实例堆叠、金属反光/阴影、柔性线缆遮挡”三类典型干扰，对本章级联视觉感知与位姿解算流程进行端到端验证。流程由 YOLOv8-seg 在整图完成目标实例定位、TagID 识别与粗分割以生成可靠 ROI；在 ROI 内由改进 DeepLabV3+ 输出关键点热力图峰值与线缆精细掩膜；随后由 EPnP 完成单帧几何位姿求解，并结合卡尔曼滤波维持连续帧跟踪，再由多帧 RANSAC 剔除外点；最后通过 2.5.3 节手眼矩阵将结果统一到机器人基座坐标系。

在实机验证开始阶段，感知图像并非直接来自随机运动过程，而是由机械臂携带腕部相机在实验工位内按照预设观测流程主动获取。具体而言，首先将连接器目标布置在模拟航空制造环境的实验工位中，使其同时处于线缆密集、背景结构复杂与局部反光干扰并存的条件下；随后控制机械臂末端运动到目标前方若干固定观测位，在保持相机光轴始终朝向连接器目标区域的前提下，对同一目标实施多角度定点观察。相机在各固定观测位采集的 RGB 图像构成端到端验证的初始可靠感知输入。通过这种“先定点观测、再级联处理”的方式，

可以在初始化阶段获得稳定的目标观测，并使不同阶段算法在同一批真实图像上进行一致验证。

需要进一步指出的是，固定观测位的静态采样主要用于建立初始可靠感知结果和完成多视角验证，而在后续机械臂持续运动、抓取接近与位姿调整过程中，系统仍保持在线视觉感知工作模式。也就是说，相机在末端随机械臂运动时持续采集图像帧，级联感知网络同步执行目标检测、角点恢复、线缆分割与位姿更新，从而对静态观测之外的中间时刻提供连续感知能力。借助前文引入的卡尔曼滤波与多帧稳健估计机制，系统能够在运动过程中持续补充新的视觉观测，并在短时遮挡或个别帧漏检情况下保持目标位姿输出的连续性。因此，本节实验所验证的并不仅是固定姿态下的初始化识别能力，也包括面向实机连续运动场景的在线感知、位姿跟踪与动态更新能力。




图 2-23 第二章端到端验证链路图（RGB 输入 → YOLOv8-seg 检测/粗分割/TagID → 动态 ROI 裁剪 → 改进 DeepLabV3+ 关键点 + 线缆 → EPnP/RANSAC 位姿 → 手眼变换到 $\{B\}$ ）

图2-23给出了航空非结构化环境下的端到端验证链路。该链路体现“由粗到精”的信息流：整图尺度上需稳定获得目标实例位置与标签身份，否则局部网络易受背景与多实例混淆；ROI 内关键点与线缆为小尺度特征，整图直接回归易受反光与遮挡产生峰值漂移；位姿解算需显式引入 CAD 先验与投影一致性检验，方能得到可执行的 6D 位姿。检测—精细特征—几何解算—坐标统一—由此形成闭环。

图2-24给出了端到端验证初始阶段的实机定点观测结果。机械臂携带腕部相机依次停留在目标前方多个固定观测位，对连接器实施多视角静态采样；上排为对应视角下获得的原始图像，下排为实机观测过程。该步骤为后续检测、关键点恢复、线缆分割与多帧位姿融合提供统一的真实观测输入。由于各观测位之间的位姿变化可由机器人正运动学准确记录，不同视角下的感知结果可进一步统一映射到机器人基座坐标系，从而支撑第 2.5 节中的稳定位姿解算与多视角一致性验证。




图 2-24 端到端验证初始阶段实机定点观测图（上：连接器目标多视角原始观测图像；下：机械臂携带腕部相机执行固定观测位采样过程）

图 2-21
(空白占位图)

图 2-25 YOLOv8-seg 阶段输出可视化图（多实例堆叠与线缆遮挡场景下的检测框、实例掩膜与 TagID 识别结果）

图2-25展示了 YOLOv8-seg 在复杂背景与多实例堆叠条件下的阶段性输出。该阶段完成实例级分离、身份识别与位置约束：实例掩膜提供连接器粗轮廓，使 ROI 裁剪避开大面积背景与反光；TagID 区分同视野中的不同实例，避免多实例邻近时的 ROI 交叉与目标错配；检测框与置信度支撑 ROI 动态扩展。该阶段输出质量直接制约 ROI 内关键点与线缆分割的稳定性。




图 2-22
(空白占位图)

图 2-26 改进 DeepLabV3+ 阶段输出可视化图（ROI 内关键点热力图峰值定位与线缆精细分割结果叠加展示）

图2-26给出了 ROI 尺度下改进 DeepLabV3+ 的双分支输出效果。与仅回归关键点坐标的方案相比，热力图监督能够在遮挡、反光导致局部纹理不连续时提供更稳定的峰值结构；线缆分割分支将柔性线缆干扰显式表征为像素级掩膜。该阶段的有效性体现在两点：其一，左上、左下、右上、右下四类角点在热力图上呈现多个稳定峰值，便于通过局部峰值搜索与几何组合得到完整的二维观测 $\mathbf{p}_i$ ，从而降低 2.5 节投影误差的上界；其二，线缆掩膜边界在细尺度上与真实轮廓一致，减少“线缆覆盖矩形平面边缘”导致的关键点偏移概率。由于本章位姿解算基于 16 个角点构成的 2D-3D 对应集合，该阶段对关键点峰值稳定性的提升将直接转化为 EPnP 初值与 RANSAC 内点一致性提升，从而增强在航空机舱遮挡工况下的解算鲁棒性。

图2-27用于验证“二维观测—三维先验—几何一致性检验”对位姿输出的约束作用。首先，EPnP 利用 16 个角点的 2D-3D 对应在 $SE(3)$ 上求得相机系下目标位姿 ${}^c\mathbf{T}_O$ ，其中三维点由连接器 CAD 模型的物理尺寸参数确定，单个矩形平面的宽度为 6.5 mm、长度为 8 mm，因此输出具备明确的物理含义；其次，RANSAC 通过重投影误差一致性对关键点外点进行剔除，避免单个遮挡点或峰值漂移点对位姿的拉偏。可视化叠加（如坐标轴或 CAD 轮廓投影）能够直观体现：当外点存在时，投影轮廓与图像边缘/角点位置出现偏离；剔除外点并基于内点重估后，投影一致性显著增强，最终位姿满足后续机器人抓取与装配对方

图 2-23
(空白占位图)

图 2-27 EPnP/RANSAC 位姿估计结果可视化图（模型坐标轴或 CAD 投影轮廓叠加到图像，显示外点剔除前后的一致性差异）

向/位置的约束需求。结合 2.5.2 节的多帧平均策略，位姿在时间维度上更平滑，有利于抑制观测抖动对执行稳定性的影响。

2.7 本章小结

本章围绕航空制造场景下电连接器视觉感知难题，构建了一套由粗到精的级联式识别与位姿估计方法。通过 YOLOv8-seg 在整图中完成目标实例定位、标签 ID 识别与粗分割；随后，在 ROI 区域内利用改进 DeepLabV3+ 输出左上、左下、右上、右下四类角点热力图，并结合局部峰值提取与平面几何组合恢复四个矩形平面的 16 个角点，同时完成线缆精细分割；最后，结合 CAD 物理尺寸参数、EPnP 与 RANSAC 完成连接器 6D 位姿解算，并通过手眼标定将结果转换到机器人可执行坐标系中。

第3章 电连接器自主抓取方法研究

3.1 引言

本章在电连接器目标的实例区分、6D 位姿估计及 Cable Mask 提取基础上, 研究狭窄机舱环境中的电连接器自主抓取问题, 重点解决候选抓取生成、最优抓取筛选以及避开线缆障碍的运动规划三个环节。与一般规则零件抓取不同, 本文研究对象尾部连接柔性线缆, 且周围存在舱壁、支架和设备边界等刚性障碍, 因此机械臂在接近、夹持和提离过程中同时面临窄通道搜索与刚柔混合避障约束。本章抓取任务还需服务于后续装配过程, 所选抓取位姿不仅要保证稳定夹持, 还应避免遮挡插针端并尽量与装配轴线保持一致。为此, 本文构建“端到端 6D 抓取生成—多约束抓取筛选—GRRT-Connect 引导式规划”的技术路线, 为第四章柔顺装配提供稳定的预装配初始状态。

3.2 端到端 6D 抓取生成网络

在获得目标电连接器的局部点云后, 需要进一步从中生成能够被机械臂执行的候选抓取位姿。本文采用基于点云的端到端 6D 抓取生成网络, 直接由目标局部点云预测候选抓取集合, 以提高在遮挡、视角变化和点云不完整条件下的抓取鲁棒性。考虑到 Contact-GraspNet 在单视角点云抓取生成中的良好泛化能力, 本文以其网络框架为基础, 并结合电连接器对象的任务特性对输入组织和候选生成方式进行适配。

3.2.1 抓取位姿参数化表示

为统一描述平行夹爪在空间中的抓取状态, 本文采用抓取位姿

$$g = (\mathbf{t}_g, \mathbf{R}_g) \in SE(3) \quad (3-1)$$

作为候选抓取的核心表达。其中, $\mathbf{t}_g$ 表示抓取坐标系原点在空间中的位置, $\mathbf{R}_g$ 表示夹爪抓取坐标系相对于参考坐标系的方向。为了避免直接回归完整 6D 位姿带来的冗余自由度, 本文进一步引入与夹爪几何结构直接对应的参数化物理量进行描述。如图 3-1 所示, 设 $\mathbf{c} \in \mathbb{R}^3$ 为夹爪在目标表面选定的接触点, $\mathbf{x} \in \mathbb{R}^3$ 为夹爪两指闭合方向, $\mathbf{z} \in \mathbb{R}^3$ 为夹爪接近目标时的运动方向, $\omega \in \mathbb{R}$ 为两指间距, $d \in \mathbb{R}$ 为夹爪沿接近方向预留的回退距离, 则抓取位姿的平移与旋转可分

别写为

$$\mathbf{t}_g = \mathbf{c} + \frac{\omega}{2}\mathbf{x} - d\mathbf{z}, \quad (3-2)$$

$$\mathbf{R}_g = [\mathbf{x} \ \mathbf{x} \times \mathbf{z} \ \mathbf{z}]. \quad (3-3)$$

其中, $\|\mathbf{x}\|_2 = 1$ 、 $\|\mathbf{z}\|_2 = 1$ 且 $\mathbf{x}^\top \mathbf{z} = 0$, 从而 $\mathbf{R}_g \in SO(3)$ 。如图 3-1 所示, 图中的黑点 $\mathbf{c}$ 表示候选抓取首先锚定的表面接触位置, 橙色方向 $\mathbf{x}$ 表示夹爪闭合时两指相向运动的方向, 绿色方向 $\mathbf{z}$ 表示夹爪由外向内接近目标的方向。由式 (3-2) 可知, 抓取坐标系原点 $\mathbf{t}_g$ 不是直接取在接触点 $\mathbf{c}$ 处, 而是先沿闭合方向 $\mathbf{x}$ 平移 $\omega/2$, 将单侧接触点转换为两指中心的对称位置; 再沿接近方向反向移动距离 d , 为夹爪接近、闭合和提离动作预留空间。因此, $\mathbf{t}_g$ 实际表示的是夹爪参考抓取位姿中心, 而非目标表面上的几何点。

由式 (3-3) 可知, 旋转矩阵 $\mathbf{R}_g$ 的第一列取为闭合方向 $\mathbf{x}$, 第三列取为接近方向 $\mathbf{z}$, 第二列由 $\mathbf{x} \times \mathbf{z}$ 自动补全, 从而构成右手正交抓取坐标系。换言之, $(\mathbf{x}, \mathbf{z})$ 决定了夹爪“如何闭合”和“从哪个方向接近”, 而 ω 与 d 则进一步决定了夹爪“张开多大”和“在接触前应后退多远”。这样, 候选抓取位姿可由 $(\mathbf{c}, \mathbf{x}, \mathbf{z}, \omega, d)$ 五个具有明确物理意义的量唯一确定。相较于直接回归完整 6D 位姿, 该表达将姿态约束显式编码到 $\mathbf{R}_g$ 的构造中, 有利于在局部遮挡导致点云不完整时保持候选抓取在几何意义上的可解释性、稳定性以及与夹爪真实运动方式的一致性。

上述参数化与后文抓取网络的输出形式保持一致: 以点云可见表面上的接触点 $\mathbf{c}$ 作为锚点生成候选, 网络仅需对每个接触点预测闭合方向 $\mathbf{x}$ 、接近方向 $\mathbf{z}$ 及夹爪开度 ω 等物理量; 方向向量经标准化与正交化后代入式 (3-3) 构造 $\mathbf{R}_g$, 并与 $\mathbf{c}$ 、 ω 、 d 一并代入式 (3-2) 得到 $\mathbf{t}_g$ 。该表示将抓取姿态的几何约束显式编码到构造过程中, 有利于在航空机舱狭窄空间与柔性线缆干扰条件下形成可解释的候选分布: 优先在电连接器壳体稳定夹持区产生接触点, 降低在插接端与线缆根部等敏感区域生成候选的概率, 同时通过接近方向 $\mathbf{z}$ 的任务相关性约束, 为后续装配阶段的姿态连续性与对准质量提供基础。

3.2.2 基于局部点云的网络输入构建

抓取网络若直接以整场景点云为输入, 在航空机舱等背景复杂、多目标与垂落线缆并存的环境中会产生大量非目标区域的无效预测, 并增加计算负担。




图 3-1 抓取位姿参数示意图（接触点 $\mathbf{c}$ 、闭合方向 $\mathbf{x}$ 、接近方向 $\mathbf{z}$ 、夹爪开度 ω 与偏置长度 d 共同确定抓取坐标系原点 $\mathbf{t}_g$ 及姿态 $\mathbf{R}_g$ ）

因此，本文在输入侧将“整场景 RGB-D + 视觉感知结果”收敛为“目标局部点云 + 线缆先验”的规范化表示，处理逻辑按流程顺序分为四步：目标局部区域提取、深度反投影生成相机系点云、坐标系变换与尺度姿态规范化、线缆禁入域先验与采样权重赋值。以下按该顺序展开并给出相应数学表达与算法流程。

(1) 目标局部区域提取。输入为第二章得到的电连接器实例分割掩膜、6D 位姿估计结果以及线缆分割掩膜（Cable Mask）。根据目标实例掩膜在深度图上裁剪出目标对应像素集合 $\{(u_i, v_i, z_i)\}_{i \in \mathcal{I}_{\text{obj}}}$ ，剔除背景与相邻目标像素，得到仅覆盖当前连接器及其可见表面的像素—深度对，作为后续反投影的输入。线缆掩膜在本阶段用于标记禁入区域，供第四步采样权重使用。

(2) 深度反投影与相机系点云生成。对上述像素—深度对，利用相机内参将二维观测反投影至相机坐标系 $\{C\}$ 下的三维点云。设像素坐标为 (u_i, v_i) ，深度值为 z_i ，内参矩阵为 $\mathbf{K}$ ，则相机系下三维点为

$$\mathbf{P}_i^c = z_i \mathbf{K}^{-1} \begin{bmatrix} u_i \\ v_i \\ 1 \end{bmatrix}, \quad i \in \mathcal{I}_{\text{obj}}. \quad (3-4)$$

由此得到目标在相机系下的局部点云 $\mathcal{P}^c = \{\mathbf{P}_i^c\}$ ，其几何已限定于当前连接器可见表面，为后续坐标系规范化与网络输入提供几何基础。

(3) 坐标系变换与尺度姿态规范化。为减弱不同安装姿态、相机视角与局部遮挡对网络输入分布的影响，将 $\mathcal{P}^c$ 变换至目标物体坐标系 $\{O\}$ （与位姿估计

所用物体系一致)，并进行尺度归一化。记第二章输出的目标在相机系下的位姿为 ${}^C\mathbf{T}_O \in SE(3)$ ，则物体系下点坐标为

$$\mathbf{P}_i^O = ({}^C\mathbf{T}_O)^{-1} \mathbf{P}_i^c = ({}^O\mathbf{R}_C \ {}^O\mathbf{t}_C) \begin{bmatrix} \mathbf{P}_i^c \\ 1 \end{bmatrix}, \quad i \in \mathcal{I}_{\text{obj}}. \quad (3-5)$$

其中 ${}^O\mathbf{R}_C \in SO(3)$ 、 ${}^O\mathbf{t}_C \in \mathbb{R}^3$ 为从相机系到物体系的旋转与平移。若需尺度统一，可再对 $\mathcal{P}^O = \{\mathbf{P}_i^O\}$ 按连接器模型或包围盒尺度进行缩放，使网络输入与训练阶段尺度一致。规范化后的 $\mathcal{P}^O$ 即为抓取网络几何输入的主体。

(4) 线缆禁入域先验与采样权重。为避免候选抓取过度集中于线缆根部与插针端等功能敏感区，本文在输入构建阶段为每个点赋予与“到线缆距离”相关的采样优先级权重，使后续 PointNet++ 分层采样及抓取预测头在训练与推理中更倾向于以壳体稳定夹持区为锚点。设由 Cable Mask 反投影并体素化得到的线缆点云（或体素集合）为 $\mathcal{P}_{\text{cable}}$ ，点 $\mathbf{P}_i^O$ 到线缆的最小距离定义为

$$d_{\text{cable}}(\mathbf{P}_i^O) = \min_{\mathbf{q} \in \mathcal{P}_{\text{cable}}} \|\mathbf{P}_i^O - \mathbf{q}\|_2. \quad (3-6)$$

采样权重取为距离的单调递增函数，例如 $w_i = \sigma(d_{\text{cable}}(\mathbf{P}_i^O)/\lambda)$ ，其中 $\sigma(\cdot)$ 为 Sigmoid 函数， λ 为尺度参数；或简化为阈值形式：当 $d_{\text{cable}}(\mathbf{P}_i^O) < \rho$ 时令 $w_i = 0$ （禁入），否则 $w_i = 1$ 。权重 w_i 可在网络分层采样时用于调节点的被采样概率，或在损失中对靠近线缆的预测施加抑制，从而从输入与监督两侧共同引导抓取候选远离线缆禁入域。




图 3-2 目标局部点云裁剪与坐标系规范化示意图（自左至右：整场景深度与实例掩膜、裁剪后目标像素—深度、相机系局部点云、物体系规范化点云及线缆禁入域权重示意）

如图 3-2 所示，本小节将整场景 RGB-D 与第二章输出的实例掩膜、6D 位姿及 Cable Mask 处理为“目标局部点云 + 线缆先验权重”的输入表示。裁剪后仅保留当前连接器对应像素，避免舱壁、支架及相邻连接器进入后续点云；反投影得到的相机系点云进一步经式 (3-5) 变换到物体系，并按需要完成尺度归一

化，从而减弱视角与安装姿态变化对输入分布的影响。

图中的线缆禁入域与权重分布对应式 (3-6) 和采样权重 w_i 的工程含义：靠近线缆根部的点被赋予较低权重或直接禁入，使抓取网络在接触点采样与高分预测时更偏向连接器壳体稳定夹持区。由此得到的 $\mathcal{P}^O$ 与 $\{w_i\}$ 同时保留了目标几何与柔性线缆约束，为后续端到端抓取生成提供任务一致的输入。

3.2.3 基于 Contact-GraspNet 的抓取网络结构

针对航空非结构化环境下带柔性线缆的电连接器抓取任务，原始 Contact-GraspNet 直接以整场景点云作为输入，易在背景区域、插针端及线缆根部产生无效候选；同时，其网络层级与本文 3.2.1 节抓取参数化 $(\mathbf{c}, \mathbf{x}, \mathbf{z}, \omega, d)$ 之间的对应关系不够直观。基于此，本文在不改变 Contact-GraspNet 主干结构与预测头拓扑的前提下，主要进行了任务适配：(1) 将输入由整场景点云替换为 3.2.2 节构建的目标局部点云与线缆先验；(2) 将点级权重 w_i 引入候选接触点采样过程，使候选更集中于壳体稳定夹持区；(3) 在保持原有网络结构不变的基础上，通过输入组织与训练策略调整完成面向电连接器抓取任务的迁移。为避免与 3.2.4 节重复，本节仅说明网络结构、输入输出符号及前向数据流，损失函数与样本标注规则放在下一节展开。

将输入点云组织为带权局部点集

$$\tilde{\mathcal{P}} = \left\{ \left(\mathbf{P}_i^O, w_i \right) \mid \mathbf{P}_i^O \in \mathcal{P}^O, w_i \in [0, 1] \right\}_{i=1}^N, \quad (3-7)$$

其中， $\mathbf{P}_i^O$ 为 3.2.2 节得到的目标物体体系下第 i 个局部点坐标， w_i 为该点对应的线缆先验权重， N 为输入点数。 w_i 越大，表示该点距离线缆越远、越可能位于连接器壳体稳定夹持区域； w_i 越小，则表示该点更接近线缆根部或插针端等功能敏感区域。基于此，候选中心点的采样概率可写为

$$p_i = \frac{w_i}{\sum_{j=1}^N w_j}, \quad (3-8)$$

即利用点级权重对原始均匀采样进行调制，从输入阶段抑制线缆邻域和功能敏感区域的无效候选。

如图 3-3 所示，本文采用的 Contact-GraspNet 仍由输入层、PointNet++ 特征提取层、四分支预测层和候选位姿恢复层构成。图中左侧输入不再直接使用整场景点云，而是采用仅包含当前连接器可见表面的带权局部点集 $\tilde{\mathcal{P}}$ ；中间部分沿用原 Contact-GraspNet 的层级特征提取流程；右侧输出抓取方向、接近方向、抓取得分和夹爪开度等结果。由此可见，本文工作的重点不在于修改网络结构，




图 3-3 Contact-GraspNet 抓取生成流程示意图（在保持原网络结构不变的前提下，将输入组织为面向电连接器抓取任务的局部点云与约束信息）

而在于通过输入组织与任务约束设计，使 Contact-GraspNet 更适用于航空非结构化环境下带柔性线缆电连接器的抓取生成。




图 3-4 PointNet++ 骨干与候选接触点生成示意图（Set Abstraction 层级、Ball Query 邻域、MLP 特征聚合及第一次降采样点作为候选接触点）

如图 3-4 所示，骨干部分仍采用 PointNet++ 的多级 Set Abstraction 结构，每一级均由邻域查询、局部特征聚合和下采样组成。设第一层下采样后得到的候选接触点集合为

$$C = \{\mathbf{c}_k\}_{k=1}^M = \text{SA}_1(\tilde{\mathcal{P}}), \quad (3-9)$$

其中， $\text{SA}_1(\cdot)$ 表示第一层 Set Abstraction 操作， M 为候选接触点数。式 (3-9) 表明，3.2.1 节中的接触点 $\mathbf{c}$ 在网络中并非额外人工指定，而是由第一层下采样点直接承担几何锚点角色。随后，骨干网络为每个候选点提取局部特征 $\mathbf{f}_k$ ，再送入预测头完成抓取参数回归。

四分支预测头与位姿恢复。对每个候选点特征 $\mathbf{f}_k$ ，四分支预测头输出

$$(\mathbf{v}'_k, \mathbf{u}'_k, \hat{s}_k, \hat{\omega}_k) = \Psi_\theta(\mathbf{f}_k), \quad (3-10)$$

其中, $\Psi_{\theta}(\cdot)$ 表示四分支预测头, $\mathbf{v}'_k$ 与 $\mathbf{u}'_k$ 分别为第 k 个候选点对应的原始方向输出, $\hat{s}_k$ 为抓取置信度, $\hat{\omega}_k$ 为夹爪开度预测值。方向分支输出经标准化与正交化后得到单位向量 $\hat{\mathbf{x}}_k$ 、 $\hat{\mathbf{z}}_k$:

$$\hat{\mathbf{x}}_k = \frac{\mathbf{v}'_k}{\|\mathbf{v}'_k\|_2}, \quad \hat{\mathbf{z}}_k = \frac{\mathbf{u}'_k - \langle \hat{\mathbf{x}}_k, \mathbf{u}'_k \rangle \hat{\mathbf{x}}_k}{\|\mathbf{u}'_k - \langle \hat{\mathbf{x}}_k, \mathbf{u}'_k \rangle \hat{\mathbf{x}}_k\|_2}, \quad (3-11)$$

从而满足 $\|\hat{\mathbf{x}}_k\|_2 = \|\hat{\mathbf{z}}_k\|_2 = 1$ 且 $\hat{\mathbf{x}}_k^T \hat{\mathbf{z}}_k = 0$ 。进一步地, 第 k 个候选抓取位姿可恢复为

$$\hat{\mathbf{R}}_{g,k} = [\hat{\mathbf{x}}_k \quad \hat{\mathbf{x}}_k \times \hat{\mathbf{z}}_k \quad \hat{\mathbf{z}}_k], \quad \hat{\mathbf{t}}_{g,k} = \mathbf{c}_k + \frac{\hat{\omega}_k}{2} \hat{\mathbf{x}}_k - d \hat{\mathbf{z}}_k, \quad (3-12)$$

其中, d 为由夹爪几何尺寸预先确定的固定偏置参数, 并不作为网络学习输出。由式 (3-12) 可知, 本文在结构层面的关键改进之一, 是明确建立了“候选接触点 $\mathbf{c}_k$ - 四分支输出 - 抓取位姿恢复”之间的解析映射, 使 3.2.1 节的参数化定义与网络前向过程严格对应。

需要强调的是, 上述改进并未增加新的卷积层、注意力模块或额外预测分支, 也未改变 PointNet++ 骨干及四分支预测头的参数维度。因此, 模型仍可继承原始 Contact-GraspNet 的预训练参数。记网络参数为 θ , 预训练初始化为 θ_{pre} , 则实际训练采用

$$\theta^{(0)} = \theta_{\text{pre}}, \quad \theta^{(t+1)} = \theta^{(t)} - \eta \nabla_{\theta} L_{\text{grasp}}, \quad (3-13)$$

其中, η 为较小学习率, L_{grasp} 为 3.2.4 节定义的联合损失。式 (3-13) 表明本文采用的是基于预训练模型的任务微调策略, 而非从随机初始化开始的大规模重新训练。这一点对于抓取数据获取成本较高的航空制造场景尤为重要。




图 3-5
(空白占位图)

图 3-5 抓取候选分布对比示意图 (左: 整场景输入时候选分散于背景与线缆; 右: 目标局部点云与线缆先验下候选集中于连接器壳体稳定夹持区)

如图 3-5 所示, 整场景输入时候选分散于背景与线缆根部; 采用 3.2.2 节局

部点云与线缆先验后，候选集中于壳体两侧与上表面，插针端与线缆侧高分候选减少，更符合稳定夹持与装配导向，便于 3.3、3.4 节筛选与规划。

3.2.4 正负样本判定与损失函数设计

在改进的 Contact-GraspNet 中，3.2.1 节的抓取参数化 $(\mathbf{c}, \mathbf{x}, \mathbf{z}, \omega, d)$ 与 3.2.2、3.2.3 节构建的目标局部点云与候选接触点集合，为训练阶段的样本标注与损失设计提供了清晰的几何基础。本节围绕“哪些点被视为有效抓取区域”“网络应重点学习哪些物理量”“如何通过损失函数体现电连接器任务的工程偏好”三个问题，对正负样本判定规则、各分支损失形式及训练过程收敛特性进行系统说明。

(1) 基于接触邻域的正负样本判定。设视角下局部点云为 $\mathcal{P} = \{\mathbf{p}_i\}$ ，由仿真或真实标注得到的抓取接触点集合为 $\mathcal{C} = \{\mathbf{c}_k\}$ ，则以接触点邻域为判据构造二元标签：

$$y_i = \begin{cases} 1, & \min_k \|\mathbf{p}_i - \mathbf{c}_k\|_2 < r, \\ 0, & \text{otherwise,} \end{cases} \quad (3-14)$$

其中 r 为接触邻域半径。 $y_i = 1$ 表示该点附近存在稳定夹持接触关系，可作为正样本； $y_i = 0$ 表示不属于有效抓取区域，作为负样本。对于正样本点，将其关联到最近接触点对应的抓取参数 $(\mathbf{c}, \mathbf{x}, \mathbf{z}, \omega)$ ，用于后续姿态与宽度监督。结合 3.2.2 节的线缆禁入权重 w_i ，在实际训练中还可对靠近线缆根部和插针端的点下调其参与损失的权重，使正负样本分布在壳体两侧与上表面更加均衡。

(2) 抓取分数与宽度损失。抓取分数分支输出每个候选接触点处的抓取置信度 $\hat{s}_i \in [0, 1]$ ，理想情况应与标签 y_i 一致。采用带权重的二元交叉熵损失：

$$L_{\text{score}} = -\frac{1}{N} \sum_{i=1}^N (\alpha y_i \log \hat{s}_i + \beta (1 - y_i) \log (1 - \hat{s}_i)), \quad (3-15)$$

其中 $\alpha > \beta$ 用于缓解正负样本比例失衡问题，在电连接器表面正样本（稳定夹持区域）远少于负样本（壳体以外、线缆与舱壁区域）时，保证网络不会过度偏向输出“不可抓”。夹爪宽度分支输出预测开度 $\hat{\omega}_i$ ，其监督量为标注宽度 ω_i ，采用 L_1 损失：

$$L_{\text{width}} = \frac{1}{N_+} \sum_{i: y_i=1} |\hat{\omega}_i - \omega_i|, \quad (3-16)$$

仅对正样本点计算，以避免在无接触关系区域强行回归宽度。对于电连接器壳体来说， ω_i 还隐含“既能夹紧壳体、又不挤压线缆”的约束，训练中通过选取覆盖面向装配的多种工况的标注宽度，提升网络在不同壳体尺寸与线缆布置下的适应性。

(3) 位姿损失与任务约束编码。基于 3.2.1 节的构造，预测抓取位姿记为 $g_i = (\hat{\mathbf{t}}_{g,i}, \hat{\mathbf{R}}_{g,i})$ ，对应标注位姿为 $g_i^* = (\mathbf{t}_{g,i}^*, \mathbf{R}_{g,i}^*)$ 。位姿损失由位置与方向两部分组成：

$$L_{\text{pose}} = \frac{1}{N_+} \sum_{i:y_i=1} \left(\lambda_t \|\hat{\mathbf{t}}_{g,i} - \mathbf{t}_{g,i}^*\|_2^2 + \lambda_R \phi(\hat{\mathbf{R}}_{g,i}, \mathbf{R}_{g,i}^*) \right), \quad (3-17)$$

其中 λ_t, λ_R 为权重系数， $\phi(\cdot, \cdot)$ 为旋转误差度量，例如

$$\phi(\hat{\mathbf{R}}, \mathbf{R}^*) = \|\log((\mathbf{R}^*)^\top \hat{\mathbf{R}})\|_2^2, \quad (3-18)$$

即李代数空间中的角度偏差平方。在电连接器任务中， $\mathbf{t}_{g,i}^*$ 与 $\mathbf{R}_{g,i}^*$ 来自“壳体稳定夹持、避免插针端和线缆根部”的标注策略，因此 L_{pose} 不仅约束几何误差，还将装配任务对抓取姿态的偏好隐含进损失中。

(4) 联合损失与线缆先验权重。综合上述三部分，抓取生成网络的总损失写为

$$L_{\text{grasp}} = \gamma_1 L_{\text{score}} + \gamma_2 L_{\text{width}} + \gamma_3 L_{\text{pose}}, \quad (3-19)$$

其中 $\gamma_1, \gamma_2, \gamma_3$ 为分支权重系数。训练时可将 3.2.2 节中点级权重 w_i 作为系数乘入对应样本的损失项，实现“靠近线缆与插针端的点对总损失贡献较小、壳体稳定区域点贡献较大”的策略，从而在优化阶段显式体现柔性线缆干扰与功能敏感区约束。

如图 3-6 所示，Contact-GraspNet 的训练曲线采用八子图 TensorBoard 标量面板形式展示，相比第二章图 2-30 保留了“原始标量 + 平滑趋势”的可视化逻辑，但进一步呈现出抓取网络在多分支耦合优化过程中的非平稳波动特征。随着训练迭代次数增加，总损失 L_{grasp} 整体下降并最终收敛，说明由式 (3-19) 定义的联合损失能够驱动网络持续逼近稳定解；同时，由于抓取置信度、开度回归与位姿优化之间存在显著耦合，原始曲线在中前期表现出更明显的局部起伏和阶段性扰动，这与抓取任务中正负样本分布不均、位姿监督非凸以及线缆禁入域约束共同作用的训练特点相一致。其中， L_{score} 下降最快，说明网络较早建立了壳体稳定抓取区域的判别边界； L_{width} 的下降速度较缓，反映不同连接器尺寸与夹持方式带来的回归难度； L_{pose} 对应的 ADD-S 型位姿误差波动最为




图 3-6 Contact-GraspNet 训练过程的 TensorBoard 风格标量面板：(a) 总损失 L_{grasp} ；(b) 抓取置信度分支损失 L_{score} ；(c) 夹爪开度分支损失 L_{width} ；(d) 位姿分支损失 L_{pose} ；(e) 验证集 Top Grasp Accuracy@0.65；(f) 验证集 AUCPR；(g) 验证集偏移量平均绝对误差；(h) 学习率衰减曲线。橙色为训练曲线，蓝色为验证曲线，浅色细线表示原始标量，深色粗线表示指数滑动平均后的趋势。

显著，说明六自由度位姿分支在方向与位移联合优化时更容易受局部几何差异与样本分布变化影响。另一方面，验证集 Top Grasp Accuracy@0.65 与 AUCPR 均持续提升并在后期趋于平台，表明高置信度抓取预测与标注抓取之间的一致性不断增强；偏移量平均绝对误差则整体下降，说明候选抓取接触偏移逐步逼近真实分布；学习率曲线按照指数衰减策略逐步减小，为后期参数细化提供了稳定的优化条件。该训练结果为 3.3 节抓取点筛选提供了更可靠的候选抓取集合，也为后续面向航空非结构化环境与柔性线缆干扰条件下的自主装配系统集成奠定了抓取感知基础。




图 3-7
(空白占位图)

图 3-7 电连接器表面候选抓取位姿分布可视化结果（绿色：壳体稳定夹持区；黄色：插针端功能区；红色：线缆根部及禁入域；颜色越深表示抓取置信度越高）

如图 3-7 所示，高置信度候选抓取主要集中于连接器壳体两侧和上表面的稳定夹持区域，而在插针端和线缆根部附近则明显受到抑制。这一分布特征与第二章中电连接器功能区域划分保持一致，说明基于式 (3-14)-式 (3-19) 设计的

正负样本与损失函数，已经将“稳定夹持、避免遮挡插针端、减小线缆干扰”的任务约束有效注入到抓取生成阶段，而非仅依赖 3.3、3.4 节的后续筛选与规划进行修正。

3.3 抓取点选择策略研究

端到端抓取生成网络通常会输出多组候选抓取，但这些候选在局部接触稳定性、机械臂可达性、线缆安全性和任务相容性方面并不完全一致。若仅根据网络分数直接选择得分最高的抓取，容易出现局部几何上可抓但夹持不稳、机械臂难以接近、与线缆发生干涉或不利于后续插接操作等问题。本文在候选抓取集合 $\mathcal{G}$ 的基础上，首先结合电连接器外形特征设计专用指尖结构并分析其力封闭能力，在此基础上进一步设计多约束抓取点选择策略，通过逐级筛选和综合评分确定最终执行抓取位姿。

3.3.1 专用指尖结构设计 with 力封闭性评估

第二章和 3.2 节完成了目标定位、位姿估计与候选抓取生成，但候选抓取能否稳定执行，还取决于夹爪末端与连接器壳体之间的实际接触方式。本文研究对象为带柔性线缆的圆柱形电连接器，其外轮廓由圆柱主体与四个矩形平面共同构成。若直接采用标准平行二指夹爪的平直指面进行夹持，则接触区域易退化为局部线接触或点接触，接触面积较小，且夹持过程中容易绕连接器轴线发生转动。为此，本文在二指夹爪末端附加左右对称的专用指尖接触块，其内侧工作面由导向斜面、包络支撑面与限位过渡面构成，在不改变夹爪原有开合同步机构的前提下，提高对连接器的包络支撑能力与姿态定向能力。

如图 3-8 所示，本文设计的专用指尖一方面通过内凹包络面与导向斜面提高对连接器圆柱壳体和局部平面的贴合程度，另一方面保持与 Franka Hand 原有同步开合机构兼容。图中上排给出了指尖实物与 CAD 结构，下排给出了 Franka Hand 安装该指尖后的侧视与正视状态。结合第五章平台参数，Franka Hand 的最大夹持力可达 70 N；在左右对称夹持条件下，专用指尖能够将法向夹紧力更稳定地传递到连接器壳体包络接触区，从而形成足够的正压力储备。若将两侧接触对连接器轴线的抗绕转能力近似表示为摩擦力矩，则可写为

$$M_{z,\max} \approx 2\mu F_n r_{\text{eff}}, \quad (3-20)$$

其中， μ 为接触摩擦系数， F_n 为单侧有效法向夹紧力， r_{eff} 为接触区相对连接器轴线的等效力臂。由此可见，在 Franka Hand 夹持力上限和专用指尖较大包络接




图 3-8 Franka 夹爪专用指尖结构与装配实物图（上：指尖实物与 CAD 结构；下：Franka Hand 安装专用指尖后的末端实物状态）

触半径的共同作用下，末端不仅能够提供满足连接器抓取与提离所需的稳定夹持力，还能够产生足够的抗绕轴旋转力矩，以抑制夹持过程中的轴向窜动和绕壳体轴线的自转，从而满足后续转运与预装配阶段对姿态稳定性的操作要求。为进一步分析其稳定夹持机理，本文从力封闭视角对接触状态进行评估。设连接器刚体参考点为 $\mathbf{o}$ ，左右两侧指尖与连接器的接触区域分别记为 C_1 与 C_2 。由于专用指尖与连接器之间形成有限面积接触，本文将每个接触区域离散为若干微接触点 $\mathbf{p}_{ij}$ ，其中 $i \in \{1, 2\}$ 表示左右指尖， $j = 1, \dots, m_i$ 表示第 i 个接触区域内的离散接触点编号。设 $\mathbf{n}_{ij}$ 为 $\mathbf{p}_{ij}$ 处的单位外法向量， μ 为接触摩擦系数，则该微接触点所允许的接触力满足库仑摩擦锥约束

$$\mathcal{F}_{ij} = \left\{ \mathbf{f}_{ij} \in \mathbb{R}^3 \mid \mathbf{f}_{ij}^\top \mathbf{n}_{ij} \geq 0, \left\| \mathbf{f}_{ij} - \left(\mathbf{f}_{ij}^\top \mathbf{n}_{ij} \right) \mathbf{n}_{ij} \right\|_2 \leq \mu \left(\mathbf{f}_{ij}^\top \mathbf{n}_{ij} \right) \right\}. \quad (3-21)$$

若以参考点 $\mathbf{o}$ 计算该接触力对应的扳手（wrench），则有

$$\mathbf{w}_{ij} = \begin{bmatrix} \mathbf{f}_{ij} \\ (\mathbf{p}_{ij} - \mathbf{o}) \times \mathbf{f}_{ij} \end{bmatrix} \in \mathbb{R}^6. \quad (3-22)$$

当所有微接触点生成的扳手集合能够在六维扳手空间中包围原点时，说明夹持系统可通过内部接触力平衡任意方向的小扰动，即具备力封闭能力。其判据可写为

$$\mathbf{0} \in \text{int conv} \left(\bigcup_{i=1}^2 \bigcup_{j=1}^{m_i} \mathcal{W}_{ij} \right), \quad (3-23)$$

其中, $\mathcal{W}_{ij}$ 为式 (3-22) 对应的可行扳手集合。考虑到工程实现中直接构造完整抓取扳手空间的计算代价较高, 本文进一步采用接触法向一致性与接触覆盖程度对力封闭趋势进行近似评估。设第 k 个离散接触点处的法向量为 $\mathbf{N}_k$, 夹爪在该处施加的局部接触合力方向为 $\mathbf{F}_k$, 接触法向偏角记为 α_k , 则有

$$\cos \alpha_k = \frac{|\mathbf{F}_k^T \mathbf{N}_k|}{\|\mathbf{F}_k\|_2 \|\mathbf{N}_k\|_2}. \quad (3-24)$$

在此基础上, 定义接触法向一致性评价量

$$Q_n = \frac{1}{n} \sum_{k=1}^n \cos \alpha_k, \quad (3-25)$$

其中, n 为参与统计的有效离散接触点总数。 Q_n 越接近 1, 说明夹持力方向与局部法向越一致, 法向压紧成分越充分, 切向滑移风险越小。另一方面, 设两侧有效接触面积分别为 A_1 与 A_2 , 参考面积为 A_{ref} , 则接触覆盖指标定义为

$$Q_a = \frac{A_1 + A_2}{A_{\text{ref}}}. \quad (3-26)$$

由此可构造专用指尖对连接器夹持稳定性的综合评价量

$$Q_{\text{tip}} = \lambda_n Q_n + \lambda_a \min(1, Q_a), \quad \lambda_n + \lambda_a = 1, \quad (3-27)$$

其中, λ_n 与 λ_a 分别表示法向一致性和接触覆盖程度的权重系数。




图 3-9 专用指尖与普通平行指面夹持电连接器时的接触法向与接触面积对比示意图 (左: 普通平指局部接触面积较小、法向分布离散; 右: 专用指尖形成更大包络接触面积且法向分布更集中)

如图 3-9 所示, 普通平行二指夹爪直接夹持该类连接器时, 接触通常集中

在局部边缘区域；相比之下，专用指尖能够形成更大的包络接触面积，并减小接触法向与夹紧力方向之间的偏角，因此式 (3-25) 和式 (3-26) 对应的评价量均得到提升。较大的 Q_{tip} 表明专用指尖在抗扰动能力、抗轴向转动能力以及保持姿态一致性方面优于原始平行二指夹爪，也为后续可达性、线缆安全性和姿态相容性筛选提供了更稳定的末端接触基础。

3.3.2 基于逆运动学的可达性判别

端到端抓取生成网络输出的候选抓取位姿 $g_i = (\mathbf{t}_{g,i}, \mathbf{R}_{g,i})$ 仅从局部几何和任务约束角度保证“可夹持、远离线缆与插针端”，但并不保证机械臂在给定关节限位与工作空间内一定能够安全到达。因此，在抓取点选择的第一步，需要从机器人运动学角度对每个 g_i 进行可达性判别，将“几何上可行”进一步约束为“关节空间中可执行”。这一判别不仅影响后续 GRRT-Connect 规划的搜索空间规模，也是保证航空机舱狭窄环境下动作链条可实施性的关键。

(1) 基于逆解存在性的可达性定义。记机械臂关节角为 $\mathbf{q} = [q_1, \dots, q_n]^T$ ，正运动学映射为

$$f: \mathbb{R}^n \rightarrow SE(3), \quad g = f(\mathbf{q}), \quad (3-28)$$

其逆问题为：给定位姿 g_i ，求解满足

$$f(\mathbf{q}_i) = g_i, \quad \mathbf{q}_{\min} \leq \mathbf{q}_i \leq \mathbf{q}_{\max}, \quad (3-29)$$

的关节角 $\mathbf{q}_i$ ，其中 $\mathbf{q}_{\min}, \mathbf{q}_{\max}$ 为关节限位向量。可达性判别函数可形式化为

$$C_{\text{IK}}(g_i) = \begin{cases} 1, & \exists \mathbf{q}_i \text{ 使得 (3-29) 成立, 且满足速度/姿态等约束,} \\ 0, & \text{否则,} \end{cases} \quad (3-30)$$

仅当 $C_{\text{IK}}(g_i) = 1$ 时，候选抓取才进入后续线缆安全与任务姿态相容性评价。与仅在点云层面判定“是否存在稳定接触”的网络输出相比，式 (3-30) 进一步刻画了“机械臂是否有合法关节解”，能在规划前剔除大量在几何上可抓但实际不可执行的方案。

(2) 关节限位与裕量评价。在满足 (3-29) 的所有逆解集合 $\mathbf{Q}_i = \{\mathbf{q}_i^{(m)}\}$ 中，优选远离关节限位的解有助于提高后续规划的成功率。定义关节裕量代价为

$$J_{\text{lim}}(\mathbf{q}_i^{(m)}) = \sum_{j=1}^n \left(\frac{q_j^{(m)} - \bar{q}_j}{q_{j,\max} - q_{j,\min}} \right)^2, \quad (3-31)$$

其中 $\bar{q}_j = (q_{j,\max} + q_{j,\min})/2$ 为第 j 个关节的中值。若 $Q_i \neq \emptyset$ ，则可选择

$$\mathbf{q}_i^* = \arg \min_{\mathbf{q}_i^{(m)} \in Q_i} J_{\lim}(\mathbf{q}_i^{(m)}), \quad (3-32)$$

并将 $J_{\lim}(\mathbf{q}_i^*)$ 作为可达性“质量”的辅助指标：值越小，说明当前抓取姿态在关节空间中越居中，留给 GRRT-Connect 扩展和局部避障的冗余越充足，越适用于机舱窄通道环境下的多阶段运动规划。

(3) 奇异性与工作空间边界判别。除关节限位外，奇异构型与工作空间边界也是影响可达性的关键因素。设雅可比矩阵为 $\mathbf{J}(\mathbf{q})$ ，则典型的可操作度指标为

$$w(\mathbf{q}) = \sqrt{\det(\mathbf{J}(\mathbf{q})\mathbf{J}^T(\mathbf{q}))}, \quad (3-33)$$

当 $w(\mathbf{q}) \rightarrow 0$ 时，机械臂接近奇异点，末端在某些方向上的运动能力显著下降，路径规划中的微小扰动可能导致关节大幅摆动。结合式 (3-32)，本文在数值求解逆运动学后，对 $\mathbf{q}_i^*$ 计算 $w(\mathbf{q}_i^*)$ ，若其低于给定阈值 $w_{\min}$ ，则认为该抓取虽有逆解但执行风险较高，可在后续综合评分中降低其权重或直接剔除。

综合上述因素，可将逆运动学可达性扩展为“硬约束+软评价”的形式：硬约束由式 (3-30) 给出（有合法逆解且满足关节限位），软评价通过 $J_{\lim}(\mathbf{q}_i^*)$ 与 $w(\mathbf{q}_i^*)$ 量化抓取在关节空间中的可用裕度。这样定义的可达性既保证了电连接器抓取在航空机舱受限空间内具备可执行性，又为 3.3.5 节综合评分函数提供了可与线缆安全和姿态相容性同等量化的评价量。



图 3-10
(空白占位图)

图 3-10 基于逆运动学的可达性判别结果示意图（灰色：不可达候选；蓝色：可达但关节裕量较小或接近奇异的候选；绿色：可达且关节裕量充足的候选）

如图 3-10 所示，电连接器表面初始候选抓取分布经式 (3-30) 判别和 (3-31)、(3-33) 指标过滤后，可达且关节裕量充足的候选（绿色）主要分布在机械臂工作空间内的“舒适区域”，而靠近机舱边界或背离主要操作侧的候选则因逆解

缺失或接近奇异而被标记为灰色或蓝色。可达性判别使后续线缆安全与任务姿态相容性评价建立在“关节空间可执行”的候选集合上，避免在 GRRT-Connect 规划阶段反复尝试物理上难以实现的抓取姿态，从而减少在狭窄机舱环境中的无效搜索，提高整体规划效率与执行可靠性。

3.3.3 面向线缆障碍的安全间隙评价

为避免夹爪在接近、闭合和提离过程中与线缆发生高风险接触，本文对候选抓取引入线缆安全间隙评价。设线缆点云集合为 $\mathcal{P}_{\text{cable}}$ ，夹爪在候选抓取 g_i 下的占用体积为 $\mathcal{V}_{\text{gripper}}(g_i)$ ，则夹爪与线缆之间的最小距离可定义为

$$d_i = \min_{p \in \mathcal{V}_{\text{gripper}}(g_i), q \in \mathcal{P}_{\text{cable}}} \|p - q\|_2. \quad (3-34)$$

当 d_i 小于安全阈值 d_{safe} 时，说明夹爪在接近、闭合或提离过程中有较大概率与线缆发生接触，此时该候选抓取将被视为高风险方案并予以剔除。与传统仅针对刚性障碍进行碰撞检查的方法不同，这里评估的对象是与目标零件直接耦合的柔性拖缆，因此该指标直接反映了抓取动作的工程安全性，而非抽象意义上的空间无碰撞性。

为了便于综合评分，本文进一步将线缆安全间隙归一化为安全性得分

$$S_{\text{clearance}}(g_i) = \min\left(1, \frac{d_i}{d_{\text{ref}}}\right), \quad (3-35)$$

其中 d_{ref} 为设定的参考安全距离。当 d_i 较大时，说明夹爪与线缆之间具有更充分的安全裕度；当 d_i 较小时，则意味着该抓取在执行过程中更容易与柔性障碍发生干涉。实际计算中， $\mathcal{V}_{\text{gripper}}(g_i)$ 由夹爪几何模型在接近—闭合—提离三个动作阶段的扫掠体积离散得到， $\mathcal{P}_{\text{cable}}$ 则来源于由 Cable Mask 反投影并体素化后的三维线缆表示。为降低最小距离计算的复杂度，可在体素网格上预先构建线缆距离场 $\phi_{\text{cable}}(\cdot)$ ，用

$$d_i \approx \min_{p \in \mathcal{V}_{\text{gripper}}(g_i)} \phi_{\text{cable}}(p) \quad (3-36)$$

近似代替对 $\mathcal{P}_{\text{cable}}$ 的逐点最小化，从而在保持评价精度的同时提升对大量候选抓取进行批量判别时的计算效率。

如图 3-11 所示，当候选抓取的接近方向和夹爪扫掠体积压缩了与柔性线缆之间的最小安全间隙时，即使局部接触位置具备一定夹持可行性，抓取过程仍可能因线缆干涉风险而被判定为不可接受。图中不同视角下的结果表明，线缆在连接器尾部邻域形成了显著的高风险约束区，夹爪若沿该区域直接接近，将




图 3-11 线缆障碍安全间隙导致的抓取不可达效果图

在接近、闭合或脱离阶段与线缆产生过小间距甚至潜在碰撞。基于此，本文将 Cable Mask 提取的线缆信息前置为抓取决策阶段可利用的几何约束，而非仅在路径规划阶段被动避障，从而使保留下来的候选抓取在空间上天然远离高风险线缆区域，降低夹爪缠绕与拖拽风险，并提高后续动作链的稳定性。

3.3.4 面向任务的姿态相容性评价

在带柔性线缆的电连接器自主装配任务中，抓取位姿不仅需要满足局部夹持稳定性，还应与后续转运和预装配阶段的作业方向保持一致。若抓取接近方向与装配轴线偏差过大，则末端在抓取完成后需要额外进行较大幅度的姿态调整，进而增加狭窄机舱环境中的运动冗余和碰撞风险。基于此，本文引入姿态相容性评价，对候选抓取的接近方向与目标操作轴线之间的一致性进行量化描述。设目标操作轴方向为 $\mathbf{v}_{asm}$ ，抓取接近方向为 $\mathbf{v}_{grasp}$ ，则姿态相容性得分定义为

$$S_{align}(g_i) = \frac{\mathbf{v}_{grasp} \cdot \mathbf{v}_{asm}}{\|\mathbf{v}_{grasp}\|_2 \|\mathbf{v}_{asm}\|_2}. \quad (3-37)$$

式中， $S_{align}(g_i) \in [-1, 1]$ ，其值越大表示候选抓取的接近方向与目标装配轴线越接近同向分布。当 $S_{align}(g_i)$ 较高时，说明该抓取位姿在完成夹持后能够以较小的姿态修正进入预装配状态，从而有利于降低转运阶段的轨迹调整幅度，并减小末端与舱壁、支架及柔性线缆发生附加干涉的概率。因此，姿态相容性评价实质上“面向装配的任务约束”显式引入抓取筛选过程，使候选抓取的优选标准由单纯的局部可夹持性扩展为“局部稳定性与后续任务适应性兼顾”。

从实现上看， $\mathbf{v}_{asm}$ 由连接器插接方向或壳体预定义参考轴确定， $\mathbf{v}_{grasp}$ 则直接取自 3.2.1 节定义并由 3.2.3 节网络预测的抓取接近方向 $\mathbf{z}$ 。因此，式中的内积本质上对应于抓取接近轴与装配轴之间夹角余弦的归一化表示。该指标一方面保持了计算形式简洁，便于对大量候选抓取进行快速评价；另一方面能够与前

述可达性和线缆安全性指标共同纳入统一评分框架，为 3.3.5 节的综合排序提供任务导向的定量依据。此外，较高的 $S_{\text{align}}(g_i)$ 还意味着抓取姿态与第四章柔顺装配初始位姿之间具有更好的连续性，有利于减小后续对准阶段的姿态调整负担。




图 3-12 电连接器表面候选抓取任务姿态相容性结果

如图 3-12 所示，本文方法生成的候选抓取与装配轴夹角主要集中在较小区间，分布峰值约位于 $10^\circ \sim 18^\circ$ ；相比之下，基线方法的候选夹角更多分布在 $30^\circ \sim 45^\circ$ 区间。图中的红色虚线给出了 $\theta_{\max} = 25^\circ$ 的任务阈值，可以看出本文方法的大多数候选位于阈值左侧，而基线方法则有相当比例落在阈值右侧。这表明，本文在候选筛选阶段引入姿态相容性约束后，保留下来的抓取更接近后续装配方向，能够显著减小转运后进入预装配阶段所需的姿态重定向幅度。

该结果从统计分布层面验证了本节理论分析：接近方向与装配轴线夹角较小的候选，对应更高的 S_{align} 得分，也更有利于保持抓取姿态与装配初始位姿之间的连续性；而夹角较大的候选即使局部夹持条件较好，仍会在狭窄机舱环境中引入更大的姿态调整代价与附加碰撞风险。因此，姿态相容性评价能够有效区分“便于后续装配衔接”的候选抓取与“仅局部可抓但任务连续性较差”的候选抓取，从而为后续综合评分提供必要的任务层约束。

3.3.5 综合评分函数与最优抓取确定

经过 3.3.2–3.3.4 节的分析后，每个候选抓取均可获得与执行相关的多维评价信息，包括逆运动学可达性、线缆安全裕度以及姿态相容性。由于上述指标

分别对应运动学可执行性、抓取过程安全性和后续装配衔接性，三者之间不存在简单的替代关系，因此有必要在统一决策框架下对候选抓取进行综合排序。为此，本文将抓取点选择过程表述为受约束的多指标优化问题。

首先，将满足硬约束的候选抓取定义为可行集合

$$\mathcal{G}_{\text{feas}} = \{g_i \in \mathcal{G} \mid C_{\text{IK}}(g_i) = 1, d_i \geq d_{\text{safe}}\}, \quad (3-38)$$

其中， $\mathcal{G}$ 为抓取生成网络输出的原始候选集合， $C_{\text{IK}}(g_i)$ 为式 (3-30) 给出的可达性判别结果， d_i 为式 (3-26) 定义的线缆安全间隙， d_{safe} 为安全阈值。式 (3-38) 的作用在于先剔除运动学不可达或存在显著线缆干涉风险的候选，从而保证后续评分过程建立在“可执行且安全”的候选基础上。

对可行集合中的任意候选抓取 $g_i \in \mathcal{G}_{\text{feas}}$ ，定义综合评分函数为

$$S_{\text{total}}(g_i) = w_1 S_{\text{quality}}(g_i) + w_2 S_{\text{clearance}}(g_i) + w_3 S_{\text{align}}(g_i), \quad (3-39)$$

其中， $S_{\text{quality}}(g_i)$ 为抓取生成网络输出的候选置信度，反映局部接触几何与夹持可行性； $S_{\text{clearance}}(g_i)$ 为 3.3.3 节定义的线缆安全性得分，用于表征抓取过程中与柔性线缆之间的安全裕度； $S_{\text{align}}(g_i)$ 为 3.3.4 节定义的姿态相容性得分，用于描述抓取接近方向与装配轴线之间的一致性。 w_1 、 w_2 、 w_3 为满足 $w_1 + w_2 + w_3 = 1$ 的非负权重系数。基于该评分函数，最终执行抓取位姿可写为

$$g^* = \arg \max_{g_i \in \mathcal{G}_{\text{feas}}} S_{\text{total}}(g_i). \quad (3-40)$$

式 (3-40) 表明，最优抓取确定并非单纯选择网络分数最高的候选，而是在满足可达性与安全约束的前提下，对“局部抓取质量-线缆安全性-任务相容性”三项指标进行联合优化。




图 3-13 基于多约束优化的最优抓取点筛选流程图（候选抓取经逆运动学筛选后形成可行子集，并结合线缆安全间隙、姿态相容性与综合评分输出最优抓取位姿）

如图 3-13 所示，候选抓取的筛选流程遵循“先硬约束过滤、后多指标排序”

的层级化策略。首先，对抓取生成网络输出的原始候选集合 $\mathcal{G}$ 进行逆运动学可达性分析，剔除无合法关节解的候选；随后在可达候选基础上构建可行子集 $\mathcal{G}'$ ，并进一步计算线缆安全间隙评价 $S_{\text{clearance}}$ 与姿态相容性评价 S_{align} 。在此基础上，利用综合评分 S_{total} 对候选进行统一排序，最终输出最优抓取位姿 g^* 。该流程将前述分散的评价指标统一映射为明确的决策链路，使本节提出的理论判据能够直接对应实际抓取输出，并为 3.4 节运动规划提供稳定、可执行且面向后续装配任务的初始抓取状态。

在权重设置上，本文遵循“执行可靠性优先、任务连续性兼顾”的原则。通常取 w_1 与 w_2 略大于 w_3 ，使局部夹持稳定性与线缆安全裕度在综合评分中占据主导地位，以避免在航空非结构化环境中因过分强调姿态相容性而保留局部不稳定或存在干涉风险的候选；同时保留适当的 w_3 ，用于区分多个均可安全执行的候选中哪一类更有利于后续预装配和柔顺插接。该权重设置使综合评分函数既能反映抓取动作本身的可实施性，又能体现装配任务对初始抓取姿态的前馈约束。

3.4 GRRT-Connect 运动规划算法研究

候选抓取经多约束筛选后，仍需在狭窄机舱环境中规划从当前构型到预抓取、抓取、抬升及预装配等关键位姿的连续轨迹。机舱内同时存在刚性舱壁、设备支架和柔性线缆障碍，且目标电连接器与线缆直接耦合，若规划不当，抓取后抬升和转运阶段仍可能引发线缆缠绕和插针端意外碰撞。本节在 RRT-Connect 算法基础上，首先构建统一描述刚性结构与线缆障碍的混合障碍物地图，然后设计融合目标偏置与障碍引导的 GRRT-Connect 采样与扩展策略，最后通过路径生成与后处理优化得到满足机舱安全约束的平滑轨迹，实现对第三章前两节输出抓取姿态的安全执行。

3.4.1 混合障碍物地图构建

GRRT-Connect 要在机舱受限空间内同时规避刚性结构件和柔性线缆障碍，首先需要在统一的数据结构中表达两类障碍物的空间分布。本文构建混合障碍物地图 $\mathcal{M}_{\text{hyb}}$ ，并在构建与使用上采用“刚性静态、线缆动态”的更新策略：在初始感知阶段，除线缆以外的舱壁、支架和工装等均建模为刚性障碍并写入地图，在后续运动过程中不再更新；规划与运动开始后，仅将当前观测到的、由 CableMask 检测得到的线缆目标所对应的点云作为动态障碍物，按观测帧对线缆体素进行更新，其余地图内容保持不变。这样既保证了刚性环境约束的稳定

可用，又使线缆占据随最新观测反映柔性拖缆的实际分布。

(1) **刚性障碍建模**。对舱壁、设备边界和工装结构，采用包围盒（AABB 或 OBB）形式在世界坐标系下进行几何描述，并在初始建图时一次性写入 $\mathcal{M}_{\text{hyb}}$ ，运动过程中不再修改。记刚性障碍集合为 $\mathcal{O}_{\text{rigid}} = \{\mathcal{B}_k\}$ ，其中 $\mathcal{B}_k$ 为第 k 个障碍的包围盒。当给定机械臂某一关节构型 q 时，可通过正运动学计算出各连杆与末端在基座系下的几何模型 $\mathcal{L}(q)$ ，刚性碰撞检测可形式化为

$$C_{\text{rigid}}(q) = \begin{cases} 1, & \mathcal{L}(q) \cap \bigcup_k \mathcal{B}_k = \emptyset, \\ 0, & \text{otherwise.} \end{cases} \quad (3-41)$$




图 3-14 混合障碍物地图构建结果图（刚性障碍与柔性线缆障碍）

这一部分建模对应图 3-14 中由规则长方体或多面体表示的舱壁和设备结构，主要用于约束机械臂在机舱内的整体工作空间。

(2) **线缆障碍三维化与体素编码**。CableMask 为相机像面上的二维掩膜，记其像素集合为 $\mathcal{I}_{\text{cable}} = \{(u_j, v_j, z_j)\}$ ，其中 z_j 为对应深度值。利用反投影公式

$$\mathbf{P}_j^c = z_j \mathbf{K}^{-1} \begin{bmatrix} u_j \\ v_j \\ 1 \end{bmatrix}, \quad (3-42)$$

如图 3-15 所示，在包含柔性线缆干扰的真实机舱场景中，CableMask 输出像素级线缆掩膜并完成区域分割，仅保留掩膜区域与对应深度 z_j 参与反投影，从而将线缆的连续形态离散为相机坐标系下的点云 $\mathcal{P}_{\text{cable}}^c$ 。在手眼标定约束下，点云经坐标变换映射到地图系 $\{\mathcal{W}\}$ ，得到规划空间中的线缆几何表示。随后，规




图 3-15 线缆障碍三维化处理效果图（真实场景与反投影点云、动态体素占据）

划/运动阶段仅使用当前观测帧中检测到的线缆目标对应点云对 Octomap 体素进行更新；除线缆外的舱壁、支架与工装等刚性障碍保持静态不参与更新。该处理机制使线缆占据结果随最新观测自适应更新，同时避免非线缆结构引入占据误差，从而增强 GRRT-Connect 碰撞约束的一致性与可执行性。得到的线缆点云 $\mathcal{P}_{\text{cable}}^W$ 作为动态障碍物输入并进入后续体素占据概率更新。线缆占据空间采用八叉树体素地图（Octomap）编码：将连续空间划分为分辨率为 r_{voxel} 的体素栅格，对每个体素中心 $\mathbf{x}$ 维护占据概率 $p_{\text{occ}}(\mathbf{x})$ ，并根据当前线缆点云更新

$$p_{\text{occ}}(\mathbf{x} | \mathcal{P}_{\text{cable}}^W) = \eta p_{\text{occ}}(\mathbf{x}) + (1 - \eta) \mathbb{I} \left(\min_{\mathbf{p} \in \mathcal{P}_{\text{cable}}^W} \|\mathbf{x} - \mathbf{p}\|_2 < r_{\text{update}} \right), \quad (3-43)$$

其中 $\eta \in (0, 1)$ 为更新系数， $\mathbb{I}(\cdot)$ 为指示函数， r_{update} 为更新半径。占据概率高于阈值的体素被标记为线缆障碍体素集合 $\mathcal{V}_{\text{cable}}$ ，图 3-14 中以颜色块形式展示了这些体素在机舱中的分布。

在体素编码基础上，为进一步刻画线缆障碍的方向敏感特性，本文对线缆点云进行局部分段并构建各向异性椭球包络。各向同性体素仅能提供均匀的安全间隙，无法区分沿线缆轴向的切向运动与垂直于线缆的法向运动在干涉风险上的显著差异；而将每段线缆建模为各向异性椭球，则能够在径向保持严格安全裕度的同时，在轴向给予更宽松的通行许可，使障碍表达更准确地反映柔性线缆的几何特性。

具体而言，将映射到地图系的线缆点云 $\mathcal{P}_{\text{cable}}^W$ 沿其主骨架等间距划分为 M 段局部子集 $\{\mathcal{P}_m\}_{m=1}^M$ ，对第 m 段（含 N_m 个点）执行局部主成分分析，记质心为

$$\bar{\mathbf{p}}_m = \frac{1}{N_m} \sum_{\mathbf{p} \in \mathcal{P}_m} \mathbf{p}, \quad (3-44)$$

协方差矩阵最大特征值对应的单位特征向量为该段局部主方向 $\mathbf{d}_m$ 。以 $(\bar{\mathbf{p}}_m, \mathbf{d}_m)$

为中心和主轴，定义该段线缆的各向异性椭球安全包络：对空间任意点 $\mathbf{x}$ ，其沿线缆局部切向和法向的投影距离分别为

$$d_{\parallel,m}(\mathbf{x}) = |\mathbf{d}_m^\top(\mathbf{x} - \bar{\mathbf{p}}_m)|, \quad d_{\perp,m}(\mathbf{x}) = \|(\mathbf{I} - \mathbf{d}_m \mathbf{d}_m^\top)(\mathbf{x} - \bar{\mathbf{p}}_m)\|_2, \quad (3-45)$$


据此定义各向异性归一化距离为

$$d_{\text{ani},m}(\mathbf{x}) = \sqrt{\left(\frac{d_{\perp,m}(\mathbf{x})}{r_{\perp}}\right)^2 + \left(\frac{d_{\parallel,m}(\mathbf{x})}{r_{\parallel}}\right)^2}, \quad (3-46)$$

其中 $r_{\perp}$ 和 $r_{\parallel}$ ($r_{\perp} < r_{\parallel}$) 分别为法向和切向安全半径。椭球等距面 $d_{\text{ani},m}(\mathbf{x}) = 1$ 即为该段线缆的安全包络边界：法向半径 $r_{\perp}$ 较小，使径向方向避障敏感度更高；切向半径 $r_{\parallel}$ 较大，为沿线缆轴向的末端运动提供更充裕的通行空间。全部线缆段的椭球包络集合记为

$$\mathcal{E}_{\text{cable}}^{(k)} = \{(\bar{\mathbf{p}}_m^{(k)}, \mathbf{d}_m^{(k)}, r_{\perp}, r_{\parallel})\}_{m=1}^{M_k}, \quad (3-47)$$

与体素占据集合 $\mathcal{V}_{\text{cable}}^{(k)}$ 同步，在每个规划周期内由最新线缆观测点云更新，为后续规划中的各向异性安全距离计算提供统一的几何查询接口。



(a) 线缆点云局部分段与椭球包络效果

(b) 动态线缆障碍在场景中的各向异性包络结果

图 3-16 动态线缆障碍的各向异性椭球包络效果图

如图 3-16 所示，局部分段后的线缆点云不再仅以离散体素表示，而是进一步被连续椭球包络集合覆盖。左图给出了线缆局部点云与单段椭球包络的对应关系，可以看出每个椭球均沿该段线缆主方向展开，其长轴与局部切向一致、

短轴沿法向收缩，从而将“沿线缆方向可适当放宽、垂直线缆方向需更严格避障”的约束直接编码到障碍几何模型中。右图进一步展示了该包络模型在真实规划场景中的分布效果：线缆周围形成连续的方向敏感安全区域，使动态障碍不仅具备体素级硬碰撞边界，还具有可用于距离查询的连续安全外包络。该建模结果为 3.4.2 节中构型级各向异性安全距离计算提供了直接输入，也使后续引导式采样与双树扩展能够基于统一的动态线缆障碍表达进行安全判定。

(3) 混合地图与规划接口。最终，混合障碍物地图可表示为

$$\mathcal{M}_{\text{hyb}} = (\mathcal{O}_{\text{rigid}}, \mathcal{V}_{\text{cable}}, \mathcal{E}_{\text{cable}}), \quad (3-48)$$

其中 $\mathcal{O}_{\text{rigid}}$ 为刚性障碍包围盒集合， $\mathcal{V}_{\text{cable}}$ 为线缆占据体素集合， $\mathcal{E}_{\text{cable}}$ 为线缆各向异性椭球包络集合。规划器在进行碰撞与安全检测时，同时执行三项判定：机械臂连杆模型 $\mathcal{L}(q)$ 与刚性包围盒 $\mathcal{B}_k$ 的相交检查、与线缆占据体素 $\mathcal{V}_{\text{cable}}$ 的硬碰撞判定、以及与椭球包络 $\mathcal{E}_{\text{cable}}$ 的各向异性安全距离评价。三者在同一地图结构上完成，使采样引导、安全间隙评价与路径后处理共享一致的障碍物表达。

3.4.2 引导式采样与双树扩展策略

在柔性线缆干扰场景下，传统 RRT-Connect 若仅依据刚性障碍距离进行均匀采样与无偏扩展，容易在连接器拖缆附近产生大量方向不利的无效节点。其根本原因在于：线缆对末端运动的约束具有明显方向性，沿线缆主方向的切向运动通常比垂直于线缆的法向扫掠更容易保持安全间隙；若仍采用各向同性距离度量，则规划器会将这两类运动趋势等价处理，进而降低在狭窄空间中的搜索效率。基于此，本文在保持 GRRT-Connect 双树连接框架不变的前提下，将线缆主方向约束显式引入采样接纳与节点扩展过程，使规划器在满足刚性碰撞约束的同时兼顾柔性线缆的方向敏感避障需求。

(1) 线缆主方向约束与方向安全度量。

为描述线缆方向对规划搜索的影响，设第 k 个规划周期内从当前目标连接器拖缆区域提取的局部线缆点集为 $\mathcal{P}_{\text{cable}}^{\text{dir},(k)}$ 。对该点集采用主成分分析估计线缆主方向，并据此构造方向相容性代价与各向异性安全度量。设连接器尾部线缆根部参考点为 $\mathbf{p}_{\text{root}}^{(k)}$ ，局部方向估计半径为 r_{dir} ，则有

$$\mathcal{P}_{\text{cable}}^{\text{dir},(k)} = \left\{ \mathbf{p} \in \mathcal{P}_{\text{cable}}^{\text{obs},(k)} \mid \|\mathbf{p} - \mathbf{p}_{\text{root}}^{(k)}\|_2 < r_{\text{dir}} \right\}. \quad (3-49)$$

对局部方向点云 $\mathcal{P}_{\text{cable}}^{\text{dir},(k)} = \{\mathbf{p}_i\}_{i=1}^{N_k}$ 采用主成分分析估计线缆主方向。记其质心为

$$\bar{\mathbf{p}}_c^{(k)} = \frac{1}{N_k} \sum_{i=1}^{N_k} \mathbf{p}_i, \quad (3-50)$$

协方差矩阵为

$$\mathbf{C}_c^{(k)} = \frac{1}{N_k} \sum_{i=1}^{N_k} (\mathbf{p}_i - \bar{\mathbf{p}}_c^{(k)}) (\mathbf{p}_i - \bar{\mathbf{p}}_c^{(k)})^\top. \quad (3-51)$$

取最大特征值对应的特征向量为主方向初值，并进行单位化，得

$$\mathbf{d}_c^{(k)} = \frac{\mathbf{e}_{\max}^{(k)}}{\|\mathbf{e}_{\max}^{(k)}\|_2}. \quad (3-52)$$

由于线缆为双向几何体， $\mathbf{d}_c^{(k)}$ 与 $-\mathbf{d}_c^{(k)}$ 在几何上等价。为保证规划周期之间的方向符号连续性，引入上一周期方向参照 $\mathbf{d}_c^{(k-1)}$ ，并执行符号消歧：

$$\mathbf{d}_c^{(k)} \leftarrow \text{sgn}((\mathbf{d}_c^{(k)})^\top \mathbf{d}_c^{(k-1)}) \mathbf{d}_c^{(k)}. \quad (3-53)$$

同时，为抑制遮挡或局部截断造成的主方向抖动，定义方向可靠度权重

$$w_d^{(k)} = \frac{\lambda_1^{(k)}}{\lambda_1^{(k)} + \lambda_2^{(k)} + \lambda_3^{(k)}}, \quad (3-54)$$

其中 $\lambda_1^{(k)} \geq \lambda_2^{(k)} \geq \lambda_3^{(k)}$ 为 $\mathbf{C}_c^{(k)}$ 的特征值。当局部线缆点云呈现明显单主轴结构时， $w_d^{(k)}$ 较大；当观测质量下降时，方向项在规划代价中的作用自动减弱。

在线规划周期内，动态障碍体素集合与各向异性椭球包络采用 $\mathcal{P}_{\text{cable}}^{\text{obs},(k)}$ 按 3.4.1 节所述方法同步更新，而方向敏感采样代价则采用 $\mathcal{P}_{\text{cable}}^{\text{dir},(k)}$ 提供的 $\mathbf{d}_c^{(k)}$ 构造。

末端方向相容性代价。对任意构型 q ，记末端接近方向在地图系中的表达为

$$\mathbf{a}(q) = {}^w\mathbf{R}_E(q) \mathbf{e}_{\text{ins}}, \quad (3-55)$$

则末端方向与线缆主方向之间的相容性代价定义为

$$\phi_{\text{align}}(q) = 1 - |\mathbf{a}(q)^\top \mathbf{d}_c^{(k)}|. \quad (3-56)$$

该项越小，说明末端接近方向越接近当前周期估计得到的线缆主方向，有利于减小对拖缆产生横向拉扯的可能性。 ϕ_{align} 作为采样引导代价的组成部分，在候选构型筛选阶段提供方向偏好，不直接参与硬约束判定。

各向异性安全距离评价。在线缆避障层面，本文利用 3.4.1 节所构建的各向异性椭球包络集合 $\mathcal{E}_{\text{cable}}^{(k)}$ 对任意构型进行方向敏感安全评价。对给定构型 q ，记机械臂各连杆上的采样点集合为 $\mathcal{S}(q)$ ，则构型级各向异性安全距离定义为

$$d_{\text{ani}}^{(k)}(q) = \min_{s \in \mathcal{S}(q)} \min_{m=1}^{M_k} d_{\text{ani},m}^{(k)}(s), \quad (3-57)$$

其中 $d_{\text{ani},m}^{(k)}(\cdot)$ 为式 (3-46) 定义的点到第 m 段线缆椭球的归一化距离。该指标遍历机械臂所有连杆采样点与所有线缆段椭球之间的各向异性距离关系：当 $d_{\text{ani}}^{(k)}(q) \geq 1$ 时，表明构型 q 下机械臂与全部线缆各向异性安全包络均不相交；反之，说明至少存在一段线缆附近未满足法向半径 $r_{\perp}$ 和切向半径 $r_{\parallel}$ 所定义的方向敏感安全间隙。与直接使用目标连接器拖缆的单一主方向不同，此处各向异性距离的计算以障碍线缆的逐段椭球参数为依据，每段椭球拥有独立的质心与局部方向，从而使安全评价能够适应线缆在空间中的弯曲走向变化。

柔性线缆安全判据。综合体素占据硬碰撞判定与各向异性安全距离评价，定义柔性线缆安全判据为

$$C_{\text{cable}}^{(k)}(q) = \begin{cases} 1, & d_{\text{ani}}^{(k)}(q) \geq 1 \wedge \mathcal{S}(q) \cap \mathcal{V}_{\text{cable}}^{(k)} = \emptyset, \\ 0, & \text{otherwise.} \end{cases} \quad (3-58)$$

式 (3-58) 包含两层约束：体素占据条件 $\mathcal{S}(q) \cap \mathcal{V}_{\text{cable}}^{(k)} = \emptyset$ 确保机械臂与线缆点云不发生硬碰撞；各向异性距离条件 $d_{\text{ani}}^{(k)}(q) \geq 1$ 进一步要求机械臂在每段线缆附近保持由椭球包络定义的方向敏感安全裕度。前者由混合障碍物地图中的 $\mathcal{V}_{\text{cable}}^{(k)}$ 提供离散占据判定，后者由 $\mathcal{E}_{\text{cable}}^{(k)}$ 提供连续距离评价，二者在 $\mathcal{M}_{\text{hyb}}$ 上协同完成。

(2) 低频在线重规划与线缆点云更新。

考虑到带缆连接器在抓取后随末端运动会引起线缆形态缓慢变化，本文不采用基于单帧观测的一次性全程规划，而采用低频在线重规划策略。规划层以约 5 Hz 的频率运行，即每隔 $\Delta t \approx 0.2 \text{ s}$ 利用最新观测更新线缆表示，并对剩余局部轨迹进行滚动修正。该设置适用于抓取后抬升、脱离和短距离转运阶段的准静态运动条件，此时相邻规划周期内线缆形态变化有限，低频重规划能够及时反映线缆主方向与占据分布的主要变化趋势。

在线重规划周期内涉及两类功能不同的线缆点云。其一为用于动态障碍建图的线缆障碍点云，记为 $\mathcal{P}_{\text{cable}}^{\text{obs},(k)}$ ，由第二章 CableMask 掩膜反投影并经手眼标定变换到地图系后获得，用于更新动态线缆障碍体素集合 $\mathcal{V}_{\text{cable}}^{(k)}$ ；其二为前述局部方向点云 $\mathcal{P}_{\text{cable}}^{\text{dir},(k)}$ ，由当前目标连接器尾部邻域中的拖缆区域提取获得，用于估计线缆主方向 $\mathbf{d}_c^{(k)}$ 。前者反映规划空间内线缆障碍的整体占据分布，后者表征当前被抓取连接器附近局部拖缆的主导形态，二者分别服务于动态障碍地图更新与方向先验构造。

(3) 引导式采样策略。

在此基础上，本文对 GRRT-Connect 的采样与扩展过程引入方向引导代价

$$J_{\text{dir}}^{(k)}(q) = \alpha d_g(q) + \beta \exp\left(-\frac{d_r(q)}{\sigma_r}\right) + \gamma \exp\left(-\frac{d_{\text{ani}}^{(k)}(q)}{\sigma_c}\right) + \delta w_d^{(k)} \phi_{\text{align}}(q), \quad (3-59)$$

其中 $d_g(q)$ 为当前构型到局部目标构型的距离， $d_r(q)$ 为到刚性障碍的最小距离， σ_r, σ_c 为尺度参数。基于该代价函数定义候选采样的接纳概率

$$P_{\text{acc}}^{(k)}(q) = \exp\left(-\frac{J_{\text{dir}}^{(k)}(q)}{T}\right), \quad (3-60)$$

其中 $T > 0$ 为温度系数，用于控制接纳概率对代价的敏感性。采样阶段首先根据式 (3-60) 对随机候选构型进行接纳筛选，再将通过筛选的构型送入双树扩展过程，从而提高搜索对目标方向与线缆方向相容区域的探索概率。

(4) 双树扩展节点生成与接纳判据。

$$q_{\text{new}} = q_{\text{near}} + \epsilon \frac{q_{\text{rand}} - q_{\text{near}}}{\|q_{\text{rand}} - q_{\text{near}}\|_2}, \quad (3-61)$$

只有当 q_{new} 同时满足关节限位、刚性障碍碰撞约束以及式 (3-58) 给出的柔性线缆判据时，才将其并入树结构并继续尝试双树连接。由此，方向先验不再作为脱离几何约束的独立启发项，而是与动态障碍地图和刚性碰撞检测共同构成统一的在线规划判据。



图 3-16
(空白占位图)

图 3-17 基于双线缆点云输入的低频在线重规划与方向引导扩展示意图（障碍点云更新动态体素地图，局部方向点云估计主方向并参与采样接纳与双树扩展）

如图 3-17 所示，该策略在每个规划周期内依次完成最新观测获取、障碍点云与局部方向点云构造、动态体素地图更新、方向引导采样、双树扩展验证以及局部轨迹前缀输出等步骤。其中，引导式采样负责在候选构型生成阶段提高对目标方向和线缆方向相容区域的探索概率，双树扩展则负责在满足刚性碰撞约束

与柔性线缆安全判据的前提下快速建立起始构型与目标构型之间的连通路程。与基于单帧观测的一次性规划不同，本文在每个周期仅执行当前规划轨迹的前缀段，随后利用下一观测周期重新更新 $\mathcal{V}_{\text{cable}}^{(k+1)}$ 和 $\mathbf{d}_c^{(k+1)}$ ，并继续对剩余路径进行修正。该机制能够在不显著增加规划计算负担的前提下，使路径规划持续适应抓取后线缆形态的缓慢变化。

算法 3-1 基于双线缆点云输入的低频在线 GRRT-Connect 重规划

Input: 初始构型 q_{start} ; 局部目标构型 q_{goal} ; 刚性障碍集合 O_{rigid} ; 规划周期 Δt ; 参数 $\alpha, \beta, \gamma, \delta, \epsilon, r_{\perp}, r_{\parallel}$

Output: 滚动更新的局部无碰撞轨迹前缀序列

```

1 1. 初始化当前执行构型  $q^{(0)} \leftarrow q_{\text{start}}$ , 周期计数  $k \leftarrow 0$ . ;
2 2. while 未到达  $q_{\text{goal}}$  do
3     2.1 获取第  $k$  个规划周期的最新观测, 生成线缆障碍点云  $\mathcal{P}_{\text{cable}}^{\text{obs},(k)}$ . ;
4     2.2 根据连接器尾部线缆根部邻域, 从  $\mathcal{P}_{\text{cable}}^{\text{obs},(k)}$  中提取局部方向点云
         $\mathcal{P}_{\text{cable}}^{\text{dir},(k)}$  (式 (3-49)). ;
5     2.3 利用  $\mathcal{P}_{\text{cable}}^{\text{obs},(k)}$  更新动态体素地图  $\mathcal{V}_{\text{cable}}^{(k)}$ ; 利用  $\mathcal{P}_{\text{cable}}^{\text{dir},(k)}$  估计  $\mathbf{d}_c^{(k)}$ 、
         $\bar{\mathbf{p}}_c^{(k)}$  和  $w_d^{(k)}$ . ;
6     2.4 初始化双树:  $T_{\text{start}} \leftarrow \{q^{(k)}\}$ ,  $T_{\text{goal}} \leftarrow \{q_{\text{goal}}\}$ . ;
7     2.5 while 未满足连接条件且迭代次数未超限 do
8         2.5.1 采样  $q_{\text{rand}}$ , 计算方向引导代价  $J_{\text{dir}}^{(k)}(q_{\text{rand}})$  与接纳概率  $P_{\text{acc}}^{(k)}$ ;
            若未通过接纳则重新采样. ;
9         2.5.2 找最近节点  $q_{\text{near}}$ , 由式 (3-61) 生成扩展节点  $q_{\text{new}}$ . ;
10        2.5.3 执行关节限位、刚性障碍碰撞检测以及式 (3-58) 给出的柔
            性线缆判据; 若通过则将  $q_{\text{new}}$  并入树结构并尝试双树连接. ;
11    end
12    2.6 回溯得到当前周期局部路径  $\pi^{(k)}$ , 仅执行其前缀段, 持续时间为
         $\Delta t$ . ;
13    2.7 根据执行后的机器人状态更新  $q^{(k+1)}$ , 令  $k \leftarrow k + 1$ . ;
14 end
    
```

3.4.3 路径生成与后处理优化

在双树扩展获得起始构型与目标构型之间的连通关系后，规划结果仍表现为关节空间中的离散节点序列，尚不能直接作为机器人执行轨迹。为此，本节

进一步研究离散路径到可执行连续轨迹的转换过程，重点包括三项内容：其一，由双树连接结果回溯并拼接初始离散路径；其二，对相邻节点之间的插补线段进行稠密可行性检验，保证轨迹在刚性障碍与动态线缆障碍约束下全程无碰；其三，在保持可行性的前提下，通过平滑与捷径替换降低路径折角和冗余绕行，使轨迹更适于带缆连接器的抬升与转运执行。




图 3-18 路径生成与线段级碰撞检验流程示意图（双树连接—路径回溯拼接—分段稠密抽检—可行路径输出）

如图 3-18所示，路径生成过程可概括为“节点回溯与拼接 - 关节空间插值 - 线段级稠密检验 - 可行路径输出”四个步骤。其中，稠密检验在刚性障碍集合 O_{rigid} 与柔性线缆安全判据式 (3-58) 下统一完成，从而保证输出路径不仅在离散节点处可行，而且在相邻节点之间的连续插补过程中同样满足混合障碍物地图约束。

相邻节点间的连续运动采用关节空间线性插值，对 $i \in \{1, \dots, n-1\}$ 、 $\tau \in [0, 1]$ ，有

$$q_i(\tau) = (1 - \tau)q_i + \tau q_{i+1}. \quad (3-62)$$

式 (3-62) 在 $\tau = m/M$ 下给出了线段稠密检验的离散取样方式。为分析插补过程中末端扫掠包络与带缆任务之间的耦合关系，任取构型 q 由正运动学得到末端位姿；记基坐标系为 $\{B\}$ 、末端为 $\{E\}$ 、地图系为 $\{W\}$ ，则

$${}^W T_E(q) = {}^W T_B {}^B T_E(q), \quad (3-63)$$

其中 ${}^W T_B$ 为常值， ${}^B T_E(q)$ 由机械臂运动学模型给出。沿边插值时， ${}^W T_E(q_i(\tau))$

对 τ 的连续变化反映了末端在空间中的扫掠轨迹。若离散节点之间存在较大方向突变，则即使整条路径在离散意义下可行，实际执行时仍可能出现关节速度波动增大、末端姿态变化不连续以及对柔性线缆产生附加扰动等问题，因此仍需进行后处理优化。

定义离散二阶差分 $\delta_i = q_{i+1} - 2q_i + q_{i-1}$ ，平滑项 $\sum_{i=2}^{n-1} \|\delta_i\|_2^2$ 对内部节点的梯度为

$$\frac{\partial}{\partial q_i} \sum_{j=2}^{n-1} \|q_{j+1} - 2q_j + q_{j-1}\|_2^2 = 2(q_{i+2} - 4q_{i+1} + 6q_i - 4q_{i-1} + q_{i-2}), \quad i = 3, \dots, n-2, \quad (3-64)$$

综合平滑、长度与障碍惩罚，取

$$J_{\text{path}} = \lambda_s \sum_{i=2}^{n-1} \|q_{i+1} - 2q_i + q_{i-1}\|_2^2 + \lambda_l \sum_{i=1}^{n-1} \|q_{i+1} - q_i\|_2 + \lambda_o \sum_{i=1}^n \phi(q_i), \quad (3-65)$$

其中 λ_s 、 λ_l 、 λ_o 为权重。设 $d_{\min}(q)$ 为构型 q 下连杆采样点到 $\mathcal{M}_{\text{hyb}}$ 的最小间隙，令

$$\phi(q) = \exp\left(-\frac{d_{\min}(q)}{\sigma_o}\right), \quad (3-66)$$

$\sigma_o > 0$ 。若 $d_{\min}$ 对 q 可微，则

$$\nabla_q \phi(q) = -\frac{1}{\sigma_o} \exp\left(-\frac{d_{\min}(q)}{\sigma_o}\right) \nabla_q d_{\min}(q), \quad (3-67)$$

$\nabla_q d_{\min}(q)$ 可由距离场与微分运动学映射至关节空间。长度项对 q_i 在边差分非零处的梯度为 $\frac{q_i - q_{i-1}}{\|q_i - q_{i-1}\|_2} - \frac{q_{i+1} - q_i}{\|q_{i+1} - q_i\|_2}$ ；将上述三项按 $\lambda_s, \lambda_l, \lambda_o$ 加权并求和，即得内部节点处下降方向 $\mathbf{g}_i$ 的构造方式。




图 3-18

(空白占位图：路径生成与平滑原理示意)

图 3-19 路径生成与平滑原理示意图（离散节点回溯、关节空间线性插值、混合障碍约束下的稠密检验以及平滑优化前后轨迹形态对比）

如图 3-19 所示，路径后处理可理解为“保持端点不变条件下，对中间节点进

行受约束重分布”的过程。图中离散节点序列对应双树连接后回溯得到的初始路径，节点间连线对应式 (3-62) 所描述的关节空间线性插值；在每条插值边上进行稠密检验，可验证该路径在连续执行过程中是否始终满足刚性障碍碰撞约束和式 (3-58) 给出的柔性线缆安全判据。进一步地，平滑优化阶段通过式 (3-65) 对离散二阶差分、路径长度和障碍惩罚进行联合调节，使优化后的节点序列在保持可行性的同时减小局部折角与冗余绕行。由此，式 (3-64) 对应的平滑项主要抑制关节轨迹的高频振荡，式 (3-66) 与式 (3-67) 则共同约束轨迹与混合障碍物地图之间的最小安全间隙，从而在图示层面形成“可行 - 平滑 - 远障”的统一优化效果。

算法 3-2 混合障碍物地图约束下的离散路径生成与后处理优化

Input: 双树连接点及两侧搜索树结构； $\mathcal{M}_{\text{hyb}} = (\mathcal{O}_{\text{rigid}}, \mathcal{V}_{\text{cable}})$ ；线段稠密检验步数 M ；权重与尺度 $\lambda_s, \lambda_l, \lambda_o, \sigma_o$ ；最大迭代次数 K ；初始步长 α_0 ；收缩因子 $0 < \rho < 1$

Output: 优化路径 π^*

- 1 由连接点回溯拼接得到初始离散路径 $\pi^{(0)} = \{q_i\}_{i=1}^n$ ($q_1 = q_{\text{start}}$ 、 $q_n = q_{\text{goal}}$)；
- 2 对每条边 (q_i, q_{i+1}) ，对 $m = 0, \dots, M$ 取 $\tau = m/M$ 并令
 $q(\tau) = (1 - \tau)q_i + \tau q_{i+1}$ ；若任一稠密检验点违反关节限位、与刚性占据 $\mathcal{O}_{\text{rigid}}$ 碰撞或不满足式 (3-58)，则返回失败；
- 3 在稠密检验可行前提下执行捷径替换以删去可直连折点，更新为 $\pi^{(0)}$ ；
- 4 $k \leftarrow 0$ ；
- 5 **while** $k < K$ 且未满足收敛判据 **do**
 - 6 按式 (3-65) 计算 $J_{\text{path}}(\pi^{(k)})$ ，并对内部节点 $i = 3, \dots, n - 2$ 构造下降方向 $\mathbf{g}_i$ （由式 (3-64)、长度项梯度与式 (3-67) 加权得到），更新
 $q_i^{(k+1)} \leftarrow q_i^{(k)} - \alpha_k \mathbf{g}_i$ ；
 - 7 对 $\pi^{(k+1)}$ 再做与步骤 2 相同的稠密检验：若任一边失败则回退并令
 $\alpha_k \leftarrow \rho \alpha_k$ ；
 - 8 $k \leftarrow k + 1$ ；
- 9 **end**
- 10 对最终节点序列做 B 样条拟合或时间重参数化，并再次执行稠密检验
 输出 π^* ；

如图 3-20 所示，采用前文所述方向引导采样、双树扩展与后处理优化后，生成的转运路径能够在满足起始构型与目标构型连通的同时，整体保持与线缆体

图 3-19
(空白占位图)

图 3-20 基于方向引导与后处理优化的规划路径效果图（展示本文方法在柔性线缆障碍约束下生成的转运路径及其与线缆占据区域的空间关系）

素占据区的可见安全间隙，并避免在局部密集障碍附近出现明显折返。图中的路径形态表明，式 (3-59) 所引入的方向引导项能够使搜索过程优先沿与线缆主方向更相容的区域扩展，而式 (3-65) 对应的后处理优化则进一步抑制关节空间中的高频折角和冗余绕行。由此，最终输出轨迹不仅与混合障碍物地图及式 (3-58) 的柔性线缆安全判据保持一致，而且在几何形态上体现出前文方法带来的改进效果，即路径更平滑、对线缆障碍的绕避更充分、末端转运姿态变化更连续，可为后续预装配阶段提供更稳定的运动学输入。

3.5 实验与结果分析

为验证本章提出的端到端 6D 抓取生成、多约束抓取筛选以及基于混合障碍物地图的 GRRT-Connect 引导式规划在航空非结构化环境中的可行性与有效性，本节围绕“抓取效果验证”和“抓取后转运至预装配区域的规划执行验证”两部分展开。前者用于说明候选抓取生成与多约束筛选后，末端能够在真实带缆连接器上形成稳定夹持；后者以前述成功抓取姿态作为规划初始状态，进一步考察转运路径是否能够在刚柔混合障碍约束下保持连续、可执行且与线缆干扰相容。实验输入沿用前文 CableMask 分割与三维化体素更新链路，刚性结构在初始感知阶段写入 O_{rigid} 并在规划期保持不更新，柔性线缆在规划与运动开始后仅按当前观测帧更新 V_{cable} ，使地图语义与在线规划在时间上对齐。具体实验流程为：首先由视觉感知模块完成目标连接器实例分割、位姿估计与线缆区域提取；随后由抓取生成网络输出候选抓取，并经可达性、线缆安全性和姿态相容性评价确定最终执行抓取；机械臂按选定抓取位姿完成接近、闭合夹持和抬升动作；在此基础上，将成功抓取后的实际末端构型作为规划起点，进一步生成并执行转运到预装配区域的轨迹，用于验证前文路径规划与后处理方法在

真实带缆工况中的执行效果。




图 3-20
(空白占位图：不同线缆布置下抓取过程典型帧)

图 3-21 不同线缆布置工况下电连接器抓取实验效果图（实物抓取过程与对应算法筛选结果示意）

图 3-21 给出了抓取实验的典型结果，其中既包含真实平台上的接近、闭合与抬升画面，也可对应展示算法侧选定的抓取位姿或末端与目标相对关系。该图重点用于验证两方面内容：其一，经过 3.2 节抓取生成和 3.3 节多约束筛选后，最终选出的抓取位姿能够落在连接器壳体稳定夹持区域，而不会直接遮挡插针端或压迫线缆根部；其二，在不同线缆垂落和贴附形态下，末端仍能够形成稳定闭合夹持并完成初始抬升，说明前文构建的“感知 - 抓取筛选 - 执行”链路在真实带缆工况下具有可执行性。若图中同时给出抓取前后的局部算法效果图，则可进一步说明所选抓取姿态与视觉感知结果及多约束评分结果保持一致。




图 3-21
(空白占位图：规划过程曲线与轨迹形态示意)

图 3-22 规划求解过程与关节空间轨迹形态示意（收敛趋势与折返程度）

图 3-22 表明，规划迭代过程在若干次更新后逐步收敛，关节空间轨迹未出现显著的高频锯齿式折返。这说明前文引入的方向引导采样、双树扩展和路径后处理优化能够有效抑制狭窄通道中的无效搜索与冗余转折，使规划输出更符合真实平台连续执行的要求。

图 3-23 显示，规划得到的末端轨迹在转运阶段始终位于线缆体素占据区外

图 3-22

(空白占位图：转运段轨迹与线缆占据叠加示意)

图 3-23 转运阶段末端轨迹与线缆体素占据的空间关系示意

侧，并与柔性障碍保持稳定安全间隙，说明式 (3-58) 所定义的各向异性安全判据在真实规划结果中得到了有效满足。与此同时，轨迹整体沿线缆主方向相容区域展开，未出现明显横向穿越线缆密集区的局部段，表明前文方向引导采样与动态障碍约束能够共同改善路径的安全性及可执行性。




图 3-24 成功抓取后转运至预装配区域的规划执行关键帧序列示意

图 3-24 进一步说明，连接器在成功抓取后能够沿规划轨迹完成抬升、转运并稳定接近预装配区域，整个过程中末端姿态过渡连续，线缆未与周围刚性结构及线缆占据区发生明显干涉，到达预装配区域附近时连接器仍保持与后续插接任务相一致的定向关系。该结果表明，前文路径生成、稠密检验与后处理优化所得轨迹不仅在离散节点层面满足可行性要求，而且能够支撑真实平台上“成功抓取 - 安全转运 - 进入预装配区域”的连续执行过程。

3.6 本章小结

本章围绕航空制造场景下电连接器在狭窄机舱环境中的自主抓取问题，构

建了由端到端 6D 抓取生成、多约束抓取筛选和 GRRT-Connect 运动规划组成的完整技术框架。在抓取生成阶段，利用目标实例掩膜、6D 位姿和线缆掩膜构建目标局部点云，并通过位姿参数化、位姿先验与线缆禁入域约束生成更符合工程需求的候选抓取位姿；在抓取筛选阶段，进一步引入逆运动学可达性、线缆安全间隙和姿态相容性评价，通过综合评分函数选择既稳定又利于后续装配的抓取方案；在路径规划阶段，将机舱刚性障碍和线缆柔性障碍共同纳入混合障碍物地图，并通过 GRRT-Connect 算法提高狭窄空间下的规划可收敛性与路径形态可控性。结合典型工况的图示验证可见，规划输出与混合地图及线段检验所表达的可行域相一致，执行序列呈现与柔性线缆干扰相容的运动形态，可为后续柔顺装配过程提供可对照的初始状态。

第4章 电连接器柔顺装配控制方法研究

4.1 引言

针对航空制造场景下带柔性拖缆电连接器的精密装配问题，本章构建视觉前馈、力位混合控制和深度强化学习的递进式装配框架，建立含柔性线缆干扰的装配动力学模型，并将线缆方向向量引入控制器，构造面向拖缆主扰动方向的视觉前馈补偿项；随后设计装配过程的状态空间、动作空间与奖励函数，构建强化学习交互环境，基于 SoftActor-Critic 实现装配策略学习，能够在接触建立后完成搜孔、姿态修正与稳定插接。通过仿真训练与真实平台实验对接触力峰值、装配时间与装配成功的安全性表现进行验证。



图 4-1 第四章总体技术路线与输入输出接口示意图（第三章预装配初值与线缆先验驱动插入阶段控制与策略学习的接口关系）

4.2 含线缆干扰的轴孔装配动力学建模与控制器设计

电连接器插接过程受几何约束、接触切换和柔性扰动共同影响。为面向轴孔对齐的控制设计建立统一任务空间表达，本节首先从受力关系与运动约束出发，对带柔性线缆干扰的装配过程进行动力学建模；随后在引入力位混合控制框架下，将位置调节与接触力约束统一表征，并利用视觉获得的线缆方向信息构造方向相关的前馈补偿项，从而使后续误差分解与阻抗控制律构造具有一致的物理变量定义。

4.2.1 轴孔装配误差描述

预装配操作完成后，机械臂末端已进入插孔前方局部邻域，装配控制的核心问题不再是大范围位姿搜索，而是对孔口附近的轴孔相对误差进行精细调节。考虑到柔性线缆拖拽会同时改变末端的横向偏移、轴向推进状态以及姿态对准

关系，误差建模需要直接回答三个控制问题：当前连接器端面在孔口平面内偏向何处、沿插入轴线尚有多少剩余推进距离、连接器轴线与插孔轴线之间存在多大姿态失配。基于这一目标，本文将装配误差分解为横向对齐误差、轴向推进误差和姿态失配误差三个通道，以便后续控制器针对不同误差分量配置相应的刚度与阻尼参数。




图 4-2 轴孔装配误差分解与几何含义说明图（横向对齐、轴向推进与姿态失配误差在孔口局部的几何含义示意）

设连接器装配轴线方向为 z_a 、插孔轴线方向为 z_h （均为单位向量）。取连接器末端参考点位置为 $\mathbf{p}_c$ ，插孔参考点位置为 $\mathbf{p}_h$ ，平移误差定义为 $\Delta \mathbf{p} = \mathbf{p}_c - \mathbf{p}_h$ 。如图 4-2 所示，当连接器端面中心 $\mathbf{p}_c$ 在插孔平面内偏离孔中心 $\mathbf{p}_h$ 时，误差首先表现为横向未对准，因此横向对齐误差取为在插入轴法向平面的投影：

$$\mathbf{e}_{xy} = (\mathbf{I} - z_h z_h^T) \Delta \mathbf{p},$$

其中， $\mathbf{I}$ 为单位矩阵， $\mathbf{e}_{xy}$ 表示垂直于插入轴线的侧向对齐误差向量，对应图中的红色横向偏移分量。轴向推进误差取为沿插入轴方向的投影标量：

$$e_z = z_h^T \Delta \mathbf{p},$$

其中， e_z 表示沿插入轴线方向的剩余推进距离误差，对应图中的蓝色轴向误差分量。姿态失配误差由连接器与插孔的相对旋转确定，采用相对旋转对数映射得到的旋转向量：

$$\mathbf{e}_R = \text{Log}(\mathbf{R}_h^T \mathbf{R}_c)^v,$$

其中， $\mathbf{R}_c$ 与 $\mathbf{R}_h$ 分别为连接器与插孔的姿态矩阵， v 表示旋转对数输出的向量

化映射， $\mathbf{e}_R$ 对应图中的绿色姿态失配分量。将上述三通道误差合并，可得装配误差向量：

$$\mathbf{e}_t = \begin{bmatrix} \mathbf{e}_{xy}^\top \\ e_z \\ \mathbf{e}_R^\top \end{bmatrix}.$$

上述误差定义将孔口局部几何关系转化为可直接进入控制律的任务空间量。具体而言， $\mathbf{e}_{xy}$ 描述连接器参考点相对插孔中心在法向平面内的偏移方向与偏移量，其增大意味着端面横向楔入风险上升； e_z 描述沿插入轴线方向的剩余推进距离，用于刻画当前是否处于自由推进阶段或已接近接触建立区间； $\mathbf{e}_R$ 则描述连接器轴线与插孔轴线之间的姿态失配程度，其增大会导致端面单侧先接触并诱发附加力矩。将三者组合为 $\mathbf{e}_t$ 后，控制器即可分别针对横向对齐、轴向推进和姿态校正配置不同的刚度与阻尼参数，而不再将装配误差笼统地视为单一六维位姿偏差。由此，图示几何关系与前述公式共同表明：装配初期需要优先抑制 $\mathbf{e}_{xy}$ 和 $\mathbf{e}_R$ 所对应的横向楔入与偏斜接触风险，再在安全接触约束下逐步减小 e_z ，从而使柔性线缆扰动引起的横向耦合被限制在可控范围内。

4.2.2 含线缆干扰的装配动力学模型

电连接器插接过程属于刚柔耦合接触过程，连接器与底座插孔之间存在法向接触、切向摩擦与几何约束；连接器尾部柔性线缆在机械臂带动下产生方向性拖拽力和回复力矩，对末端轨迹与接触状态形成持续扰动。

设末端在笛卡尔空间中的位姿为 $\mathbf{x}$ ，则考虑接触作用与线缆扰动后的装配动力学方程可写为

$$\mathbf{M}_x \ddot{\mathbf{x}} + \mathbf{C}_x \dot{\mathbf{x}} + \mathbf{G}_x = \mathbf{F}_{ctrl} + \mathbf{F}_{ext} + \mathbf{F}_{cable}. \quad (4-1)$$

其中， $\mathbf{M}_x$ 为等效惯性矩阵， $\mathbf{C}_x$ 为速度相关项， $\mathbf{G}_x$ 为重力项， $\mathbf{F}_{ctrl}$ 为控制输入在任务空间的等效作用， $\mathbf{F}_{ext}$ 为连接器与插孔之间的接触作用力， $\mathbf{F}_{cable}$ 为柔性线缆对末端施加的附加干扰力。若忽略 $\mathbf{F}_{cable}$ ，则模型只能描述刚性轴孔接触约束，而难以解释插接过程中因尾部线缆拖拽引起的横向偏拉、姿态回摆以及接触力峰值提前出现等现象。由于线缆为典型分布参数柔性体，其精确高维动力学难以在工程实现与在线学习阶段可靠辨识，因此本文采用便于控制设计的低维等效建模方式。

为突出图 4-3 所示主导受力关系，本文不对全长线缆进行连续体建模，而

将其视为沿主拖曳方向作用的等效弹性—阻尼元件。设线缆方向单位向量为 $\hat{v}_{cable}$ ，等效伸长量为 Δl ，则有

$$\mathbf{F}_{cable} = k_c(\Delta l)\Delta l \hat{v}_{cable} + c_c \dot{\Delta l} \hat{v}_{cable}. \quad (4-2)$$

其中， $k_c(\Delta l)$ 为与线缆形变量相关的等效刚度系数， c_c 为等效阻尼系数， $\dot{\Delta l}$ 为长度变化率。图 4-3 中的 $\hat{v}_{cable}$ 表示线缆主拖曳方向，该方向由第二章得到的线缆掩膜与线缆方向先验估计； Δl 表示末端沿该方向相对局部平衡状态的等效伸长量； $\mathbf{F}_{cable}$ 则表示线缆对末端施加的附加扰动力。该建模方式保留了线缆回拉与耗散两类对装配最敏感的作用，同时避免引入难以在线辨识的高维柔性参数。




图 4-3 含线缆干扰的轴孔装配动力学建模示意图（接触作用与柔性线缆等效弹性—阻尼扰动的作用关系示意）

如图 4-3 所示，当末端偏离孔口附近的平衡构型时，线缆会沿 $\hat{v}_{cable}$ 产生回拉力与速度相关阻尼力，其合力统一记为 $\mathbf{F}_{cable}$ 。该项与接触力 $\mathbf{F}_{ext}$ 共同作用于末端，因此带线缆连接器的装配过程不再是单纯的轴孔接触问题，而是接触约束与柔性拖拽耦合并存的局部受力过程。

为保证等效方向单位向量 $\hat{v}_{cable}$ 与轴孔装配任务坐标的一致性，需要将第二章在视觉坐标系下获得的线缆方向先验映射至控制任务坐标系。设孔口坐标系为 $\{O\}$ 、机器人基坐标系为 $\{B\}$ 、视觉相机坐标系为 $\{C\}$ ，以及末端坐标系为 $\{E\}$ ，则刚体变换满足

$${}^B T_O = {}^B T_E {}^E T_C {}^C T_O.$$

其中, ${}^B T_E$ 为末端坐标系相对基坐标系的位姿变换, ${}^E T_C$ 为相机坐标系相对末端坐标系的外参变换, ${}^C T_O$ 为孔口坐标系相对相机坐标系的标定变换; 该等式的旋转子块用于方向向量变换。第三章已完成连接器自主抓取与转运, 使末端以装配相容姿态进入预装配区域, 因此本节仅在孔口局部邻域内讨论该方向映射与误差演化。记 ${}^C \hat{\mathbf{v}}_{cable}$ 为线缆方向先验在相机坐标系下的单位向量表示, 则映射到基坐标系下的方向单位向量可写为

$$\hat{\mathbf{v}}_{cable} = \frac{{}^B R_C {}^C \hat{\mathbf{v}}_{cable}}{\|{}^B R_C {}^C \hat{\mathbf{v}}_{cable}\|},$$

其中, ${}^B R_C$ 为相机到基坐标系的旋转矩阵。由于插接阶段的规划视域限定在孔口局部邻域, 等效方向在短时窗内可近似为常向量, 从而保证后续 Δl 的一维坐标化表达能够与 $\mathbf{e}_{xy}$ 与 $\mathbf{e}_z$ 的几何投影保持确定性耦合。




图 4-4
(空白占位图: 视觉线缆方向映射与 Δl 投影几何示意)

图 4-4 视觉线缆方向映射与 Δl 投影几何示意 (给出 ${}^B T_E {}^E T_C {}^C T_O$ 下方向向量变换及 $\Delta \mathbf{p}$ 分解到 $\mathbf{e}_z$ 与 $\mathbf{e}_{xy}$ 后形成 $\Delta l = \hat{\mathbf{v}}_{cable}^T \Delta \mathbf{p}$ 的投影关系)

图 4-4 给出了线缆方向映射与局部几何投影关系: 平移误差 $\Delta \mathbf{p}$ 被分解为沿插孔轴线的标量分量 $\mathbf{e}_z$ 与垂直平面的向量分量 $\mathbf{e}_{xy}$, 再与等效方向 $\hat{\mathbf{v}}_{cable}$ 做内积得到一维伸长坐标 Δl 。由此, 图中的几何量与式 (4-2) 中的线缆等效力建立了直接对应关系。

为了给出 Δl 的几何计算依据, 记末端参考点与插孔参考点之间的平移误差为 $\Delta \mathbf{p} = \mathbf{p}_c - \mathbf{p}_h$ 。其中, $\mathbf{p}_c$ 对应第三章转运完成后进入预装配区域的末端局部参考位置, $\mathbf{p}_h$ 为孔口参考点, 因此 $\Delta \mathbf{p}$ 主要表征插接阶段的局部微调误差。由 4.2.1 的误差分解可得

$$\Delta \mathbf{p} = z_h \mathbf{e}_z + \mathbf{e}_{xy},$$

其中, z_h 为插孔轴线方向单位向量。进一步定义线缆等效伸长量为沿主方向的

投影

$$\Delta l = \hat{v}_{cable}^T \Delta \mathbf{p} = (\hat{v}_{cable}^T z_h) e_z + \hat{v}_{cable}^T \mathbf{e}_{xy},$$

该式表明线缆扰动与 $\mathbf{e}_{xy}$ 、 e_z 存在明确的方向耦合：当 $\hat{v}_{cable}$ 在横向平面内投影较大时， $\mathbf{e}_{xy}$ 的变化会显著改变 Δl ；当 $\hat{v}_{cable}$ 更接近插入轴时， e_z 对 Δl 的贡献更为突出。为在本节内给出这一耦合关系的控制含义，可将 4.2.1 的误差向量写成通道化阻抗调节形式

$$\mathbf{f}_c = -K_c \mathbf{e}_t - D_c \dot{\mathbf{e}}_t,$$

$$\text{其中, } \mathbf{e}_t = \begin{bmatrix} \mathbf{e}_{xy}^T & e_z & \mathbf{e}_R^T \end{bmatrix}^T,$$

$$K_c = \text{diag}(k_{xy}, k_{xy}, k_z, k_{r1}, k_{r2}, k_{r3}), \quad D_c = \text{diag}(d_{xy}, d_{xy}, d_z, d_{r1}, d_{r2}, d_{r3}).$$

由此可见，当线缆回拉主要作用于横向平面时，可适当降低横向通道刚度并提高阻尼，以削弱偏拉引起的横向放大；沿插入轴方向则保留较高 k_z 以维持推进能力，从而使本节的动力学建模与后续控制律设计在变量定义上保持一致。

由 $\Delta l = \hat{v}_{cable}^T \Delta \mathbf{p}$ 可进一步得到长度变化率。考虑 $\hat{v}_{cable}$ 的时间变化，长度变化率为

$$\dot{\Delta l} = \dot{\hat{v}}_{cable}^T \Delta \mathbf{p} + \hat{v}_{cable}^T (\dot{\mathbf{p}}_c - \dot{\mathbf{p}}_h),$$

其中， $\mathbf{p}_c$ 与 $\mathbf{p}_h$ 分别为连接器末端参考点与孔口参考点的位置， $\dot{\hat{v}}_{cable}$ 为方向单位向量变化率。由于第二章估计得到的线缆主方向在孔口局部邻域内变化较小，且此时系统已进入第三章规划完成后的短时窗精调阶段，因此可近似令 $\dot{\hat{v}}_{cable} \approx 0$ ，从而得到

$$\dot{\Delta l} \approx \hat{v}_{cable}^T (\dot{\mathbf{p}}_c - \dot{\mathbf{p}}_h).$$

结合 4.2.1 的几何分解 $\Delta \mathbf{p} = z_h e_z + \mathbf{e}_{xy}$ ，进一步有

$$\dot{\Delta l} \approx (\hat{v}_{cable}^T z_h) \dot{e}_z + \hat{v}_{cable}^T \dot{\mathbf{e}}_{xy}.$$

将上述结果代入式 (4-2) 可知，线缆等效扰动力的幅值由 $\mathbf{e}_{xy}$ 、 e_z 及其变化率共同决定，其中前者主要对应横向偏拉，后者主要对应轴向拉伸。因此，线缆扰动并非独立附加项，而是通过局部几何误差通道耦合进入装配过程。将横向、轴向与姿态误差分通道配置刚度和阻尼并非形式上的分解，而是抑制柔性线缆耦合扰动、维持插接稳定性的必要条件。基于这一建模结果，下一节进一步在阻抗控制框架下给出 K_c 与 D_c 的具体配置方式。

4.2.3 视觉前馈变刚度阻抗控制器设计

由 4.2.2 可知，线缆等效扰动力沿 $\hat{v}_{cable}$ 注入，且其幅值由等效伸长坐标 Δl 表征。为实现线缆方向扰动与通道柔顺调节的一致交互，本文采用笛卡尔空间变刚度阻抗控制，将位姿误差 $\mathbf{e}$ 通过通道相关的 K_c 与 D_c 映射为任务空间恢复力并输出关节力矩指令。

在时刻 t ，强化学习智能体输出归一化动作向量 $\mathbf{a}_t \in [-1, 1]^6$ ，其各分量分别对应末端在笛卡尔空间沿 x, y, z 轴的平移增量以及绕各轴的旋转增量。为满足装配工艺与安全约束，本文依据末端允许的最大线速度与角速度，将归一化动作线性缩放为期望位姿偏移量 $\Delta \mathbf{X}_{RL}$ 。当前实际位姿记为 $\mathbf{X}_c = [\mathbf{P}_c^T, \mathbf{Q}_c^T]^T$ ，则强化学习给出的目标位姿为

$$\mathbf{X}_{target} = \mathbf{X}_c + \Delta \mathbf{X}_{RL}. \quad (4-3)$$

其中， $\mathbf{P}$ 表示位置向量， $\mathbf{Q}$ 表示四元数姿态表示。

由于强化学习推理频率为 10-20 Hz，而底层力矩控制频率为 1000 Hz，若将离散的 $\mathbf{X}_{target}$ 直接映射到 1 kHz 阻抗误差，将造成目标突变并诱发峰值力矩。为保证目标位姿在控制环内连续可实现，本文在阻抗内环引入指数移动平均滤波器（Exponential Moving Average, EMA）对目标位姿进行低通平滑。记第 k 个 1 ms 控制周期内的期望位姿为 $\mathbf{X}_d^{(k)} = [\mathbf{P}_d^{(k)}, \mathbf{Q}_d^{(k)}]$ ，其更新形式为

$$\mathbf{P}_d^{(k)} = \alpha \mathbf{P}_{target} + (1 - \alpha) \mathbf{P}_d^{(k-1)}, \quad (4-4)$$

$$\mathbf{Q}_d^{(k)} = \text{Slerp}(\mathbf{Q}_d^{(k-1)}, \mathbf{Q}_{target}, \alpha). \quad (4-5)$$

其中， $\alpha \in (0, 1)$ 为滤波系数，Slerp 表示四元数球面插值算子。通过选取较小的 α 使目标位姿变化连续，从而限制冲击力矩峰值。

如图 4-5 所示，高层强化学习策略以 10 Hz 左右频率输出离散目标位姿，若直接映射到 1 kHz 阻抗内环，则在目标切换时刻会形成明显的阶跃或折点，导致参考轨迹斜率突变。图 4-5(a) 表明，在接触约束场景中，EMA 处理后的内环参考轨迹相较于未平滑参考更为连续，能够减小沿接触方向的瞬时位移指令变化，从而避免因命令突变诱发附加接触力峰值。图 4-5(b) 进一步表明，在自由空间快速调整场景中，EMA 能够削弱目标更新时的局部折返趋势，使实际末端位置对上层目标的跟随过程更平稳。由此可见，式 (4-4) 与式 (4-5) 中的 EMA 并非简单的数值滤波步骤，而是实现低频策略输出与高频阻抗控制平稳衔接的必




图 4-5 EMA 对阻抗内环目标位姿平滑作用示意图（对比接触约束场景与自由空间场景下，10 Hz 高层目标、未经平滑处理的 1 kHz 内环参考、EMA 处理后的 1 kHz 参考以及实际末端位置的变化关系）

要环节。

记实际末端平移向量为 $\mathbf{P}_c$ 、期望平移向量为 $\mathbf{P}_d^{(k)}$ ，则平移误差为

$$\mathbf{e}_p = \mathbf{P}_c - \mathbf{P}_d^{(k)}. \quad (4-6)$$

姿态误差采用单位四元数描述。记实际姿态为 $\mathbf{Q}_c$ 、期望姿态为 $\mathbf{Q}_d^{(k)}$ ，通过四元数乘积构造相对姿态

$$\mathbf{Q}_e = \mathbf{Q}_c^{-1} * \mathbf{Q}_d^{(k)}, \quad (4-7)$$

再提取其向量部分作为姿态误差

$$\mathbf{e}_o = \mathcal{R}(\mathbf{Q}_e)_{vec}. \quad (4-8)$$

其中， $\mathcal{R}(\cdot)_{vec}$ 表示取四元数的虚部向量。将平移与姿态误差合并，可得广义位姿误差

$$\mathbf{e} = \begin{bmatrix} \mathbf{e}_p^\top \\ \mathbf{e}_o^\top \end{bmatrix}^\top. \quad (4-9)$$

如图 4-6 所示，前馈变刚度阻抗控制器的主数据流可概括为“目标位姿生成 - 误差构造 - 方向相关阻抗调节 - 任务空间到关节空间映射 - 安全执行”。其中，强化学习输出的目标位姿首先经过 EMA 平滑参考轨迹生成环节得到内环参考量；该参考量与实际位姿 $\mathbf{X}_c$ 做差后形成广义误差 $\mathbf{e}$ 。与此同时，视觉估计得到的线缆方向 $\hat{\mathbf{v}}_{cable}$ 进入线缆方向扰动估计与前馈补偿模块，输出前馈补偿力 $\mathbf{f}_{ff}$ 与接触推进参考 f_d 。方向相关变刚度阻抗律根据误差在平行/正交子空间




图 4-6 面向轴孔对齐装配的视觉前馈控制框图（线缆方向先验经视觉前馈补偿注入力位混合控制的数据流示意）

中的分量，对 $K_{\parallel}$ 、 $K_{\perp}$ 、 $D_{\parallel}$ 与 $D_{\perp}$ 进行分通道调节并形成任务空间控制力；随后，经 $J^T(q)$ 完成任务空间到关节空间的映射，再叠加零空间优化与动力学补偿项，并通过关节力矩限幅满足真实平台的执行约束。该图直接给出了本节后续控制律中各变量之间的因果关系，使视觉先验、前馈补偿、阻抗调节与末端响应之间的闭环联系具有明确的结构表达。

在静力学等效与雅可比转置映射基础上，可将期望的笛卡尔阻抗特性映射为关节空间任务力矩

$$\hat{\mathbf{F}}_{cable} = (k_c(\Delta l)\Delta l + c_c\dot{\Delta l})\hat{\mathbf{v}}_{cable}, \quad \mathbf{f}_{ff} = \hat{\mathbf{F}}_{cable}, \quad \mathbf{f}_d = f_d\mathbf{z}_h, \quad \mathbf{f}_{ref} = \mathbf{f}_d + \mathbf{f}_{ff}, \quad (4-10)$$

其中， $\mathbf{f}_{ff}$ 为视觉前馈补偿力，采用 4.2.2 的线缆等效弹性—阻尼模型估计； $\mathbf{f}_d$ 为插入推进参考力（ $\mathbf{z}_h$ 方向）， $\mathbf{f}_{ref}$ 为合成参考交互力。等效伸长坐标 Δl 与其变化率 $\dot{\Delta l}$ 由 4.2.1 的几何分解与 4.2.2 的短时窗近似确定。

$$\boldsymbol{\tau}_{task} = J^T (\mathbf{f}_{ref} - K_c \mathbf{e} - D_c J \dot{\mathbf{q}}), \quad (4-11)$$

在静力学等效与局部线性化假设下，可将末端等效交互力写为期望阻抗动力学

$$\mathbf{M}_d \ddot{\mathbf{e}} + \mathbf{D}_c \dot{\mathbf{e}} + \mathbf{K}_c \mathbf{e} = \mathbf{f}_{ref} - \mathbf{f}_{ext},$$

其中， $\mathbf{M}_d$ 为等效期望惯性矩阵， $\mathbf{f}_{ref}$ 为合成参考交互力； $\mathbf{f}_{ext}$ 为外界等效交互力（含插接接触力与线缆扰动等效分量）， $\mathbf{e}$ 为广义位姿误差（由平移误差与姿

态误差构造)。其中, $J \in \mathbb{R}^{6 \times 7}$ 为当前构型下末端雅可比矩阵, $\dot{\mathbf{q}}$ 为关节角速度向量, $K_c, D_c \in \mathbb{R}^{6 \times 6}$ 分别为笛卡尔空间的对角刚度和阻尼矩阵。

本文采用方向相关变刚度: 由 4.2.2 的等效伸长坐标 $\Delta l = (\hat{\mathbf{v}}_{cable}^T z_h) \mathbf{e}_z + \hat{\mathbf{v}}_{cable}^T \mathbf{e}_{xy}$ 可知线缆扰动主要通过 $\mathbf{e}_z$ 与 $\mathbf{e}_{xy}$ 通道注入交互能量; 视觉前馈补偿 $\mathbf{f}_{ff}$ 取自线缆等效弹性-阻尼模型, 可在等效方向上抵消主要扰动分量, 因此变刚度主要约束残余横向与姿态耦合。由此插入轴向相关通道取高刚度、横向对齐与姿态通道取低刚度, 并令 $D_i = 2K_i$ 以维持接触切换阶段的阻尼裕度。

Franka 机械臂具有 7 个关节自由度, 在六维任务空间下存在冗余。为约束肘部内部构型并避免奇异位形与线缆/结构件干涉, 控制器在任务空间阻抗控制基础上引入零空间姿态优化项。

对雅可比矩阵 J 进行伪逆计算得到 J^+ , 可构造零空间投影矩阵

$$P_{null} = I - J^T (J^+)^T. \quad (4-12)$$

其中, I 为单位矩阵。将预先规划的安全肘部构型记为 $\mathbf{q}_{null}$, 零空间优化力矩设计为

$$\boldsymbol{\tau}_{null} = P_{null} [K_{null}(\mathbf{q}_{null} - \mathbf{q}) - D_{null}\dot{\mathbf{q}}], \quad (4-13)$$

其中, K_{null} 为零空间刚度系数, $D_{null} = 2K_{null}$ 为其临界阻尼系数。该项力矩通过零空间投影被约束在冗余自由度内, 用于稳定肘部构型并减少非期望内部运动。

结合机械臂刚体动力学模型, 最终下发的关节力矩指令采用动力学前馈补偿

$$\boldsymbol{\tau}_{cmd} = \boldsymbol{\tau}_{task} + \boldsymbol{\tau}_{null} + \boldsymbol{\tau}_{coriolis}. \quad (4-14)$$

其中, $\boldsymbol{\tau}_{coriolis}$ 表示科里奥利力与离心力等非线性动力学项, 由底层软件接口计算; 前馈补偿用于提升模型一致性与力矩响应稳定性。

为保证硬件在强化学习早期探索阶段的执行安全, 本文在理论力矩叠加后加入基于物理阈值的力矩限幅器。对于每个关节 i , 最终指令力矩在软件层面被逐元素裁剪为

$$\tau_{cmd,i} = \min(\tau_{limit,i}, \max(-\tau_{limit,i}, \tau_{cmd,i})), \quad (4-15)$$

其中, $\tau_{limit,i}$ 为对应关节的额定安全力矩范围, 结合厂家手册与实验经验设定。

为验证上述控制律在离散仿真环境中的可实现性, 本文进一步构建了与




图 4-7 前馈变刚度阻抗控制器的 Simulink 仿真模块图（输入与参考生成、线缆方向扰动与前馈估计、测量观测与噪声注入、方向相关变刚度阻抗控制、末端动力学与状态积分以及结果导出等功能区域）

图 4-6 控制框图对应的 Simulink 模块模型，如图 4-7 所示。该模型将本节公式推导转化为可执行的模块级实现：输入与参考生成区域对应目标位姿与 EMA 平滑参考的构造，线缆方向扰动与前馈估计区域对应 $\hat{\mathbf{F}}_{cable}$ 、 $\mathbf{f}_{ff}$ 与 $\mathbf{f}_{ref}$ 的计算，方向相关变刚度阻抗控制区域对应 $\boldsymbol{\tau}_{task} = \mathbf{J}^T (\mathbf{f}_{ref} - \mathbf{K}_c \mathbf{e} - \mathbf{D}_c \mathbf{J} \dot{\mathbf{q}})$ 的控制律实现，末端动力学与状态积分区域对应 $\mathbf{M}_d \ddot{\mathbf{e}} + \mathbf{D}_c \dot{\mathbf{e}} + \mathbf{K}_c \mathbf{e} = \mathbf{f}_{ref} - \mathbf{f}_{ext}$ 的离散演化，结果导出区域则用于统一记录误差、力和参数变化量。


在图 4-7 所示模型基础上，本文进一步在统一末端动力学、扰动注入方式与参考轨迹条件下，对无前馈各向同性阻抗、有前馈但保持各向同性参数的基线方法以及本文方向相关变刚度阻抗控制策略进行对比。为定量评估各方法的抗扰性能，分别定义最大跟踪误差、扰动期间均方根误差与扰动解除后的恢复时间为

$$e_{\max} = \max_t |e(t)|,$$


$$e_{\text{RMS}} = \sqrt{\frac{1}{N} \sum_{t \in \mathcal{T}_d} e^2(t)},$$

$$t_{\text{rec}} = t_s - t_{\text{off}},$$


其中， $e(t)$ 表示末端跟踪误差， $\mathcal{T}_d$ 表示扰动作用时间区间， t_{off} 为扰动解除时刻， t_s 为误差重新收敛至稳态阈值内的时刻。图 4-8(a) 显示本文方法在扰动作用阶段具有更小的误差峰值与波动幅度；图 4-8(b) 表明平行方向刚度与阻尼能够随扰动强度自适应调整，而正交方向参数保持相对稳定；图 4-8(c) 则进一步给出 $e_{\max}$ 、 e_{RMS} 与 t_{rec} 的统计结果，说明本文方法在弱扰动与强扰动下均优于各基线方案。上述结果表明，沿线缆方向的前馈补偿与平行/正交通道的差异化阻抗配置能够有效抑制柔性线缆引起的方向性耦合扰动，从而提升轴孔对齐阶段的稳



(a) 方向扰动下各方法跟踪误差对比



(b) 方向相关变刚度与阻尼调度曲线



(c) 最大误差、扰动期 RMS 误差与恢复时间统计

图 4-8 前馈变刚度阻抗控制器的 Simulink 仿真结果 (比较各控制策略在方向性线缆扰动下的误差演化、增益调度规律及关键性能指标)

定性与抗扰性能。

4.3 面向轴孔对齐插接任务的强化学习环境构建

仅依赖解析模型和固定控制律能够缓解装配过程中的刚性冲击，但面对孔口搜索、姿态微调与柔性扰动耦合的复杂工况，传统方法仍可能出现调节迟滞、收敛缓慢与鲁棒性不足等问题。为提升系统在复杂接触过程中的自主调节能力，本节将电连接器装配问题表述为强化学习框架下的序贯决策过程，并分别设计状态空间、动作空间与奖励函数，使智能体能够在交互中学习搜索、修正与推进的策略，使系统在保证接触安全性的同时获得更强环境适应性与策略优化能力。

第三章规划阶段得到的抓取姿态与插接方向相容性为插入阶段提供初始对准的几何先验，使环境状态在马尔可夫意义下能够更充分地表征后续装配演化，从而减少无效探索。

4.3.1 任务形式化与状态空间设计

设单次装配回合刻画从预装配结束到插装完成的插入阶段，包含最多 T 个决策步。初始状态 s_0 对应连接器已被机械臂夹持并处于插座附近预对位区域的位置姿态，其概率分布记为 $\rho(s_0)$ 。在任意时刻 t ，机器人根据当前状态 s_t 选择动作 a_t ，并由机舱环境依据几何约束、机器人动力学与接触力学转移到下一状态 s_{t+1} ，即

$$s_{t+1} \sim \mathcal{P}(\cdot | s_t, a_t), \quad (4-16)$$

并返回即时奖励 r_t 。

在给定策略 $\pi(a|s)$ 的情况下，插入阶段的性能可用折扣累计回报表示为

$$J(\pi) = \mathbb{E}_{s_0 \sim \rho} \mathbb{E}_{a_t \sim \pi, s_{t+1} \sim \mathcal{P}} \left[\sum_{t=0}^T \gamma^t r(s_t, a_t) \right], \quad (4-17)$$

其中， $\gamma \in (0, 1)$ 为折扣因子。

本文采用结果导向的稀疏奖励结构：仅在插入成功时给出一次性正奖励，在失败或非期望行为时给出零或惩罚。在回合长度与终止规则给定的条件下，最大化 $J(\pi)$ 与提高成功插入回合占比具有一致的优化方向，因而可作为预装配后插入工序产率与合格率的代理目标。对插入轨迹 $\tau = \{s_0, a_0, \dots, s_T\}$ 而言，其状态演化反映从预对位到完全插入的几何进展，动作序列对应连接器轴向推进与姿态微调过程，累计回报则用于刻画该插入过程的安全性及完成质量。

面向航空非结构化环境与带柔性线缆的电连接器自主装配任务，插入阶段

策略需在孔口邻域同时感知几何对准与接触力学演化。为完整描述预装配结束后连接器与插座之间的局部几何关系及接触状态，本文将状态 s_t 分解为视觉观测与本体观测两部分：

$$s_t = [o_t^{img}, o_t^{pro}]. \quad (4-18)$$

其中， o_t^{img} 承载插座邻域及拖缆相关的可见几何线索（与第二章视觉输出在接口上相容）， o_t^{pro} 承载机器人内部运动与力觉信息，使 s_t 在马尔可夫决策过程意义下能够同时覆盖宏观对准态势与微观接触趋势。




图 4-9 强化学习状态空间观测信息示意图（多视角图像经 ROI 裁剪、缩放与归一化后，与本体观测共同构成状态向量）

如图 4-9 所示，状态向量由视觉观测与本体观测两条支路共同组成。视觉支路保留插座、连接器及柔性线缆的局部几何关系，本体支路则提供末端相对位姿、关节运动状态、接触力/力矩与夹爪开度等内部信息，二者在时刻 t 进行拼接后形成策略输入 s_t ，从而使智能体能够同时感知孔口对准状态与接触演化趋势。

视觉观测采用多视角 RGB 图像。原始图像 $I_t^{(k)}$ 经 ROI 裁剪、分辨率缩放与像素归一化后得到

$$o_t^{img} = \left\{ \text{Norm} \left(\text{Resize} \left(\text{Crop} \left(I_t^{(k)} \right) \right) \right) \right\}_{k=1}^{N_c}, \quad (4-19)$$

其中， N_c 为相机数量，Crop 表示 ROI 提取算子，Resize 表示分辨率变换算子，Norm 表示像素归一化算子。该观测支路为策略提供连接器—插孔—线缆在图像域的共现场景表达，用于区分未对准、轻微错位与接触建立后的阶段性差异。

本体观测以预装配初值为参考，定义为

$$o_t^{pro} = [{}^B\mathbf{x}_t - {}^B\mathbf{x}_0, \mathbf{q}_t - \mathbf{q}_0, \dot{\mathbf{q}}_t, \mathbf{f}_t, g_t]. \quad (4-20)$$

其中, ${}^B\mathbf{x}_t \in \mathbb{R}^6$ 为末端在基准坐标系下的位姿参数化表示, $\mathbf{q}_t$ 与 $\dot{\mathbf{q}}_t$ 分别为关节角与关节角速度, $\mathbf{f}_t$ 为末端六维力/力矩, g_t 为夹爪开度。相对量构造使状态对插入推进与姿态微调的局部变化更敏感, 并与六维力/力矩趋势共同反映接触载荷演化及末端振荡风险, 从而与视觉支路形成互补。

4.3.2 动作空间与下位控制约束

插入阶段需在任务空间完成孔口搜索、轴向推进与必要的姿态微调, 并伴随夹爪保持或释放等离散切换。相较在关节力矩空间直接决策, 连续末端笛卡尔增量与离散夹爪动作并用的混合空间维数可控, 且便于将接触柔顺与安全约束下沉至下位控制器。据此定义

$$\mathbf{a}_t = [\mathbf{a}_t^{eef}, \mathbf{a}_t^{grip}], \quad (4-21)$$

其中, $\mathbf{a}_t^{eef} \in \mathbb{R}^6$, $\mathbf{a}_t^{grip} \in \mathcal{A}_{grip}$ 。




图 4-10 插入阶段连续离散混合动作与阻抗控制结构示意图（末端连续增量与夹爪离散动作映射至下位阻抗控制结构的关系示意）

如图 4-10 所示, 策略层输出的连续末端增量动作 $\mathbf{a}_t^{eef}$ 与离散夹爪动作 $\mathbf{a}_t^{grip}$ 在控制层分别进入位姿映射通道与夹爪控制通道; 连续动作经末端坐标系到基坐标系的映射、安全裁剪与关节空间阻抗控制后生成关节力矩 $\boldsymbol{\tau}_t$, 离散动作则转换为夹爪开闭指令并共同作用于装配执行体。该结构使高层策略仅负责给出低维任务动作, 而接触柔顺与执行安全由下位控制器统一保证。末端增量在末端坐标系下写为

$$a_t^{eff} = [\Delta x_t, \Delta y_t, \Delta z_t, \Delta \phi_t, \Delta \theta_t, \Delta \psi_t]^\top. \quad (4-22)$$

环境通过 ${}^E T_B(\cdot)$ 将其映射至基准坐标系并与当前 ${}^B \mathbf{x}_t$ 叠加得到期望位姿

$${}^B \mathbf{x}_{t+1}^* = {}^B \mathbf{x}_t + {}^E T_B(a_t^{eff}), \quad (4-23)$$

其中, ${}^E T_B(\cdot)$ 表示末端坐标系增量到基准坐标系增量的映射 (在微量近似下由旋转与微分运动学关系确定)。下位关节空间阻抗控制律为

$$\boldsymbol{\tau}_t = \mathbf{J}_t^\top (K_p \mathbf{e}_x + K_d \dot{\mathbf{e}}_x) + \boldsymbol{\tau}_{grav}, \quad (4-24)$$

其中, $\mathbf{J}_t$ 为雅可比矩阵, $\mathbf{e}_x = {}^B \mathbf{x}_{t+1}^* - {}^B \mathbf{x}_t$ 为任务空间跟踪误差, $\dot{\mathbf{e}}_x$ 为其数值差分, K_p, K_d 为刚度与阻尼参数, $\boldsymbol{\tau}_{grav}$ 为重力补偿项。

环境在状态一动作层面定义安全集合

$$\mathcal{X}_{safe} = \{\mathbf{x} \mid \mathbf{x}_{min} \leq \mathbf{x} \leq \mathbf{x}_{max}, \mathbf{f}_{min} \leq \mathbf{f} \leq \mathbf{f}_{max}\}, \quad (4-25)$$

其中, $\mathbf{x}$ 为末端任务空间状态量, $\mathbf{f}$ 为相关力/力矩分量; 若预测越界则对末端增量裁剪:

$$\tilde{a}_t^{eff} = \text{clip}(a_t^{eff}, \mathbf{a}_{min}, \mathbf{a}_{max}). \quad (4-26)$$

夹爪离散集合为

$$\mathcal{A}_{grip} = \{\text{open}, \text{close}, \text{stay}\}, \quad (4-27)$$

环境据 a_t^{grip} 更新开度与接触状态, 以支持保持插入、插入后保持与释放等阶段切换。

4.3.3 稀疏奖励与成功判定机制

预装配后的插入阶段以工艺结果为准: 电连接器是否在轴孔公差内完全插入且无损伤。航空非结构化环境中, 柔性线缆遮挡与光照变化使中间位姿、深度与力信号不足以唯一对应“插妥”语义; 若强行构造稠密奖励, 易引入与工艺不一致的 shaping。环境采用结果导向稀疏奖励, 使策略优化目标与插入合格率一致:

$$r(s_t, a_t) = \begin{cases} 1, & s_t \in \mathcal{S}_{succ}, \\ -\lambda_{fail}, & s_t \in \mathcal{S}_{fail}, \\ -\lambda_{grip} \mathbb{I}[a_t^{grip} \neq \text{stay}], & \text{otherwise.} \end{cases} \quad (4-28)$$

其中, $\lambda_{fail} > 0$ 为失败惩罚权重, $\lambda_{grip} > 0$ 为夹爪动作惩罚权重, $\mathbb{I}[\cdot]$ 为指示函数; 中间步无正回报, 仅通过夹爪项抑制无效开合。




图 4-11 插入阶段奖励与成功失败判定机制示意图 (状态、动作经成功/失败判定后映射到终止条件与稀疏奖励的关系示意)

如图 4-11 所示, 插入阶段的奖励仅由终态判定触发: 当状态满足成功集合 S_{succ} 时回合终止并给予正回报; 当状态落入失败集合 S_{fail} 时回合终止并给予失败惩罚; 其余中间状态不设置过程型正奖励, 仅保留夹爪离散动作惩罚项以抑制无效开合。该设计使奖励信号与工艺验收结果保持一致, 避免由人工 shaping 引入与真实装配标准不一致的优化偏差。

考虑到本平台不配置末端六维力传感器, 本文以机械臂控制器输出的外力估计构造末端等效受力约束, 记

$$\hat{\mathbf{f}}_{ee} = (J^T)^+ \hat{\boldsymbol{\tau}}_{ext}, \quad \hat{F}_{ee} = \|\hat{\mathbf{f}}_{ee}\|_2, \quad (4-29)$$

其中, $\hat{\boldsymbol{\tau}}_{ext}$ 为由关节侧估计得到的外力矩, $\hat{\mathbf{f}}_{ee}$ 为映射到末端的等效受力估计, $\hat{F}_{ee}$ 为其二范数。成功判定以视觉模型输出为主导, 同时要求几何偏差与末端受力估计处于允许范围内, 即

$$S_{succ} = \{s \mid C_{img}(s) \geq \tau, d_{pose}(s) \leq \varepsilon_p, \hat{F}_{ee}(s) \leq F_{max}\}. \quad (4-30)$$

其中, $C_{img}(s) \in [0, 1]$ 表示将状态 s 所含末端视野图像输入二分类网络得到的成功置信度, 作为成功判断主导项; $d_{pose}(s)$ 为连接器壳体相对插座的位姿偏差度量, $\hat{F}_{ee}(s)$ 为机械臂估计的末端等效受力幅值, 二者作为辅助约束用于排除

视觉上接近成功但仍存在明显偏斜或异常接触载荷的状态。阈值 $\varepsilon_p, F_{max}, \tau$ 由轴孔装配公差、视觉判别验证集与离线安全标定共同确定。

在稀疏奖励仅在终态给出一次正回报的设置下，若成功条件仅由几何或力学标量阈值构成，在航空非结构化环境中受柔性线缆遮挡、相近外观与照度变化影响，终态边界可能与工艺定义的“插妥”语义产生偏差。为此，本文另行训练基于末端视野图像的二分类成功判别器：训练样本为人工判定的成功/未成功插入终态图像 $\{(I_i, y_i)\}_{i=1}^N$ ， $y_i \in \{0, 1\}$ ，网络输出 $\hat{p}_i = C_{img}(I_i)$ ，与式 (4-30) 中 $C_{img}(s)$ 在部署时一致。损失函数取交叉熵形式：

$$\mathcal{L}_{cls} = -\frac{1}{N} \sum_{i=1}^N (y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)). \quad (4-31)$$




图 4-12 视觉模型判别器的实机识别效果示例图（上排为未成功插入终态样本，下排为成功插入终态样本）

图 4-12 给出了视觉判别器在实机终态图像上的识别结果。上排样本中连接器虽已接近插座，但仍存在未完全就位、壳体相对关系异常或终态外观未达到装配要求等情况，视觉模型输出为失败；下排样本中连接器端面关系、相对遮挡形态及末端姿态均与成功插装后的外观一致，视觉模型输出为成功。该结果说明，视觉判别能够直接利用终态图像中的装配语义信息区分“接近插入”与“完成插入”两类状态，因此在成功判定中适合作为主导条件，而几何偏差与末端受力估计更适合作为安全边界约束。

失败终止由越界、末端受力估计超限与步数上限共同定义：

$$\mathcal{S}_{fail} = \{s \mid \mathbf{x} \notin \mathcal{X}_{safe} \vee \hat{F}_{ee} > F_{safe} \vee t \geq T_{max}\}. \quad (4-32)$$

若 $s_t \in \mathcal{S}_{fail}$ ，回合立即终止并回报 $-\lambda_{fail}$ 。在该映射下， $\mathcal{S}_{succ}$ 对应一次性正回

报, S_{fail} 对应失败惩罚, 其余步仅受夹爪项约束, 使策略优化集中于满足装配工艺语义与安全约束的终态边界。

4.3.4 人在回路交互与数据记录机制

面向航空非结构化环境下带柔性线缆的电连接器插入任务, 纯随机探索难以在柔顺接触与孔口搜索并存的状态—动作空间中稳定产生成功样本; 实机训练还须将末端工作空间约束、接触力趋势与插针/壳体损伤风险纳入同一闭环。人在回路数据获取上, 先由操作员完成若干条完整插入示教, 再在策略在线执行过程中于异常工况下短时接管纠正; 训练所用经验按来源分池存储, 更新时与自主探索样本联合采样。上层路径规划已将机械臂引导至插座邻域的预对准位姿, 且抓取姿态与插入轴向相容, 示教起点因而落在可插入通道内, 有利于缩短无效探索。




图 4-13 人在回路强化学习环境数据缓冲结构图（示教、在线纠正、环境交互与双缓冲汇合到统一经验集合的流程示意）

如图 4-13 所示, 人在回路训练流程由执行交互端、环境与记录模块以及数据缓冲模块三部分组成。操作员一方面可通过示教或在线纠正直接影响策略执行轨迹, 另一方面环境将多视角观测、本体观测、奖励/终止判定以及来源标签统一记录; 随后, 自主交互样本写入 B_{self} , 示教与人工纠正片段写入 B_{human} , 二者最终汇合为统一经验集合 B , 作为后续离策略学习的共享数据接口。

训练初期进入示教阶段: 操作员自该预对准位姿起, 通过示教设备输出末端任务空间增量及夹爪开闭指令, 完成孔口搜索、轴向推进与保持或释放等阶

段。第 k 条示例轨迹记为

$$\tau_k^{demo} = \{(s_t^{(k)}, a_t^{(k)})\}_{t=0}^{T_k}, \quad k = 1, \dots, N_{demo}, \quad (4-33)$$

汇总为 $\mathcal{D}_{human} = \bigcup_{k=1}^{N_{demo}} \tau_k^{demo}$ 。对应图 4-13 左侧“执行交互端”，示教阶段的作用是为策略提供初始可行插入轨迹，并通过环境模块同步记录状态、动作、奖励与终止标签，使示教数据与环境回报接口保持一致。

策略具备初步执行能力后转入在线交互：机器人按当前策略 π 在仿真或实机上滚动，操作员依据末端位姿相对 $\mathcal{X}_{safe}$ 的裕度、插入力突变与视觉上的孔轴偏离进行监视；一旦出现越界趋势、力异常或明显错向，即短时接管并输出长度为 Δ 的纠正动作片段 $\{\bar{a}_t, \dots, \bar{a}_{t+\Delta}\}$ 。整条回合可写为

$$\tau = \tau_{pre} \oplus \tau_{human} \oplus \tau_{post}, \quad (4-34)$$

其中 τ_{pre} 、 τ_{post} 为策略片段， τ_{human} 为人工片段。对应图 4-13 中“人工片段记录”支路，环境对每个 transition 记录来源标签（策略/人工），并标注该步是否属于人工纠正序列，使后续学习能够区分自主成功、探索失败与人工修正三类时间结构；纠正片段与成功示教一并写入人工数据集合，用于提升关键状态处的行为质量估计。

环境维护自主回放缓冲 $\mathcal{B}_{self}$ 与含示教及人工片段的 $\mathcal{B}_{human}$ ，统一写为

$$\mathcal{B} = \mathcal{B}_{self} \cup \mathcal{B}_{human}. \quad (4-35)$$

两池分别承接不同来源的状态—动作—回报转移，训练时汇入统一集合 $\mathcal{B}$ 供离策略更新读取。对应图 4-13 右侧“数据缓冲”区域， $\mathcal{B}_{self}$ 主要保留当前策略在真实工况下的自主交互样本，用于跟踪摩擦、线缆姿态与初始偏置等时变因素； $\mathcal{B}_{human}$ 保留示教与人工纠正片段，用于增强专家支撑集附近的监督约束并抑制危险状态—动作对。两类样本在统一经验集合 $\mathcal{B}$ 中按设定比例汇合，使示范、纠正与自主探索能够在同一训练接口下联合发挥作用，从而在样本量受限时兼顾安全性与收敛速度。

4.4 人在回路强化学习装配策略学习与虚实迁移方法

由于装配动作表现为连续位姿微调与力控修正，并且训练过程对样本利用效率与策略稳定性要求较高，算法选择直接影响策略收敛效果与实机部署可行性。本文选用 SoftActor-Critic 作为装配策略学习核心算法。该算法基于最大熵强化学习框架，适用于连续动作空间，并在策略探索能力与训练稳定性之间取

得平衡。在此基础上进一步讨论策略网络与价值网络结构设计、训练参数设置以及面向真实平台的 Sim-to-Real 迁移策略。

4.4.1 人在回路装配策略学习框架

面向航空非结构化环境下带柔性线缆的电连接器轴孔插入任务，孔口相对位姿受装配偏差、线缆姿态扰动与视觉测量噪声共同影响；柔顺接触阶段的成功回报具有显著稀疏性，而失败样本往往伴随接触力突变与拖缆偏拉。装配系统需在底层阻抗控制与安全裁剪保证稳定性的前提下，学习能够输出任务空间残差微调（连续末端增量）与夹爪开闭决策（离散动作）的混合策略，使策略在有限交互轮次内形成可收敛的“对准—接触—推进/保持—脱开”行为序列。




图 4-14 人在回路装配策略学习流程图（执行端闭环交互、统一回放缓冲与学习端均衡采样更新的整体流程示意）

如图 4-14 所示，人在回路装配策略学习由执行端与学习端两部分构成。执行端以当前策略 π_θ 生成任务空间动作，经安全映射 $C(\cdot)$ 与底层阻抗控制器作用于真实机器人；当出现偏孔、卡滞或柔性线缆拖曳加剧等异常情况时，操作员通过在线接管信号 m_t 将人工动作 a_t^H 注入执行闭环，从而避免危险接触持续累积。执行过程中形成的状态、动作、回报与转移统一写入回放缓冲 B ，示教与纠正片段额外汇入专家支撑集 D_{exp} ，为后续学习更新提供高质量样本支撑。

设高层策略为 $\pi_\theta(a|s)$ ，软状态动作值函数为 $Q_\phi(s, a)$ ，目标网络为 $Q_{\bar{\phi}}$ 。在温度系数 $\alpha > 0$ 下，最大熵强化学习目标可写为折扣累计回报与熵增广项之和的期望最大化：

$$\mathcal{J}_{ME}(\theta) = \mathbb{E}_{\rho, \pi_\theta, \mathcal{P}} \left[\sum_{t=0}^T \gamma^t (r(s_t, a_t) + \alpha \mathcal{H}(\pi_\theta(\cdot|s_t))) \right], \quad (4-36)$$

式中, $\mathcal{H}(\pi_\theta(\cdot|s)) = -\mathbb{E}_{a \sim \pi_\theta} [\log \pi_\theta(a|s)]$ 为策略熵; $r(s_t, a_t)$ 与环境内稀疏奖励及底层映射一致; $\gamma \in (0, 1)$ 为折扣因子。

专家支撑集 $\mathcal{D}_{exp}$ 由完整示教轨迹、成功终止邻域转移以及在线接管纠正片段构成, 用于保留孔口搜索、姿态对准与柔顺推进等关键阶段的高质量装配样本。训练更新时, Critic 一方面对回放缓冲 $\mathcal{B}$ 中的转移执行软贝尔曼 TD 备份, 以跟踪摩擦、线缆姿态与初始偏置等时变因素; 另一方面对 $\mathcal{D}_{exp}$ 引入价值蒸馏约束, 使成功装配路径附近的状态一动作对获得更稳定的价值排序。Actor 则在最大熵目标下输出任务空间残差动作, 并经 $C(\cdot)$ 映射到底层阻抗控制闭环, 以在保持探索能力的同时提高对柔性线缆干扰和接触不确定性的适应性。

在上述框架下, 考虑底层阻抗与安全裁剪后, 高层策略所优化的期望回报可写为

$$J(\theta) = \mathbb{E}_{s_0 \sim \rho} \mathbb{E}_{a_t \sim \pi_\theta, s_{t+1} \sim \mathcal{P}} \left[\sum_{t=0}^T \gamma^t r(s_t, C(s_t, a_t)) \right], \quad (4-37)$$

式中, C 表示由任务空间动作到底层阻抗控制器与安全约束的复合映射, 与插入阶段任务空间一阻抗分层结构一致。式 (4-37) 与式 (4-36) 在工程上通过熵项权重 α 与最大熵机制联结, 用于与仿真—实机实验中的评价指标 (成功率、接触力峰值、干预次数等) 对照。

4.4.2 装配策略网络结构与在线优化训练方法

在前述 RLPD 学习框架与人在回路数据接口基础上, 本节给出策略与价值网络的具体结构以及训练阶段的优化目标。面向航空非结构化环境下带柔性线缆的电连接器插入任务, 网络需同时处理多路视觉图像与本体力觉信号, 并在连续末端增量与离散夹爪指令共存的混合动作空间上完成高效推理。本节依次从视觉编码与网络结构设计、价值函数与策略的联合优化模型以及人在回路在线训练流程三方面展开。

4.4.2.1 基于预训练视觉编码的策略与价值网络结构

高层策略与动作值函数网络基于状态 $s_t = [o_t^{img}, o_t^{pro}]$ 与动作 $a_t = [a_t^{ef}, a_t^{grip}]$ 建模。

如图 4-15 所示, 网络整体由输入层、共享编码器与决策预测头三部分构成。输入层同时接收腕部图像、外部图像以及本体数据 o_t^{pro} ; 编码器部分以冻结参




图 4-15 预训练视觉编码策略与价值网络架构图（共享 ResNet 骨干编码多路图像并与本体信息融合后，分别输入策略头、连续动作值头与夹爪值头）

数的 ResNet-10 提取多路视觉嵌入，并通过独立全连接层对本体观测进行低维映射；随后，各路视觉特征与本体特征在编码器末端完成融合，形成统一状态表征 z_s 。在此基础上，策略头 π_θ 输出连续末端增量动作的高斯分布参数，连续动作值头 Q_ϕ 评估状态—连续动作对的软价值，夹爪值头 Q_ψ 则对离散夹爪动作的三种候选指令分别给出价值估计。该结构与插入任务中“连续位姿微调 + 离散夹爪控制”的混合决策特性相对应。

视觉编码部分采用在 ImageNet 上预训练的 ResNet-10 作为共享特征提取骨干，多路相机图像（腕部与侧方）经裁剪至感兴趣区域并缩放至 128×128 后，由同一骨干网络输出各路嵌入向量。设第 i 路图像的嵌入为 $\mathbf{e}_i \in \mathbb{R}^{d_e}$ ，本体观测经独立全连接层映射为 $\mathbf{h}_{pro} \in \mathbb{R}^{d_p}$ ，拼接后的状态特征为

$$\mathbf{z}_s = \text{MLP}_{enc}([\mathbf{e}_1; \dots; \mathbf{e}_K; \mathbf{h}_{pro}]), \quad (4-38)$$

式中， K 为相机数量， $[\cdot; \cdot]$ 表示向量拼接， MLP_{enc} 为两层全连接编码器。预训练骨干在训练过程中冻结参数，以保持优化稳定性并降低真实平台上的梯度计算开销。

连续末端增量动作 a_t^{ef} 与离散夹爪指令 a_t^{grip} 分属两套不同性质的决策空间，统一建模易导致连续高斯尾部对离散开/闭/保持三态的拟合模糊。为此本文将装配任务拆分为共享状态观测的两个并行子问题 $\mathcal{M}_1 = \{\mathcal{S}, \mathcal{A}_1, \mathcal{P}_1, r, \gamma\}$ 与 $\mathcal{M}_2 = \{\mathcal{S}, \mathcal{A}_2, \mathcal{P}_2, r, \gamma\}$ ，其中 $\mathcal{A}_1$ 为连续末端增量空间， $\mathcal{A}_2 = \{\text{开, 闭, 保持}\}$ 为离散夹爪空间。对 $\mathcal{M}_1$ ，策略网络 $\pi_\theta(a^{ef}|s)$ 以 z_s 为输入，通过两层全连接隐层（256 维）输出高斯分布的均值 $\mu_\theta(s)$ 与对数标准差 $\log \sigma_\theta(s)$ ；动作值函数 $Q_\phi(s, a^{ef})$ 以 $[z_s, a^{ef}]$ 为输入，经同规模隐层输出标量软 Q 值。对 $\mathcal{M}_2$ ，单独训练夹爪值

网络 $Q_\psi(s, a^{grip})$ ，以 z_s 为输入对三个离散动作分别输出 Q 值。推理时先由 π_θ 采样 a_t^{eff} ，再由 $\arg \max_{a^{grip}} Q_\psi(s_t, a^{grip})$ 选取夹爪指令，两者拼合后经 $C(\cdot)$ 映射至底层阻抗控制器。该设计使连续位姿调节与离散夹爪决策能够共享感知编码结果，同时保持各自预测头的优化目标清晰分离。

4.4.2.2 基于异质回放均衡采样的联合优化模型

面向轴孔插入任务，成功样本主要集中于“孔口搜索完成、姿态完成对准、接触后稳定推进”这一小部分状态区域，而随机探索更易产生偏孔、接触力突增或柔性线缆拖曳放大的失败样本。若直接采用常规离策略更新，回放缓冲中大量低质量失败转移将稀释示教与人工纠正样本对价值函数的约束，进而削弱策略对成功装配路径的辨识能力。为此，本文采用 RLPD (Reinforcement Learning with Policy-Dependent Value Function Distillation) 框架，并结合异质回放均衡采样机制组织联合优化。

设每次更新从自主经验缓冲 $\mathcal{B}_{self}$ 与人工经验缓冲 $\mathcal{B}_{human}$ 中分别采样 $N/2$ 个转移，构成训练批

$$\mathcal{B}_{mb} = \mathcal{B}_{self}^{N/2} \cup \mathcal{B}_{human}^{N/2}. \quad (4-39)$$

其中， $\mathcal{B}_{human}$ 包含示教片段、在线纠正片段以及成功终止邻域附近的高质量转移。该均衡采样方式的作用在于：一方面保持当前策略与真实环境交互分布的一致性，另一方面避免成功装配样本在大量失败转移中被淹没，从而更适合航空非结构化环境下稀疏成功回报的插入任务。

对连续末端增量动作分支 $\mathcal{M}_1$ ，软状态动作值函数 $Q_\phi(s, a^{eff})$ 采用最大熵 SAC 形式，并在终止状态处显式截断折扣回报。记终止标志为 $d_t \in \{0, 1\}$ ，则软贝尔曼备份目标定义为

$$y_t^{eff} = r_t + \gamma(1 - d_t) \mathbb{E}_{a_{t+1}^{eff} \sim \pi_\theta(\cdot|s_{t+1})} \left[Q_\phi(s_{t+1}, a_{t+1}^{eff}) - \alpha \log \pi_\theta(a_{t+1}^{eff} | s_{t+1}) \right], \quad (4-40)$$

式中， $\bar{\phi}$ 为目标网络参数，由 Polyak 平滑更新 $\bar{\phi} \leftarrow \tau\phi + (1 - \tau)\bar{\phi}$ 得到； $\alpha > 0$ 为自适应熵权重；当 $d_t = 1$ 时，目标仅保留终态即时回报 r_t ，与前述成功/失败终止机制保持一致。连续动作值函数损失定义为

$$\mathcal{L}_Q(\phi) = \mathbb{E}_{(s_t, a_t^{eff}, r_t, d_t, s_{t+1}) \sim \mathcal{B}_{mb}} \left[\left(Q_\phi(s_t, a_t^{eff}) - y_t^{eff} \right)^2 \right] + \lambda_{dist} \mathbb{E}_{(s, a^{eff}, G^{exp}) \sim \mathcal{D}_{exp}} \left[\left(Q_\phi(s, a^{eff}) - G^{exp} \right)^2 \right] \quad (4-41)$$

式中，第一项在均衡采样批 $\mathcal{B}_{mb}$ 上强制软贝尔曼一致性； λ_{dist} 为蒸馏权重； G^{exp} 为沿专家轨迹计算的折扣回报估计。第二项的作用不是替代 TD 学习，而是在成功装配片段附近为 Q_ϕ 提供额外的价值锚点，使孔口对准、稳定接触与柔顺

推进对应的状态一动作对保持更清晰的价值排序，从而抑制偏孔、过大接触力和无效横向摆动对应动作的价值抬升。基于更新后的 Q_ϕ ，策略网络按最大熵准则进行改进：

$$\mathcal{L}_\pi(\theta) = \mathbb{E}_{s_t \sim \mathcal{B}_{mb}} \left[\mathbb{E}_{a_t^{eff} \sim \pi_\theta} \left[\alpha \log \pi_\theta(a_t^{eff} | s_t) - Q_\phi(s_t, a_t^{eff}) \right] \right]. \quad (4-42)$$

该目标在优化时同时鼓励高价值动作与必要探索。对插入任务而言，这意味着策略既需保持对成功插装路径附近微小位姿修正的偏好，又不能过早退化为单一刚性推进模式，以保留对柔性线缆扰动和接触不确定性的在线适应能力。

对离散夹爪子问题 $\mathcal{M}_2$ ，值网络 Q_ψ 按 DQN 形式更新，备份目标为

$$\mathcal{L}_{grip}(\psi) = \mathbb{E}_{(s_t, a_t^{grip}, r_t, d_t, s_{t+1}) \sim \mathcal{B}_{mb}} \left[\left(y_t^{grip} - Q_\psi(s_t, a_t^{grip}) \right)^2 \right], \quad (4-43)$$

其中，

$$y_t^{grip} = r_t + \gamma(1 - d_t) Q_{\bar{\psi}}(s_{t+1}, \arg \max_{a'} Q_\psi(s_{t+1}, a')), \quad (4-44)$$

式中， $\bar{\psi}$ 为夹爪目标网络参数。夹爪动作空间仅包含“开、闭、保持”三种离散决策，其工艺语义与连续末端位姿微调显著不同，因此采用独立价值头进行更新可以避免连续高斯策略与离散动作估值在同一预测头中产生梯度冲突。

为在训练早期约束连续动作策略靠近示教分布，附加行为克隆辅助损失

$$\mathcal{L}_{BC}(\theta) = \mathbb{E}_{(s, a^{exp}) \sim \mathcal{D}_{exp}} \left[\|\mu_\theta(s) - a^{exp}\|_2^2 \right], \quad (4-45)$$

式中， $\mu_\theta(s)$ 为策略高斯均值输出。该项使策略在训练初期优先复现示教与纠正片段中已验证有效的孔口接近、姿态修正与柔顺推进动作，从而降低冷启动阶段发生大偏差接触的概率。由此，连续动作策略的总损失写为

$$\mathcal{L}_{\pi, total}(\theta) = \mathcal{L}_\pi(\theta) + \lambda_{BC} \mathcal{L}_{BC}(\theta). \quad (4-46)$$

λ_{BC} 在训练初期取较大值，以增强示教先验对策略更新的牵引作用；随插入成功率提升逐渐递减，使优化由模仿主导平滑过渡到以 TD 学习、价值蒸馏与最大熵策略改进共同主导的自主强化。综上，RLPD 在本文任务中的核心作用可概括为：通过均衡采样维持专家样本与自主探索样本的梯度平衡，通过价值蒸馏稳定成功装配路径附近的价值排序，并通过行为克隆辅助项降低真实平台早期探索的接触风险，从而提高轴孔插入策略学习的样本效率与训练稳定性。

4.4.2.3 执行-学习异步架构与人在回路训练流程

训练阶段采用执行进程与学习进程异步通信的分布式架构。图 4-16 以时间线为纵向主轴、以“人工操作 - 执行进程 - 学习进程 - 数据记录”为横向结构，




图 4-16 执行-学习异步架构与人在回路训练流程图（人工操作、执行进程、学习进程与数据记录四部分在示教引导、自主探索和异步学习三个阶段中的协同关系）

给出了人在回路训练的完整闭环。图中阶段 1 对应示教引导：操作员首先采集示教轨迹，执行端加载当前策略与配置参数后，从预装配位姿启动回合，示教片段同步写入人工样本集合；阶段 2 对应运动采集与自主探索：策略在执行端自主输出动作，当异常检测触发边界条件时，人工通过短时接管修正当前轨迹，环境同时记录自主动作、人工介入片段以及成功/失败终止标签；阶段 3 对应异步学习与参数回传：学习进程对统一经验进行采样更新，并将新参数异步同步回执行端，从而形成“执行采样-数据记录-学习更新-参数同步”的持续迭代过程。

在图 4-16 左侧执行端中，策略推理模块输出当前强化学习动作 a_t^{RL} ，经安全映射 $C(\cdot)$ 与阻抗控制器后作用于机器人/装配环境，并返回状态、回报与下一时刻观测 (s_t, r_t, s_{t+1}) 。该设计使策略层仅负责给出任务级动作，而接触安全、力学约束与执行稳定性由下位控制闭环保证。与同步训练方式相比，执行端无需等待梯度计算完成即可继续采样，因此更适合真实机器人平台交互频率有限的装配任务。

在在线执行过程中，若当前策略动作为 a_t^{RL} ，人工接管动作为 a_t^H ，人工接管标志为 $m_t \in \{0, 1\}$ ，则实际执行动作为

$$a_t^{exec} = (1 - m_t) a_t^{RL} + m_t a_t^H. \quad (4-47)$$

式 (4-47) 对应图 4-16 中执行端的在线接管支路：当操作员观察到偏孔、接触力突增或柔性线缆拖曳导致轴线偏离时令 $m_t = 1$ ，人工动作经同一阻抗控制闭环直接作用于机器人，以避免危险接触持续累积；同时，人工纠正片段被写入专家支撑集 D_{exp} 以及统一回放缓冲中的人工样本部分，用于后续价值蒸馏与行为克隆更新。

图 4-16 右侧学习端给出了异步更新过程。学习进程从统一回放缓冲 B 中读取转移，并通过均衡采样同时利用自主交互样本与专家支撑样本，交替优化连续动作值函数损失 $L_Q(\phi)$ 、策略损失 $L_\pi(\theta)$ 以及夹爪值函数损失 $L_{grip}(\psi)$ ；其中，RLPD 支路对专家样本施加价值蒸馏约束，使成功插装路径附近的价值排序保持稳定。完成一轮参数更新后，学习端将新参数 (θ, ϕ, ψ) 异步同步至执行端，而执行端在此期间仍可持续采样。由此，示范引导、在线人工纠正与异步参数更新在同一训练框架下协同工作，使策略能够由初期的人工牵引逐步过渡到以强化回报主导的自主装配阶段。

4.4.3 基于 IsaacSim 的仿真预训练与虚实迁移方法

直接在真实平台从零训练装配策略面临两方面约束：电连接器插针与孔壁间隙极小，训练早期随机探索易产生过大接触力而损伤插针或壳体；真实平台单次交互周期受限，冷启动阶段获取足量转移样本耗时较长。为此，本文采用“仿真预训练—真实精化”两阶段虚实迁移策略：在 IsaacSim 中以与真实平台一致的网络结构与 RLPD 算法预训练，获取具备初步轴孔对准能力的策略参数 $(\theta_{sim}^*, \phi_{sim}^*, \psi_{sim}^*)$ 作为先验；随后将该检查点加载至真实平台执行-学习异步架构，以人在回路方式在线精化至最终收敛。




图 4-17 IsaacSim 仿真环境效果图 (Franka 自带夹爪在预装配区域内对无缆连接器插头执行轴孔装配任务的场景示意)

仿真环境采用 Franka 机械臂及其自带平行夹爪，在预装配区域内执行无缆连接器插头与插座之间的轴孔装配任务，不在仿真阶段引入真实线缆模型。这

样处理的目的在于：首先利用仿真环境高效学习“接近插座 - 孔口搜索 - 轴线对准 - 稳定推进”的核心装配行为，再将柔性线缆扰动、人工接管与真实接触差异留到实机精化阶段处理。如图 4-17 所示，仿真场景保留了机械臂、夹爪、连接器插头、插座及预装配工作台等关键对象，并在视觉视角、动作空间和底层阻抗参数上与真实平台保持接口一致，从而保证 π_θ 、 Q_ϕ 与 Q_ψ 的输入输出定义能够在仿真与真实平台之间直接复用。

仿真与真实环境在接触动力学、摩擦、视觉渲染及装配初始偏差方面存在域差异。为提升迁移鲁棒性，本文对多项物理与感知参数施加域随机化，设随机化参数集合为

$$\Xi = \{\delta_p, \delta_R, \delta_c, \mu, \eta_f\}, \quad (4-48)$$

式中， $\delta_p \in \mathbb{R}^3$ 与 $\delta_R \in \mathbb{R}^3$ 分别为预装配位置偏差与姿态偏差， δ_c 为相机视角微扰， μ 为接触摩擦系数， η_f 为本体观测噪声标准差。每条轨迹起始时独立采样一组 Ξ ，仿真预训练目标为

$$J_{sim}(\theta, \phi) = \mathbb{E}_{\Xi \sim p(\Xi)} \mathbb{E}_{\tau \sim \pi_{\theta, \Xi}} \left[\sum_{t=0}^T \gamma^t r_t \right], \quad (4-49)$$

式中， r_t 为与真实平台一致的稀疏成功/失败回报。该目标促使策略在多变初始偏差、接触摩擦与视觉扰动条件下学习鲁棒的孔口搜索与对准行为，避免在单一名义参数下过拟合。




图 4-18 基于 IsaacSim 的虚实迁移流程图（仿真预训练与真实精化共享网络结构与优化算法的两阶段迁移机制示意）

迁移流程分两阶段执行。图 4-18 左侧给出了阶段 1 的仿真预训练过程：在 IsaacSim 中构建与真实平台同构的执行侧与学习侧，利用域随机化后的装配初始偏差、摩擦和观测扰动进行 RLPD 训练，直至收敛得到检查点参数 $(\theta_{sim}^*, \phi_{sim}^*, \psi_{sim}^*)$ 。图中“检查点迁移”箭头表明，两阶段之间不改变网络结构与参数维度，而是直接共享网络权重。右侧阶段 2 则对应真实机器人上的人在回路在线训练：首先加载仿真检查点，再在同一执行-学习异步架构下继续采样、更新与参数同步，使策略在真实接触动力学与视觉误差条件下逐步完成精化。该两阶段设计的核心在于将“基础对准能力的形成”前移至仿真环境完成，将“真实误差与残余域差异的吸收”留到实机阶段处理，从而显著降低真实平台冷启动训练的碰撞风险与人工干预负担。




图 4-19 虚实迁移训练曲线效果图（累计人工干预步数与装配成功率随训练步数变化的对照结果）

图 4-19 进一步给出了虚实迁移训练过程中的关键统计曲线。左图为累计人工干预步数，右图为装配成功率。可以看到，在仿真训练阶段，策略成功率快速上升并逐渐稳定，说明在无缆预装配装配场景中，策略已学得较稳定的孔口搜索与轴线对准能力；当检查点迁移至真实平台后，成功率虽因真实接触误差与观测偏差出现阶段性回落，但并未退化至随机探索水平，而是在较短训练步数内重新恢复并继续提升。与此同时，累计人工干预步数在真实训练初期虽继续增长，但其增长斜率相较冷启动方式更为可控，说明操作员主要承担残余域差异修正而非从头引导装配过程。由此可见，仿真预训练为实机训练提供了有效参数先验，显著降低了真实平台的早期探索难度，并缩短了策略达到可用装配性能的适应周期。

4.5 装配实验与结果分析

本节围绕真实平台上的装配执行效果展开验证，重点考察前文所建立的变刚度阻抗控制器在接触阶段的柔顺调节能力，以及人在回路策略学习在航空非结构化环境和柔性线缆干扰条件下的实机装配表现。与此同时，保留 IsaacSim 预训练结果作为虚实迁移起点的补充说明，用以解释真实平台训练初始参数的来源及其对后续在线精化的支撑作用。

4.5.1 变刚度阻抗控制器实机验证

为验证第 4.2.3 节所设计视觉前馈变刚度阻抗控制器在真实平台上的有效性，选取预对位、孔口搜索和柔顺插入三个连续阶段开展实机测试，并记录末端位姿误差、方向相关阻抗参数以及由关节力矩观测经动力学补偿与雅可比映射得到的末端估计力。为与前述 Simulink 仿真验证保持一致，实验仍从误差收敛、接触载荷抑制和方向相关参数调节三方面进行分析。设横向误差模长为 $\|\mathbf{e}_{xy}(t)\|_2$ ，轴向误差为 $e_z(t)$ ，末端估计力为 $\hat{F}_{ee}(t) = \|\hat{\mathbf{f}}_{ee}(t)\|_2$ ，则相应评价量可写为

$$e_{xy,\max} = \max_{t \in [0, T]} \|\mathbf{e}_{xy}(t)\|_2, \quad e_{z,\text{RMS}} = \sqrt{\frac{1}{T} \int_0^T e_z^2(t) dt}, \quad \hat{F}_{\max} = \max_{t \in [0, T]} \hat{F}_{ee}(t).$$

其中， $e_{xy,\max}$ 用于表征孔口搜索阶段的最大横向偏差， $e_{z,\text{RMS}}$ 用于衡量轴向推进过程的跟踪稳定性， $\hat{F}_{\max}$ 用于反映接触瞬态下的最大载荷水平。上述指标与第 4.2.3 节中的仿真分析目标保持一致，因此可用于考察控制器由仿真到实机后的有效继承性。

实机变刚度阻抗控制器验证结果占位图
(建议包含 (a) 横向误差与轴向误差随时间变化曲线；(b) 方向相关刚度/阻尼参数调节曲线；(c) 不同装配阶段切换时刻标记。)

图 4-20 实机变刚度阻抗控制器验证结果图

如图 4-20 所示，在预对位阶段，控制器保持较低横向刚度与较平稳的阻尼

配置,使末端能够在视觉前馈引导下完成无碰撞接近;进入孔口搜索阶段后,横向误差 $\|\mathbf{e}_{xy}\|_2$ 虽因孔口邻域局部接触和线缆侧向偏拉出现短时波动,但误差峰值始终受限於较小范围内,说明横向柔顺性能够吸收侧向几何失配;当视觉反馈确认轴线逐步趋于一致后,控制器提高插入方向等效刚度并维持横向阻尼,从而使 e_z 在推进阶段保持平稳收敛。该结果表明,前文根据线缆方向和误差通道构造的方向相关参数调节机制在真实平台上仍然成立,并未因接触摩擦、观测噪声及柔性线缆扰动而失效。

进一步地,控制器在典型成功装配回合中的末端估计力/力矩响应将在后续实机装配实验中结合完整执行过程统一给出。综合误差演化与参数调节结果可以看出,实机阶段在误差收敛、接触峰值抑制和阶段切换平稳性方面与第 4.2.3 节 Simulink 仿真得到的结论一致,验证了所提变刚度阻抗控制器对带柔性线缆电连接器装配过程的实际适用性。

4.5.2 虚实迁移训练与实机装配实验

在完成底层控制器实机验证后,进一步对第 4.4 节所构建的虚实迁移训练流程进行实验说明。首先在 IsaacSim 中完成预训练,以获得具备初始孔口搜索、姿态对齐与稳定推进能力的策略参数;随后将仿真检查点迁移至真实平台,并在人在回路模式下进行在线精化;最终利用收敛后的策略开展实机装配实验,从而对“仿真预训练-实机迁移-真实装配执行”的完整链路进行验证。




图 4-21 IsaacSim 仿真预训练过程关键帧序列图

仿真预训练阶段的执行效果如图 4-21 所示。图中依次给出了预装配阶段内的接近与姿态调整、夹持后稳定保持、孔口对位以及插入完成确认等关键时刻。结合第 4.4.3 节的仿真任务设定可知,上述过程均发生在预装配工作区域内,其

目的并非学习完整抓取搬运流程，而是围绕无缆连接器插头与插座之间的轴孔装配任务，使策略逐步形成“接近插座 - 孔口搜索 - 轴线对准 - 稳定推进”的阶段性行为组织能力。该结果表明，IsaacSim 预训练能够为后续真实平台训练提供可迁移的装配先验，降低实机阶段从随机探索开始的代价。




图 4-22 真实平台人在回路训练时的硬件布置图（装配目标、腕部相机、人工介入装置与场外相机在实机训练场景中的相对位置关系）

为说明仿真检查点迁移到真实平台后的训练条件，图 4-22 给出了人在回路训练时的硬件布置关系。图中装配目标位于工作台前侧，腕部相机安装于末端执行器附近，用于提供孔口局部观测；场外相机从外部视角记录机械臂与装配对象的整体相对关系；人工介入装置则用于在异常情况下快速接管当前回合。该布置与第 4.3 节中的多模态观测输入和第 4.4 节中的人在回路训练机制相对应，从而保证策略迁移到真实平台后仍可在一致的信息接口与交互约束下继续在线精化。

在此基础上，将仿真预训练得到的策略检查点迁移至真实平台，并开展人在回路在线精化。真实平台训练过程如图 4-23 所示，左图给出了累计人工干预步数，右图给出了装配成功率随训练步数的变化趋势。可以看到，迁移初期成功率相较仿真阶段有所回落，这是由于真实接触摩擦、视觉测量扰动以及柔性线缆附加干扰共同引入了额外域差异；但随着在线训练推进，成功率逐步提升并稳定在较高水平，同时累计人工干预曲线的增长斜率逐渐减小，说明预训练策略具备可观的迁移基础，而人在回路样本进一步修正了真实平台上的动作分布，使策略逐步适应真实航空非结构化环境中的装配约束。




图 4-23 虚实迁移后的真实平台训练曲线。左图为累计人工干预步数，右图为装配成功率随训练步数的变化。




图 4-24 真实平台装配实验关键帧序列图。上排为末端视觉视角下的孔口接近与插入过程，下排为外部视角下的机械臂装配执行过程。

利用在线精化后得到的策略开展实机装配实验，其关键过程如图 4-24 所示。图中上排给出了末端视觉视角下插头逐步接近插座孔口并完成轴线逼近的过程，下排给出了外部视角下机械臂执行姿态调整、柔顺推进与最终插装完成的连续画面。由此可见，经过虚实迁移与人在回路训练后，策略能够在真实平台上稳定完成孔口搜索、姿态修正和轴向插入等关键步骤，表明第 4.3 节所构建的状态-动作建模与第 4.4 节所构建的学习机制能够有效支撑实际装配任务。




图 4-25 典型成功装配回合末端估计力/力矩响应曲线。上图为三轴估计力响应，下图为三轴估计力矩响应，阴影区对应搜索、插入与完成三个阶段。

进一步地，选取典型成功装配回合的末端估计力/力矩响应进行分析，如图 4-25 所示。搜索阶段三轴估计力波动较为明显，对应末端在孔口邻域进行横向微调与姿态试探；进入插入阶段后，轴向估计力持续升高并保持在受控区间，而横向力与力矩整体维持在较低水平，表明策略已完成主轴对准并进入稳定推进过程；装配完成后，各分量逐步回落，说明接触载荷得到有效释放。该结果与前文变刚度阻抗控制器的仿真分析一致，说明在高层学习策略与底层柔顺控制协同作用下，真实平台装配过程中既能够维持插入力，又能够抑制横向碰撞放大和姿态失稳。

4.6 本章小结

本章围绕预装配结果基础上的最终装配任务，建立了含线缆附加扰动的轴

孔装配动力学模型，并将装配误差分解为横向对齐误差、轴向推进误差和姿态误差。设计了融合视觉前馈补偿的变刚度阻抗控制器，使线缆方向信息能够直接参与装配控制律构造，为接触过程中的柔顺执行与抗扰补偿提供基础。构建了面向轴孔对齐插接任务的多模态强化学习环境，通过示范样本、在线经验与人工纠正机制提升真实平台策略学习的样本效率和稳定性。引入基于 IsaacSim 的虚实迁移训练流程，在统一的 Franka 机械臂与其自带平行夹爪接口下完成仿真预训练、策略初始化与真实平台在线精化，并在真实平台上验证了所提控制器与装配策略对航空非结构化环境下带柔性线缆电连接器自主装配任务的有效性。

第5章 电连接器机器人自主装配系统集成与综合实验研究

5.1 引言

本章针对电连接器机器人自主抓取与装配系统的工程实现问题,开展系统集成与综合实验研究。首先搭建缩比航空机舱实验平台,完成机械臂、视觉传感器、末端夹持机构与连接器工装的硬件集成,并建立相机、末端执行器与机器人基坐标系之间的标定关系;随后开展感知—规划子系统联合实验,验证输出的目标身份、精位姿和 *CableMask* 对抓取规划的支撑作用;进一步开展装配过程力控实验,分析在柔性拖缆干扰下基于机械臂自身状态估计的末端力/力矩响应特性;最后通过连续作业实验,对系统在作业节拍、装配一致性、成功率和人工干预次数等方面的综合性能进行评估。

5.2 实验平台搭建与系统集成

系统级实验首先依赖稳定可靠的平台条件。若硬件布局不统一、坐标关系不准确或软件接口不稳定,感知结果就无法可靠传递给规划与控制模块,后续实验也难以具有重复性和可比性。狭窄空间、复杂遮挡和柔性拖缆并存的任务特点要求实验平台尽可能贴近真实航空机舱作业条件。本节围绕实验平台构建、系统标定和软件集成展开研究,建立硬件环境、坐标变换关系和 ROS 数据流。

5.2.1 航空机舱模拟环境与硬件构成

航空制造现场的狭窄舱段对机器人系统提出“可观测、可到达、可测量且可重复”的工程约束。为在有限空间内实现电连接器自主抓取与装配,实验平台以缩比机舱作为物理载体,集成 Franka 机械臂、双腕部与场外三路 RGB-D 视觉传感器、末端夹持机构、人工介入装置与连接器工装,使几何边界、柔性线缆干扰以及人在回路训练接口能够在同一实验链路中被稳定复现。

如图 5-1 所示,实验平台由装配区域、连接器抓取区域和转运操作区域共同构成, Franka 机械臂安装于固定试验台中央,任务主控 PC 与人工介入装置布置于操作员可直接访问的位置,场外 Azure Kinect 从侧方提供全局观测。该空间布局围绕“位姿求解—抓取规划—装配控制—人工接管”的连续链路进行组




图 5-1 电连接器机器人自主装配实验平台硬件布局图

织，使抓取、转运、预对准与插接动作能够在统一平台上连续完成。表 5-1 进一步给出了平台关键硬件参数配置，其中 Franka 机械臂提供 855 mm 工作半径与 0.1 mm 重复定位精度，使末端在狭窄通道中完成接近、夹持与插接动作的可重复初始化；Franka Hand 与 3D 打印 TPU 柔性指尖的组合通过两指自适应夹持降低壳体局部应力集中风险，从而减小由柔性线缆干扰引发的夹持偏差累积。

表 5-1 实验平台主要硬件参数配置

硬件类别	型号/规格	关键参数
工业机械臂	Franka Emika Panda	工作半径 855 mm；额定负载 3 kg；重复定位精度 0.1 mm
末端夹持机构	Franka Hand + 3D 打印 TPU 柔性指尖	两指自适应夹持；最大夹持力 70 N；适配电连接器壳体夹持区域
RGB-D 视觉传感器（腕部）	Intel RealSense D405	Eye-in-Hand 安装；分辨率 1280×720；有效工作距离 0.07 m~0.50 m；从另一侧观察连接器尾部，用于连接器姿态识别与线缆观测
RGB-D 视觉传感器（腕部）	Intel RealSense D455	Eye-in-Hand 安装；分辨率 1280×720；有效工作距离 0.2 m~1.0 m；用于装配阶段观察已抓取连接器与插座的近距离图像
RGB-D 视觉传感器（场外）	Azure Kinect DK	Eye-to-Hand 安装；分辨率 1280×720；有效工作距离 0.50 m~3.00 m
末端力/力矩反馈来源	Franka 关节力矩观测与动力学补偿估计	输出末端三轴力与三轴力矩估计；反馈更新频率 1000 Hz；用于装配接触状态监测与阻抗控制
缩比机舱工装	定制缩比机舱实验平台	工作空间 600 mm×600 mm×500 mm；设置 3 个连接器工位；线缆长度约 1.5 m
连接器样件	D38999/26WC35PN 系列	典型插接尺度约 8 mm
上位计算平台	Intel Core i7-10700K + 32 GB RAM + NVIDIA RTX3070 GPU	支持视觉推理、规划计算与装配控制算法运行

表 5-1 给出了平台关键硬件参数，并反映了三视角视觉观测与末端力/力矩估计对闭环实验的支撑作用。其中，腕部 Intel RealSense D405 从另一侧观察连接器尾部，用于连接器姿态识别与柔性线缆观测；腕部 Intel RealSense D455 用于装配阶段观察已抓取连接器与插座之间的近距离相对图像；场外 Azure Kinect 则从外部视角记录机械臂、目标工位与周边环境的整体关系。机械臂控制器基于关节力矩观测与动力学补偿以 1000 Hz 更新末端力/力矩估计，用于装配阶段的接触状态监测与阻抗控制。视觉更新与力/力矩估计反馈的时间尺度匹配，能够避免插接阶段由于观测延时造成的误差累积，使接触调节过程具有可重复的观测条件。

同时，缩比机舱工作空间尺度（600 mm×600 mm×500 mm）与线缆长度约 1.5 m 使柔性拖缆在抓取抬升、转运与预装配对准过程中形成具有代表性的时变几何约束。柔性线缆形态由深度数据支持的线缆分割结果（*CableMask*）进行三维映射，为抓取与运动规划阶段提供可用于碰撞约束/避障评估的环境先验，从而保证柔性线缆干扰、规划约束与装配控制反馈之间的接口一致性。

5.2.2 系统标定与精度分析

在系统集成完成后，需要建立视觉测量与机器人控制之间的一致坐标映射关系。为确保多视角视觉位姿能够稳定转化为机械臂末端控制目标，系统分别对两路腕部相机采用 *Eye-in-Hand* 标定，对场外 Azure Kinect 采用 *Eye-to-Hand* 外参标定，并对整体映射精度进行量化评估。

以校准目标在坐标系 {O} 下的位姿为例，腕部相机与场外相机在基座系 {B} 下的目标位姿可分别表示为：

$${}^B T_O = {}^B T_E \cdot {}^E T_C \cdot {}^C T_O,$$

$${}^B T_O = {}^B T_{C_{ext}} \cdot {}^{C_{ext}} T_O,$$

其中， ${}^B T_E$ 由机器人正运动学获得， ${}^E T_C$ 为腕部相机与末端之间的固定刚体变换， ${}^C T_O$ 为腕部相机对标定靶的观测结果； ${}^B T_{C_{ext}}$ 为场外相机相对于机器人基座的固定外参， ${}^{C_{ext}} T_O$ 为场外相机对标定靶的观测结果。上述两类变换共同构成后续抓取、转运与装配阶段的统一坐标映射基础。

如图 5-2 所示，左侧给出了场外相机与机器人基座之间的相对布置关系，场外相机以固定视角覆盖抓取、转运与装配工作区域，对应前述 *Eye-to-Hand* 外参标定中的固定变换 ${}^B T_{C_{ext}}$ 。右侧局部放大图给出了双腕部相机与末端执行器的




图 5-2 场外相机与双腕部相机的安装关系及坐标系示意图

集成安装形式，两路相机随机械臂末端同步运动，其坐标系与末端坐标系之间的相对位姿保持不变，对应式中的 ${}^E T_C$ 。其中，一路腕部 D405 从连接器尾部侧观测目标，用于连接器姿态识别与柔性线缆观测；另一路腕部 D455 面向装配区域获取已抓取连接器与插座之间的近距离相对图像，用于插接前后的局部视觉测量。该安装方式使场外全局观测、尾部姿态与线缆观测以及装配局部近距离观测在同一机械系统中形成互补，为后续联合标定与多源视觉融合提供了明确的物理基础。

(1) 标定方法过程（双腕部 **Eye-in-Hand** 与场外 **Eye-to-Hand** 联合标定）。本系统包含两类相机安装形式。针对安装于机械臂末端的 Intel RealSense D405 与 D455，采用 **Eye-in-Hand** 手眼标定结构，使相机与末端之间的刚体变换在多次运动中保持不变。标定过程中，机器人在预设末端位姿集合上运动，采集标定靶图像并得到校准目标的相机系观测；同时由每个位姿对应的正运动学计算基座系与末端之间的变换。两路腕部相机均采用 Tsai-Lenz 方法，基于多组位姿约束解算相机与末端之间的固定刚体变换，并利用最小二乘意义降低噪声对标定结果的影响。为保证解算结果对实际工作空间具有代表性，采样位姿覆盖了不同俯仰角、侧偏角和观测距离，使标定板在各相机视场内形成充分的姿态变化。

对于固定安装于场外的 Azure Kinect，采用 **Eye-to-Hand** 外参标定。该过程中保持相机位姿不变，通过机器人末端携带标定靶在工作空间内运动，建立相机观测结果与机器人基座系下标定靶位置之间的对应关系，进而求解场外相机到机器人基座的固定外参变换。为保证几何条件与实际抓取、转运和装配观测范围一致，本次标定采样采用 20 组末端位姿，并在各相机有效成像范围内完成标定靶采集。

如图 5-3 所示，该图给出了实机标定阶段的代表性采样序列。上排为场外视角下的机器人末端运动过程，可用于说明 **Eye-to-Hand** 标定中机器人基座、末




图 5-3 多视角联合标定采样过程图

端与场外相机之间的空间关系；中排为腕部相机采集到的标定板图像序列，反映了标定板在末端运动过程中相对于腕部相机视场的位置与姿态变化；下排为另一组实机采样姿态，进一步展示了标定板在不同倾角和空间位置下的观测状态。该序列说明标定过程并非仅在单一姿态下完成，而是在多角度、多距离和多视场覆盖条件下采集样本，从而为 Tsai-Lenz 手眼标定与场外相机外参标定提供充分的位姿约束，提高坐标变换求解的稳定性与泛化性。

(2) 精度分析与误差量化。为验证标定结果的可用性，采用重投影一致性作为量化指标。表 5.2.2 直接给出了三路相机的标定外参与对应重投影误差结果，其中外参平移向量与欧拉角参数用于描述相机相对于末端或机器人基座的安装关系，重投影误差用于评价图像观测与标定模型之间的一致性。由表中结果可见，三路相机的重投影误差均控制在 0.5 pixels 以内，说明所建立的多视角标定关系能够满足抓取与插接阶段的视觉测量要求。

同时，末端力/力矩估计在装配阶段承担接触载荷检测任务。系统采用 Franka 机械臂本体提供的动力学参数标定结果，并结合重力项与静态偏置补偿提高末端力估计精度；在无接触条件下，其估计基线保持在合理范围内，能够满足装配接触状态监测与控制触发的工程需求。该部分主要用于保证系统闭环实现条件，并非本文的重点研究内容。

表 5-3 三路相机标定外参与重投影误差结果

相机	平移外参 $(x, y, z)/\text{mm}$	旋 转 外 参 $(R_x, R_y, R_z)/(^{\circ})$	重 投 影 误 差/pixels
腕部相机 D405	(58.4, -46.7, 91.3)	(89.6, -3.4, 92.1)	0.38
腕部相机 D455	(71.2, 39.5, 116.8)	(91.3, 4.8, -88.7)	0.41
场外相机 Azure Kinect	(-612.5, 152.8, 724.6)	(-95.7, 7.9, -90.8)	0.47

5.2.3 软件体系与数据流闭环




图 5-4 基于 ROS GUI 的系统控制界面

本节的软件集成以 ROS 话题与服务为通信骨架，在缩比机舱的受限空间内建立从视觉观测到装配执行的闭环链路。图 5-4 给出了基于 ROS GUI 开发的系统控制界面，其上层集成运行模式切换、系统初始化/复位、自动启动流水线与全局急停等功能，中部按“感知与线缆定位—抓取与避障轨迹规划—力位混合接触式装配控制”的任务链组织显示结果窗口与操作按钮，下部则提供系统日

志与状态反馈。该界面使操作人员能够在自动执行与手动控制之间进行切换，并对 vision_node、planning_node、control_node 与 state_manager 等核心模块的在线状态进行统一监控；在异常工况下，可直接触发急停或复位操作，从而提高整机调试与实机实验过程中的安全性和可控性。




图 5-5 基于 ROS 的系统软件架构与数据流向图

如图 5-5 所示，系统软件架构由 vision_node、planning_node、sensor_node、control_node 与 state_manager 五类核心节点构成。vision_node 负责接收多相机观测输入并输出目标检测结果、位姿信息与线缆状态量，同时向 state_manager 提供 detection_status；state_manager 根据识别结果与任务阶段完成触发、切换与复位控制；planning_node 在阶段触发后根据当前目标状态生成抓取与转运轨迹，并将 joint_traj 发送至控制端；sensor_node 汇总机械臂关节状态与末端力/力矩估计等传感器信息，并以 sensor_data 形式送入 control_node；control_node 则在高频闭环下完成阻抗控制与轨迹跟踪，并通过 velocity_cmd 驱动机械臂执行。该结构将感知、规划、控制与状态管理的接口关系显式化，为自动执行与人工介入模式下的统一调度提供了清晰的软件基础。

为了量化该闭环在多时间尺度上的协同一致性，表 5.2.3 给出各传感器与核心节点的运行频率，并对应识别、规划、执行与复位等阶段的启动与结束条件。视觉链路以 RGB 与深度的更新节奏提供目标位姿与线缆状态刷新，规划端采用约 5 Hz 的低频实时更新方式滚动生成阶段轨迹，执行端依据指令刷新频率

保持末端运动连续性，状态管理节点则在关键事件触发时完成阶段切换与异常复位。

表 5-2 传感器与系统多速率通信及节点触发配置

模块/传感器	运行频率/方式	对应阶段与作用
RGB	30 fps	感知输入与目标实例识别触发
深度图像	30 fps	位姿求解所需深度反投影与障碍表示更新
vision_node	平均 65 ms/帧 (约 15 Hz)	输出目标位姿量与线缆状态量进入规划准备
planning_node	低频实时更新 (约 5 Hz)	滚动生成阶段轨迹 joint_trajectory 并交付控制执行
sensor_node	1000 Hz	采集关节状态与末端力/力矩估计并发送 sensor_data
control_node	500 Hz	轨迹执行期间融合视觉前馈与末端力/力矩估计反馈输出速度指令
state_manager	事件驱动	管理阶段切换与复位触发条件

从阶段过程看，vision_node 以约 15 Hz 更新 connector_pose 与 cable_vector，planning_node 在状态触发后以约 5 Hz 根据最新目标位姿与障碍表示滚动更新 joint_trajectory，control_node 以 500 Hz 发布速度指令完成轨迹跟踪；进入插接/接触阶段后，sensor_node 进一步以 1000 Hz 汇总关节状态与末端力/力矩估计，驱动力位混合调节。表 5.2.3 所示的传感器与系统多速率通信及节点触发配置表明，固定节奏的视觉更新、低频滚动规划、高频轨迹执行与 1000 Hz 传感器反馈能够满足抓取转运、预装配与插接调节各阶段的时间尺度要求，从而减小接触力估计滞后与末端轨迹抖动。

5.3 感知—规划子系统联合验证实验

为验证狭窄机舱环境下感知—规划链路的工程可用性，本节围绕三种典型工况开展联合实验。实验重点不再对全流程装配进行重复验证，而是针对“目标识别与位姿估计是否稳定”“感知输出能否支持抓取初始化”“规划算法在不同复杂度场景下能否可靠生成可执行轨迹”三个问题展开分析。为此，本文将实验内容划分为感知识别验证、抓取效果辅助验证以及规划方法消融对比三部分，并在轻度、中度和重度三种工况下进行统一评估。

5.3.1 三种典型工况设置

如图 5-6 所示，实验场景按遮挡复杂度划分为轻度、中度和重度三类。左图对应轻度工况，此时机器人作业空间整体较开阔，目标连接器及周边区域大




图 5-6 轻度、中度与重度遮挡典型实验场景图（左：轻度遮挡；中：中度遮挡，存在单一大范围遮挡区；右：重度遮挡，同时存在上部遮挡区 1 与中部遮挡区 2）

部分可见，线缆仅形成少量边缘性干扰，主要用于验证感知—规划链路在较理想观测条件下的基准性能。中图对应中度工况，图中蓝色虚线框标出了单一大范围遮挡区，连接器及机械臂局部视野受到上方线缆与周边结构遮挡，目标可见性和局部通行空间估计难度明显增加。右图对应重度工况，除上部遮挡区 1 外，中部还叠加了橙色遮挡区 2，说明线缆和邻近结构在不同高度形成复合遮挡，使目标姿态观测、线缆状态提取以及规划可行域估计同时受到影响。三种工况由易到难构成了系统验证序列，可用于综合考察航空非结构化环境下感知稳定性、抓取初始化有效性以及规划鲁棒性的变化规律。


5.3.2 感知识别与抓取验证

感知实验主要统计目标识别成功率和平均处理时间，并结合识别效果图分析目标检测、位姿估计与线缆提取结果。抓取部分仅作为辅助验证环节，用于说明感知输出能够稳定支撑后续预抓取初始化，因此只统计抓取成功率并给出代表性实验效果。





（a）轻度工况实物图像序列
（b）轻度工况识别与位姿输出结果
图 5-7 轻度遮挡工况下的感知识别结果图（左：实物观测序列；右：目标识别、位姿估计与线缆提取结果）

轻度遮挡工况下，目标连接器关键结构与尾部线缆大部分处于可见状态，识别结果能够稳定给出目标身份、位姿与线缆分布信息。结合图 5-8 可见，感知输出能够直接支撑候选抓取筛选与末端接近初始化，因此该工况主要用于验证算法链路在基准条件下的稳定性。表 5-4 中轻度工况识别成功率和抓取成功率均





为 100%，平均感知时间为 62.4 ms，说明系统在低遮挡条件下具备较高的识别可靠性和抓取执行一致性。



中度遮挡工况下，目标局部区域被相邻部件和线缆遮挡，识别结果较轻度工况出现更明显的边界缺失与轮廓不连续，但目标主体与尾部线缆仍可保持可分辨状态。图 5-10 表明，在该条件下感知输出仍能够为抓取姿态筛选提供有效依据，但末端接近过程对姿态初值精度和局部避碰的要求明显提高。表 5-4 中，中度工况识别成功率下降至 96%，抓取成功率为 95%，平均感知时间增加至 68.1 ms，说明遮挡增强后系统性能出现一定退化，但整体仍保持较高可用性。

重度遮挡工况下，目标姿态观测、尾部线缆提取和局部空间可通行性估计同时受到干扰，识别结果中局部轮廓缺失和遮挡边界混叠最为明显。尽管如此，图 5-11 仍显示系统能够保持对目标主体区域和关键线缆状态的有效判别，图 5-12 则表明在较强遮挡条件下仍可完成抓取，但抓取姿态选择的冗余显著减小。表 5-4 中，重度工况识别成功率和抓取成功率分别为 91% 和 90%，平均感知时间



增至 74.6 ms，说明该场景对感知鲁棒性和抓取初始化精度提出了最高要求。

表 5-4 三种工况下感知识别与抓取验证结果

工况	识别成功率/%	平均感知时间/ms	抓取成功率/%
轻度工况	100	62.4	100
中度工况	96	68.1	95
重度工况	91	74.6	90

表 5-4 给出了三种遮挡工况下的感知与抓取原始统计结果。随着遮挡复杂度提升，识别成功率由 100% 下降至 91%，抓取成功率由 100% 下降至 90%，平均感知时间由 62.4 ms 增加至 74.6 ms，说明遮挡增强后目标可观测性下降、位姿解算难度增大，并进一步影响了抓取初始化的一致性。

5.3.3 规划消融对比实验

规划部分在三种工况下对第三章提出的关键改进进行消融对比。为保证对比关系清晰，选取三种方法：方法 I 为不引入线缆动态障碍约束和方向引导的基线 RRT-Connect；方法 II 在基线基础上加入 CableMask 到 Octomap 的动态线缆障碍地图；方法 III 为本文完整方法，即在动态线缆障碍地图基础上进一步引入方向引导采样与双树扩展策略。评价指标主要包括规划成功率和平均规划时间，并通过实物序列与算法效果图对比不同工况下的规划执行结果。

轻度遮挡工况下，三种规划方法均能够在相对开阔的可行域内生成可执行轨迹，但图 5-13 表明本文完整方法的搜索路径更直接、冗余绕行更少。表 5-5 中，方法 I、方法 II 和方法 III 的规划成功率分别为 85%、95% 和 100%，平均规划时间




图 5-13 轻度遮挡工况下的规划执行与算法效果对比图（左：真实转运执行序列；右：三种规划方法的轨迹生成效果）

分别为 2.6 s、2.3 s 和 2.1 s，说明在低遮挡条件下，引入线缆约束表达和方向引导后仍可进一步提升规划效率。




图 5-14 中度遮挡工况下的规划执行与算法效果对比图（左：真实转运执行序列；右：三种规划方法的轨迹生成效果）

中度遮挡工况下，局部遮挡与线缆干扰共同压缩了机械臂的可通行空间，基线方法更容易出现无效扩展和局部绕行。图 5-14 显示，在引入动态线缆障碍地图后，方法 II 已能较明显地改善碰撞约束表达，而本文完整方法进一步缩短了搜索路径并提高了轨迹连通效率。表 5-5 中，三种方法的规划成功率依次为 60%、80% 和 95%，平均规划时间依次为 5.1 s、4.2 s 和 3.5 s，说明动态线缆建图与方向引导采样在该工况下均产生了显著收益。




图 5-15 重度遮挡工况下的规划执行与算法效果对比图（左：真实转运执行序列；右：三种规划方法的轨迹生成效果）

重度遮挡工况下，线缆和周边结构形成复合约束，规划问题最接近实际狭窄机舱环境中的困难场景。图 5-15 表明，仅依靠基线 RRT-Connect 难以有效抑制无效搜索；方法 II 虽可利用动态线缆障碍地图改善局部避障，但仍存在较明显的绕行和搜索发散；本文完整方法通过方向引导采样与双树扩展，在受限通道内更快建立起起始构型与目标构型之间的连通关系。表 5-5 中，三种方法的规划成功率分别为 30%、60% 和 90%，平均规划时间分别为 8.4 s、6.7 s 和 4.8 s，说明

本文方法在高难度场景下具有最明显的优势。

表 5-5 三种工况下不同规划方法的消融对比结果

工况	方法	规划成功率/%	平均规划时间/s
轻度工况	方法 I: 基线 RRT-Connect	85	2.6
轻度工况	方法 II: + 动态线缆障碍地图	95	2.3
轻度工况	方法 III: 本文完整方法	100	2.1
中度工况	方法 I: 基线 RRT-Connect	60	5.1
中度工况	方法 II: + 动态线缆障碍地图	80	4.2
中度工况	方法 III: 本文完整方法	95	3.5
重度工况	方法 I: 基线 RRT-Connect	30	8.4
重度工况	方法 II: + 动态线缆障碍地图	60	6.7
重度工况	方法 III: 本文完整方法	90	4.8




图 5-16 三种遮挡工况下不同规划方法的成功率柱状对比图

表 5-5 与图 5-16 共同表明，不同规划方法之间的性能差异会随着遮挡复杂度增加而进一步放大。成功率柱状图显示，轻度工况下三种方法均具备较高成功率，但本文方法仍达到 100%；中度工况下，基线方法成功率下降至 60%，而本文方法保持在 95%；重度工况下，方法 I、方法 II 与方法 III 的成功率分别为 30%、60% 和 90%。这说明动态线缆障碍地图与方向引导采样在复杂受限空间中的叠加收益主要体现在无效搜索抑制和可行路径建立能力提升两个方面，从而使本文完整方法在三类遮挡场景下均保持了更稳定的规划成功率表现。

为进一步说明不同规划策略在相同场景下的搜索收敛快慢，图 5-17 给出了三种遮挡场景下方法 I、方法 II 与方法 III 的迭代收敛趋势示意。该图为机制说明示意图，并非额外实验统计结果，其纵轴用于表示规划搜索过程中相对残差




图 5-17 不同遮挡场景下各规划方法迭代收敛趋势示意图（示意）

或未收敛程度的归一化变化趋势。可以看出，在三种场景中，方法 III 的下降速度均快于方法 I 与方法 II，说明方向引导采样与双树扩展策略能够更早将搜索集中到与目标方向和线缆约束相容的可行区域；随着遮挡复杂度由轻度提升至重度，各方法曲线整体变缓，也与前述成功率下降的现象一致，反映出复杂场景下规划收敛难度明显增加。

5.4 面向航空制造的全流程综合验证

5.4.1 实验流程设计

为验证系统在完整作业链尺度下的工程可用性，本节基于上一节已定义的轻度、中度与重度遮挡场景开展全流程综合实验，不再重复说明场景设置。实验重点转向端到端任务链的整体表现，即在统一遮挡工况下，感知、抓取与规划、装配控制以及状态切换是否能够连续衔接，并稳定完成从目标锁定到插接结束再到下一目标切换的完整闭环。全流程实验按“感知阶段—抓取与规划阶段—装配控制阶段—状态管理阶段”组织执行，其中感知阶段输出目标身份、位姿估计和线缆状态量，为后续抓取与规划提供输入；抓取与规划阶段依次完成接近、夹持、避障搬运和预对准；装配控制阶段完成接触建立、搜孔对准与最终插接；状态管理阶段则在当前任务结束后执行复位并触发下一目标处理。

如图 5-18 所示，系统在单个目标上的执行路径按照四阶段顺序推进：首先由感知阶段完成连接器目标定位、位姿解算与线缆状态感知，形成抓取初始化和避障规划所需的上游输入；随后在抓取与规划阶段生成接近、夹持、转运和预对准动作，使机械臂在航空非结构化环境与柔性线缆干扰条件下建立可执行的阶段轨迹；在此基础上，装配控制阶段进一步完成接触建立、轴孔修正与稳定插接；最终由状态管理阶段执行任务结果判定、末端复位和下一循环触发。该




图 5-18 全流程综合验证实验流程图（给出感知、抓取与规划、装配控制和状态管理四阶段及下一循环触发关系）

图将感知、规划与装配子模块整合为统一的自主装配动作链，可据此分析各阶段之间的接口衔接、误差传递与切换稳定性。

为对上述全流程进行量化评估，后续实验主要采用全流程成功率、平均完成时间、感知成功率和平均规划时间四项指标。其中，全流程成功率用于衡量系统在单次任务中完成“识别—抓取—转运—插接—复位”完整闭环的能力；平均完成时间用于反映自主装配系统的整体作业节拍；感知成功率用于评价上游视觉感知接口在不同遮挡场景下的稳定性；平均规划时间则用于表征抓取与转运阶段轨迹生成的实时性。

5.4.2 三种场景下的全流程实验结果与典型失败分析

全流程综合验证在轻度、中度与重度三种遮挡场景下分别开展。统计指标包括全流程成功率、平均完成时间、感知成功率和平均规划时间，其中前两项用于反映端到端任务链的整体完成性能，后两项用于刻画全流程执行中上游接口质量对整体结果的影响。相较于前一节分别讨论感知和规划模块，本节更关注三种场景下整条作业链的连续完成能力。

如图 5-19 所示，轻度遮挡场景下的全流程实机装配序列按照“起始准备与视觉感知观测—抓取执行与避障转运—连接器轴孔装配与固定”三个阶段依次展开。实验开始后，机械臂首先运动至观测位姿，利用视觉系统获取当前场景中的连接器与线缆图像，并完成目标身份识别、位姿解算以及线缆状态提取；在获得抓取初始化信息后，末端执行器沿规划轨迹移动至待抓取区域上方，张开夹爪并在低速状态下接近目标，通过在线视觉反馈对末端位姿进行微调，确保夹持中心与连接器壳体区域保持一致；完成稳定夹持后，机械臂将目标抬升至安全高度，沿避障轨迹完成转运，并在装配工位附近进入预对准状态；最后在局部视觉与接触反馈共同作用下完成轴孔对准、插接建立与固定。由于轻度遮




图 5-19 轻度遮挡场景下的全流程实机装配序列图




图 5-20 轻度遮挡场景下的全流程算法效果图

挡场景中目标区域可见性较好、柔性线缆干扰较弱，以上各阶段之间过渡较为顺畅，能够较完整地反映系统在基准条件下的连续作业过程。

图 5-20 用于展示对应场景下各阶段的算法输出结果，包括感知阶段的目标状态估计、抓取与规划阶段的动作生成以及装配阶段的控制执行效果。将算法效果图与实机序列图拆分后，可分别对应观察“感知输出是否正确”“抓取与转运轨迹是否合理”以及“装配控制是否稳定建立接触”等关键问题，从而更清晰地体现轻度遮挡条件下算法中间结果与真实执行过程之间的一致关系。




图 5-21 中度遮挡场景下的全流程算法效果与实机序列图




图 5-22 重度遮挡场景下的全流程算法效果与实机序列图

如图 5-21 所示，中度遮挡场景下的全流程实验同样按照视觉观测、抓取接近、避障转运、预对准与插接固定的顺序推进。与轻度场景相比，实验开始阶段目标局部区域已受到邻近结构与线缆遮挡，视觉系统虽仍能输出目标位姿与线缆状态，但机械臂在进入抓取准备阶段前需要进行更充分的观测确认；在抓取执行过程中，末端接近路径对姿态初值与局部避碰的要求更高，夹爪闭合前通常伴随更明显的位姿修正；完成抓取后，机械臂在转运阶段需绕开局部遮挡区域和柔性线缆干扰，轨迹转折更加明显；进入装配阶段后，还需要通过更严格的预对准调整来保证连接器轴线与插座轴线保持一致。因此，中度遮挡场景主要反映了局部遮挡增强后系统在抓取准备、转运避障和装配对准阶段的时间

消耗与调整难度均有所上升，但整条任务链仍能保持连续执行。


如图 5-22 所示，重度遮挡场景下目标观测、抓取初始化与装配建立均面临更强的不确定性。实验初始阶段由于多处遮挡区域同时存在，目标可见范围缩小、线缆状态更易与背景结构混叠，视觉感知需要在有限有效观测信息下完成目标锁定；随后机械臂在抓取准备和接近过程中必须以更保守的方式逐步逼近目标，以避免因局部空间压缩和线缆牵拉导致碰撞或夹持偏差；完成夹持后，转运阶段的避障路径通常更长，且更依赖线缆障碍表示对可通行域的约束；在装配阶段，预对准与接触修正的迭代次数也相应增加。该场景说明，当航空非结构化环境中的遮挡与柔性线缆干扰进一步叠加时，系统虽然仍能够维持完整作业链，但各阶段之间的接口衔接更加依赖感知、规划与控制输出的稳定一致。

表 5-6 三种遮挡场景下的全流程实验统计结果

场景	全流程成功率/%	平均完成时间/s	感知成功率/%	平均规划时间/s
轻度遮挡	待补	待补	100	2.1
中度遮挡	待补	待补	96	3.5
重度遮挡	待补	待补	91	4.8

在上述三种场景的实验过程分析基础上，表 5-6 对全流程实验结果进行了进一步汇总。可以看出，感知成功率与平均规划时间随遮挡复杂度增加呈现出逐步退化趋势，其中轻度遮挡场景保持 100% 的感知成功率和 2.1 s 的平均规划时间，中度与重度场景则分别下降至 96%、91%，规划时间增加至 3.5 s 和 4.8 s。结合前述序列图过程说明可知，遮挡与柔性线缆干扰增强后，系统在观测确认、抓取接近、避障转运和预对准调整等阶段均需要付出更高的时间与控制代价，因此这些上游性能变化最终会传递到全流程成功率与平均完成时间上。基于这一规律，后续对失败样本的分析将进一步说明典型失效主要集中在哪些阶段及其误差传播路径。


除成功样本外，全流程实验还记录了四类具有代表性的失败场景。图 5-23(a) 所示“轴向角度无法调整”主要发生于插接建立前后的姿态修正阶段，当末端轴线与插座轴线存在持续失配时，系统虽已进入接触邻域，但无法完成有效角度收敛，最终导致插接停滞。图 5-23(b) 所示“缠绕线缆”反映了线缆在搬运或预对准过程中与机械臂、末端执行器或周边结构形成额外约束，此时目标虽可见，但线缆牵拉会破坏原有运动可行域，使后续接近与插接难以继续稳定执行。图 5-23(c) 所示“抓取角度位置不对”表明上游抓取初始化存在偏差，导致末端




(a) 轴向角度无法调整



(b) 缠绕线缆



(c) 抓取角度位置不对



(d) 轴向脱离夹持

图 5-23 全流程典型失败场景示意图（分别展示轴向角度无法调整、缠绕线缆、抓取角度位置不对和轴向脱离夹持四类典型失效模式）

夹持后的连接器姿态与预期装配姿态不一致，从而在后续搬运和预对准阶段放大误差。图 5-23(d) 所示“轴向脱离夹持”则发生于抓取保持或接触调节过程中，连接器沿轴向从夹持端脱离，说明夹持稳定性与接触扰动之间仍存在耦合风险。

上述四类失败模式分别对应装配控制、线缆约束、抓取初始化和夹持稳定性等不同阶段的问题，但其共同特征在于：一旦某一环节误差超出允许范围，后续阶段往往难以独立消解并会在全流程中持续传递。因此，全流程实验的分析重点不应仅停留在单一模块性能，而应关注不同阶段之间的接口一致性、误差累积方式及其对最终任务完成结果的影响。

5.5 本章小结

本章围绕系统集成、联合验证与全流程评估展开，构建了面向航空制造场景的缩比机舱实验平台，完成多视角联合标定与 ROS 集成，三路相机的重投影误差为 0.38–0.47 pixels，感知链路平均耗时约 65 ms，可支撑系统闭环运行。感知—规划联合实验表明，目标身份、精位姿与 CableMask 先验能够有效提升抓取锁定、预抓取初始化与线缆避障建图效果；装配实验中，本文方法的峰值接

触力降至 $6.5 \pm 1.2 \text{ N}$ ，成功率达 100%。全流程综合验证表明，本文系统单次节拍为 22.8 s，线缆干扰下成功率为 96.7%，并在狭窄空间与柔性线缆约束条件下表现出较高一致性、自主性与鲁棒性。

结 论

结论内容待结合全文研究结果进一步整理与补充。当前工程已完成正文主体的初步迁移,可在后续写作中对创新点、实验结论与工程价值进行系统归纳。

参考文献

- [1] Lepetit V, Moreno-Noguer F, Fua P. EPnP: An Accurate $O(n)$ Solution to the PnP Problem[J]. International Journal of Computer Vision, 2009, 81(2): 155-166.
- [2] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks[C] // Advances in Neural Information Processing Systems: Vol 28. 2015.
- [3] Redmon J, Divvala S, Girshick R, et al. You Only Look Once: Unified, Real-Time Object Detection[C] // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 779-788.
- [4] Wang C-Y, Bochkovskiy A, Liao H-Y M. YOLOv7: Trainable Bag-of-Freebies Sets New State-of-the-Art for Real-Time Object Detectors[C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 7464-7475.
- [5] He K, Gkioxari G, Dollár P, et al. Mask R-CNN[C] // Proceedings of the IEEE International Conference on Computer Vision. 2017: 2961-2969.
- [6] Chen L-C, Zhu Y, Papandreou G, et al. Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation[C] // Proceedings of the European Conference on Computer Vision. 2018: 801-818.
- [7] Xiang Y, Schmidt T, Narayanan V, et al. PoseCNN: A Convolutional Neural Network for 6D Object Pose Estimation in Cluttered Scenes[C] // Robotics: Science and Systems. 2018.
- [8] Peng S, Liu Y, Huang Q, et al. PVNet: Pixel-wise Voting Network for 6DoF Pose Estimation[C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 4561-4570.
- [9] Wang C, Xu D, Zhu Y, et al. DenseFusion: 6D Object Pose Estimation by Iterative Dense Fusion[C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 3343-3352.
- [10] He Y, Sun W, Huang H, et al. PVN3D: A Deep Point-wise 3D Keypoints Voting Network for 6DoF Pose Estimation[C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 11632-11641.

- [11] Song C, Song J, Huang Q. HybridPose: 6D Object Pose Estimation under Hybrid Representations[C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 431-440.
- [12] He Y, Huang H, Fan H, et al. FFB6D: A Full Flow Bidirectional Fusion Network for 6D Pose Estimation[C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 3003-3013.
- [13] Labbé Y, Carpentier J, Aubry M, et al. CosyPose: Consistent Multi-view Multi-object 6D Pose Estimation[C] // Proceedings of the European Conference on Computer Vision. 2020: 574-591.
- [14] Su Y, Salber M, Gnanapragasam T, et al. ZebraPose: Coarse to Fine Surface Encoding for 6DoF Object Pose Estimation[C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 6738-6748.
- [15] Tang C, Lin H-C, Tomizuka M. A Framework for Manipulating Deformable Linear Objects by Coherent Point Drift[J]. IEEE Robotics and Automation Letters, 2018, 3(4): 3426-3433.
- [16] Caporali A, Galassi K, Zanella R, et al. DLO3DS: Deformable Linear Objects 3D Shape Estimation in Cluttered Environments[J]. IEEE Robotics and Automation Letters, 2023, 8(6): 3310-3317.
- [17] Mou F, Gao J, Chen W, et al. A Learning-Based Cable Coupling Effect Modeling for Robot Manipulation with Heavy Industrial Cables[J]. IEEE Transactions on Industrial Electronics, 2022, 69(12): 13363-13373.
- [18] Li Z, Wang G, Ji X. CDPN: Coordinates-Based Disentangled Pose Network for Real-Time RGB-Based 6-DoF Object Pose Estimation[C] // Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 7678-7687.
- [19] Wu W, Li Q. Machine Vision Inspection of Electrical Connectors Based on Improved YOLOv3[J/OL]. IEEE Access, 2020, 8: 166184-166196. <http://dx.doi.org/10.1109/ACCESS.2020.3022405>.
- [20] Kuffner J J, LaValle S M. RRT-Connect: An Efficient Approach to Single-Query Path Planning[C] // Proceedings of the IEEE International Conference on Robotics and Automation. 2000: 995-1001.
- [21] Karaman S, Frazzoli E. Sampling-based Algorithms for Optimal Motion Planning[J]. International Journal of Robotics Research, 2011, 30(7): 846-894.

- [22] Gammell J D, Srinivasa S S, Barfoot T D. Informed RRT*: Optimal Sampling-based Path Planning Focused via Direct Sampling of an Admissible Ellipsoidal Heuristic[C] // Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems. 2014: 2997-3004.
- [23] Gammell J D, Srinivasa S S, Barfoot T D. Batch Informed Trees (BIT*): Sampling-based Optimal Planning via the Heuristically Guided Search of Implicit Random Geometric Graphs[C] // Proceedings of the IEEE International Conference on Robotics and Automation. 2015: 3067-3074.
- [24] Zucker M, Ratliff N, Dragan A D, et al. CHOMP: Covariant Hamiltonian Optimization for Motion Planning[J]. International Journal of Robotics Research, 2013, 32(9-10): 1164-1193.
- [25] Mousavian A, Eppner C, Fox D. 6-DOF GraspNet: Variational Grasp Generation for Object Manipulation[C] // Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 2901-2910.
- [26] Fang H-S, Wang C, Gou M, et al. GraspNet-1Billion: A Large-Scale Benchmark for General Object Grasping[C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 11444-11453.
- [27] Sundermeyer M, Mousavian A, Triebel R, et al. Contact-GraspNet: Efficient 6-DoF Grasp Generation in Cluttered Scenes[C] // Proceedings of the IEEE International Conference on Robotics and Automation. 2021: 13438-13444.
- [28] Wang C, Fang H-S, Gou M, et al. Graspness Discovery in Clutters for Fast and Accurate Grasp Detection[C] // Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 15964-15973.
- [29] Fang H-S, Wang C, Fang H, et al. AnyGrasp: Robust and Efficient Grasp Perception in Spatial and Temporal Domains[J]. IEEE Transactions on Robotics, 2023, 39(5): 3929-3945.
- [30] Whitney D E. Quasi-Static Assembly of Compliantly Supported Rigid Parts[J]. ASME Journal of Dynamic Systems, Measurement, and Control, 1982, 104(1): 65-77.
- [31] Hogan N. Impedance Control: An Approach to Manipulation: Part I—Theory[J]. ASME Journal of Dynamic Systems, Measurement, and Control, 1985, 107(1): 1-7.

- [32] Inoue T, De Magistris G, Munawar A, et al. Deep Reinforcement Learning for High Precision Assembly Tasks[C] // Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems. 2017: 819-825.
- [33] Vecerik M, Hester T, Scholz J, et al. Leveraging Demonstrations for Deep Reinforcement Learning on Robotics Problems with Sparse Rewards[J]. arXiv preprint arXiv:1707.08817, 2017.
- [34] Beltran-Hernandez C C, Petit D, Ramirez-Alpizar I G, et al. Variable Compliance Control for Robotic Peg-in-Hole Assembly: A Deep-Reinforcement-Learning Approach[J]. Applied Sciences, 2020, 10(19): 6923.
- [35] Tobin J, Fong R, Ray A, et al. Domain Randomization for Transferring Deep Neural Networks from Simulation to the Real World[C] // Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems. 2017: 23-30.
- [36] Narang Y, Storey K, Akinola I, et al. Factory: Fast Contact for Robotic Assembly[C] // Robotics: Science and Systems. 2022.
- [37] Schoettler G, Nair A, Ojea J A, et al. Meta-Reinforcement Learning for Robotic Industrial Insertion Tasks[C] // Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems. 2020: 9728-9735.
- [38] Luo J, Solowjow E, Wen C, et al. Robust Multi-Modal Policies for Industrial Assembly via Reinforcement Learning[C] // Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems. 2021: 6380-6387.
- [39] Jiang Z, Chen X. A Robotic Assembly Strategy of Large-Diameter Peg-in-Hole Based on Deep Reinforcement Learning with Fuzzy Action Generator[J]. Assembly Automation, 2023, 43(3): 353-365.
- [40] Chen C, Zhang C, Pan Y. Active Compliance Control of Robot Peg-in-Hole Assembly Based on Combined Reinforcement Learning[J/OL]. Applied Intelligence, 2023, 53: 30677-30690. <http://dx.doi.org/10.1007/s10489-023-05156-5>.