

硕士学位论文

(学术学位论文)

面向航空制造的电连接器机器人自主抓取 与装配系统研究

**RESEARCH ON ROBOTIC AUTONOMOUS
GRASPING AND ASSEMBLY SYSTEM FOR
ELECTRICAL CONNECTORS IN AVIATION
MANUFACTURING**

待填写

哈尔滨工业大学

2026 年 3 月

国内图书分类号：TP242
国际图书分类号：621.8

学校代码：10213
密级：公开

硕士学位论文

面向航空制造的电连接器机器人自主抓取 与装配系统研究

硕士研究生：待填写

导 师：待填写

申 请 学 位：工学硕士

学 科 或 类 别：机械工程

所 在 单 位：机电工程学院

答 辩 日 期：2026 年 3 月

授予学位单位：哈尔滨工业大学

Classified Index: TP242

U.D.C: 621.8

Dissertation for the Master's Degree

**RESEARCH ON ROBOTIC
AUTONOMOUS GRASPING AND
ASSEMBLY SYSTEM FOR ELECTRICAL
CONNECTORS IN AVIATION
MANUFACTURING**

Candidate:	To Be Filled
Supervisor:	To Be Filled
Academic Degree Applied for:	Master of Engineering
Specialty:	Mechanical Engineering
Affiliation:	School of Mechatronics Engineering
Date of Defence:	March, 2026
Degree-Confering-Institution:	Harbin Institute of Technology

摘 要

本文面向航空制造场景下电连接器机器人自主抓取与装配任务，围绕复杂机舱环境中目标遮挡严重、柔性线缆干扰显著以及狭窄空间运动受限等问题，研究电连接器视觉感知、自主抓取规划与柔顺装配控制方法。论文以电连接器为核心对象，构建由目标识别与位姿估计、候选抓取生成与筛选、引导式避障路径规划以及装配控制组成的技术路线，为形成面向航空非结构化环境的自主装配系统提供方法基础。

在视觉感知方面，论文研究多实例连接器识别、标签身份区分、6D 位姿估计及线缆掩膜提取方法；在自主抓取方面，研究面向装配任务的候选抓取生成、多约束抓取筛选以及避开柔性线缆障碍的运动规划策略；在装配执行方面，进一步为后续柔顺控制与系统集成提供状态输入与轨迹先验。现有内容已迁移至本 LaTeX 工程中，后续可在此基础上继续完善摘要、参考文献、图表与实验结果。

关键词：航空制造；电连接器；自主抓取；柔顺装配；机器人系统

Abstract

This thesis focuses on robotic autonomous grasping and assembly of electrical connectors in aviation manufacturing scenarios. Aiming at severe occlusion, flexible cable interference, and motion constraints in narrow cabin environments, the work investigates visual perception, grasp planning, and compliant assembly methods for electrical connectors. The overall technical route includes target recognition and pose estimation, candidate grasp generation and selection, guided collision-free motion planning, and subsequent assembly-oriented control.

The current LaTeX project has been initialized according to the HIT thesis template, and the existing thesis content has been migrated into chapter files. It can be further refined by completing metadata, references, figures, tables, and experimental results.

Keywords: aviation manufacturing, electrical connector, autonomous grasping, compliant assembly, robotic system

目 录

摘 要	I
Abstract	II
第 1 章 绪论	1
1.1 课题来源	1
1.2 课题研究背景及意义	1
1.3 国内外研究现状	2
1.3.1 目标感知与 6D 位姿估计研究现状	2
1.3.2 复杂受限空间规划与避障研究现状	5
1.3.3 机器人精密力控装配研究现状	7
1.3.4 国内外研究现状分析	9
1.4 本文的主要研究内容	10
第 2 章 基于深度学习的电连接器识别与位姿估计研究	12
2.1 引言	12
2.2 标签识别数据集的制作与分析	12
2.2.1 数据采集与标注方案	13
2.2.2 数据增强	14
2.2.3 数据集特征分析	15
2.3 基于 YOLOv8-seg 的目标检测与实例分割	17
2.3.1 算法选型与总体结构	17
2.3.2 损失函数与训练参数设置	19
2.3.3 动态 ROI 裁剪策略	22
2.4 基于改进 DeepLabV3+ 的关键特征提取与线缆分割	23
2.4.1 网络模型分析	24
2.4.2 高斯热力图建模方法	25
2.4.3 改进输出头与联合损失设计	28
2.5 基于 EPnP 与 RANSAC 的电连接器位姿解算	31
2.5.1 相机投影模型与 EPnP 求解	32
2.5.2 基于 RANSAC 的外点剔除	33

2.5.3 手眼标定与坐标系转换	35
2.6 算法验证实验.....	36
2.7 本章小结	39
第 3 章 电连接器自主抓取方法研究	40
3.1 引言	40
3.2 端到端 6D 抓取生成网络	40
3.2.1 抓取位姿参数化表示	40
3.2.2 基于局部点云的网络输入构建	41
3.2.3 改进的 Contact-GraspNet 网络结构	44
3.2.4 正负样本判定与损失函数设计	46
3.3 抓取点选择策略研究	48
3.3.1 基于逆运动学的可达性判别.....	48
3.3.2 面向线缆障碍的安全间隙评价	50
3.3.3 面向任务的姿态相容性评价.....	52
3.3.4 综合评分函数与最优抓取确定	52
3.4 GRRT-Connect 运动规划算法研究.....	53
3.4.1 混合障碍物地图构建	54
3.4.2 引导式采样与双树扩展策略.....	56
3.4.3 路径生成与后处理优化	60
3.5 实验与结果分析	63
3.6 本章小结	65
第 4 章 电连接器柔顺装配控制方法研究	66
4.1 引言	66
4.2 含线缆干扰的轴孔装配动力学建模与控制器设计	66
4.2.1 轴孔装配误差描述	66
4.2.2 含线缆干扰的装配动力学模型	68
4.2.3 视觉前馈变刚度阻抗控制器设计	71
4.3 面向轴孔对齐插接任务的强化学习环境构建	74
4.3.1 任务形式化与状态空间设计.....	75
4.3.2 动作空间与下位控制约束.....	76
4.3.3 稀疏奖励与成功判定机制.....	78
4.3.4 人在回路交互与数据记录机制	79
4.4 人在回路强化学习装配策略学习与虚实迁移方法	81

4.4.1 人在回路装配策略学习框架.....	81
4.4.2 装配策略网络结构与在线优化训练方法.....	83
4.4.3 基于 IsaacSim 的仿真预训练与虚实迁移方法.....	86
4.5 装配实验与结果分析.....	87
4.5.1 IsaacSim 仿真预训练验证.....	88
4.5.2 真实平台人在回路训练与装配验证.....	89
4.6 本章小结.....	91
第 5 章 电连接器机器人自主装配系统集成与综合实验研究	92
5.1 引言.....	92
5.2 实验平台搭建与系统集成.....	92
5.2.1 航空机舱模拟环境与硬件构成.....	92
5.2.2 系统标定与精度分析.....	94
5.2.3 软件体系与数据流闭环.....	95
5.3 感知—规划子系统联合验证实验.....	97
5.4 面向航空制造的全流程综合验证.....	101
5.4.1 实验流程设计.....	101
5.4.2 综合效能评估与结果分析.....	102
5.5 本章小结.....	105
结 论	106
参考文献	107

第 1 章 绪论

1.1 课题来源

本课题来源于国家自然科学基金集成项目“面向航空制造的人-机器人协作技术及应用研究”，资助号：92048301。

1.2 课题研究背景及意义

在国家航空装备智能制造升级需求推动下，机舱电气系统的自动化装配已成为提升整机质量与可靠性的重要方向。电连接器作为机舱内信号与能量传输的关键节点，其装配质量直接关系到飞行安全与维护成本。当前该工序仍以人工为主，操作者需在布满管路、线槽与设备舱壁的狭窄空间中借助手持工具完成插接与锁紧，长期高强度作业导致一致性、可重复性和过程可追溯性不足。随着机舱内部系统集成度持续提高，单纯依赖人工已难以满足高可靠、标准化装配的要求，机器人替代或协同人工作业具有迫切的工程需求。

航空机舱装配环境与传统工业产线存在显著差异，可归纳为三方面。第一，空间约束突出：机舱内部结构件、舱壁与管线支架密集，布线区域狭窄且多处于深腔位置，机械臂接近目标时面临典型窄通道问题。第二，光照条件恶劣：金属舱壁强反射、局部照明不均与深阴影并存，严重干扰基于边缘与纹理特征的传统视觉算法。第三，装配对象呈刚柔耦合特性：电连接器尾部整合有柔性线缆，线缆在重力与布线约束作用下呈随机弯曲形态，在视觉层面遮挡壳体、定位孔等关键几何特征，在动力学层面引入随位姿变化的拖拽力与回复力矩，使感知精度与装配可靠性同时受到制约。

上述环境特殊性决定了电连接器机器人自主抓取与装配本质上是一个涉及复杂环境感知、柔性障碍建模、狭窄空间规划和不确定接触控制的跨模块耦合问题。然而现有研究大多针对单一子问题展开，如仅优化 6D 位姿估计精度、仅考虑刚性障碍下的运动规划，或仅围绕标准 *peg-in-hole* 任务进行策略学习，尚未形成针对航空机舱环境中带柔性拖缆电连接器抓取与装配的系统化解决方案。

在此背景下，构建面向航空制造的电连接器机器人自主抓取与装配系统，具有重要的理论价值和工程意义。在理论层面，该研究有助于推动复杂遮挡下目标感知与位姿估计、柔性障碍参与的受限空间规划以及带未知扰动的接触装

配控制等方向的交叉融合，为构建“感知—规划—控制”闭环的机器人装配理论体系提供实践支撑。在工程层面，通过实现电连接器从识别、抓取、避障搬运到柔顺插接的全流程自动化，可显著提升航空机舱装配效率与一致性，降低人工劳动强度，并为后续复杂线缆束装配与人机协作奠定基础。

1.3 国内外研究现状

1.3.1 目标感知与 6D 位姿估计研究现状

目标感知与 6D 位姿估计是机器人自主装配系统的前端关键环节，其任务是从单目、双目或 RGB-D 观测中获取目标类别、实例身份及完整的六自由度姿态信息，为后续抓取规划与装配控制提供几何约束。在航空机舱电连接器装配场景中，该问题因多实例共存、金属壳体纹理贫乏、局部强反光以及柔性线缆遮挡等因素而呈现更高的复杂度，不仅需要完成连接器身份识别与精确位姿估计，还需同步提取线缆延伸形态以服务于后续规划与力控模块。

早期 6D 位姿估计方法以 EPnP^[1] 等几何求解器与 RANSAC 鲁棒估计范式为代表，在已知二维—三维对应关系条件下可高效求解物体位姿，但高度依赖可靠的局部特征提取。在航空机舱环境中，金属壳体弱纹理与强镜面反射使特征检测器频繁失效，柔性线缆的大面积遮挡进一步削弱了可用特征，导致几何方法鲁棒性明显下降。

随着深度学习的快速发展，基于卷积神经网络的目标检测方法成为复杂场景视觉感知的主流方案。以 Faster R-CNN^[3] 为代表的两阶段检测框架（如图1-1所示）与以 YOLO^[4] 为代表的单阶段回归式检测框架（如图1-2所示）分别从精度和速度两个维度推动了目标检测的进步。Wang 等人于 2023 年提出的 YOLOv7^[5] 进一步将实时检测精度推至新高度。




图 1-1
(空白占位图)

图 1-1 Faster R-CNN 模型结构示意图（RPN 区域建议网络与 RoI Pooling 联合检测框架）

在实例分割方面，Mask R-CNN^[6] 通过在检测框架中增加像素级掩膜预测分

图 1-2
(空白占位图)

图 1-2 YOLO 模型结构示意图 (单阶段回归式检测框架的端到端预测流程)

支开创了检测—分割联合学习范式; DeepLabV3+^[7] 则以编码器—解码器结构与空洞可分离卷积在语义分割精度与效率之间取得了良好平衡。上述技术的持续进步为复杂遮挡条件下的电连接器多实例识别与线缆掩膜提取奠定了方法基础。

在基于深度学习的 6D 位姿估计方面, 研究路线已从 PoseCNN^[8] 等直接回归方法发展为关键点投票、稠密对应和多模态融合等多条技术路径。Peng 等人于 2019 年提出 PVNet^[9], 采用像素级关键点投票策略, 通过对目标表面各像素预测指向预定义关键点方向向量并进行投票聚合来定位关键点, 有效缓解了遮挡对关键点检测的影响。Wang 等人于 2019 年提出 DenseFusion^[10], 将 RGB 特征与深度点云特征在像素级进行稠密融合, 并通过迭代精化网络逐步优化位姿预测, 在 YCB-Video 等基准数据集上取得了当时的最优精度。

He 等人于 2020 年提出 PVN3D^[11], 将关键点投票机制拓展至三维点云空间, 通过深度逐点投票网络在三维空间中定位关键点, 进一步提升了对遮挡和杂乱背景的鲁棒性。Song 等人于 2020 年提出 HybridPose^[12], 引入关键点、边向量和对称对应三种混合中间表示, 利用多类型几何特征的互补性增强位姿回归在遮挡工况下的稳定性。上述方法的技术路线对比如图 1-3 所示。

图 1-3
(空白占位图)

图 1-3 典型 6D 位姿估计方法技术路线对比示意图 (由直接回归、关键点投票、稠密对应到多模态融合的演进路径)

在多实例场景与面向装配的位姿估计方面，近年来涌现了若干重要进展。He 等人于 2021 年提出 FFB6D^[13]，构建了 RGB 与点云之间的双向全流融合网络，在特征编码阶段实现两种模态信息的深度交互，显著提升了对低纹理与遮挡物体的位姿估计精度。Labbé 等人于 2020 年提出 CosyPose^[14]，面向多视图多物体场景，通过单视图位姿假设生成、跨视图鲁棒匹配以及物体级光束法平差三个阶段的级联处理，实现了对多实例场景中各物体 6D 位姿的一致性估计，并在 BOP Challenge 2020 中获得最佳整体方法与最佳纯 RGB 方法等多项冠军。Su 等人于 2022 年提出 ZebraPose^[15]，采用分层二进制表面编码策略，以由粗到精的方式建立图像像素与模型表面的稠密对应关系，在 LM-O 与 YCB-V 基准上部分指标已超越 RGB-D 方法。上述研究表明，6D 位姿估计技术正从单对象静态识别向面向多实例、多模态融合和装配任务导向的综合感知阶段演进。

在柔性线缆与细长变形物体感知方面，Tang 等人于 2018 年提出基于相干点漂移的柔性线性物体操作框架^[16]，利用 B 样条曲线建模线缆形状并结合点云信息实现三维状态估计，为线缆形态的实时感知提供了方法基础。Caporali 等人于 2023 年提出 DLO3DS 方法^[17]，通过多视图二维图像重建柔性线性物体的三维形状，平均重建误差达到 0.82 mm，验证了在工业级精度要求下利用普通相机实现线缆三维感知的可行性。

Mou 等人于 2022 年在重型工业电缆操作研究中提出基于二维卷积神经网络的电缆耦合效应建模方法^[18]，通过数据驱动方式学习电缆对机器人末端力与力矩的影响规律，耦合效应估计精度超过 85%，表明将柔性电缆的动力学特性纳入系统建模可显著提升对耦合干扰的预测能力。

在国内研究方面，清华大学 Li 等人于 2019 年提出 CDPN^[19]，通过将旋转与平移解耦为坐标预测与位姿回归两个独立子任务，在 LINEMOD 数据集上取得了当时最优的纯 RGB 位姿估计精度，并在 BOP Challenge 2019 中获最佳纯 RGB 方法奖，验证了解耦策略在弱纹理目标位姿估计中的有效性。在工业视觉检测方面，Wu 等人于 2020 年提出基于改进 YOLOv3 的电连接器机器视觉检测方法^[20]，通过 K-means 聚类优化锚框比例、特征图融合与残差结构改进，实现了对电连接器焊点缺陷与旋转缺陷的自动化检测，准确率达 93.5%，表明基于深度学习的目标检测方法已具备在电连接器工业检测场景中落地的可行性。上述国内工作为本文面向航空机舱场景的电连接器多实例检测与线缆精细分割提供了重要的方法借鉴与工程经验。

综合上述研究可以看出，目标感知与 6D 位姿估计技术已在遮挡鲁棒性、多模态融合和多实例处理方面取得显著进展，但针对“柔性线缆严重遮挡条件下

多实例电连接器区分与面向装配的位姿及线缆形态联合估计”这一组合问题仍缺乏针对性解决方案。现有研究通常将柔性线缆视为背景或一般遮挡源，未将其系统建模为后续抓取规划与力控装配所需的重要几何与物理信息载体，这限制了感知结果在整条抓取—装配链路中的可利用程度。

1.3.2 复杂受限空间规划与避障研究现状

在完成目标感知与位姿估计之后，机器人需要在复杂受限空间内规划从当前构型到目标抓取位姿以及从抓取位姿到装配位姿的无碰撞轨迹，运动规划算法的性能直接影响系统的安全性与效率。传统路径规划方法包括基于图搜索的 A* 与 D* 算法，以及基于随机采样的 PRM 和 RRT 系列算法，其中 RRT 类方法因对高维配置空间的良好适应性而被广泛用于机械臂运动规划问题。

Kuffner 与 LaValle 于 2000 年提出 RRT-Connect 算法^[19]，采用双树同步扩展与贪心连接策略使高维配置空间中的规划效率显著提升，已成为机械臂运动规划的经典基线方法，其搜索树扩展过程如图1-4所示。然而后续研究表明，该算法在存在长窄通道的配置空间中仍面临大量无效采样问题，桥接测试等采样策略虽可改善窄通道场景中的可行性，但整体收敛速度仍有提升空间。



图 1-4
(空白占位图)

图 1-4 RRT-Connect 算法双树搜索扩展示意图（起始树 $\mathcal{T}_{init}$ 与目标树 $\mathcal{T}_{goal}$ 交替扩展并贪心连接的过程）

在渐近最优规划方面，Karaman 与 Frazzoli 于 2011 年提出的 RRT*^[21] 通过代价函数与邻域重连机制从理论上证明了路径代价的渐近最优性，Gammell 等人在此基础上先后提出 Informed RRT*^[22] 与 BIT*^[23]，分别通过椭球启发式采样和批量启发式搜索进一步加速了收敛。在轨迹优化方面，CHOMP^[24] 利用协变量哈密顿框架在轨迹平滑性与障碍物代价间进行迭代优化，为受限空间中的路径质量优化提供了有效手段。

在面向特定受限环境的规划改进方面，已有研究针对工业装配场景中的狭

窄空间约束展开工作。相关方法通过引入目标偏置采样、环境势场引导和窄通道检测等启发式策略，在典型窄通道场景中显著缩短规划时间并提高路径成功率。同时，面向多约束环境的规划方法将几何约束、关节极限和末端姿态要求统一纳入采样与校验框架，为航空制造等空间高度受限的应用场景提供了技术参考。上述研究表明，通过引入启发式信息、环境结构特征以及局部优化策略，可显著改善传统 RRT 类算法在受限空间中的性能表现。

在抓取生成方面，近年来基于深度学习的六自由度抓取生成方法取得了快速发展。Mousavian 等人于 2019 年提出 6-DOF GraspNet^[25]，采用变分自编码器从单目深度图像生成六自由度抓取姿态，通过对抓取质量进行评估与精化实现了对未知物体的泛化抓取生成。Fang 等人于 2020 年构建 GraspNet-1Billion 基准数据集^[26]，包含超过 97000 张 RGB-D 图像和十亿量级标注抓取位姿，并提出基于点云的端到端抓取生成网络，通过解耦接近方向与操作参数实现抓取姿态的高效预测，如图1-5所示。Sundermeyer 等人于 2021 年提出 Contact-GraspNet^[27]，利用深度网络从场景点云直接预测接触点和六自由度抓取姿态分布，在复杂遮挡与堆叠场景中展现出良好的泛化性和较高的抓取成功率，为“感知—抓取一体化”的系统设计提供了实践范式。

图 1-5
(空白占位图)

图 1-5 基于点云的 6DoF 抓取生成方法流程示意图（场景/局部点云输入—特征提取—接近方向与夹持参数多分支预测—候选抓取位姿集合输出）

在面向装配任务的抓取规划方面，研究重点逐渐从单纯提升抓取成功率转向考虑抓取姿态与后续任务目标之间的相容性。具体而言，抓取姿态不仅需要保证夹持稳定性，还需满足后续插接操作对末端朝向和接近方向的约束，即任务相容性抓取。近期研究通过将分割模型与抓取网络级联实现对指定目标的选择性抓取，部分工作还将装配方向约束编码至抓取评分函数中，从候选集合中筛选与装配轴线对齐度最高的姿态。

在国内学者的工作中，上海交通大学卢策吾团队在通用抓取感知领域做出

了系统性贡献。在构建 GraspNet-1Billion 大规模基准^[26]的基础上, Wang 等人于 2021 年提出基于 Graspness 先验的抓取检测方法^[27], 通过几何可抓取性度量对场景点云进行快速筛选, 在 GraspNet-1Billion 基准上将检测精度提升超过 30 AP 的同时保持了较高的推理速度。Fang 等人于 2023 年进一步提出 AnyGrasp^[28], 实现了空间与时间域上鲁棒、高效的七自由度稠密抓取感知, 在超过 300 种未知物体的料箱拣选任务中达到 93.3% 的成功率, 接近人类水平, 为复杂杂乱场景中的高精度抓取提供了工业级解决方案。上述国内研究为本文面向航空制造场景的抓取生成与规划提供了技术基础与数据支撑。

然而, 上述研究大多在开放或半结构化桌面环境中验证, 鲜有工作将柔性线缆作为显式障碍纳入抓取可达性分析与路径规划。在电连接器机舱装配场景下, 机器人不仅需要避开舱壁和设备等刚性障碍, 还需避开与目标零件耦合的柔性线缆, 其形态随时间动态变化。现有规划方法通常将柔性障碍等效为静态膨胀后的刚性体, 并未充分利用视觉感知到的线缆形态信息构建动态障碍物地图, 这在狭窄机舱空间内容易导致路径与线缆发生缠绕或近距离擦碰, 影响抓取与装配可靠性。

1.3.3 机器人精密力控装配研究现状

机器人精密装配, 尤其是 peg-in-hole、插拔连接器等接触丰富型任务, 是工业机器人技术的重要应用领域之一。Whitney^[28]建立的柔顺中心理论与 Hogan^[29]提出的阻抗控制理论(其等效模型如图1-6所示)构成了力控装配的经典理论基础, 在此之上衍生出导纳控制、混合力/位置控制等柔顺方法, 广泛应用于处理装配过程中的接触不确定性。

图 1-6
(空白占位图)

图 1-6 阻抗控制等效弹簧—阻尼—质量模型示意图(机器人末端与环境交互的力—位动力学关系)

随着非结构化环境下装配需求的提升, 传统解析模型在应对多源不确定性与复杂干扰力时逐渐显现局限。深度强化学习因此被引入装配领域: Inoue 等

人^[30]率先将 DRL 应用于高精度 peg-in-hole 任务并实现亚毫米级装配，验证了数据驱动策略在精密装配中的可行性。

Vecerik 等人于 2017 年提出利用人工示教数据增强深度强化学习的探索效率^[31]，通过将示教轨迹与智能体交互数据统一存储于优先经验回放缓冲区，在稀疏奖励条件下显著加速了柔性零件插入任务的策略收敛。Beltran-Hernandez 等人于 2020 年提出基于深度强化学习的变柔顺控制方法^[32]，针对位置控制型机器人的 peg-in-hole 任务通过域随机化与迁移学习实现了从仿真到实物的策略迁移，在存在孔位不确定性的条件下完成了高精度插接。

在仿真到真实迁移方面，Tobin 等人^[33]提出的域随机化方法通过在仿真中随机化视觉参数实现了策略的 Sim-to-Real 迁移；Narang 等人^[34]提出的 Factory 仿真框架利用 GPU 加速碰撞检测将接触丰富型场景仿真速度提升超过两万倍，为大规模装配策略学习提供了高效平台。

Schoettler 等人于 2020 年针对工业连接器插入任务，提出基于深度强化学习结合视觉输入与自然奖励信号的方法^[35]，在真实机器人上完成了连接器插入操作，实验表明将强化学习与先验信息相结合可在合理的真实交互次数内求解接触丰富型插入任务。上述仿真到实机迁移的一般流程如图1-7所示。




图 1-7
(空白占位图)

图 1-7 基于深度强化学习的装配策略仿真到实机迁移流程示意图（仿真环境构建—域随机化训练—Sim-to-Real 策略迁移—真实机器人部署）

在多模态策略学习与奖励设计方面，研究者致力于将视觉、力觉和本体感觉信息统一纳入装配策略的学习框架。Luo 等人于 2021 年发表面向工业装配的鲁棒多模态策略大规模研究^[36]，通过系统比较结合示教的 DRL 方法与专业工业集成商的基线方案，在 NIST 标准装配基准上证明 DRL 系统在速度与可靠性方面均优于后者，为 DRL 在真实工业场景中的落地提供了有力证据。Jiang 与 Chen 于 2023 年提出结合 DDPG 与模糊动作生成器的大直径轴孔装配策略^[37]，通过模糊规则补偿强化学习输出的动作偏差，在保持训练收敛速度的同时将装

配接触力降低约 30%，为复杂接触工况下精密装配的奖励函数与动作空间设计提供了参考。

在柔性电缆干扰方面，Mou 等人于 2022 年提出基于学习的电缆耦合效应建模方法^[18]，通过二维卷积神经网络预测重型工业电缆对机器人末端的附加力与力矩，耦合效应估计精度超过 85%，末端定位误差小于 0.01 mm，表明柔性线缆对运动控制及装配过程具有不可忽视的动力学影响，将其显式纳入控制模型可显著提升操作精度。

在国内相关研究方面，Chen 等人于 2023 年提出基于组合强化学习的机器人轴孔装配主动柔顺控制方法^[21]，通过状态判断深度 Q 网络与参数优化深度 Q 网络的级联架构在线调整变阻抗控制器参数，在 0.40 mm 间隙条件下装配成功率达 96%，验证了将强化学习策略分层解耦可有效提高物理机器人装配任务的学习效率与成功率。结合前述 Jiang 与 Chen^[37] 在模糊策略补偿以及 Mou 等人^[18] 在柔性电缆耦合效应建模方面的工作，国内学者在强化学习与力控装配的交叉领域已形成多点布局，但针对带拖缆电连接器这一特殊对象的干扰补偿策略仍有待深入。

然而，现有基于 DRL 的装配策略大多将外部干扰力简化为随机噪声或统计分布，并未显式利用视觉信息估计柔性线缆的方向与形态来构建前馈补偿项。在带拖缆电连接器装配任务中，线缆拖拽力具有明确的方向性且随插接深度非线性变化，仅依靠策略网络的隐式建模难以高效应对此类结构化干扰，限制了现有方法在刚柔耦合装配场景中的适用性。

1.3.4 国内外研究现状分析

综合上述三个方向的研究进展，目标感知与位姿估计、受限空间运动规划以及精密力控装配等领域均已形成较为丰富的方法体系，但现有成果大多围绕单一子问题独立展开，针对航空机舱环境下带柔性拖缆电连接器的多模块紧密耦合工程场景，尚未形成系统性解决方案。在视觉感知方面，基于关键点投票与多模态融合的 6D 位姿估计方法在遮挡鲁棒性上持续提升，但主要面向刚性遮挡工况设计，航空机舱中柔性线缆造成的大面积、形态时变遮挡与之存在本质差异；同时线缆延伸方向与空间形态尚未被纳入感知输出，导致后续规划与力控环节缺乏完整的几何先验。在运动规划与抓取方面，RRT* 系列算法与深度学习抓取生成网络在开放或半结构化场景中表现良好，但柔性线缆构成的动态障碍难以通过传统膨胀策略准确刻画，现有抓取评分体系也较少纳入后续装配方向约束，抓取—装配链路的任务相容性缺乏系统性考量。在力控装配方面，

阻抗控制与深度强化学习的融合已在标准接触丰富型任务中得到验证，但现有策略通常将外部干扰简化为各向同性噪声，未能刻画柔性线缆拖拽力沿特定方向的非线性变化，亟需引入视觉估计的线缆方向信息构建显式前馈补偿项。

针对上述问题，本文将围绕以下三个核心科学与工程问题展开研究：（1）在复杂光照、多实例和柔性线缆严重遮挡条件下，如何构建能够同时输出电连接器身份、6D 位姿以及线缆延伸方向等信息的级联视觉感知系统，为后续抓取与装配提供高质量输入。（2）在狭窄机舱空间中，如何利用视觉感知到的舱壁与线缆形态信息构建动态障碍物地图，并在此基础上设计兼顾搜索效率与安全性的引导式 RRT-Connect 规划策略，实现面向装配的连接器的抓取路径规划。（3）在存在柔性拖拽显著干扰的装配过程中，如何利用视觉估计的线缆方向向量构建前馈补偿项，并与深度强化学习策略相结合，形成兼具鲁棒性和安全性的柔顺装配控制框架。

1.4 本文的主要研究内容

针对航空机舱电连接器机器人自主抓取与装配任务中柔性线缆遮挡、狭窄空间约束与刚柔耦合干扰等关键问题，本文从视觉感知、抓取规划、柔顺装配及系统集成四个方面展开研究，构建面向航空制造的电连接器机器人自主抓取与装配系统。课题主要研究内容与全文组织架构如图1-8所示，具体包括以下四个方面。



图 1-8
(空白占位图)

图 1-8 课题主要研究内容流程图（级联视觉感知—自主抓取规划—柔顺装配控制—系统集成验证的级联关系与各章对应）

（1）面向柔性线缆遮挡环境的电连接器级联视觉感知与 6D 位姿估计方法研究。针对多实例混叠、光照复杂及柔性线缆遮挡等问题，设计“由粗到精”的

级联视觉感知框架：第一阶段利用 YOLOv8-seg 完成多电连接器的检测、标签识别与实例分割；第二阶段在裁剪后的兴趣区域上采用改进 DeepLabV3+ 进行关键点热力图预测与线缆精细分割；最后结合 EPnP/RANSAC 输出电连接器 6D 位姿及线缆方向向量，为后续模块提供统一感知接口。

(2) 面向狭窄机舱空间的电连接器自主抓取与引导式 RRT-Connect 规划策略研究。以视觉感知输出的位姿与线缆掩膜为输入，构建基于点云的端到端抓取生成网络，并通过兼顾抓取质量、线缆安全间隙与装配轴线对齐度的综合评分函数选取最优抓取姿态。在路径规划方面，提出引导式 RRT-Connect 算法，将舱壁与线缆形态映射至配置空间构建混合障碍物地图，规划避开柔性线缆的安全搬运轨迹。

(3) 面向柔性拖缆干扰的深度强化学习柔顺装配控制策略研究。针对线缆拖拽产生的方向性时变干扰力，构建“视觉前馈 + 导纳控制 + 深度强化学习”的双层装配控制架构：在动力学层面引入视觉估计的线缆方向向量构建前馈补偿项，在策略层面利用 DRL 算法对位置误差、接触力及线缆方向进行联合感知，学习不同干扰工况下的柔顺装配策略。

(4) 电连接器机器人自主抓取与装配系统集成及实验验证。搭建包含工业机械臂、视觉传感器和力/力矩传感器的实验平台，完成各模块系统集成，分别开展视觉感知、抓取规划与柔顺装配实验，通过多工况对比测试验证所提方法的有效性与工程应用潜力。

全文共分五章：第一章为绪论，阐述课题背景、研究现状与主要研究内容；第二章研究级联视觉感知与 6D 位姿估计方法；第三章研究自主抓取生成与引导式运动规划策略；第四章研究基于深度强化学习的柔顺装配控制方法；第五章完成系统集成与综合实验验证。

第2章 基于深度学习的电连接器识别与位姿估计研究

2.1 引言

航空机舱内电连接器的视觉感知同时受到多实例混叠、金属反光、深阴影以及柔性线缆遮挡等因素影响，传统依赖边缘、纹理或模板匹配的视觉方法难以在该场景下同时完成目标身份识别、关键结构恢复与高精度位姿求解。为满足后续自主抓取与柔顺装配对目标状态的精确需求，本文构建了一种由粗到精的级联视觉感知方法：首先利用 YOLOv8-seg 在整图中完成连接器实例定位、标签识别与粗分割，其次利用改进 DeepLabV3+ 在局部 ROI 内提取定位孔、线缆根部等关键特征并完成线缆精细分割，最后结合 EPNP 与 RANSAC 实现鲁棒 6D 位姿解算。本章围绕数据集构建、网络设计、几何建模与实验验证展开，为第三章抓取规划和第四章线缆干扰补偿提供统一视觉输入。



图 2-1
(空白占位图)

图 2-1 第二章级联视觉感知系统总体架构图（YOLOv8-seg—ROI 裁剪—改进 DeepLabV3+—EPnP/RANSAC—手眼标定的端到端数据流）

2.2 标签识别数据集的制作与分析

为支撑本章中的目标检测、标签识别、关键点提取、线缆分割和位姿解算任务，本文构建了面向航空电连接器视觉感知的混合数据集。该数据集由真实采集数据与仿真合成数据组成，在样本数量、工况覆盖范围和标注类型上兼顾了工程真实性与网络训练需求。如图2-2所示，航空机舱非结构化环境下电连接器视觉观测常同时伴随多实例堆叠、金属反光/阴影与柔性线缆遮挡等复合干

扰，因此数据集需在采集覆盖与标注类型上同步支持一级网络的实例定位与标签身份识别，并为二级网络的关键结构提取与线缆掩膜表达提供监督信息。本节从数据采集与标注、数据增强与分布均衡以及数据集特征分析三个方面展开说明。

图 2-2
(空白占位图)

图 2-2 航空机舱非结构化环境中电连接器多实例堆叠、金属反光/阴影与柔性线缆遮挡的典型视觉场景对比图

2.2.1 数据采集与标注方案

在数据采集硬件方面，本文采用机械臂腕部搭载 Intel RealSense D435i 相机的方式获取 RGB 图像，相机与末端执行器固连，可在抓取与装配工作空间内实现多视角、近距离观测。RGB 流分辨率设置为 1920×1080 ，帧率设置为 30 fps，以尽可能保留连接器标签区域、壳体边缘及线缆细轮廓等细节信息；同时通过机械臂轨迹规划控制相机绕目标进行环绕扫描，使采集到的样本覆盖不同视角、高度与工作姿态下的成像效果。如图 2-3 所示，相机安装位置与视场范围能够充分覆盖典型航空机舱设备舱段内部的连接器分布区域，为后续在同一硬件平台上完成在线检测与抓取提供了条件。

图 2-3
(空白占位图)

图 2-3 电连接器采集硬件布局示意图（机械臂腕部安装 RealSense 相机获取多视角 RGB 图像）

在真实数据采集方面,本文围绕航空非结构化环境下电连接器的典型布置形式与照明条件,构建了包含机舱设备舱段、线槽附近以及模拟工装夹具等多种场景的采集工况。整体共获取约 2500 张真实 RGB 图像,覆盖单连接器与多连接器堆叠、不同背景纹理(舱壁、线槽、线束束缚件等)、不同光照强度以及不同线缆形态(自然下垂、搭靠设备边缘、跨越连接器阵列)等情况,在每类工况下均采集多组不同姿态和距离的样本,以提高后续网络对空间布局变化与成像噪声的适应能力。

在仿真数据集构建方面,本文基于 Blender 建立了包含连接器本体、柔性线缆与机舱局部环境的参数化场景,如图??所示。通过对相机位姿、连接器姿态、线缆形态、背景纹理以及光照条件进行域随机化,并在同一渲染流程中自动输出检测框、实例掩膜、关键点与线缆掩膜等多任务标注,最终生成约 5000 张仿真合成图像。将上述 2500 张真实样本与 5000 张仿真样本统一整理后,按 7:2:1 的比例划分为训练集、验证集和测试集,使整体数据集既保留航空机舱真实成像特性,又在姿态与遮挡分布上具有足够的覆盖度。

在标注策略上,本文采用与两级处理流程一致的层级组织方式组织监督信息。其一,一级层级以整幅 RGB 图像为输入,对每个连接器目标同时标注边界框、实例掩膜以及标签 ID/类别身份;对应网络输出边界框集合、实例掩膜集合,并得到用于单目标 ROI 裁剪的候选区域。该层级主要用于完成目标锁定与单目标 ROI 提取。其二,二级层级以一级裁剪后的单目标 ROI 图像为输入,在同一 ROI 内标注三个定位孔中心、一个线缆根部坐标以及线缆像素级掩膜;网络输出由四通道关键点热力图与一通道线缆掩膜组成,用于描述关键结构与柔性线缆的空间占据特征。该分层标注结构使得 2.3 节与 2.4 节的网络训练能够对应获得监督信号,并保证 2.5 节位姿解算以及第三章线缆障碍建模与第四章力控前馈补偿所需几何/形态观测可由同一套标签逻辑直接继承。

2.2.2 数据增强

为提升航空非结构化环境中柔性线缆干扰下的识别与位姿估计稳定性,本文将训练期数据增强区分为真实数据增强与仿真数据增强两部分:真实增强校准成像噪声与外观变化,仿真增强扩展极端姿态与遮挡分布。

针对真实采集数据,本文构建与掩膜同步的在线增强流水线,包括按概率 0.5 叠加高斯噪声、随机旋转、色彩抖动、水平/垂直翻转以及随机裁剪缩放。设像素强度为 $I(x, y)$, 高斯噪声扰动为




图 2-4
(空白占位图)

图 2-4 真实采集样本与仿真合成样本的混合数据集对比示例图（含 TagID、实例掩膜、关键点与线缆掩膜标注展示）

$$I_{\text{aug}}(x, y) = \text{clip}(I(x, y) + n(x, y)), \quad n(x, y) \sim \mathcal{N}(0, \sigma^2),$$

其中, $\sigma = 0.1$ 表示噪声标准差, $\text{clip}(\cdot)$ 表示截断到合法强度范围。随机旋转角度 θ 采样于 $[-180^\circ, 180^\circ]$, 并对图像与掩膜同步进行仿射变换以保持几何一致性; 色彩抖动在 HSV 空间对亮度、对比度、饱和度与色相实施随机扰动, Brightness=0.5。为覆盖狭窄视野下的局部截断情形, 增强流程引入随机翻转与随机裁剪缩放 ($\text{scale} \in [0.8, 1.0]$ 且重采样到 640×640)。

针对仿真合成数据, 本文将增强转化为渲染域随机化: 设渲染参数为 θ , 则

$$I = f(\theta),$$

其中, $f(\cdot)$ 为基于 Blender 的渲染映射函数, I 表示渲染得到的图像。通过对 θ 在工程可行范围内随机采样, 并在训练中最小化期望监督损失

$$\min_{\phi} \mathbb{E}_{\theta \sim p(\theta)} \left[\mathcal{L}(g_{\phi}(f(\theta)), y) \right],$$

其中, ϕ 表示网络参数, $g_{\phi}(\cdot)$ 表示从图像到预测结果的网络映射, $\mathcal{L}(\cdot)$ 表示监督损失, y 为对应的自动渲染标签。渲染参数同时扰动相机位姿、连接器姿态、线缆形态与光照纹理等因素, 从而扩展线缆掩膜形态与可见性变化的联合分布。

如图2-5所示, 高斯噪声与色彩扰动改变了标签边缘的成像纹理强度, 随机旋转扩展了线缆方向在画面中的几何可见性范围, 随机裁剪缩放则模拟了狭窄视野下细结构的局部截断与重排。该增强在保持掩膜同步变换的前提下, 使训练输入覆盖“柔性线缆干扰+成像退化”的联合外观变化。

2.2.3 数据集特征分析

如图2-6所示, 增强后不同 TagID、遮挡率区间与线缆方向样本的覆盖更趋均衡, 从而降低中高遮挡与特定线缆方向样本不足引起的训练偏置。




图 2-5
(空白占位图)

图 2-5 数据增强效果示例图（高斯噪声、随机旋转、亮度扰动等对标签区与线缆细结构的影响对比）




图 2-6
(空白占位图)

图 2-6 不同 TagID、遮挡率区间与线缆方向样本的分布统计图（增强前后类别分布与工况覆盖对比）

在数据特征分析中，针对用于‘YOLOv8-seg’的整幅图像数据，统计重点对应到图2-6中的三类联合观测变量。图 2-6 的左图以柱状形式统计不同 TagID 的样本占比，用于衡量目标身份在整体数据中的覆盖均衡性；图 2-6 的中图与右图均以散点形式刻画空间覆盖，其中中图用于描述目标中心在图像平面内的分布范围，右图用于刻画随线缆方向变化的目标尺度离散程度。上述统计共同表明，在航空非结构化环境中，多实例堆叠与柔性线缆遮挡会改变目标的表观形状与实例边界清晰度：当目标在图像平面内的中心落点更广、同时不同 TagID 与遮挡区间保持分桶均衡时，边界框与实例掩膜在遮挡条件下出现的外轮廓缺失与局部碎片化将具有更充分的样本支撑，从而使实例分割监督能够学习更具适应性的外观边界分布。

针对用于‘DeepLabV3+’的 ROI 局部数据，特征分析将统计焦点从整幅身份与尺度覆盖转移到 ROI 内关键结构可见性的空间分布，以及线缆像素级掩膜监督的有效覆盖范围。结合图2-6的统计含义，ROI 关键结构的出现位置会随线缆方向发生系统性偏移；其中图 2-6 的中图所反映的中心落点覆盖范围可对应

理解的关键结构在裁剪平面内的空间落点区间,从而影响关键点热力图峰值在 ROI 内的离散程度;图 2-6 的右图所反映的尺度参数离散性则对应理解为局部孔位与线缆根部的局部可见尺度差异,进而改变掩膜监督能够覆盖到的有效像素比例。由于柔性线缆干扰会造成定位孔边缘纹理被部分覆盖、线缆根部在 ROI 中出现不同程度的遮挡隐蔽,ROI 内热力图峰值位置与掩膜覆盖比例将随线缆方向与遮挡强度呈现多样变化;通过在数据生成与增强阶段保持线缆方向与遮挡条件的覆盖一致性,ROI 内关键结构的相对位置分布与掩膜覆盖分布能够保持多模态特性,使局部分割监督在强干扰条件下仍具备足够的样本多样性与监督有效性。

2.3 基于 YOLOv8-seg 的目标检测与实例分割

在航空机舱电连接器装配场景中,视觉系统首先需要完成目标实例定位与目标对象区分,为后续关键点提取和位姿解算提供稳定的局部输入区域。考虑到该场景中连接器本体、标签区域与柔性线缆通常同时出现,且目标之间存在尺度变化大、遮挡关系复杂和实例间距离较近等特点,本文选用 YOLOv8-seg 作为感知流程的一级网络,用于实现目标检测、标签身份识别与实例分割的联合输出。

该网络输出的边界框、类别信息和实例掩膜共同构成后续 ROI 裁剪与局部精细分析的基础数据,其中 TagID 用于确定目标对象,实例掩膜用于削弱背景干扰,边界框用于确定局部图像范围。

2.3.1 算法选型与总体结构

电连接器的视觉观测需要同时完成实例级定位与像素级轮廓约束。航空机舱非结构化环境中,连接器本体、标签区域与柔性线缆在同一画面内并存,遮挡边界容易出现不完整结构;在此条件下,单纯依赖边界框进行目标锁定难以稳定反映遮挡处的形态变化。YOLOv8-seg 的检测-分割联合输出使得 TagID 关联、边界定位与遮挡边界的像素级约束可以在同一模型预测阶段获得一致监督,从而提升实例可分性与候选区域的几何稳定性。

YOLOv8-seg 采用 Anchor-free 的中心与尺度回归机制,通过直接学习目标中心位置与边界参数完成定位,不依赖预设锚框匹配。在连接器任务中,壳体、标签与拖拽线缆对应的长宽比跨度较大,锚框匹配会引入尺度先验偏差;Anchor-free 回归能够更直接地适应该类尺度变化特征。设网络对第 i 个预测实例给出

边界框参数

$$\hat{\mathbf{b}}_i = (\hat{x}_i, \hat{y}_i, \hat{w}_i, \hat{h}_i),$$

其中, $\hat{x}_i, \hat{y}_i$ 为框中心像素坐标, $\hat{w}_i, \hat{h}_i$ 为宽高尺度, 则该回归过程无需锚框候选匹配即可输出候选定位结果。

同时, YOLOv8-seg 将检测分支与分割分支集成于统一网络框架中, 实现一次前向推理同时输出目标位置与实例掩膜。对于实例分割分支, 其掩膜预测可形式化表示为

$$\hat{M}_i = \sigma(f_{\text{seg}}(F)),$$

其中, $\hat{M}_i$ 为第 i 个实例的像素级掩膜预测, $f_{\text{seg}}(\cdot)$ 为分割预测头, F 为共享多尺度特征, $\sigma(\cdot)$ 表示非线性激活函数。实例掩膜在遮挡边界缺失时仍能够提供像素级拓扑约束, 使得目标锁定不再仅依赖框形状, 从而降低多实例堆叠与柔性线缆遮挡条件下的实例混淆。

如图2-7所示, YOLOv8-seg 由 Backbone、Neck 与 Head 三部分组成: Backbone 提取层级语义特征以表征标签与壳体的判别信息; Neck 完成多尺度特征融合以同时保留细粒度边缘响应与跨尺度上下文一致性; Head 将检测与分割预测集成到统一输出端, 从而实现边界框与实例掩膜的联合推断。




图 2-7
(空白占位图)

图 2-7 YOLOv8-seg 网络结构图 (Backbone/Neck/Head 与检测-分割联合输出的多尺度特征融合示意)

本文在实现中选用 CSPDarknet53 作为骨干网络, 并在 C2f 模块中实现跨阶段特征复用: 浅层表征用于保留壳体边缘与标签纹理的局部梯度信息, 深层表征用于提供与实例尺度变化相关的语义响应。该特征组织为检测与掩膜分支在遮挡边界处提供共享的判别依据, 从而在多实例混叠与柔性线缆遮挡条件下保持实例轮廓的一致性。由检测与分割分支联合输出的目标候选集合可写为

$$\mathcal{D} = \{ID_i, B_i, s_i, M_i\}_{i=1}^N,$$

式中, ID_i 表示标签身份, B_i 表示边界框, s_i 表示检测置信度, M_i 表示实例分割掩膜, N 为候选目标数量。




图 2-8
(空白占位图)

图 2-8 YOLOv8-seg 在多实例堆叠与线缆遮挡条件下的检测与实例分割效果图 (含 TagID 识别结果展示)

如图 2-8 所示, 在多连接器实例堆叠与柔性线缆遮挡条件下, 边界框用于给出候选定位的空间范围, 而实例掩膜用于补足遮挡边缘的像素级轮廓约束。掩膜输出能够在目标轮廓局部不完整时保持拓扑连贯性, 从而降低由局部缺失引发的实例交叉干扰, 增强 TagID 与对应实例之间的关联稳定性。

2.3.2 损失函数与训练参数设置

电连接器装配场景中, 视觉模型需要同时完成连接器实例的身份判别与遮挡边界的像素级轮廓恢复。YOLOv8-seg 通过检测分支输出候选框集合与置信度, 并通过分割分支输出实例掩膜, 实现由框约束到掩膜约束的耦合学习。多任务损失函数用于将身份分类、目标定位与实例轮廓学习统一到同一优化目标中, 其形式为

$$\mathcal{L}_{\text{det}} = \lambda_{\text{cls}} \mathcal{L}_{\text{cls}} + \lambda_{\text{box}} \mathcal{L}_{\text{box}} + \lambda_{\text{obj}} \mathcal{L}_{\text{obj}} + \lambda_{\text{seg}} \mathcal{L}_{\text{seg}},$$

其中, $\mathcal{L}_{\text{cls}}$ 用于约束标签身份与类别预测, $\mathcal{L}_{\text{box}}$ 用于边界框定位回归, $\mathcal{L}_{\text{obj}}$ 用于前景置信度估计, $\mathcal{L}_{\text{seg}}$ 用于实例掩膜预测; 权重系数为 $\lambda_{\text{cls}}, \lambda_{\text{box}}, \lambda_{\text{obj}}, \lambda_{\text{seg}}$ 。

为明确各项损失的监督形式, 分类与置信度分别采用交叉熵形式建模。以单个候选位置的分类概率 p_c 与 one-hot 标签 y_c 为例, 分类损失写为

$$\mathcal{L}_{\text{cls}} = - \sum_c y_c \log p_c.$$

对于目标置信度 p_{obj} 与目标指示 $t_{\text{obj}} \in \{0, 1\}$ ，其损失写为

$$\mathcal{L}_{\text{obj}} = -t_{\text{obj}} \log p_{\text{obj}} - (1 - t_{\text{obj}}) \log(1 - p_{\text{obj}}).$$

分割分支在像素级对实例掩膜进行监督。令线缆实例掩膜真值为 $M(x, y) \in \{0, 1\}$ ，预测概率为 $\hat{M}(x, y)$ ，则二值交叉熵损失为

$$\mathcal{L}_{\text{bce}} = -\frac{1}{HW} \sum_x \sum_y (M(x, y) \log \hat{M}(x, y) + (1 - M(x, y)) \log (1 - \hat{M}(x, y))),$$

Dice 损失用于增强区域重叠的一致性：

$$\mathcal{L}_{\text{dice}} = 1 - \frac{2 \sum_x \sum_y \hat{M}(x, y) M(x, y) + \epsilon}{\sum_x \sum_y \hat{M}(x, y) + \sum_x \sum_y M(x, y) + \epsilon}.$$

因此掩膜预测损失可写为

$$\mathcal{L}_{\text{seg}} = \mathcal{L}_{\text{bce}} + \lambda_{\text{dice}} \mathcal{L}_{\text{dice}}.$$

在定位回归项 $\mathcal{L}_{\text{box}}$ 中，采用 CIoU 损失对遮挡情形下的框回归进行联合约束。IoU 定义为预测框与真实框交并比：

$$\text{IoU} = \frac{\text{area}(\mathbf{b} \cap \mathbf{b}^{gt})}{\text{area}(\mathbf{b} \cup \mathbf{b}^{gt})}.$$

CIoU 在 IoU 约束之外引入中心点距离项与宽高比一致性项，从而将“重叠程度”扩展为“几何接近性 + 形态一致性”的联合优化目标。令预测框中心与真实框中心的欧氏距离为

$$\rho(\mathbf{b}, \mathbf{b}^{gt}) = \sqrt{(x - x^{gt})^2 + (y - y^{gt})^2},$$

定义最小外接框对角线长度为 c ，则中心距离惩罚项写为 $\rho^2(\mathbf{b}, \mathbf{b}^{gt})/c^2$ 。宽高比一致性项定义为

$$v = \frac{4}{\pi^2} \left(\arctan \frac{w^{gt}}{h^{gt}} - \arctan \frac{w}{h} \right)^2,$$

平衡因子 α 取

$$\alpha = \frac{v}{(1 - \text{IoU}) + v}.$$

最终 CIoU 损失写为

$$\mathcal{L}_{\text{CIoU}} = 1 - \text{IoU} + \frac{\rho^2(\mathbf{b}, \mathbf{b}^{gt})}{c^2} + \alpha v.$$

在遮挡边界局部缺失时，重叠区域 IoU 会出现波动，但中心距离与整体形态一致性仍提供可用于候选 ROI 稳定生成的几何梯度，因此 CIoU 在航空非结构化环境中对定位回归的鲁棒性更强。

在训练实现方面，输入尺寸设为 640×640 ，BatchSize 设为 16，训练轮数设为 300，优化器采用 SGD，Momentum 设为 0.937。该参数组合在保证图像细节表达的同时，降低遮挡样本的梯度方差，并提升收敛稳定性。



图 2-9
(空白占位图)

图 2-9 YOLOv8-seg 训练过程曲线图（分类/置信度/框回归/分割等损失与关键指标随 epoch 变化）

由图2-9可以观察到，各分项损失随 epoch 的推进呈现整体下降趋势，分类相关损失首先收敛，随后定位回归与掩膜分割损失逐步趋于稳定。该现象对应于优化目标的梯度耦合关系：在初期阶段，分类与置信度监督为候选目标关联建立基础；随着候选框的中心与尺度预测逐步稳定，CIoU 中的中心距离与宽高比一致性项开始提供更有效的回归约束；在后期阶段，分割损失的下降与掩膜形态连贯性的提升共同作用，使得遮挡边缘的像素级轮廓能够更稳定地被学习。训练过程中曲线的同步收敛说明了框回归与掩膜监督在遮挡样本上的协同学习是有效的。

该协同学习可在检测结果中得到体现：如图2-8所示，多连接器实例堆叠条件下，边界框为实例归属提供空间范围，实例掩膜在遮挡边缘缺失时仍能保持一定拓扑连贯性，从而降低由局部缺失引发的实例混淆概率。该对应关系验证了多任务联合损失对航空非结构化环境下电连接器实例分割的适配性。

2.3.3 动态 ROI 裁剪策略

一级感知网络的输出用于生成局部精细处理的感兴趣区域 ROI。如果裁剪窗口过小，连接器边缘与线缆上下文会被截断，影响遮挡关系的恢复；若裁剪窗口过大，则引入无关背景削弱二级网络的局部聚焦能力。为此本文根据检测框置信度与目标尺度自适应调整 ROI 窗口大小。

设一级检测边界框为 $B = (x, y, w, h)$ ，其检测置信度为 $s \in [0, 1]$ ，则扩展后的裁剪窗口定义为

$$B' = (x, y, \gamma(s)w, \gamma(s)h),$$

其中，动态扩展因子 $\gamma(s)$ 定义为

$$\gamma(s) = \gamma_{\min} + (\gamma_{\max} - \gamma_{\min})(1 - s).$$

当检测置信度较高时，可采用较小扩展因子提高局部聚焦性；当检测置信度较低时，适当扩大裁剪区域可以保留更多上下文信息，降低因一级定位偏差造成的二级输入截断风险。为保持二级网络输入尺度统一，裁剪后的 ROI 图像被重采样至固定尺寸 $I_{\text{roi}} \in \mathbb{R}^{256 \times 256 \times 3}$ ，并记录从原图到 ROI 的仿射变换矩阵，以便后续将关键点坐标映射回原始图像坐标系。

为给出可逆的几何映射关系，令扩展裁剪窗口中心仍为 B 的中心 (x, y) ，则裁剪窗口左上角可写为

$$x_0 = x - \frac{\gamma(s)w}{2}, \quad y_0 = y - \frac{\gamma(s)h}{2},$$

并定义从裁剪窗口到 ROI 的缩放比例

$$s_x = \frac{256}{\gamma(s)w}, \quad s_y = \frac{256}{\gamma(s)h}.$$

对任意原图坐标 (X, Y) ，其对应的 ROI 坐标 (u, v) 通过齐次坐标仿射变换给出：

$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} s_x & 0 & -s_x x_0 \\ 0 & s_y & -s_y y_0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} X \\ Y \\ 1 \end{bmatrix}.$$

因此，ROI 内关键点预测坐标 (u_j, v_j) 可以通过逆仿射变换映射回原图：

$$\begin{bmatrix} X_j \\ Y_j \\ 1 \end{bmatrix} = \begin{bmatrix} 1/s_x & 0 & x_0 \\ 0 & 1/s_y & y_0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} u_j \\ v_j \\ 1 \end{bmatrix}.$$

同理，线缆像素级掩膜在裁剪与重采样过程中采用相同的几何映射规则，从而保证二级网络的关键点热力图监督与线缆掩膜监督在坐标系层面一致。



图 2-10 基于检测置信度的动态 ROI 裁剪示意图 ($\gamma(s)$ 自适应扩展与仿射回映射关系)

如图2-10所示，动态扩展因子 $\gamma(s)$ 决定裁剪窗口的覆盖范围；仿射映射矩阵将原图坐标 (X, Y) 映射到 ROI 坐标 (u, v) ，逆变换则保证二级网络输出的关键点坐标能够回到原图参考系。该坐标一致性使关键点热力图监督与线缆像素级掩膜监督在遮挡边界条件下仍保持严格的几何对齐，从而避免标签与预测结果在坐标系层面的偏移误差。

2.4 基于改进 DeepLabV3+ 的关键特征提取与线缆分割

一级检测输出的边界框与粗掩膜可用于锁定目标实例的空间范围，但难以直接刻画定位孔、插接端面以及线缆根部等关键几何结构。为此，本文在 ROI 图像上引入改进 DeepLabV3+ 网络，利用大感受野上下文建模能力实现关键点热力图预测与线缆精细分割，并以统一的像素级监督约束提升遮挡条件下的结构可辨性。本节将从网络选型与空洞卷积原理、高斯热力图建模方法以及改进输出头与联合损失设计三个方面展开说明。

2.4.1 网络模型分析

DeepLabV3+ 的优势在于其对语义与边界的协同建模能力：编码器用于提取具有判别性的高层语义特征，ASPP 模块通过多空洞率分支并行聚合多尺度上下文信息，解码器再引入浅层细节特征对空间边界进行细化恢复。该结构在保证感受野覆盖的同时兼顾局部纹理分辨率，适合处理航空非结构化环境中由金属反光、阴影与柔性线缆遮挡共同引起的外观变化，使得网络能够在局部纹理不稳定时仍保持对端面轮廓与孔位布局的整体一致性判断。

本文二级视觉感知的目标是：在一级网络生成的单目标 ROI 内，同时预测三个定位孔中心与一个线缆根部的关键点热力图，并输出线缆像素级掩膜，以支撑后续位姿解算与线缆方向先验构建。为满足该目标，网络需要在 ROI 局部范围内区分“孔位边缘纹理—壳体边界—线缆细轮廓”三类高频细节，并在遮挡与反光条件下保持关键点响应峰值的稳定性。然而，原始 DeepLabV3+ 的输出端主要面向单一语义分割任务，难以直接满足“多通道关键点热力图+线缆分割掩膜”的并行输出需求；同时，线缆像素占比通常远小于背景与壳体区域，若仅采用单一分割监督，容易在训练中出现细线缆断裂、边界收缩等现象。为此，有必要对解码端的输出头进行任务化改造，并在损失函数层面对关键点与线缆两类监督进行联合设计，从而为下一节的改进网络结构与优化目标构建提供依据。

DeepLabV3+ 提取多尺度上下文特征的关键在于空洞卷积，其一维形式为

$$y[i] = \sum_{k=1}^K x[i + r \cdot k] w[k],$$

式中， $x[i]$ 表示输入特征， $w[k]$ 表示卷积核参数， r 为空洞率。当 $r = 1$ 时，该运算退化为普通卷积；当 $r > 1$ 时，卷积核在不显著增加参数量的条件下扩大感受野，因此网络能够利用更大范围的结构上下文判断遮挡区域内可能存在的关键特征。对于本文研究对象而言，定位孔与端面轮廓之间具有相对稳定的几何布局，因此只要网络能够同时观察到足够的壳体上下文，就有可能在局部遮挡条件下恢复有效的关键点响应。

如图2-11所示，多空洞率的并行上下文建模与编码器-解码器的特征融合共同决定了模型的输出特性：一方面，ASPP 的大感受野分支能够在遮挡发生时提供“全局布局一致性”的约束，避免孔位响应被局部线缆边缘牵引；另一方面，解码端引入的浅层细节信息能够对孔位边缘与线缆细结构进行空间细化。基于

该结构特性，模型能够输出较为稳定的关键点热力图与线缆概率图。然而，在本文任务中需要同时输出四通道关键点热力图与单通道线缆掩膜，并对两类输出采用差异化的监督权重；同时，线缆遮挡会导致前景/背景像素占比显著不均，使得仅依赖单一分割损失容易出现边界收缩或细线缆断裂。为此，需要对原网络的输出头进行任务化改造，并在损失函数层面对关键点与线缆两类监督实施联合设计，从而保证关键结构定位与线缆分割在遮挡条件下的同步稳定。




图 2-11
(空白占位图)

图 2-11 DeepLabV3+ 网络结构示意图（ASPP 多空洞率上下文建模与编码器-解码器融合路径）

2.4.2 高斯热力图建模方法

为在柔性线缆遮挡与强反光条件下稳定提取连接器局部关键结构，本文将关键点定位由“直接回归坐标”转化为“回归密集响应图”。与坐标回归仅在单点上提供监督不同，热力图建模在关键点邻域内构造连续的软标签，使网络在训练阶段获得更充分的空间梯度信息；同时，密集监督与 DeepLabV3+ 的全卷积输出形式一致，便于将解码端的像素级特征直接映射为关键点响应分布，从而提高遮挡条件下峰值位置的可辨性与稳定性。

为对比两类监督形式的差异，设第 j 个关键点的真实坐标为 $\mathbf{p}_j = [x_j, y_j]^\top$ ，坐标回归分支直接输出 $\hat{\mathbf{p}}_j = [\hat{x}_j, \hat{y}_j]^\top$ ，常用的回归损失可写为

$$\mathcal{L}_{\text{reg}} = \frac{1}{N_k} \sum_{j=1}^{N_k} \|\hat{\mathbf{p}}_j - \mathbf{p}_j\|_2^2.$$

该损失在监督层面仅对单点坐标误差进行惩罚，等价于在二维平面上以 Dirac 分布 $\delta(\mathbf{x} - \mathbf{p}_j)$ 作为目标，使得训练梯度主要集中于“坐标偏差”的一阶方向上，难以显式利用关键点邻域内的边缘纹理与几何布局信息。相比之下，热力图建模将关键点表示为二维连续分布。令 $\mathbf{x} = [x, y]^\top$ ，则式 (2-xx) 可写为

$$H_j(\mathbf{x}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{p}_j\|_2^2}{2\sigma^2}\right),$$

并可进一步构造归一化概率分布

$$\tilde{H}_j(\mathbf{x}) = \frac{H_j(\mathbf{x})}{\sum_x \sum_y H_j(x, y)}.$$

在推理阶段，关键点坐标既可由 $\arg \max$ 得到，也可采用 soft-argmax 的期望形式给出

$$\hat{\mathbf{p}}_j = \sum_x \sum_y \mathbf{x} \tilde{H}_j(\mathbf{x}),$$

其中， $\tilde{H}_j$ 为对预测热力图归一化后的分布。如图2-12所示，热力图监督将误差从“单点坐标偏差”扩展为“邻域分布匹配”，使得损失函数在关键点邻域内产生连续的空间梯度，从而更有利于在遮挡与反光引起的局部纹理不稳定条件下保持峰值位置的鲁棒性。

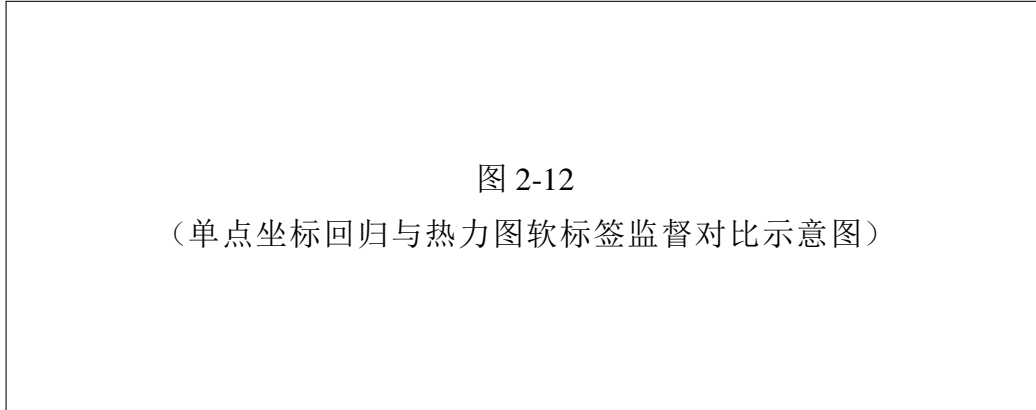


图 2-12
(单点坐标回归与热力图软标签监督对比示意图)

图 2-12 关键点监督形式对比示意图（单点坐标回归/高斯热力图软标签/soft-argmax 解码）

结合本文任务，二级网络在单目标 ROI 内需要同时输出三个定位孔中心与一个线缆根部的二维观测。该关键点集合一方面用于构造稳定的二维—三维对应关系以支撑位姿解算，另一方面与线缆掩膜的主方向信息共同描述线缆根部的几何落点与延伸趋势，使后续“刚体位姿 + 柔性障碍先验”的联合表达具备统一的像素级来源。

在样本预处理阶段，一级网络裁剪得到的 ROI 被统一重采样到固定分辨率输入平面，以消除目标尺度差异对二级网络训练稳定性的影响。对于第 j 个关键点，设其标注坐标为 (x_j, y_j) ，本文采用二维高斯核构造目标热力图 $H_j(x, y)$ ，其表达式为

$$H_j(x, y) = \exp\left(-\frac{(x - x_j)^2 + (y - y_j)^2}{2\sigma^2}\right),$$

式中, (x, y) 表示热力图平面上的任意像素位置, (x_j, y_j) 表示关键点中心位置, σ 控制概率峰的扩散范围。




图 2-13
(空白占位图)

图 2-13 关键点高斯热力图建模示意图 (σ 控制扩散半径与峰值-邻域软标签监督形式)

在参数设置方面, 本文取 $\sigma = 2$ 作为热力图扩散系数, 以在定位精度与训练稳定性之间取得平衡。当 σ 过小时, 监督有效区域过窄, 梯度主要集中于极小邻域, 遮挡导致的边缘纹理扰动更易引起峰值漂移; 当 σ 过大时, 响应分布过于平坦, 关键点中心的区分性降低并引入更明显的定位偏差。因此, σ 的选取本质上对应“空间不确定度建模”与“中心可分性”的折中。

在监督组织形式上, 若关键点总数记为 N_k , 则网络输出 N_k 个关键点热力图通道, 每个通道仅对应一个语义明确的结构点, 如左定位孔、右定位孔、中心定位孔或线缆根部; 本文取 $N_k = 4$ 。该通道化编码避免不同结构点在同一响应图上的竞争, 使解码端能够为每类结构点学习更具针对性的局部判别特征, 并与线缆分割分支共享编码与 ASPP 的上下文表示, 实现“刚性孔位布局 + 柔性线缆形态”的同域特征表达。

在训练目标上, 将热力图视为关键点位置的概率型表征, 可将预测热力图 $\hat{H}_j(x, y)$ 与目标热力图 $H_j(x, y)$ 的差异转化为像素级能量最小化问题。采用均方误差损失时, 优化过程等价于在每个像素位置上对响应幅值进行一致性拟合, 其梯度在关键点邻域内连续变化, 从而相对降低坐标回归中由单点监督引起的梯度震荡; 同时, 热力图的峰值幅值可作为关键点置信度的直接度量, 为后续在遮挡样本上进行异常点抑制提供可用的质量指标。该建模方式为下一节在 DeepLabV3+ 解码端引入面向关键点与线缆的双分支输出提供了与之匹配的标签定义与优化目标。

关键点热力图分支采用均方误差损失约束预测热力图与目标热力图的一

致性。设第 j 个关键点的预测热力图为 $\hat{H}_j(x, y)$ ，则其损失可写为

$$\mathcal{L}_{kp} = \frac{1}{N_k} \sum_{j=1}^{N_k} \sum_x \sum_y (\hat{H}_j(x, y) - H_j(x, y))^2.$$

2.4.3 改进输出头与联合损失设计

根据上一节的建模结果，二级网络的监督信号由关键点高斯热力图和线缆分割掩膜共同构成。为使网络输出形式与构造的标签保持一致，本文对 DeepLabV3+ 解码端的输出层进行改进，构建面向电连接器局部感知任务的双分支输出头。

在经过编码器、ASPP 模块以及解码器特征融合后，设共享特征图记为 F 。在此基础上，分别设置关键点热力图预测分支和线缆分割分支：关键点分支输出四个关键结构的热力图张量 $\hat{H} \in \mathbb{R}^{H \times W \times N_k}$ ；线缆分支输出单通道线缆概率图 $\hat{M}_c \in \mathbb{R}^{H \times W}$ 并经阈值化得到线缆二值掩膜。

为保证输出与热力图软标签幅值定义一致，关键点分支与线缆分割分支均采用逐位置的线性映射并通过非线性函数约束到概率区间。设共享特征在位置 (x, y) 处的向量为 $\mathbf{F}(x, y) \in \mathbb{R}^C$ ，则关键点热力图预测与线缆概率预测可分别表示为

$$\hat{H}_j(x, y) = \sigma(\mathbf{w}_j^\top \mathbf{F}(x, y) + b_j),$$

其中， $\mathbf{w}_j$ 与 b_j 为第 j 个关键点的映射参数， $\sigma(\cdot)$ 为将输出压缩到 $[0, 1]$ 的非线性函数；

$$\hat{M}_c(x, y) = \sigma(\mathbf{w}_c^\top \mathbf{F}(x, y) + b_c),$$

其中， $\mathbf{w}_c$ 与 b_c 为线缆分割分支参数。由 $\hat{H}_j(x, y)$ 在关键点提取阶段采用软-argmax 期望形式得到坐标，归一化预测热力图分布为

$$\tilde{\hat{H}}_j(x, y) = \frac{\hat{H}_j(x, y)}{\sum_x \sum_y \hat{H}_j(x, y) + \eta_0},$$

其中， η_0 为数值稳定常数，则有

$$\hat{x}_j = \sum_x \sum_y x \cdot \tilde{\hat{H}}_j(x, y), \quad \hat{y}_j = \sum_x \sum_y y \cdot \tilde{\hat{H}}_j(x, y).$$

如图2-14所示，双分支输出头通过“共享语义上下文+任务专用像素映射”的方式实现并行监督：关键点热力图通道提供定位孔中心的软响应分布，线缆



图 2-14
(空白占位图)

图 2-14 改进 DeepLabV3+ 双分支输出头示意图（关键点热力图分支 + 线缆分割分支的共享特征与输出通道定义）

分支提供像素级线缆概率，使两类任务在同一 ROI 内具有一致的监督坐标系。由于关键点通道之间采用独立输出，定位孔中心响应不会被线缆边界的高梯度纹理直接竞争；同时，线缆概率图由像素级损失连续约束细长结构的边界连通性，从而在柔性线缆遮挡与局部反光条件下维持可用于后续 EPnP/RANSAC 的二维观测质量。

在损失函数设计方面，针对两类输出采用分项约束并进行加权求和。线缆分割分支采用加权二值交叉熵损失与 Dice 损失相结合的方式进行监督，其表达式分别为

$$\mathcal{L}_{wbce} = -\frac{1}{HW} \sum_x \sum_y (\beta M(x, y) \log \hat{M}_c(x, y) + (1 - M(x, y)) \log (1 - \hat{M}_c(x, y))),$$

$$\beta = \frac{|\Omega_-|}{|\Omega_+|},$$

其中， Ω_+ 表示线缆像素集合， Ω_- 表示非线缆像素集合； β 为正负样本权重系数，用于缓解类别不均衡对细长线缆分割的梯度抑制。

$$\mathcal{L}_{dice} = 1 - \frac{2 \sum_x \sum_y \hat{M}_c(x, y) M(x, y) + \epsilon}{\sum_x \sum_y \hat{M}_c(x, y) + \sum_x \sum_y M(x, y) + \epsilon},$$

式中， $M(x, y)$ 表示线缆分割真值标签， $\hat{M}_c(x, y)$ 表示预测概率， ϵ 为平滑项。由此，线缆分支的损失可写为

$$\mathcal{L}_{cable} = \mathcal{L}_{wbce} + \lambda_{dice} \mathcal{L}_{dice},$$

其中, λ_{dice} 为 Dice 损失权重系数。

最终, 二级网络的总损失函数定义为

$$\mathcal{L}_{\text{seg}} = \lambda_{\text{kp}} \mathcal{L}_{\text{kp}} + \lambda_{\text{cable}} \mathcal{L}_{\text{cable}},$$

式中, λ_{kp} 和 λ_{cable} 分别表示关键点热力图任务与线缆分割任务的权重系数。关键点损失函数采用均方误差形式, 其表达为

$$\mathcal{L}_{\text{kp}} = \frac{1}{N_k} \sum_{j=1}^{N_k} \sum_x \sum_y (\hat{H}_j(x, y) - H_j(x, y))^2,$$

其中, $H_j(x, y)$ 为目标高斯热力图, $\hat{H}_j(x, y)$ 为预测热力图。

联合损失的梯度耦合关系可写为

$$\nabla_{\theta} \mathcal{L}_{\text{seg}} = \lambda_{\text{kp}} \nabla_{\theta} \mathcal{L}_{\text{kp}} + \lambda_{\text{cable}} \nabla_{\theta} \mathcal{L}_{\text{cable}},$$

其中, θ 表示二级网络参数。该形式说明关键点与线缆两类监督在共享解码特征上共同影响梯度方向, 从而实现并行收敛。




图 2-15
(空白占位图)

图 2-15 二级网络训练与推理效果示意图 (关键点热力图峰值定位 + 线缆精细分割结果可视化)

在训练实现方面, 二级网络输入来自一级检测得到的单目标 ROI, 并将 ROI 重采样到固定尺度 $I_{\text{roi}} \in \mathbb{R}^{256 \times 256 \times 3}$ 。网络前向获得关键点热力图 $\{\hat{H}_j\}$ 与线缆概率图 $\hat{M}_c$ 后, 按上述损失定义计算 $\mathcal{L}_{\text{kp}}$ 与 $\mathcal{L}_{\text{cable}}$, 再由权重系数形成 $\mathcal{L}_{\text{seg}}$, 并通过反向传播更新参数。参数迭代满足

$$\theta_{t+1} = \theta_t - \eta_t \nabla_{\theta} \mathcal{L}_{\text{seg}},$$

其中, η_t 为迭代学习率。由于线缆分支采用加权 BCE 以及 Dice 项, 细长线缆在遮挡条件下仍可保持足够的正类梯度贡献; 由于关键点分支采用连续高斯软标

监督，热力图峰值在训练过程中趋于稳定，从而降低 soft-argmax 坐标提取的不连续误差。

如图2-15所示，在典型柔性线缆遮挡工况下，关键点热力图峰值能够稳定落在定位孔中心邻域，且不同关键点通道之间保持区分性；线缆分割概率图在遮挡边界处仍呈现连续的细长响应，二值掩膜较少出现局部收缩或断裂。该趋势与联合损失的性质相一致：当 $\mathcal{L}_{kp}$ 下降时，预测热力图与目标高斯软标签在关键点邻域内差异被抑制，进而减小由峰值漂移引起的坐标误差；当 $\mathcal{L}_{cable}$ 降低时，加权 BCE 提高正类像素的优化权重，Dice 项度量区域重叠一致性，从而增强遮挡条件下的边界连贯性。该同步优化结果为第 2.5 节 EPnP/RANSAC 位姿解算提供更可靠的二维关键点观测集合，并为第四章线缆形态先验构建提供可复用的线缆掩膜输入。

为了便于量化训练效果，关键点定位误差可定义为

$$d_j = \sqrt{(\hat{x}_j - x_j)^2 + (\hat{y}_j - y_j)^2},$$

其中， (x_j, y_j) 为标注关键点坐标， $(\hat{x}_j, \hat{y}_j)$ 为由预测热力图提取的坐标。平均关键点误差写为

$$\text{MAE}_{kp} = \frac{1}{N_k} \sum_{j=1}^{N_k} d_j.$$

线缆分割质量可用 Dice 系数表征为

$$\text{Dice} = \frac{2 \sum_x \sum_y \hat{M}_c(x, y) M(x, y)}{\sum_x \sum_y \hat{M}_c(x, y) + \sum_x \sum_y M(x, y) + \epsilon}.$$

当 MAE_{kp} 随迭代降低且 Dice 随迭代提升时，说明输出头改造与联合损失设计能够在遮挡工况下同时提升关键点峰值定位精度与线缆边界一致性，从而满足后续位姿解算与干扰补偿对观测质量的要求。

2.5 基于 EPnP 与 RANSAC 的电连接器位姿解算

经过二级网络处理后，系统已经获得定位孔、线缆根部和线缆掩膜等局部精细视觉结果。为实现从图像特征到机器人可执行状态的转换，必须进一步结合相机模型和连接器 CAD 几何先验，将二维关键点映射为三维刚体位姿参数。航空机舱场景中的线缆遮挡、局部反光与分割偏差会使少量关键点观测发生明显漂移，若采用普通 PnP 求解，异常点会显著拉偏最终位姿结果。本文采用 EPnP 进行高效初值求解，并利用 RANSAC 基于重投影误差剔除外点，以在保证解算

效率的同时增强对遮挡干扰的鲁棒性。

2.5.1 相机投影模型与 EPnP 求解

位姿解算基于针孔相机模型。设物体系下第 i 个三维关键点为 $\mathbf{P}_i^O = [X_i, Y_i, Z_i]^T$ ，相机系下为 $\mathbf{P}_i^C = \mathbf{R}\mathbf{P}_i^O + \mathbf{t}$ ，像素观测为 $\mathbf{p}_i = [u_i, v_i]^T$ ，则

$$s_i \begin{bmatrix} u_i \\ v_i \\ 1 \end{bmatrix} = \mathbf{K}\mathbf{P}_i^C, \quad \mathbf{K} = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix},$$

其中， s_i 为深度尺度， $\mathbf{R} \in SO(3)$ 、 $\mathbf{t} \in \mathbb{R}^3$ 为待求位姿， f_x, f_y 为焦距， c_x, c_y 为主点。



图 2-16
(空白占位图)

图 2-16 相机模型与 PnP 位姿解算统一示意图（光心 O 、图像平面、物体系 $\{O\}$ 与相机系 $\{C\}$ 、三维点 $\mathbf{P}_i^O/\mathbf{P}_i^C$ 、像素 $\mathbf{p}_i$ 、控制点 $\mathbf{C}_j$ 及位姿 $\mathbf{R}, \mathbf{t}$ 的几何与解算流程）

如图 2-16 所示，物方点经 $\mathbf{R}, \mathbf{t}$ 变换至相机系后由 $\mathbf{K}$ 投影为像素，二级网络提供的二维关键点即 $\mathbf{p}_i$ ，与 CAD 三维点 $\mathbf{P}_i^O$ 构成 2D-3D 对应；EPnP 在该对应下通过控制点参数化将位姿求解转化为线性方程组。

本文采用 EPnP 在给定 2D-3D 对应下求 $\mathbf{R}, \mathbf{t}$ 。在物体系中取四个非共面控制点 $\mathbf{C}_j^O$ ($j = 1, \dots, 4$)，由 CAD 与选点规则确定。物方任意关键点用控制点仿射组合表示：

$$\mathbf{P}_i^O = \sum_{j=1}^4 \alpha_{ij} \mathbf{C}_j^O, \quad \sum_{j=1}^4 \alpha_{ij} = 1,$$

α_{ij} 仅与物体几何有关，由 $\mathbf{P}_i^O$ 与 $\mathbf{C}_j^O$ 预先算得。记控制点在相机系下坐标为 $\mathbf{c}_j^C = (x_j, y_j, z_j)^T$ ，则相机系下关键点为

$$\mathbf{P}_i^C = \mathbf{R}\mathbf{P}_i^O + \mathbf{t} = \sum_{j=1}^4 \alpha_{ij} \mathbf{c}_j^C.$$

将投影方程写为归一化像面形式。记 $\tilde{u}_i = (u_i - c_x)/f_x$, $\tilde{v}_i = (v_i - c_y)/f_y$, 则有 $X_i^C = \tilde{u}_i Z_i^C$, $Y_i^C = \tilde{v}_i Z_i^C$, 其中 $\mathbf{P}_i^C = (X_i^C, Y_i^C, Z_i^C)^\top$ 。代入 $\mathbf{P}_i^C = \sum_j \alpha_{ij} \mathbf{c}_j^C$ 得

$$\sum_{j=1}^4 \alpha_{ij} x_j = \tilde{u}_i \sum_{j=1}^4 \alpha_{ij} z_j, \quad \sum_{j=1}^4 \alpha_{ij} y_j = \tilde{v}_i \sum_{j=1}^4 \alpha_{ij} z_j.$$

对每个关键点 i 得到关于 12 个未知量 $\mathbf{x} = [x_1, y_1, z_1, \dots, x_4, y_4, z_4]^\top$ 的两个线性方程。设共有 n 组 2D-3D 对应 (本文为四个关键点, $n = 4$; RANSAC 子集亦取四点), 则得到 $2n$ 个方程的线性方程组 $\mathbf{Ax} = \mathbf{0}$ (或齐次形式下求 $\mathbf{x}$ 的非零解再尺度化)。解出 $\mathbf{c}_j^C$ 后, 由物体系与相机系下控制点对应 $\mathbf{c}_j^C = \mathbf{R}\mathbf{c}_j^O + \mathbf{t}$ 通过最小二乘或 SVD 恢复 $\mathbf{R}$ 与 $\mathbf{t}$, 并施以正交化保证 $\mathbf{R} \in SO(3)$ 。

综上, 在当前任务下 EPnP 的输入为: 二级网络输出的四个二维关键点 $\mathbf{p}_i$ (三定位孔中心 + 线缆根部) 与 CAD 中对应 $\mathbf{P}_i^O$; 通过上述控制点参数化建立 $\mathbf{Ax} = \mathbf{0}$, 求解得控制点相机坐标, 再反解位姿。四点对应即可建立 8 个方程、12 个未知量, 在齐次约束下可求唯一解, 与 2.5.2 节 RANSAC 每次抽取的最小子集规模一致, 便于在遮挡导致单点偏差时通过多次抽样得到稳定位姿。

2.5.2 基于 RANSAC 的外点剔除

考虑部分关键点因线缆遮挡、强反光或热力图漂移而产生错误观测, 引入 RANSAC 对关键点集合进行鲁棒估计。其优化目标可表示为

$$(\hat{\mathbf{R}}, \hat{\mathbf{t}}) = \arg \min_{\mathbf{R}, \mathbf{t}} \sum_{i \in \mathcal{I}} \|\mathbf{p}_i - \pi(\mathbf{P}_i, \mathbf{R}, \mathbf{t})\|_2^2,$$

式中, $\mathcal{I}$ 表示内点集合, $\pi(\cdot)$ 表示相机投影函数。

在本文任务中, RANSAC 的“模型”即由 2.5.1 节 EPnP 基于 2D-3D 对应求得的位姿 $(\mathbf{R}, \mathbf{t})$; “模型假设”指每次从当前关键点集合中随机抽取一组最小子集, 用该子集的 2D-3D 对应通过 EPnP 求得一个候选 $(\mathbf{R}, \mathbf{t})$, 并假定该位姿在未被遮挡、无漂移的“内点”上成立。由于 EPnP 需至少四组对应方可求解, 最小子集规模取为 4, 与二级网络输出的四个关键点 (三定位孔中心 + 线缆根部) 一致; 若抽样到的四点中混入因线缆遮挡或热力图峰值漂移导致的错误观测, 则本次假设的位姿将偏离真实值, 后续用重投影误差筛选出的内点数量会偏少。因此, RANSAC 通过多次随机抽样, 以“内点数量最多”的假设作为最终位姿, 从而在部分关键点为外点的条件下仍能稳定估计连接器位姿, 满足航空机舱遮挡与反光场景下的鲁棒解算需求。

设第 i 个关键点为重投影误差为

$$e_i = \|\mathbf{p}_i - \pi(\mathbf{P}_i, \mathbf{K}, \mathbf{R}, \mathbf{t})\|_2^2,$$

则其内点判据为 $e_i < \tau$ ；当前方案中取 $\tau = 3$ 像素，以兼顾高精度装配要求与遮挡条件下的鲁棒性。算法2-1给出基于 EPnP 的 RANSAC 位姿估计流程。

算法 2-1 基于 EPnP 的 RANSAC 位姿估计

Input: 二维关键点 $\{\mathbf{p}_i\}$ ，对应三维点 $\{\mathbf{P}_i^O\}$ ，内参 $\mathbf{K}$ ，重投影阈值 τ ，最大迭代次数 $N_{\max}$

Output: 位姿 $(\hat{\mathbf{R}}, \hat{\mathbf{t}})$ 及内点集合 $\mathcal{I}^*$

```

1 for  $k = 1$  to  $N_{\max}$  do
2     从当前对应中随机抽取 4 组 2D-3D 对;
3     用 EPnP 求解得候选位姿  $(\mathbf{R}_k, \mathbf{t}_k)$ ;
4     对全部关键点计算  $e_i = \|\mathbf{p}_i - \pi(\mathbf{P}_i^O, \mathbf{K}, \mathbf{R}_k, \mathbf{t}_k)\|_2^2$ ;
5     统计内点集合  $\mathcal{I}_k = \{i : e_i < \tau\}$  的规模  $|\mathcal{I}_k|$ ;
6     if  $|\mathcal{I}_k| > |\mathcal{I}^*|$  then
7         更新  $\mathcal{I}^* := \mathcal{I}_k$ ，并记录  $(\mathbf{R}^*, \mathbf{t}^*) := (\mathbf{R}_k, \mathbf{t}_k)$ ;
8     end
9 end
10 以  $\mathcal{I}^*$  为内点，用全部内点重新运行 EPnP（或最小二乘）得到最终
     $(\hat{\mathbf{R}}, \hat{\mathbf{t}})$ ;
11 return  $(\hat{\mathbf{R}}, \hat{\mathbf{t}})$  与  $\mathcal{I}^*$ 
    
```

图 2-17
(空白占位图)

图 2-17 EPnP+RANSAC 位姿解算流程图（关键点输入 → EPnP 初值 → 重投影误差判据 → 外点剔除 → 位姿重估）

如图2-18所示，RANSAC 外点剔除前后，重投影误差分布与内点集合会发

生明显变化。剔除前，受线缆遮挡或热力图漂移影响的关键点对应的 e_i 较大，若直接采用全部点做 EPnP 或最小二乘，这些外点会拉偏位姿估计。剔除后，仅保留 $e_i < \tau$ 的内点参与最终位姿求解（或用于对最优假设的再估计），误差分布更集中、内点集合在图像上的空间分布与真实定位孔/线缆根部更一致，从而为后续手眼标定与抓取规划提供更可靠的位姿输入。该效果与算法2-1中“以内点数量最大为准则选取假设、再以内点集合重算位姿”的步骤相对应。实际系统中，最终位姿结果采用 RANSAC 剔除后多帧结果的平均值，以进一步抑制单帧观测噪声、提高位姿输出的稳定性。




图 2-18
(空白占位图)

图 2-18 RANSAC 外点剔除效果图（剔除前后重投影误差分布与内点集合可视化）

2.5.3 手眼标定与坐标系转换

为将 2.5.1 与 2.5.2 节得到的相机系下连接器位姿转换为机器人可执行目标，本文采用 Eye-in-Hand 模式完成手眼标定。首先对涉及的各坐标系及变换符号做统一约定。

坐标系定义与符号约定。记机器人基坐标系为 $\{B\}$ ，原点固连于基座，用于描述机械臂各连杆与末端在基座下的位姿；末端法兰坐标系为 $\{E\}$ ，原点位于法兰中心，随机械臂运动；相机坐标系为 $\{C\}$ ，原点为相机光心， z 轴指前、 x, y 与像面轴一致；目标物体坐标系为 $\{O\}$ ，与连接器 CAD 或位姿解算所用物体一致。变换矩阵采用左上标“目标系”、右下标“源系”的记法： ${}^B\mathbf{T}_E \in SE(3)$ 表示将 $\{E\}$ 下的点或位姿变换到 $\{B\}$ 下，即 $\mathbf{p}^B = {}^B\mathbf{T}_E \mathbf{p}^E$ 。同理， ${}^E\mathbf{T}_C$ 为相机在末端系下的外参（手眼矩阵）， ${}^C\mathbf{T}_O$ 为 2.5 节 PnP 输出的目标在相机系下的位姿。则目标在基座系下的位姿为

$${}^B\mathbf{T}_O = {}^B\mathbf{T}_E {}^E\mathbf{T}_C {}^C\mathbf{T}_O. \quad (2-1)$$

其中， ${}^B\mathbf{T}_E$ 由机械臂正运动学实时给出， ${}^C\mathbf{T}_O$ 由本章级联感知与 EPnP/RANSAC

输出； ${}^E\mathbf{T}_C$ 为标定未知量，不随机械臂运动改变。

手眼标定原理与 Tsai-Lenz 两步法。在 Eye-in-Hand 下，相机固连于末端，故 ${}^E\mathbf{T}_C$ 为常值。令机械臂依次运动到 $i = 1, \dots, N$ 个不同姿态，在每一姿态下由正解得到 ${}^B\mathbf{T}_E^{(i)}$ ，由视觉得到 ${}^C\mathbf{T}_O^{(i)}$ 。记相邻两帧间末端在基座系下的相对运动为 $\mathbf{A}_i = ({}^B\mathbf{T}_E^{(i)})^{-1}{}^B\mathbf{T}_E^{(i+1)}$ ，目标在相机系下的相对运动（等价于相机相对目标的反向运动）为 $\mathbf{B}_i = ({}^C\mathbf{T}_O^{(i)})^{-1}{}^C\mathbf{T}_O^{(i+1)}$ ，则手眼约束可写为 $\mathbf{A}_i\mathbf{X} = \mathbf{X}\mathbf{B}_i$ ，其中 $\mathbf{X} = {}^E\mathbf{T}_C$ 为待求手眼矩阵。将该式按旋转与平移拆开，记 $\mathbf{A}_i = (\mathbf{R}_{A_i}, \mathbf{t}_{A_i})$ 、 $\mathbf{B}_i = (\mathbf{R}_{B_i}, \mathbf{t}_{B_i})$ 、 $\mathbf{X} = (\mathbf{R}_X, \mathbf{t}_X)$ ，有

$$\mathbf{R}_{A_i}\mathbf{R}_X = \mathbf{R}_X\mathbf{R}_{B_i}, \quad \mathbf{R}_{A_i}\mathbf{t}_X + \mathbf{t}_{A_i} = \mathbf{R}_X\mathbf{t}_{B_i} + \mathbf{t}_X.$$

Tsai-Lenz 两步法先由多组 $\mathbf{R}_{A_i}, \mathbf{R}_{B_i}$ 通过旋转方程求解 $\mathbf{R}_X$ （可转化为线性方程组或 SVD），再代入平移方程求 $\mathbf{t}_X$ 。本文通过多姿态采样（如 20 组标定图像）构建多组 $(\mathbf{A}_i, \mathbf{B}_i)$ ，求解 $\mathbf{X}$ 并对残差进行评估；依据已有记录，标定后重投影误差可控制在约 0.42 pixels，对应空间位置误差约 0.35 mm，能够满足后续连接器抓取与装配的精度需求。




图 2-19
(空白占位图)

图 2-19 Eye-in-Hand 手眼标定过程与坐标系关系图（ $\{B\}, \{E\}, \{C\}, \{O\}$ 及 ${}^B\mathbf{T}_O$ 链式变换）

如图 2-19 所示， $\{B\}$ 、 $\{E\}$ 、 $\{C\}$ 、 $\{O\}$ 的几何关系与式 (2-1) 的链式相乘顺序一致：基座下的目标位姿由末端位姿、手眼矩阵与相机系下目标位姿依次右乘得到。在航空非结构化环境中，该位姿在基座系下可直接用于机器人执行。

2.6 算法验证实验

本节面向航空制造场景中“多实例堆叠、金属反光/阴影、柔性线缆遮挡”三类典型干扰，对本章级联视觉感知与位姿解算流程进行端到端验证。流程由 YOLOv8-seg 在整图完成目标实例定位、TagID 识别与粗分割以生成可靠 ROI；

在 ROI 内由改进 DeepLabV3+ 输出关键点热力图峰值与线缆精细掩膜；最后由 EPnP/RANSAC 结合 CAD 先验完成连接器 6D 位姿估计并剔除外点，并通过 2.5.3 节手眼矩阵将结果统一到机器人基座坐标系。

图 2-20
(空白占位图)

图 2-20 第二章端到端验证链路图 (RGB 输入 $\rightarrow$ YOLOv8-seg 检测/粗分割/TagID $\rightarrow$ 动态 ROI 裁剪 $\rightarrow$ 改进 DeepLabV3+ 关键点 + 线缆 $\rightarrow$ EPnP/RANSAC 位姿 $\rightarrow$ 手眼变换到 $\{B\}$)

图2-20给出了航空非结构化环境下的端到端验证链路。该链路体现“由粗到精”的信息流：整图尺度上需稳定获得目标实例位置与标签身份，否则局部网络易受背景与多实例混淆；ROI 内关键点与线缆为小尺度特征，整图直接回归易受反光与遮挡产生峰值漂移；位姿解算需显式引入 CAD 先验与投影一致性检验，方能得到可执行的 6D 位姿。检测—精细特征—几何解算—坐标统一由此形成闭环。

图 2-21
(空白占位图)

图 2-21 YOLOv8-seg 阶段输出可视化图 (多实例堆叠与线缆遮挡场景下的检测框、实例掩膜与 TagID 识别结果)

图2-21展示了 YOLOv8-seg 在复杂背景与多实例堆叠条件下的阶段性输出。该阶段完成实例级分离、身份识别与位置约束：实例掩膜提供连接器粗轮廓，使 ROI 裁剪避开大面积背景与反光；TagID 区分同视野中的不同实例，避免多实例邻近时的 ROI 交叉与目标错配；检测框与置信度支撑 ROI 动态扩展。该阶段输

出质量直接制约 ROI 内关键点与线缆分割的稳定性。




图 2-22
(空白占位图)

图 2-22 改进 DeepLabV3+ 阶段输出可视化图 (ROI 内关键点热力图峰值定位与线缆精细分割结果叠加展示)

图2-22给出了 ROI 尺度下改进 DeepLabV3+ 的双分支输出效果。与仅回归关键点坐标的方案相比，热力图监督能够在遮挡、反光导致局部纹理不连续时提供更稳定的峰值结构；线缆分割分支将柔性线缆干扰显式表征为像素级掩膜。该阶段的有效性体现在两点：其一，定位孔中心与线缆根部在热力图上呈现集中峰值，便于以 soft-argmax 或峰值搜索得到亚像素级二维观测 $\mathbf{p}_i$ ，从而降低 2.5 节投影误差的上界；其二，线缆掩膜边界在细尺度上与真实轮廓一致，减少“线缆覆盖定位孔边缘”导致的关键点偏移概率。由于本章位姿解算仅依赖四个关键点构成的 2D-3D 对应，该阶段对关键点峰值稳定性的提升将直接转化为 EPnP 初值与 RANSAC 内点一致性提升，从而增强在航空机舱遮挡工况下的解算鲁棒性。




图 2-23
(空白占位图)

图 2-23 EPnP/RANSAC 位姿估计结果可视化图 (模型坐标轴或 CAD 投影轮廓叠加到图像, 显示外点剔除前后的一致性差异)

图2-23用于验证“二维观测—三维先验—几何一致性检验”对位姿输出的约束作用。首先，EPnP 利用四个关键点的 2D-3D 对应在 $SE(3)$ 上求得相机系

下目标位姿 cT_o ，将 CAD 先验引入求解，使输出具备明确的物理含义；其次，RANSAC 通过重投影误差一致性对关键点外点进行剔除，避免单个遮挡点或峰值漂移点对位姿的拉偏。可视化叠加（如坐标轴或 CAD 轮廓投影）能够直观体现：当外点存在时，投影轮廓与图像边缘/孔位位置出现偏离；剔除外点并基于内点重估后，投影一致性显著增强，最终位姿满足后续机器人抓取与装配对方向/位置的约束需求。结合 2.5.2 节的多帧平均策略，位姿在时间维度上更平滑，有利于抑制观测抖动对执行稳定性的影响。

2.7 本章小结

本章围绕航空制造场景下电连接器视觉感知难题，构建了一套由粗到精的级联式识别与位姿估计方法。通过 YOLOv8-seg 在整图中完成目标实例定位、标签 ID 识别与粗分割；随后，在 ROI 区域内利用改进 DeepLabV3+ 实现关键特征提取与线缆精细分割；最后，结合 EPnP 与 RANSAC 完成连接器 6D 位姿解算，并通过手眼标定将结果转换到机器人可执行坐标系中。

第3章 电连接器自主抓取方法研究

3.1 引言

本章在电连接器目标的实例区分、6D 位姿估计及 Cable Mask 提取基础上, 研究狭窄机舱环境中的电连接器自主抓取问题, 重点解决候选抓取生成、最优抓取筛选以及避开线缆障碍的运动规划三个环节。与一般规则零件抓取不同, 本文研究对象尾部连接柔性线缆, 且周围存在舱壁、支架和设备边界等刚性障碍, 因此机械臂在接近、夹持和提离过程中同时面临窄通道搜索与刚柔混合避障约束。本章抓取任务还需服务于后续装配过程, 所选抓取位姿不仅要保证稳定夹持, 还应避免遮挡插针端并尽量与装配轴线保持一致。为此, 本文构建“端到端 6D 抓取生成—多约束抓取筛选—GRRT-Connect 引导式规划”的技术路线, 为第四章柔顺装配提供稳定的预装配初始状态。

3.2 端到端 6D 抓取生成网络

在获得目标电连接器的局部点云后, 需要进一步从中生成能够被机械臂执行的候选抓取位姿。本文采用基于点云的端到端 6D 抓取生成网络, 直接由目标局部点云预测候选抓取集合, 以提高在遮挡、视角变化和点云不完整条件下的抓取鲁棒性。考虑到 Contact-GraspNet 在单视角点云抓取生成中的良好泛化能力, 本文以其网络框架为基础, 并结合电连接器对象的任务特性对输入组织和候选生成方式进行适配。

3.2.1 抓取位姿参数化表示

为统一描述平行夹爪在空间中的抓取状态, 本文采用抓取位姿

$$g = (\mathbf{t}_g, \mathbf{R}_g) \in SE(3) \quad (3-1)$$

作为候选抓取的核心表达, 并在此基础上引入面向夹爪几何的参数化物理量以降低位姿回归难度。设 $\mathbf{c} \in \mathbb{R}^3$ 为目标表面可见的接触点 (contact point), $\mathbf{x} \in \mathbb{R}^3$ 为夹爪平行闭合方向 (夹爪开合轴), $\mathbf{z} \in \mathbb{R}^3$ 为夹爪接近方向 (法向接近轴), $\omega \in \mathbb{R}$ 为夹爪开度 (两指间距), $d \in \mathbb{R}$ 为夹爪沿接近方向的偏置长度, 则抓取位姿的平移与旋转可分别写为

$$\mathbf{t}_g = \mathbf{c} + \frac{\omega}{2}\mathbf{x} - d\mathbf{z}, \quad (3-2)$$

$$\mathbf{R}_g = [\mathbf{x} \ \mathbf{x} \times \mathbf{z} \ \mathbf{z}]. \quad (3-3)$$

其中, $\|\mathbf{x}\|_2 = 1$ 、 $\|\mathbf{z}\|_2 = 1$ 且 $\mathbf{x}^\top \mathbf{z} = 0$, 从而 $\mathbf{R}_g \in SO(3)$ 。式中 $\mathbf{t}_g$ 表示夹爪在抓取时的参考位姿位置: 以接触点 $\mathbf{c}$ 为锚点, 沿闭合方向平移 $\omega/2$ 以使两指围绕接触区域对称分布, 并沿接近方向后退 d 以预留接近与闭合空间; $\mathbf{R}_g$ 则由闭合轴 $\mathbf{x}$ 与接近轴 $\mathbf{z}$ 构造正交抓取坐标系, 其第二列通过叉乘给出, 用于保证姿态的正交一致性。由此, 抓取位姿可由 $(\mathbf{c}, \mathbf{x}, \mathbf{z}, \omega, d)$ 的参数化物理量确定, 相较于直接回归完整 6D 位姿, 该表达将姿态约束显式编码到 $\mathbf{R}_g$ 的构造中, 有利于在局部遮挡导致点云不完整时保持候选抓取在几何意义上的可解释性与稳定性。



图 3-1
(空白占位图)

图 3-1 抓取位姿参数示意图 (接触点 $\mathbf{c}$ 、闭合方向 $\mathbf{x}$ 、接近方向 $\mathbf{z}$ 、夹爪开度 ω 与偏置长度 d)

上述参数化与后文抓取网络的输出形式保持一致: 以点云可见表面上的接触点 $\mathbf{c}$ 作为锚点生成候选, 网络仅需对每个接触点预测闭合方向 $\mathbf{x}$ 、接近方向 $\mathbf{z}$ 及夹爪开度 ω 等物理量; 方向向量经标准化与正交化后代入式 (3-3) 构造 $\mathbf{R}_g$, 并与 $\mathbf{c}$ 、 ω 、 d 一并代入式 (3-2) 得到 $\mathbf{t}_g$ 。该表示将抓取姿态的几何约束显式编码到构造过程中, 有利于在航空机舱狭窄空间与柔性线缆干扰条件下形成可解释的候选分布: 优先在电连接器壳体稳定夹持区产生接触点, 降低在插接端与线缆根部等敏感区域生成候选的概率, 同时通过接近方向 $\mathbf{z}$ 的任务相关性约束, 为后续装配阶段的姿态连续性与对准质量提供基础。

3.2.2 基于局部点云的网络输入构建

抓取网络若直接以整场景点云为输入, 在航空机舱等背景复杂、多目标与垂落线缆并存的环境中会产生大量非目标区域的有效预测, 并增加计算负担。

因此，本文在输入侧将“整场景 RGB-D + 视觉感知结果”收敛为“目标局部点云 + 线缆先验”的规范化表示，处理逻辑按流程顺序分为四步：目标局部区域提取、深度反投影生成相机系点云、坐标系变换与尺度姿态规范化、线缆禁入域先验与采样权重赋值。以下按该顺序展开并给出相应数学表达与算法流程。

(1) **目标局部区域提取**。输入为第二章得到的电连接器实例分割掩膜、6D 位姿估计结果以及线缆分割掩膜 (Cable Mask)。根据目标实例掩膜在深度图上裁剪出目标对应像素集合 $\{(u_i, v_i, z_i)\}_{i \in \mathcal{I}_{\text{obj}}}$ ，剔除背景与相邻目标像素，得到仅覆盖当前连接器及其可见表面的像素—深度对，作为后续反投影的输入。线缆掩膜在本阶段用于标记禁入区域，供第四步采样权重使用。

(2) **深度反投影与相机系点云生成**。对上述像素—深度对，利用相机内参将二维观测反投影至相机坐标系 $\{C\}$ 下的三维点云。设像素坐标为 (u_i, v_i) ，深度值为 z_i ，内参矩阵为 $\mathbf{K}$ ，则相机系下三维点为

$$\mathbf{P}_i^c = z_i \mathbf{K}^{-1} \begin{bmatrix} u_i \\ v_i \\ 1 \end{bmatrix}, \quad i \in \mathcal{I}_{\text{obj}}. \quad (3-4)$$

由此得到目标在相机系下的局部点云 $\mathcal{P}^c = \{\mathbf{P}_i^c\}$ ，其几何已限定于当前连接器可见表面，为后续坐标系规范化与网络输入提供几何基础。

(3) **坐标系变换与尺度姿态规范化**。为减弱不同安装姿态、相机视角与局部遮挡对网络输入分布的影响，将 $\mathcal{P}^c$ 变换至目标物体坐标系 $\{O\}$ （与位姿估计所用物体系一致），并进行尺度归一化。记第二章输出的目标在相机系下的位姿为 ${}^c\mathbf{T}_O \in SE(3)$ ，则物体系下点坐标为

$$\mathbf{P}_i^O = ({}^c\mathbf{T}_O)^{-1} \mathbf{P}_i^c = ({}^O\mathbf{R}_C \quad {}^O\mathbf{t}_C) \begin{bmatrix} \mathbf{P}_i^c \\ 1 \end{bmatrix}, \quad i \in \mathcal{I}_{\text{obj}}. \quad (3-5)$$

其中 ${}^O\mathbf{R}_C \in SO(3)$ 、 ${}^O\mathbf{t}_C \in \mathbb{R}^3$ 为从相机系到物体系的旋转与平移。若需尺度统一，可再对 $\mathcal{P}^O = \{\mathbf{P}_i^O\}$ 按连接器模型或包围盒尺度进行缩放，使网络输入与训练阶段尺度一致。规范化后的 $\mathcal{P}^O$ 即为抓取网络几何输入的主体。

(4) **线缆禁入域先验与采样权重**。为避免候选抓取过度集中于线缆根部与插针端等功能敏感区，本文在输入构建阶段为每个点赋予与“到线缆距离”相关的采样优先级权重，使后续 PointNet++ 分层采样及抓取预测头在训练与推理中更倾向于以壳体稳定夹持区为锚点。设由 Cable Mask 反投影并体素化得到的线缆点云（或体素集合）为 $\mathcal{P}_{\text{cable}}$ ，点 $\mathbf{P}_i^O$ 到线缆的最小距离定义为

$$d_{\text{cable}}(\mathbf{P}_i^O) = \min_{\mathbf{q} \in \mathcal{P}_{\text{cable}}} \|\mathbf{P}_i^O - \mathbf{q}\|_2. \quad (3-6)$$

采样权重取为距离的单调递增函数，例如 $w_i = \sigma(d_{\text{cable}}(\mathbf{P}_i^O)/\lambda)$ ，其中 $\sigma(\cdot)$ 为 Sigmoid 函数， λ 为尺度参数；或简化为阈值形式：当 $d_{\text{cable}}(\mathbf{P}_i^O) < \rho$ 时令 $w_i = 0$ （禁入），否则 $w_i = 1$ 。权重 w_i 可在网络分层采样时用于调节点的被采样概率，或在损失中对靠近线缆的预测施加抑制，从而从输入与监督两侧共同引导抓取候选远离线缆禁入域。

算法 3-1 给出上述四步的流程汇总。

算法 3-1 目标局部点云与线缆先验输入构建

Input: 整场景 RGB-D；目标实例掩膜、 ${}^c\mathbf{T}_O$ 与 Cable Mask（来自第二章）

Output: 物体系下目标局部点云 $\mathcal{P}^O$ ；各点采样权重 $\{w_i\}$

- 1 根据目标实例掩膜从深度图裁剪像素—深度对 $\{(u_i, v_i, z_i)\}_{i \in I_{\text{obj}}}$ ；
- 2 由式 (3-4) 反投影得到相机系点云 $\mathcal{P}^c$ ；
- 3 由式 (3-5) 将 $\mathcal{P}^c$ 变换至物体系，得 $\mathcal{P}^O$ ，必要时做尺度归一化；
- 4 由 Cable Mask 得到线缆点云/体素 $\mathcal{P}_{\text{cable}}$ ；对每点 $\mathbf{P}_i^O$ 计算 $d_{\text{cable}}(\mathbf{P}_i^O)$ 并赋权重 w_i ；
- 5 **return** $\mathcal{P}^O, \{w_i\}$

图 3-2
(空白占位图)

图 3-2 目标局部点云裁剪与坐标系规范化示意图（自左至右：整场景深度与实例掩膜、裁剪后目标像素—深度、相机系局部点云、物体系规范化点云及线缆禁入域权重示意）

如图 3-2 所示，本小节方法将“整场景—目标裁剪—反投影—坐标系与尺度规范化—线缆先验”串联为一条确定的预处理流水线。图中左侧整场景深度与实例掩膜对应算法 3-1 的输入，裁剪后仅保留当前连接器对应像素，避免舱壁、支架及相邻连接器进入后续点云；反投影后得到的相机系点云在几何上已限定于目标可见表面。经式 (3-5) 变换至物体系并做尺度归一化后，不同视角与安装姿态下的输入在统计上更一致，有利于网络聚焦连接器壳体几何与夹持区

域。图中对线缆禁入域或权重分布的标注则对应式 (3-6) 与采样权重 w_i 的工程含义：靠近线缆根部的点获得较低权重或禁入标记，使抓取网络在接触点采样与高分预测上自然偏向壳体两侧与上表面，与本文“稳定夹持、避免遮挡插针端、减少线缆干涉”的任务目标一致。

综上， $\mathcal{P}^0$ 与 $\{w_i\}$ 作为后续抓取网络的几何输入与先验，在输入层即体现壳体稳定夹持与线缆禁入的任务约束，为端到端抓取生成提供结构清晰、任务一致的输入表示。

3.2.3 改进的 Contact-GraspNet 网络结构

Contact-GraspNet 以点云为输入、经 PointNet++ 与四分支预测头输出抓取参数，但原文献对层级与预测量同 3.2.1 节参数化 $(\mathbf{c}, \mathbf{x}, \mathbf{z}, \omega, d)$ 的对应关系交代不足；整场景输入在机舱多目标与线缆并存场景下易产生无效采样、候选分散于背景或线缆根部。本节在保留其骨干与预测头框架下做两点适配：**(1) 输入**采用 3.2.2 节的 $\mathcal{P}^0$ 与 $\{w_i\}$ ，仅在连接器可见表面采样；**(2) 监督/采样**结合线缆禁入域调制损失或采样概率，使高分候选集中于壳体两侧与上表面。以下按整体架构、特征骨干与预测头分述。




图 3-3
(空白占位图)

图 3-3 端到端 6D 抓取生成网络整体架构图（输入：目标局部点云与线缆先验；特征提取：PointNet++；预测：抓取方向/接近方向/抓取得分/夹爪宽度四分支；输出：候选抓取位姿集合；虚线表示位姿先验与线缆禁入域对采样的引导）

如图 3-3 所示，网络由输入层、PointNet++ 特征层、四分支预测层与候选输出层串联。输入为 $\mathcal{P}^0$ 与可选 $\{w_i\}$ ，将计算限定于当前连接器；第一次降采样点集即候选接触点 $\mathbf{c}$ 。四分支分别输出闭合方向、接近方向、抓取得分与开度 ω ，经标准化与正交化后按式 (3-2)、式 (3-3) 重组为 6D 位姿。图中虚线表示位姿先验与线缆禁入域在采样或损失中的调制，使候选满足“壳体优先、线缆与插针端抑制”。



图 3-4
(空白占位图)

图 3-4 PointNet++ 骨干网络结构示意图 (Set Abstraction 层级、Ball Query 邻域、MLP 特征聚合及第一次降采样点即候选接触点)

如图 3-4 所示, 骨干为 PointNet++ 多级 Set Abstraction: Ball Query 取邻域、MLP 聚合特征, 第一级降采样点集即候选接触点 $\mathbf{c}$, 预测头在该点集上逐点输出 $\mathbf{x}$ 、 $\mathbf{z}$ 、得分与 ω 。 $\{w_i\}$ 可参与中心点采样概率或损失权重, 将线缆先验融入前向与训练而不改网络拓扑。

四分支预测头与位姿恢复。方向分支输出 $\mathbf{v}'$ 、 $\mathbf{u}'$, 经标准化与正交化后得单位向量 $\mathbf{x}$ 、 $\mathbf{z}$:

$$\mathbf{v} = \frac{\mathbf{v}'}{\|\mathbf{v}'\|_2}, \quad \mathbf{u} = \frac{\mathbf{u}' - \langle \mathbf{v}, \mathbf{u}' \rangle \mathbf{v}}{\|\mathbf{u}' - \langle \mathbf{v}, \mathbf{u}' \rangle \mathbf{v}\|_2}; \quad \mathbf{x} = \mathbf{v}, \mathbf{z} = \mathbf{u}. \quad (3-7)$$

满足 $\|\mathbf{x}\|_2 = \|\mathbf{z}\|_2 = 1$ 、 $\mathbf{x}^\top \mathbf{z} = 0$ 。代入式 (3-3) 得 $\mathbf{R}_g$; 结合 $\mathbf{c}$ (降采样点坐标)、 ω 与偏置 d , 由式 (3-2) 得 $\mathbf{t}_g$, 即完整 $g = (\mathbf{t}_g, \mathbf{R}_g)$ 。该构造将姿态约束编码于几何公式, 利于遮挡下保持可解释性。




图 3-5
(空白占位图)

图 3-5 抓取候选分布对比示意图 (左: 整场景输入时候选分散于背景与线缆; 右: 目标局部点云与线缆先验下候选集中于连接器壳体稳定夹持区)

如图 3-5 所示, 整场景输入时候选分散于背景与线缆根部; 采用 3.2.2 节局部点云与线缆先验后, 候选集中于壳体两侧与上表面, 插针端与线缆侧高分候选减少, 更符合稳定夹持与装配导向, 便于 3.3、3.4 节筛选与规划。

3.2.4 正负样本判定与损失函数设计

在改进的 Contact-GraspNet 中, 3.2.1 节的抓取参数化 $(\mathbf{c}, \mathbf{x}, \mathbf{z}, \omega, d)$ 与 3.2.2、3.2.3 节构建的目标局部点云与候选接触点集合, 为训练阶段的样本标注与损失设计提供了清晰的几何基础。本节围绕“哪些点被视为有效抓取区域”“网络应重点学习哪些物理量”“如何通过损失函数体现电连接器任务的工程偏好”三个问题, 对正负样本判定规则、各分支损失形式及训练过程收敛特性进行系统说明。

(1) 基于接触邻域的正负样本判定。设视角下局部点云为 $\mathcal{P} = \{\mathbf{p}_i\}$, 由仿真或真实标注得到的抓取接触点集合为 $\mathcal{C} = \{\mathbf{c}_k\}$, 则以接触点邻域为判据构造二元标签:

$$y_i = \begin{cases} 1, & \min_k \|\mathbf{p}_i - \mathbf{c}_k\|_2 < r, \\ 0, & \text{otherwise,} \end{cases} \quad (3-8)$$

其中 r 为接触邻域半径。 $y_i = 1$ 表示该点附近存在稳定夹持接触关系, 可作为正样本; $y_i = 0$ 表示不属于有效抓取区域, 作为负样本。对于正样本点, 将其关联到最近接触点对应的抓取参数 $(\mathbf{c}, \mathbf{x}, \mathbf{z}, \omega)$, 用于后续姿态与宽度监督。结合 3.2.2 节的线缆禁入权重 w_i , 在实际训练中还可对靠近线缆根部和插针端的点下调其参与损失的权重, 使正负样本分布在壳体两侧与上表面更加均衡。

(2) 抓取分数与宽度损失。抓取分数分支输出每个候选接触点处的抓取置信度 $\hat{s}_i \in [0, 1]$, 理想情况应与标签 y_i 一致。采用带权重的二元交叉熵损失:

$$L_{\text{score}} = -\frac{1}{N} \sum_{i=1}^N (\alpha y_i \log \hat{s}_i + \beta (1 - y_i) \log (1 - \hat{s}_i)), \quad (3-9)$$

其中 $\alpha > \beta$ 用于缓解正负样本比例失衡问题, 在电连接器表面正样本 (稳定夹持区域) 远少于负样本 (壳体以外、线缆与舱壁区域) 时, 保证网络不会过度偏向输出“不可抓”。夹爪宽度分支输出预测开度 $\hat{\omega}_i$, 其监督量为标注宽度 ω_i , 采用 L_1 损失:

$$L_{\text{width}} = \frac{1}{N_+} \sum_{i: y_i=1} |\hat{\omega}_i - \omega_i|, \quad (3-10)$$

仅对正样本点计算, 以避免在无接触关系区域强行回归宽度。对于电连接器壳体来说, ω_i 还隐含“既能夹紧壳体、又不挤压线缆”的约束, 训练中通过选取覆盖面向装配的多种工况的标注宽度, 提升网络在不同壳体尺寸与线缆布置下

的适应性。

(3) 位姿损失与任务约束编码。基于 3.2.1 节的构造，预测抓取位姿记为 $g_i = (\hat{\mathbf{t}}_{g,i}, \hat{\mathbf{R}}_{g,i})$ ，对应标注位姿为 $g_i^* = (\mathbf{t}_{g,i}^*, \mathbf{R}_{g,i}^*)$ 。位姿损失由位置与方向两部分组成：

$$L_{\text{pose}} = \frac{1}{N_+} \sum_{i:y_i=1} \left(\lambda_t \|\hat{\mathbf{t}}_{g,i} - \mathbf{t}_{g,i}^*\|_2^2 + \lambda_R \phi(\hat{\mathbf{R}}_{g,i}, \mathbf{R}_{g,i}^*) \right), \quad (3-11)$$

其中 λ_t, λ_R 为权重系数， $\phi(\cdot, \cdot)$ 为旋转误差度量，例如

$$\phi(\hat{\mathbf{R}}, \mathbf{R}^*) = \|\log((\mathbf{R}^*)^\top \hat{\mathbf{R}})\|_2^2, \quad (3-12)$$

即李代数空间中的角度偏差平方。在电连接器任务中， $\mathbf{t}_{g,i}^*$ 与 $\mathbf{R}_{g,i}^*$ 来自“壳体稳定夹持、避免插针端和线缆根部”的标注策略，因此 L_{pose} 不仅约束几何误差，还将装配任务对抓取姿态的偏好隐含进损失中。

(4) 联合损失与线缆先验权重。综合上述三部分，抓取生成网络的总损失写为

$$L_{\text{grasp}} = \gamma_1 L_{\text{score}} + \gamma_2 L_{\text{width}} + \gamma_3 L_{\text{pose}}, \quad (3-13)$$

其中 $\gamma_1, \gamma_2, \gamma_3$ 为分支权重系数。训练时可将 3.2.2 节中点级权重 w_i 作为系数乘入对应样本的损失项，实现“靠近线缆与插针端的点对总损失贡献较小、壳体稳定区域点贡献较大”的策略，从而在优化阶段显式体现柔性线缆干扰与功能敏感区约束。



图 3-6
(空白占位图)

图 3-6 抓取生成网络训练过程中总体损失及各分支损失收敛曲线（蓝色： L_{grasp} ；橙色： L_{score} ；绿色： L_{width} ；红色： L_{pose} ）

如图 3-6 所示，随着训练迭代次数增加，总损失 L_{grasp} 单调下降并在若干轮后趋于稳定，各分支损失均呈现出先快速下降、后缓慢收敛的典型形态。其中 L_{score} 在引入正负样本权重与线缆禁入域后收敛更平滑，说明网络能够在“壳体

稳定区正样本少、背景负样本多”的不平衡条件下仍然学习到合理的抓取置信度判别边界； L_{width} 的收敛表明网络已基本掌握不同壳体尺寸与夹持方式下的开度分布； L_{pose} 的下降则反映了基于式 (3-11) 的位姿误差度量能够有效驱动网络在闭合方向、接近方向与接触点位置三者之间建立稳定对应关系，为 3.3 节抓取点筛选提供较小初始姿态偏差。




图 3-7 电连接器表面候选抓取位姿分布可视化结果（绿色：壳体稳定夹持区；黄色：插针端功能区；红色：线缆根部及禁入域；颜色越深表示抓取置信度越高）

如图 3-7 所示，高置信度候选抓取主要集中于连接器壳体两侧和上表面的稳定夹持区域，而在插针端和线缆根部附近则明显受到抑制。这一分布特征与第二章中电连接器功能区域划分保持一致，说明基于式 (3-8)–式 (3-13) 设计的正负样本与损失函数，已经将“稳定夹持、避免遮挡插针端、减小线缆干扰”的任务约束有效注入到抓取生成阶段，而非仅依赖 3.3、3.4 节的后续筛选与规划进行修正。

3.3 抓取点选择策略研究

端到端抓取生成网络通常会输出多组候选抓取，但这些候选在机械臂可达性、线缆安全性和任务相容性方面并不完全一致。若仅根据网络分数直接选择得分最高的抓取，容易出现局部几何上可抓但机械臂难以接近、与线缆发生干涉或不利于后续插接操作等问题。本文在候选抓取集合 $\mathcal{G}$ 的基础上进一步设计多约束抓取点选择策略，通过逐级筛选和综合评分确定最终执行抓取位姿。

3.3.1 基于逆运动学的可达性判别

端到端抓取生成网络输出的候选抓取位姿 $g_i = (\mathbf{t}_{g,i}, \mathbf{R}_{g,i})$ 仅从局部几何和任务约束角度保证“可夹持、远离线缆与插针端”，但并不保证机械臂在给定关节限位与工作空间内一定能够安全到达。因此，在抓取点选择的第一步，需

要从机器人运动学角度对每个 g_i 进行可达性判别，将“几何上可行”进一步约束为“关节空间中可执行”。这一判别不仅影响后续 GRRT-Connect 规划的搜索空间规模，也是保证航空机舱狭窄环境下动作链条可实施性的关键。

(1) 基于逆解存在性的可达性定义。记机械臂关节角为 $\mathbf{q} = [q_1, \dots, q_n]^\top$ ，正运动学映射为

$$f: \mathbb{R}^n \rightarrow SE(3), \quad g = f(\mathbf{q}), \quad (3-14)$$

其逆问题为：给定位姿 g_i ，求解满足

$$f(\mathbf{q}_i) = g_i, \quad \mathbf{q}_{\min} \leq \mathbf{q}_i \leq \mathbf{q}_{\max}, \quad (3-15)$$

的关节角 $\mathbf{q}_i$ ，其中 $\mathbf{q}_{\min}, \mathbf{q}_{\max}$ 为关节限位向量。可达性判别函数可形式化为

$$C_{IK}(g_i) = \begin{cases} 1, & \exists \mathbf{q}_i \text{ 使得 (3-15) 成立, 且满足速度/姿态等约束,} \\ 0, & \text{否则,} \end{cases} \quad (3-16)$$

仅当 $C_{IK}(g_i) = 1$ 时，候选抓取才进入后续线缆安全与任务姿态相容性评价。与仅在点云层面判定“是否存在稳定接触”的网络输出相比，式 (3-16) 进一步刻画了“机械臂是否有合法关节解”，能在规划前剔除大量在几何上可抓但实际不可执行的方案。

(2) 关节限位与裕量评价。在满足 (3-15) 的所有逆解集合 $\mathbf{Q}_i = \{\mathbf{q}_i^{(m)}\}$ 中，优选远离关节限位的解有助于提高后续规划的成功率。定义关节裕量代价为

$$J_{\lim}(\mathbf{q}_i^{(m)}) = \sum_{j=1}^n \left(\frac{q_j^{(m)} - \bar{q}_j}{q_{j,\max} - q_{j,\min}} \right)^2, \quad (3-17)$$

其中 $\bar{q}_j = (q_{j,\max} + q_{j,\min})/2$ 为第 j 个关节的中值。若 $\mathbf{Q}_i \neq \emptyset$ ，则可选择

$$\mathbf{q}_i^* = \arg \min_{\mathbf{q}_i^{(m)} \in \mathbf{Q}_i} J_{\lim}(\mathbf{q}_i^{(m)}), \quad (3-18)$$

并将 $J_{\lim}(\mathbf{q}_i^*)$ 作为可达性“质量”的辅助指标：值越小，说明当前抓取姿态在关节空间中越居中，留给 GRRT-Connect 扩展和局部避障的冗余越充足，越适用于机舱窄通道环境下的多阶段运动规划。

(3) 奇异性与工作空间边界判别。除关节限位外，奇异构型与工作空间边界也是影响可达性的关键因素。设雅可比矩阵为 $\mathbf{J}(\mathbf{q})$ ，则典型的可操作度指标为

$$w(\mathbf{q}) = \sqrt{\det(\mathbf{J}(\mathbf{q})\mathbf{J}^T(\mathbf{q}))}, \quad (3-19)$$

当 $w(\mathbf{q}) \rightarrow 0$ 时，机械臂接近奇异点，末端在某些方向上的运动能力显著下降，路径规划中的微小扰动可能导致关节大幅摆动。结合式 (3-18)，本文在数值求解逆运动学后，对 $\mathbf{q}_i^*$ 计算 $w(\mathbf{q}_i^*)$ ，若其低于给定阈值 $w_{\min}$ ，则认为该抓取虽有逆解但执行风险较高，可在后续综合评分中降低其权重或直接剔除。

综合上述因素，可将逆运动学可达性扩展为“硬约束 + 软评价”的形式：硬约束由式 (3-16) 给出（有合法逆解且满足关节限位），软评价通过 $J_{\lim}(\mathbf{q}_i^*)$ 与 $w(\mathbf{q}_i^*)$ 量化抓取在关节空间中的可用裕度。这样定义的可达性既保证了电连接器抓取在航空机舱受限空间内具备可执行性，又为 3.3.4 节综合评分函数提供了可与线缆安全和姿态相容性同等量化的评价量。




图 3-8
(空白占位图)

图 3-8 基于逆运动学的可达性判别结果示意图（灰色：不可达候选；蓝色：可达但关节裕量较小或接近奇异的候选；绿色：可达且关节裕量充足的候选）

如图 3-8 所示，电连接器表面初始候选抓取分布经式 (3-16) 判别和 (3-17)、(3-19) 指标过滤后，可达且关节裕量充足的候选（绿色）主要分布在机械臂工作空间内的“舒适区域”，而靠近机舱边界或背离主要操作侧的候选则因逆解缺失或接近奇异而被标记为灰色或蓝色。可达性判别使后续线缆安全与任务姿态相容性评价建立在“关节空间可执行”的候选集合上，避免在 GRRT-Connect 规划阶段反复尝试物理上难以实现的抓取姿态，从而减少在狭窄机舱环境中的无效搜索，提高整体规划效率与执行可靠性。

3.3.2 面向线缆障碍的安全间隙评价

为避免夹爪在接近、闭合和提离过程中与线缆发生高风险接触，本文对候选抓取引入线缆安全间隙评价。设线缆点云集合为 $\mathcal{P}_{\text{cable}}$ ，夹爪在候选抓取 g_i 下的占用体积为 $\mathcal{V}_{\text{gripper}}(g_i)$ ，则夹爪与线缆之间的最小距离可定义为

$$d_i = \min_{p \in \mathcal{V}_{\text{gripper}}(g_i), q \in \mathcal{P}_{\text{cable}}} \|p - q\|_2. \quad (3-20)$$

当 d_i 小于安全阈值 d_{safe} 时，说明夹爪在接近、闭合或提离过程中有较大概率与线缆发生接触，此时该候选抓取将被视为高风险方案并予以剔除。与传统仅针对刚性障碍进行碰撞检查的方法不同，这里评估的对象是与目标零件直接耦合的柔性拖缆，因此该指标直接反映了抓取动作的工程安全性，而非抽象意义上的空间无碰撞性。

为了便于综合评分，本文进一步将线缆安全间隙归一化为安全性得分

$$S_{\text{clearance}}(g_i) = \min \left(1, \frac{d_i}{d_{\text{ref}}} \right), \quad (3-21)$$

其中 d_{ref} 为设定的参考安全距离。当 d_i 较大时，说明夹爪与线缆之间具有更充分的安全裕度；当 d_i 较小时，则意味着该抓取在执行过程中更容易与柔性障碍发生干涉。实际计算中， $\mathcal{V}_{\text{gripper}}(g_i)$ 由夹爪几何模型在接近—闭合—提离三个动作阶段的扫掠体积离散得到， $\mathcal{P}_{\text{cable}}$ 则来源于由 **Cable Mask** 反投影并体素化后的三维线缆表示。为降低最小距离计算的复杂度，可在体素网格上预先构建线缆距离场 $\phi_{\text{cable}}(\cdot)$ ，用

$$d_i \approx \min_{p \in \mathcal{V}_{\text{gripper}}(g_i)} \phi_{\text{cable}}(p) \quad (3-22)$$

近似代替对 $\mathcal{P}_{\text{cable}}$ 的逐点最小化，从而在保持评价精度的同时提升对大量候选抓取进行批量判别时的计算效率。

将提取的 **Cable Mask** 信息转化为抓取决策阶段可利用的几何约束，与仅在路径规划阶段被动避障不同，本文在抓取点选择阶段就引入线缆安全间隙约束，使最终保留下来的候选抓取在空间上天然更远离高风险线缆区域，利于减小夹爪在接近、闭合和抬升过程中的缠绕风险，并提高整体动作链的稳定性。



图 3-9
(空白占位图)

图 3-9 线缆障碍的安全间隙可视化结果

3.3.3 面向任务的姿态相容性评价

抓取姿态还应与目标作业方向保持较高一致性。若抓取方向与后续操作方向差异过大，则虽然可以完成夹持，但在转运和预对准阶段往往需要较大的姿态调整，进而增加时间代价和碰撞风险。基于这一考虑，本文引入任务相容性评价，对候选抓取的接近方向与目标操作轴线之间的一致性进行量化分析。设目标操作轴方向为 $\mathbf{v}_{asm}$ ，抓取接近方向为 $\mathbf{v}_{grasp}$ ，则姿态相容性得分定义为

$$S_{align}(g_i) = \frac{\mathbf{v}_{grasp} \cdot \mathbf{v}_{asm}}{\|\mathbf{v}_{grasp}\|_2 \|\mathbf{v}_{asm}\|_2}. \quad (3-23)$$

当 S_{align} 越接近 1 时，说明当前抓取姿态与目标操作方向越一致。这种设计使抓取评价从“局部可夹持”进一步扩展为“便于后续动作衔接”，体现了面向装配的抓取思想。在电连接器场景中，姿态相容性评价还可以与功能区域约束联合考虑：插针端和关键定位区域不宜被夹爪直接遮挡，而壳体侧壁和上表面更适合作为稳定夹持区域。任务相容性评价不仅关注方向一致性，也隐含约束了夹爪与功能敏感区域之间的空间关系。

从实现角度看， $\mathbf{v}_{asm}$ 可由第三章开头定义的装配轴线（例如插头插入方向或连接器壳体上预定义的参考方向）确定， $\mathbf{v}_{grasp}$ 则直接取自 3.2.1 和 3.2.3 节中定义和预测的接近方向 $\mathbf{z}$ 。因此，式中的内积本质上是“抓取接近轴与装配轴之间的夹角余弦”，在数值上与末端在预装配路径上的姿态调整幅度密切相关： S_{align} 越高，表示从抓取姿态平滑过渡到装配姿态所需的旋转越小，更利于在机舱狭窄空间和柔性线缆干扰下保持末端姿态稳定，也为第四章柔顺装配阶段提供更有利的初始姿态条件。

图 3-10
(空白占位图)

图 3-10 电连接器表面候选抓取任务姿态相容性结果

3.3.4 综合评分函数与最优抓取确定

在完成可达性判别、线缆安全评价和姿态相容性评价后，本文进一步构建

综合评分函数，对候选抓取进行统一排序。综合评分函数定义为

$$S_{\text{total}}(g_i) = w_1 S_{\text{quality}}(g_i) + w_2 S_{\text{clearance}}(g_i) + w_3 S_{\text{align}}(g_i), \quad (3-24)$$

其中 $S_{\text{quality}}(g_i)$ 为网络输出的抓取置信度, $S_{\text{clearance}}(g_i)$ 为线缆安全性得分, $S_{\text{align}}(g_i)$ 为姿态相容性得分, w_1 、 w_2 、 w_3 为各指标权重系数。最终执行抓取位姿定义为综合评分最高的候选抓取。相比于只依赖网络分数的基础方法, 综合评分策略能够更稳健地剔除那些局部分数较高但整体执行风险较大的抓取候选。最终选出的抓取位姿不仅具有较高的局部几何可靠性, 也更符合航空制造场景中的系统执行需求。

在权重设置上, 本文根据电连接器抓取—转运—预装配的任务特点, 通常令 w_1 与 w_2 略大于 w_3 : 一方面保证候选抓取具备足够的局部几何稳定性与线缆安全裕度, 避免因忽略柔性拖缆而引发风险; 另一方面通过 w_3 将“装配轴线一致性”纳入综合评价, 使在多个安全且可达的候选中优先选择更有利于后续装配的抓取姿态。图 3-11 所示的流程中, 综合评分函数将 3.3.1–3.3.3 小节给出的各项评价量汇总为单一标量, 使最优抓取确定过程在数学形式上更加清晰, 也便于在不同机舱工况下调整权重以适配不同的安全与效率需求。



图 3-11
(空白占位图)

图 3-11 基于多约束优化的最优抓取点筛选流程图（从候选抓取生成经逆运动学筛选、线缆安全间隙计算和姿态相容性评价后输出最优抓取位姿与预抓取位姿）

3.4 GRRT-Connect 运动规划算法研究

候选抓取经多约束筛选后, 仍需在狭窄机舱环境中规划从当前构型到预抓取、抓取、抬升及预装配等关键位姿的连续轨迹。机舱内同时存在刚性舱壁、设备支架和柔性线缆障碍, 且目标电连接器与线缆直接耦合, 若规划不当, 抓取后抬升和转运阶段仍可能引发线缆缠绕和插针端意外碰撞。本节在 RRT-Connect 算法基础上, 首先构建统一描述刚性结构与线缆障碍的混合障碍物地图, 然后

设计融合目标偏置与障碍引导的 GRRT-Connect 采样与扩展策略，最后通过路径生成与后处理优化得到满足机舱安全约束的平滑轨迹，实现对第三章前两节输出抓取姿态的安全执行。

3.4.1 混合障碍物地图构建

GRRT-Connect 要在机舱受限空间内同时规避刚性结构件和柔性线缆障碍，首先需要在统一的数据结构中表达两类障碍物的空间分布。本文构建混合障碍物地图 $\mathcal{M}_{\text{hyb}}$ ，并在构建与使用上采用“刚性静态、线缆动态”的更新策略：在初始感知阶段，除线缆以外的舱壁、支架和工装等均建模为刚性障碍并写入地图，在后续运动过程中不再更新；规划与运动开始后，仅将当前观测到的、由 CableMask 检测得到的线缆目标所对应的点云作为动态障碍物，按观测帧对线缆体素进行更新，其余地图内容保持不变。这样既保证了刚性环境约束的稳定可用，又使线缆占据随最新观测反映柔性拖缆的实际分布。

(1) **刚性障碍建模**。对舱壁、设备边界和工装结构，采用包围盒（AABB 或 OBB）形式在世界坐标系下进行几何描述，并在初始建图时一次性写入 $\mathcal{M}_{\text{hyb}}$ ，运动过程中不再修改。记刚性障碍集合为 $\mathcal{O}_{\text{rigid}} = \{\mathcal{B}_k\}$ ，其中 $\mathcal{B}_k$ 为第 k 个障碍的包围盒。当给定机械臂某一关节构型 q 时，可通过正运动学计算出各连杆与末端在基座系下的几何模型 $\mathcal{L}(q)$ ，刚性碰撞检测可形式化为

$$C_{\text{rigid}}(q) = \begin{cases} 1, & \mathcal{L}(q) \cap \bigcup_k \mathcal{B}_k = \emptyset, \\ 0, & \text{otherwise.} \end{cases} \quad (3-25)$$



图 3-12
(空白占位图)

图 3-12 混合障碍物地图构建结果图（刚性障碍与柔性线缆障碍）

这一部分建模对应图 3-12 中由规则长方体或多面体表示的舱壁和设备结构，主要用于约束机械臂在机舱内的整体工作空间。

(2) 线缆障碍三维化与体素编码。CableMask 为相机像面上的二维掩膜，记其像素集合为 $\mathcal{I}_{\text{cable}} = \{(u_j, v_j, z_j)\}$ ，其中 z_j 为对应深度值。利用反投影公式

$$\mathbf{P}_j^c = z_j \mathbf{K}^{-1} \begin{bmatrix} u_j \\ v_j \\ 1 \end{bmatrix}, \quad (3-26)$$



图 3-13 线缆障碍三维化处理效果图（真实场景与反投影点云、动态体素占据）

如图 3-13 所示，在包含柔性线缆干扰的真实机舱场景中，CableMask 输出像素级线缆掩膜并完成区域分割，仅保留掩膜区域与对应深度 z_j 参与反投影，从而将线缆的连续形态离散为相机坐标系下的点云 $\mathcal{P}_{\text{cable}}^c$ 。在手眼标定约束下，点云经坐标变换映射到地图系 $\{\mathcal{W}\}$ ，得到规划空间中的线缆几何表示。随后，规划/运动阶段仅使用当前观测帧中检测到的线缆目标对应点云对 Octomap 体素进行更新；除线缆外的舱壁、支架与工装等刚性障碍保持静态不参与更新。该处理机制使线缆占据结果随最新观测自适应更新，同时避免非线缆结构引入占据误差，从而增强 GRRT-Connect 碰撞约束的一致性与可执行性。得到的线缆点云 $\mathcal{P}_{\text{cable}}^{\mathcal{W}}$ 作为动态障碍物输入并进入后续体素占据概率更新。线缆占据空间采用八叉树体素地图（Octomap）编码：将连续空间划分为分辨率为 r_{voxel} 的体素栅格，对每个体素中心 $\mathbf{x}$ 维护占据概率 $p_{\text{occ}}(\mathbf{x})$ ，并根据当前线缆点云更新

$$p_{\text{occ}}(\mathbf{x} | \mathcal{P}_{\text{cable}}^{\mathcal{W}}) = \eta p_{\text{occ}}(\mathbf{x}) + (1 - \eta) \mathbb{I}\left(\min_{\mathbf{p} \in \mathcal{P}_{\text{cable}}^{\mathcal{W}}} \|\mathbf{x} - \mathbf{p}\|_2 < r_{\text{update}}\right), \quad (3-27)$$

其中 $\eta \in (0, 1)$ 为更新系数， $\mathbb{I}(\cdot)$ 为指示函数， r_{update} 为更新半径。占据概率高于阈值的体素被标记为线缆障碍体素集合 $\mathcal{V}_{\text{cable}}$ ，图 3-12 中以颜色块形式展示了这些体素在机舱中的分布。

(3) 混合地图与规划接口。最终，混合障碍物地图可表示为

$$\mathcal{M}_{\text{hyb}} = (\mathcal{O}_{\text{rigid}}, \mathcal{V}_{\text{cable}}), \quad (3-28)$$

规划器在进行碰撞检测时，同时检查机械臂连杆模型 $\mathcal{L}(q)$ 与刚性包围盒 $\mathcal{B}_k$ 以及线缆体素 $\mathcal{V}_{\text{cable}}$ 之间的相交关系。三维化表达能够更真实地反映夹爪扫掠体积与线缆之间的空间关系，采样引导、安全间隙评价与路径后处理均在同一地图上完成。

3.4.2 引导式采样与双树扩展策略

为在航空非结构化环境中降低柔性线缆干扰带来的方向不确定性，本文在上一小节得到的混合障碍物地图基础上引入线缆主方向 $\mathbf{d}_c$ 的方向相容约束。混合地图提供了刚性占据集合 $\mathcal{O}_{\text{rigid}}$ 以及随观测更新的线缆动态体素集合 $\mathcal{V}_{\text{cable}}$ ，但仅基于体素的各向同性距离度量会将线缆切向通行的相对宽松性等价化为统一半径，从而在相邻规划迭代中造成过度保守扩展并降低向目标推进的效率。同时，当末端在狭窄通道中的运动主要沿某一主导推进方向发生时，若未显式约束其扫掠方向与线缆主拖曳方向的相对关系，容易出现绕行但方向不利的无效扩展。

为实现方向敏感规避，本文构造一种由线缆方向向量 $\mathbf{d}_c$ 驱动的 GRRT-Connect 引导式扩展机制。该机制将 $\mathbf{d}_c$ 嵌入到启发式代价函数、采样接纳概率与柔性线缆安全判据中，使规划器在几何碰撞可验证性的约束下同时抑制柔性线缆干扰。该引导机制所需的输入由上一小节混合障碍物地图构建模块给出，线缆动态体素集合 $\mathcal{V}_{\text{cable}}$ 由 CableMask 反投影并按观测帧更新获得；线缆点云 $\mathcal{P}_{\text{cable}}^{\mathcal{W}}$ 在每次规划迭代时保持与当前观测一致，用于估计线缆主方向。线缆方向参照将在后续力位混合控制中用于切向/法向分解与阻抗参数调节，从而提升插接过程的稳定性与收敛性。

(1) 线缆方向向量估计与方向消歧。

设当前规划迭代时刻的线缆点云为 $\mathcal{P}_{\text{cable}}^{\mathcal{W}} = \{\mathbf{p}_i\}_{i=1}^N$ （单位为米）。通过主成分分析（PCA）估计线缆主方向，具体为：

$$\bar{\mathbf{p}}_c = \frac{1}{N} \sum_{i=1}^N \mathbf{p}_i, \quad (3-29)$$

其中 $\bar{\mathbf{p}}_c$ 为线缆点云的质心。对中心化数据构造协方差矩阵：

$$\mathbf{C}_c = \frac{1}{N} \sum_{i=1}^N (\mathbf{p}_i - \bar{\mathbf{p}}_c)(\mathbf{p}_i - \bar{\mathbf{p}}_c)^\top, \quad (3-30)$$

记 $\mathbf{d}_c$ 为协方差矩阵 $\mathbf{C}_c$ 最大特征值对应的特征向量，并进行单位化：

$$\mathbf{d}_c = \frac{\mathbf{e}_{\max}}{\|\mathbf{e}_{\max}\|_2} \in \mathbb{R}^3, \quad (3-31)$$

- 56 -

其中 $\mathbf{e}_{\max}$ 为最大特征值的特征向量。由于线缆为双向几何体， $\mathbf{d}_c$ 与 $-\mathbf{d}_c$ 在几何上等价。为在任务相容性上实现方向消歧，本文引入参考方向向量 $\mathbf{a}_{\text{ref}}$ ，其由当前抓取位姿对应的装配轴线给出。令

$$\mathbf{d}_c \leftarrow \text{sgn}(\mathbf{d}_c^\top \mathbf{a}_{\text{ref}}) \mathbf{d}_c, \quad (3-32)$$

其中 $\text{sgn}(\cdot)$ 为符号函数。这样，后续“方向相容性”项在插接方向变化时保持稳定的符号一致性。

(2) 末端方向轴与线缆方向的方向相容性代价。

规划器扩展的状态为关节构型 $q \in \mathcal{C}$ 。设末端坐标系记为 $\{E\}$ ，其在地图系 $\{\mathcal{W}\}$ 下的姿态旋转矩阵为 ${}^{\mathcal{W}}\mathbf{R}_E(q) \in SO(3)$ 。取末端装配/接近方向在自身坐标系下的单位基向量 $\mathbf{e}_{\text{ins}}$ （例如 $\mathbf{e}_{\text{ins}} = [0, 0, 1]^\top$ ），则末端方向轴在地图系下表达为

$$\mathbf{a}(q) = {}^{\mathcal{W}}\mathbf{R}_E(q) \mathbf{e}_{\text{ins}}. \quad (3-33)$$

为避免由于线缆双向性导致的错误惩罚，方向相容性采用绝对点积形式：

$$\phi_{\text{align}}(q) = 1 - |\mathbf{a}(q)^\top \mathbf{d}_c|. \quad (3-34)$$

其中 $\phi_{\text{align}}(q) \in [0, 1]$ ，当 $\mathbf{a}(q)$ 与 $\mathbf{d}_c$ 同方向或反方向一致时 $\phi_{\text{align}}(q)$ 取最小值。该项使规划器优先选择能沿线缆主拖曳方向推进的姿态变化，从几何上降低末端扫掠对线缆产生横向拉扯的概率。

(3) 线缆各向异性安全距离与可验证判据。

传统 $d_c(q)$ 取的是到体素占据集合 $\mathcal{V}_{\text{cable}}$ 的最小欧氏距离。为体现线缆“法向避障更敏感、切向通行相对宽松”的工程假设，本文构造以线缆主方向为轴的各向异性安全度量。

对任意空间点 $\mathbf{x} \in \mathbb{R}^3$ ，定义其相对质心的向量 $\mathbf{r} = \mathbf{x} - \bar{\mathbf{p}}_c$ ，并将该向量分解为沿线缆方向的切向分量与垂直于线缆方向的法向分量。设投影算子为

$$\mathbf{P}_{\parallel} = \mathbf{d}_c \mathbf{d}_c^\top, \quad \mathbf{P}_{\perp} = \mathbf{I} - \mathbf{d}_c \mathbf{d}_c^\top, \quad (3-35)$$

其中 $\mathbf{I}$ 为 3×3 单位矩阵。切向与法向距离分别为

$$d_{\parallel}(\mathbf{x}) = |\mathbf{d}_c^\top (\mathbf{x} - \bar{\mathbf{p}}_c)|, \quad d_{\perp}(\mathbf{x}) = \|\mathbf{P}_{\perp} (\mathbf{x} - \bar{\mathbf{p}}_c)\|_2. \quad (3-36)$$

为将其映射为统一的无量纲安全度，选取切向/法向安全半径参数 $r_{\parallel}$ 与 $r_{\perp}$ （一般取 $r_{\perp} > r_{\parallel}$ ），定义各向异性安全度量：

$$d_{\text{ani}}(\mathbf{x}) = \sqrt{\left(\frac{d_{\perp}(\mathbf{x})}{r_{\perp}}\right)^2 + \left(\frac{d_{\parallel}(\mathbf{x})}{r_{\parallel}}\right)^2}. \quad (3-37)$$

当 $d_{\text{ani}}(\mathbf{x}) < 1$ 时, 点 $\mathbf{x}$ 落入围绕线缆主轴的安全椭球域内。对机械臂连杆, 将其离散为若干碰撞采样点集合 $\mathcal{S}(q)$, 则得到该构型下最小各向异性安全度量:

$$d_{\text{ani}}(q) = \min_{\mathbf{s} \in \mathcal{S}(q)} d_{\text{ani}}(\mathbf{s}). \quad (3-38)$$

据此, 柔性线缆安全判据定义为

$$C_{\text{cable}}(q) = \begin{cases} 1, & d_{\text{ani}}(q) \geq 1 \wedge \mathbf{s} \notin \mathcal{V}_{\text{cable}} \text{ (按采样点体素检查)}, \\ 0, & \text{otherwise.} \end{cases} \quad (3-39)$$

其中条件 “ $\mathbf{s} \notin \mathcal{V}_{\text{cable}}$ ” 保证与上一小节构建的动态体素占据集合一致, 椭球域用于引入方向性安全缓冲, 使得避障几何不仅依赖体素离散误差。

(4) 方向相容采样接纳概率与方向引导的 GRRT-Connect 代价。

结合混合障碍物地图中的刚性安全距离与柔性方向安全代价, 本文在扩展候选节点上构造带方向项的代价函数:

$$J_{\text{dir}}(q) = \alpha d_g(q) + \beta \exp\left(-\frac{d_r(q)}{\sigma_r}\right) + \gamma \exp\left(-\frac{d_{\text{ani}}(q)}{\sigma_c}\right) + \delta \phi_{\text{align}}(q), \quad (3-40)$$

其中 $d_g(q)$ 表示关节空间到目标构型的距离, $d_r(q)$ 为当前构型到刚性障碍的最小距离, σ_r, σ_c 为尺度参数, $\phi_{\text{align}}(q)$ 由式 (3-34) 给出。该代价函数刻画了“趋近目标 (第一项) — 远离刚性结构 (第二项) — 在方向安全域外保持间隙 (第三项) — 末端方向与线缆方向一致 (第四项)” 的复合目标。

为在采样阶段降低无效节点数量, 本文定义候选采样的接纳概率:

$$P_{\text{acc}}(q) = \exp\left(-\frac{J_{\text{dir}}(q)}{T}\right), \quad (3-41)$$

其中 $T > 0$ 为温度系数, 用于控制接纳概率对代价的敏感性。采样与接纳过程如下: 当随机采样得到 q_{rand} 后, 计算 $P_{\text{acc}}(q_{\text{rand}})$ 并与均匀随机变量 $\xi \sim U(0, 1)$ 比较, 若 $\xi < P_{\text{acc}}(q_{\text{rand}})$ 则保留, 否则重新采样。该机制在不改变 RRT-Connect 双树框架的前提下, 将线缆方向性先验从“硬避障”扩展为“概率引导”, 显著减少末端朝不利方向摆动导致的无效扩展。

(5) 双树扩展与方向判据的联合执行。

在双树扩展阶段, 仍以起始构型 q_{start} 与目标构型 q_{goal} 分别初始化两棵搜索树。若搜索树中距离采样点最近的节点为 q_{near} , 局部扩展点为

$$q_{\text{new}} = q_{\text{near}} + \epsilon \frac{q_{\text{rand}} - q_{\text{near}}}{\|q_{\text{rand}} - q_{\text{near}}\|_2}, \quad (3-42)$$

其中 ϵ 为扩展步长。对扩展线段执行关节限位检查后, 采用“混合地图 + 方向

安全域”的联合验证：首先在 AABB 模型下完成刚性碰撞检测；随后在 $\mathcal{V}_{\text{cable}}$ 体素集合约束下完成柔性占据判定，并进一步计算式 (3-37)-(3-38) 给出的各向异性安全度量，要求满足式 (3-39)。

当满足三类约束后， q_{new} 被接纳并作为新节点加入树结构，同时在可连接条件满足时尝试双树连接。该设计使得规划器在狭窄机舱环境中不仅依赖体素离散的几何碰撞约束，也显式引入线缆主方向的连续性先验，从而形成对柔性线缆干扰的方向敏感规避。




图 3-14 线缆方向向量驱动的方向相容采样与双树扩展流程示意图

(6) 与力位混合控制的方向参照接口。

本节得到的规划轨迹由 GRRT-Connect 在混合障碍物地图 $\mathcal{M}_{\text{hyb}}$ 上生成，其中柔性部分由 $\mathcal{V}_{\text{cable}}$ 表征，并结合由 $\mathcal{P}_{\text{cable}}^{\mathcal{W}}$ 估计的方向向量 $\mathbf{d}_c$ 执行方向相容扩展。轨迹包含时间参数化后的末端位姿序列，并在同一观测帧条件下给出与线缆方向一致的参照 $\mathbf{d}_c$ 。在力位混合控制模块中，可将测得外力 ${}^{\mathcal{W}}\mathbf{f}_{\text{ext}}$ 按线缆方向进行分解：

$$f_{\parallel} = \mathbf{d}_c^{\top} {}^{\mathcal{W}}\mathbf{f}_{\text{ext}}, \quad \mathbf{f}_{\perp} = {}^{\mathcal{W}}\mathbf{f}_{\text{ext}} - f_{\parallel} \mathbf{d}_c, \quad (3-43)$$

其中 $f_{\parallel}$ 表示切向分量大小， $\mathbf{f}_{\perp}$ 表示法向分量。结合本节方向相容规划使得轨迹中末端方向变化与 $\mathbf{d}_c$ 保持一致，可在力控律中对切向/法向分量采用不同阻抗参数，降低柔性线缆拖拽造成的法向扰动传递，提升插接过程的稳定性与收敛性。

(7) 方向可靠度权重与退化容错。

由于线缆形态在航空非结构化环境中可能出现遮挡与局部截断，PCA 得到的主方向 $\mathbf{d}_c$ 可能在短时间内抖动。为避免方向项在 $P_{\text{acc}}(q)$ 与代价 $J_{\text{dir}}(q)$ 中放大误差，本文引入置信度权重 $w_d \in [0, 1]$ ，由协方差矩阵特征值比例给出：

$$w_d = \frac{\lambda_1}{\lambda_1 + \lambda_2 + \lambda_3}, \quad (3-44)$$

其中 $\lambda_1 \geq \lambda_2 \geq \lambda_3$ 为 $\mathbf{C}_c$ 的特征值。将式 (3-40) 中方向项替换为 $\delta w_d \phi_{\text{align}}(q)$ ，当 $\mathbf{d}_c$ 不可靠时 (w_d 小)，算法退化为仅依赖混合障碍物地图与各向异性安全度量的保守引导。若连续 N 次扩展均因柔性安全判据失败而未能生成可接纳节点，则进一步降低接纳阈值并增大扩展步长上限 $\epsilon_{\max}$ ，在保证碰撞约束的前提下提高跳出局部可行域的能力，从而实现容错与收敛性保障。

算法 3-2 线缆方向向量驱动的方向相容 GRRT-Connect 扩展

Input: 混合障碍物地图 $\mathcal{M}_{\text{hyb}} = (\mathcal{O}_{\text{rigid}}, \mathcal{V}_{\text{cable}})$; 动态线缆点云 $\mathcal{P}_{\text{cable}}^{\mathcal{W}}$; 起

始/目标构型 $q_{\text{start}}, q_{\text{goal}}$; 参数 $\alpha, \beta, \gamma, \delta, \epsilon, r_{\perp}, r_{\parallel}$

Output: 无碰撞规划路径 π

- 1 1. 根据 $\mathcal{P}_{\text{cable}}^{\mathcal{W}}$ 通过 PCA 估计 $\mathbf{d}_c$ 与 $\bar{\mathbf{p}}_c$; 消歧并更新方向项。;
- 2 2. 初始化双树: $T_{\text{start}} \leftarrow \{q_{\text{start}}\}$, $T_{\text{goal}} \leftarrow \{q_{\text{goal}}\}$ 。;
- 3 3. **while** 未满足连接条件且迭代次数未超限 **do**
- 4 3.1 采样 q_{rand} : 以概率 P_{goal} 取 q_{goal} , 否则从 $\mathcal{C}_{\text{free}}$ 均匀采样。;
- 5 3.2 计算方向项代价 $J_{\text{dir}}(q_{\text{rand}})$ (式 (3-40)) 并得到接纳概率 P_{acc} (式 (3-41)); 若 $\xi \geq P_{\text{acc}}$ 则返回 3.1。;
- 6 3.3 找最近节点 q_{near} , 生成扩展节点 q_{new} (式 (3-42))。;
- 7 3.4 执行约束判定: 关节限位检查; 刚性 AABB 碰撞检测; 柔性占据检查 ($\mathcal{V}_{\text{cable}}$) 与各向异性安全度量判据 (式 (3-39))。;
- 8 3.5 若判定通过, 将 q_{new} 及边加入当前树, 并尝试与另一棵树连接。;
- 9 3.6 若方向置信度下降 (式 (3-44)), 对方向项进行加权退化并重启采样。;
- 10 **end**

3.4.3 路径生成与后处理优化

本节对应运动规划链路的输出环节。前文将机舱刚性几何与柔性线缆占据统一写入 $\mathcal{M}_{\text{hyb}}$ ，并在双树扩展中引入方向相容接纳与各向异性线缆安全判据；本节将离散路径的提取与线段级验证、以及代价函数驱动的后处理优化分别用流程图与伪代码归纳，并辅以公式刻画插值、碰撞回投与梯度结构，使输出轨迹在航空非结构化环境下既满足刚柔混合避障可验证性，又抑制带缆连接器抬升与转运中的尾部摆动。




图 3-15
(空白占位图)

图 3-15 路径生成与线段级碰撞检验流程示意图（双树连接一路径回溯拼接一分段稠密抽检一可行路径输出）

图 3-15 将路径生成归纳为“回溯得到节点序列一对每条边做关节空间插值稠密检验一全程通过则输出 π ”的管线；其中稠密检验在刚性占据 O_{rigid} 与线缆各向异性安全判据式 (3-39) 上完成一致性校核，便于实现时与混合地图接口对齐。

相邻节点间的连续运动采用关节空间线性插值，对 $i \in \{1, \dots, n-1\}$ 、 $\tau \in [0, 1]$ ，有

$$q_i(\tau) = (1 - \tau)q_i + \tau q_{i+1}. \quad (3-45)$$

式 (3-45) 在 $\tau = m/M$ 下给出了线段稠密检验的离散取样方式。为分析末端扫描与带缆任务的耦合，任取 q 由正运动学得到末端位姿；记基坐标系为 $\{B\}$ 、末端为 $\{E\}$ 、地图系为 $\{W\}$ ，则

$${}^W\mathbf{T}_E(q) = {}^W\mathbf{T}_B {}^B\mathbf{T}_E(q), \quad (3-46)$$

其中 ${}^W\mathbf{T}_B$ 为常值， ${}^B\mathbf{T}_E(q)$ 由机械臂模型给出。沿边插值时 ${}^W\mathbf{T}_E(q_i(\tau))$ 对 τ 的变化率反映末端速度水平；可行 π 仍可能含高频折角，故需进入后处理。

定义离散二阶差分 $\delta_i = q_{i+1} - 2q_i + q_{i-1}$ ，平滑项 $\sum_{i=2}^{n-1} \|\delta_i\|_2^2$ 对内部节点的梯度为

$$\frac{\partial}{\partial q_i} \sum_{j=2}^{n-1} \|q_{j+1} - 2q_j + q_{j-1}\|_2^2 = 2(q_{i+2} - 4q_{i+1} + 6q_i - 4q_{i-1} + q_{i-2}), \quad i = 3, \dots, n-2, \quad (3-47)$$

综合平滑、长度与障碍惩罚，取

$$J_{\text{path}} = \lambda_s \sum_{i=2}^{n-1} \|q_{i+1} - 2q_i + q_{i-1}\|_2^2 + \lambda_l \sum_{i=1}^{n-1} \|q_{i+1} - q_i\|_2 + \lambda_o \sum_{i=1}^n \phi(q_i), \quad (3-48)$$

其中 λ_s 、 λ_l 、 λ_o 为权重。设 $d_{\min}(q)$ 为构型 q 下连杆采样点到 $\mathcal{M}_{\text{hyb}}$ 的最小间隙，

令

$$\phi(q) = \exp\left(-\frac{d_{\min}(q)}{\sigma_o}\right), \quad (3-49)$$

$\sigma_o > 0$ 。若 $d_{\min}$ 对 q 可微, 则

$$\nabla_q \phi(q) = -\frac{1}{\sigma_o} \exp\left(-\frac{d_{\min}(q)}{\sigma_o}\right) \nabla_q d_{\min}(q), \quad (3-50)$$

$\nabla_q d_{\min}(q)$ 可由距离场与微分运动学映射至关节空间。长度项对 q_i 在边差分非零处的梯度为 $\frac{q_i - q_{i-1}}{\|q_i - q_{i-1}\|_2} - \frac{q_{i+1} - q_i}{\|q_{i+1} - q_i\|_2}$; 将上述三项按 $\lambda_s, \lambda_l, \lambda_o$ 加权并求和, 即得内部节点处下降方向 $\mathbf{g}_i$ 的构造方式。

算法 3-3 混合障碍物地图约束下的离散路径生成与后处理优化

Input: 双树连接点及两侧搜索树结构; $\mathcal{M}_{\text{hyb}} = (\mathcal{O}_{\text{rigid}}, \mathcal{V}_{\text{cable}})$; 线段稠密检验步数 M ; 权重与尺度 $\lambda_s, \lambda_l, \lambda_o, \sigma_o$; 最大迭代次数 K ; 初始步长 α_0 ; 收缩因子 $0 < \rho < 1$

Output: 优化路径 π^*

- 1 由连接点回溯拼接得到初始离散路径 $\pi^{(0)} = \{q_i\}_{i=1}^n$ ($q_1 = q_{\text{start}}, q_n = q_{\text{goal}}$);
 - 2 对每条边 (q_i, q_{i+1}) , 对 $m = 0, \dots, M$ 取 $\tau = m/M$ 并令
 $q(\tau) = (1 - \tau)q_i + \tau q_{i+1}$; 若任一稠密检验点违反关节限位、与刚性占据 $\mathcal{O}_{\text{rigid}}$ 碰撞或不满足式 (3-39), 则返回失败;
 - 3 在稠密检验可行前提下执行捷径替换以删去可直连折点, 更新为 $\pi^{(0)}$;
 - 4 $k \leftarrow 0$;
 - 5 **while** $k < K$ 且未满足收敛判据 **do**
 - 6 按式 (3-48) 计算 $J_{\text{path}}(\pi^{(k)})$, 并对内部节点 $i = 3, \dots, n - 2$ 构造下降方向 $\mathbf{g}_i$ (由式 (3-47)、长度项梯度与式 (3-50) 加权得到), 更新
 $q_i^{(k+1)} \leftarrow q_i^{(k)} - \alpha_k \mathbf{g}_i$;
 - 7 对 $\pi^{(k+1)}$ 再做与步骤 2 相同的稠密检验: 若任一边失败则回退并令
 $\alpha_k \leftarrow \rho \alpha_k$;
 - 8 $k \leftarrow k + 1$;
 - 9 **end**
 - 10 对最终节点序列做 B 样条拟合或时间重参数化, 并再次执行稠密检验
 输出 π^* ;
-

如图 3-16 所示, 在相同线缆体素表达下, 标准 RRT-Connect 轨迹更贴近占据簇且折返较多, 本文 GRRT-Connect 轨迹与密集占据区间隙更大, 统计上常对

图 3-16
(空白占位图)

图 3-16 考虑柔性线缆障碍的规划路径对比图

应更少迭代与更低路径代价；蓝、红曲线分别表示两种算法结果，红色在等效转运段更显著绕开线缆体素密集区。该几何差异与方向引导扩展相一致，使算法 3-3 的初值已更接近少折返、远柔障形态；路径生成保证可达与混合地图一致的可验证无碰，后处理则进一步压低与柔性占据的近邻度并平滑关节变化，降低带缆连接器转运中的位姿漂移，为插接类操作提供更稳的运动学初值。

3.5 实验与结果分析

为验证本章提出的端到端 6D 抓取生成、多约束抓取筛选以及基于混合障碍物地图的 GRRT-Connect 引导式规划在航空非结构化环境中的可行性与有效性，本节不采用大规模跨方法数值对比，也不以单一标量指标作结论依据，而是选取若干典型工况，从图示效果上观察规划结果是否与混合地图及线段检验所表达的可行域一致、执行过程是否呈现与柔性线缆相容的运动形态。实验输入沿用前文 CableMask 分割与三维化体素更新链路，刚性结构在初始感知阶段写入 O_{rigid} 并在规划期保持不更新，柔性线缆在规划与运动开始后仅按当前观测帧更新 $\mathcal{V}_{\text{cable}}$ ，使地图语义与在线规划在时间上对齐。

图 3-17
(空白占位图：不同线缆布置下抓取过程典型帧)

图 3-17 不同线缆布置工况下电连接器抓取过程典型示意（夹持姿态与线缆相对位置）

图 3-17 从视觉上呈现不同线缆布置时末端接近与夹持阶段的典型画面。可重点观察夹爪闭合轴线是否落在连接器壳体稳定区、插针端是否未被遮挡、以及线缆根部是否未卷入夹爪扫掠包络。线缆垂落或贴近连接器侧面时，若仍能完成稳定夹持且未出现明显拉扯根部，说明前文将线缆先验写入抓取生成与多约束筛选的做法在真实几何约束下具有可执行性，并与本章所论带柔性线缆的电连接器抓取任务目标一致。

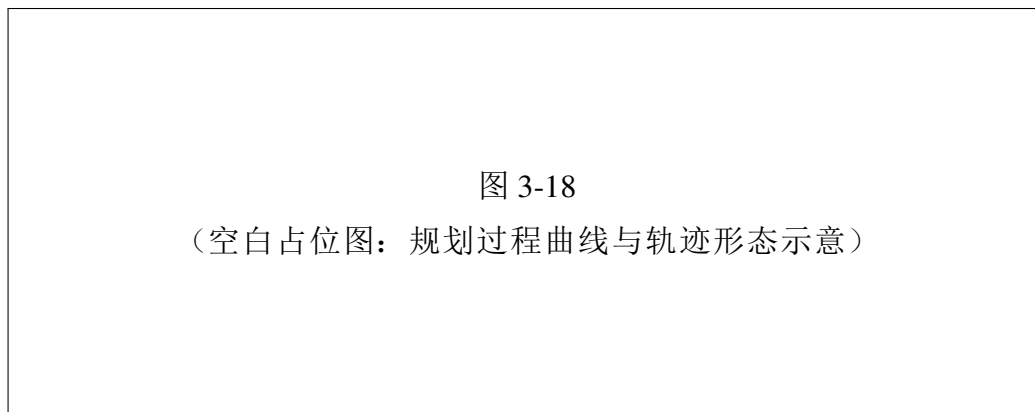


图 3-18 规划求解过程与关节空间轨迹形态示意（收敛趋势与折返程度）

图 3-18 以曲线或轨迹示意的方式展示规划迭代或关节轨迹随时间的变化形态，重在定性阅读而非读数。若曲线在若干次更新后趋于平稳、关节轨迹未出现密集锯齿式折返，可与本章 GRRT-Connect 中目标偏置与障碍引导、以及路径后处理中对平滑与冗余折点的抑制相呼应，说明规划输出在工程上更易连续执行。图中若同时标注搜索树或采样点的空间分布，还可辅助判断狭窄通道内扩展是否主要沿任务推进方向展开，而非在障碍边界附近来回试探。

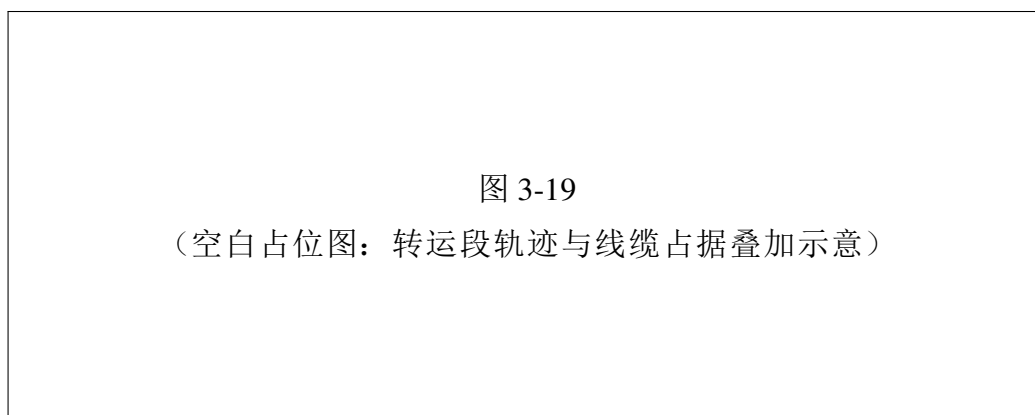


图 3-19 转运阶段末端轨迹与线缆体素占据的空间关系示意

图 3-19 将规划得到的末端轨迹或连杆扫掠示意与 $\mathcal{V}_{\text{cable}}$ 占据叠加显示，便于从几何关系上判读轨迹与柔性占据簇之间是否维持可见间隙，以及末端扫掠路径是否回避横向贴近线缆密集区等不利形态。若轨迹在体素簇外侧形成相对

平滑的绕行带，并与式 (3-39) 所表达的各向异性安全含义相一致，即可在图示层面支持混合障碍物地图与方向相容引导在规划输出上的有效性。图中末端姿态若沿线缆主拖曳方向变化较为连贯，亦可与方向相容采样引导在机理上相互印证，而无需依赖接触次数或位姿误差等标量汇总。

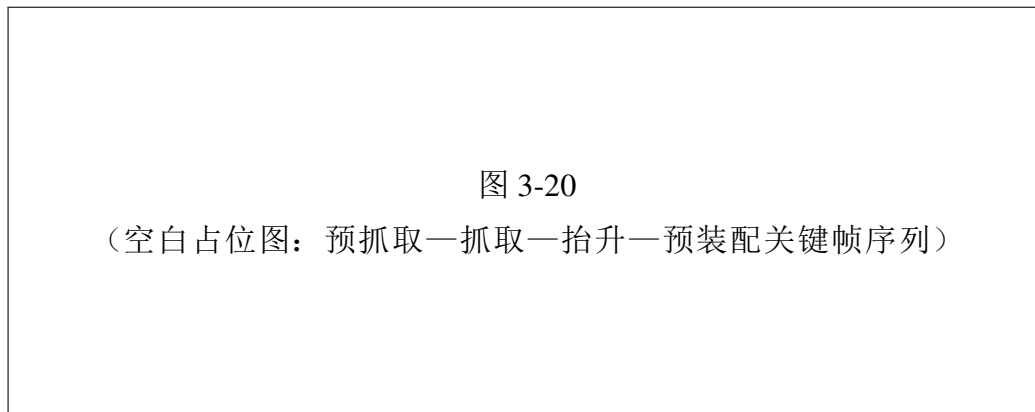


图 3-20 缩比平台上自主抓取与规划轨迹执行的关键帧序列示意

图 3-20 按时间顺序给出预抓取、闭合夹持、抬升与接近预装配位姿等关键帧。连贯阅读时应关注各阶段之间末端姿态与连接器相对位姿是否过渡自然、抬升后线缆摆动是否受控、以及接近预装配时末端轴线是否与插接方向保持可辨识的一致性。该序列从执行侧说明：算法 3-3 中稠密线段检验与后处理对插补路径全程无碰可验证性及关节空间折角平滑化的要求并非仅停留在离散节点层面，而是能够支撑一整段可观察的连续运动；混合地图刚性静态与线缆动态更新策略也使规划期约束在执行画面中具有可对照的物理对应关系。

3.6 本章小结

本章围绕航空制造场景下电连接器在狭窄机舱环境中的自主抓取问题，构建了由端到端 6D 抓取生成、多约束抓取筛选和 GRRT-Connect 运动规划组成的完整技术框架。在抓取生成阶段，利用目标实例掩膜、6D 位姿和线缆掩膜构建目标局部点云，并通过位姿参数化、位姿先验与线缆禁入域约束生成更符合工程需求的候选抓取位姿；在抓取筛选阶段，进一步引入逆运动学可达性、线缆安全间隙和姿态相容性评价，通过综合评分函数选择既稳定又利于后续装配的抓取方案；在路径规划阶段，将机舱刚性障碍和线缆柔性障碍共同纳入混合障碍物地图，并通过 GRRT-Connect 算法提高狭窄空间下的规划可收敛性与路径形态可控性。结合典型工况的图示验证可见，规划输出与混合地图及线段检验所表达的可行域相一致，执行序列呈现与柔性线缆干扰相容的运动形态，可为后续柔顺装配过程提供可对照的初始状态。

第4章 电连接器柔顺装配控制方法研究

4.1 引言

针对航空制造场景下带柔性拖缆电连接器的精密装配问题，本章构建视觉前馈、力位混合控制和深度强化学习的递进式装配框架，建立含柔性线缆干扰的装配动力学模型，并将线缆方向向量引入控制器，构造面向拖缆主扰动方向的视觉前馈补偿项；随后设计装配过程的状态空间、动作空间与奖励函数，构建强化学习交互环境，基于 SoftActor-Critic 实现装配策略学习，能够在接触建立后完成搜孔、姿态修正与稳定插接。通过仿真训练与真实平台实验对接触力峰值、装配时间与装配成功的安全性表现进行验证。

图 4-1

（空白占位图：第四章总体技术路线与输入输出接口示意图）

图 4-1 第四章总体技术路线与输入输出接口示意图（第三章预装配初值与线缆先验驱动插入阶段控制与策略学习的接口关系）

4.2 含线缆干扰的轴孔装配动力学建模与控制器设计

电连接器插接过程受几何约束、接触切换和柔性扰动共同影响。为面向轴孔对齐的控制设计建立统一任务空间表达，本节首先从受力关系与运动约束出发，对带柔性线缆干扰的装配过程进行动力学建模；随后在引入力位混合控制框架下，将位置调节与接触力约束统一表征，并利用视觉获得的线缆方向信息构造方向相关的前馈补偿项，从而使后续误差分解与阻抗控制律构造具有一致的物理变量定义。

4.2.1 轴孔装配误差描述

预装配操作完成后，机械臂末端已进入插孔前方局部邻域，装配控制的核

心目标转化为轴孔对齐误差的精细调节。考虑柔性线缆干扰会在接触建立前后改变末端受力与运动耦合关系，误差表达形式需要同时满足两点要求：一方面将横向对齐、轴向推进与姿态失配分解为可独立加权的任务空间通道；另一方面使其能够直接作为后续力位混合/阻抗控制律中的通道误差信号，从而形成方向相关的柔顺调节机制。

设连接器装配轴线方向为 z_a 、插孔轴线方向为 z_h （均为单位向量）。取连接器末端参考点位置为 $\mathbf{p}_c$ ，插孔参考点位置为 $\mathbf{p}_h$ ，平移误差定义为 $\Delta \mathbf{p} = \mathbf{p}_c - \mathbf{p}_h$ 。横向对齐误差取为在插入轴法向平面的投影：

$$\mathbf{e}_{xy} = (\mathbf{I} - z_h z_h^T) \Delta \mathbf{p},$$

其中， $\mathbf{I}$ 为单位矩阵， $\mathbf{e}_{xy}$ 表示垂直于插入轴线的侧向对齐误差向量。轴向推进误差取为沿插入轴方向的投影标量：

$$e_z = z_h^T \Delta \mathbf{p},$$

其中， e_z 表示沿插入轴线方向的剩余推进距离误差。姿态失配误差由连接器与插孔的相对旋转确定，采用相对旋转对数映射得到的旋转向量：

$$\mathbf{e}_R = \text{Log}(\mathbf{R}_h^T \mathbf{R}_c)^V,$$

其中， $\mathbf{R}_c$ 与 $\mathbf{R}_h$ 分别为连接器与插孔的姿态矩阵， v 表示旋转对数输出的向量化映射。将上述三通道误差合并，可得装配误差向量：

$$\mathbf{e}_t = \begin{bmatrix} \mathbf{e}_{xy}^T \\ e_z \\ \mathbf{e}_R^T \end{bmatrix}.$$

该误差建模将几何偏差显式分解为横向对齐、轴向推进与姿态失配三个可独立加权的物理量，并与后续变刚度阻抗控制律所采用的任务空间广义误差分量建立对应关系：其中 $\mathbf{e}_{xy}$ 与 e_z 对应平移误差在插入轴方向与横向平面的分量， $\mathbf{e}_R$ 对应姿态失配的恢复调节。该对应使通道刚度矩阵与阻尼矩阵能够对不同方向误差施加方向相关的恢复力与耗能，从而在航空非结构化环境与柔性线缆干扰条件下实现先抑制横向楔入风险、再在安全接触约束下逐步减小轴向误差的控制目标分解。

图 4-2 以几何形式标定 $\mathbf{e}_{xy}$ 、 e_z 与 $\mathbf{e}_R$ 的对应含义：当端面相对插孔轴线存在侧向偏移时， $\mathbf{e}_{xy}$ 增大；当插接尚处于未建立稳定接触的推进阶段时，沿插入轴的剩余推进距离表现为 e_z ；当连接器轴线与插孔轴线存在姿态不一致时，姿

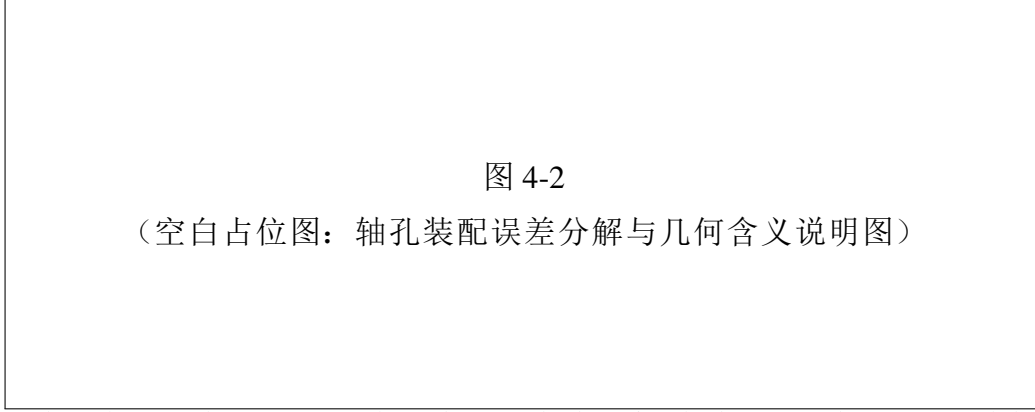


图 4-2 轴孔装配误差分解与几何含义说明图（空白占位图：轴孔装配误差分解与几何含义说明图）

态失配由 $\mathbf{e}_R$ 表征并带来端面楔入倾向，从而放大附加接触力矩。该几何对应关系为后续变刚度阻抗控制器中通道刚度/阻尼的配置提供直接依据：系统可在插接初期优先收敛对准相关误差，再在接触切换过程中逐步减小轴向误差，使柔性线缆干扰引起的横向耦合被约束在受控的柔顺通道内。

4.2.2 含线缆干扰的装配动力学模型

电连接器插接过程属于刚柔耦合接触过程，连接器与底座插孔之间存在法向接触、切向摩擦与几何约束；连接器尾部柔性线缆在机械臂带动下产生方向性拖拽力和回复力矩，对末端轨迹与接触状态形成持续扰动。

设末端在笛卡尔空间中的位姿为 $\mathbf{x}$ ，则考虑接触作用与线缆扰动后的装配动力学方程可写为

$$\mathbf{M}_x \ddot{\mathbf{x}} + \mathbf{C}_x \dot{\mathbf{x}} + \mathbf{G}_x = \mathbf{F}_{ctrl} + \mathbf{F}_{ext} + \mathbf{F}_{cable}. \quad (4-1)$$

其中， $\mathbf{M}_x$ 为等效惯性矩阵， $\mathbf{C}_x$ 为速度相关项， $\mathbf{G}_x$ 为重力项， $\mathbf{F}_{ctrl}$ 为控制输入在任务空间的等效作用， $\mathbf{F}_{ext}$ 为连接器与插孔之间的接触作用力， $\mathbf{F}_{cable}$ 为柔性线缆对末端施加的附加干扰力。线缆为典型柔性体，其精确高维动力学难以在工程与学习阶段同时获得可靠参数，因此本文采用便于控制设计与策略学习的等效建模方式。

结合线缆方向信息，将线缆视为沿主方向作用的等效弹性—阻尼元件。设线缆方向单位向量为 $\hat{\mathbf{v}}_{cable}$ ，等效伸长量为 Δl ，则有

$$\mathbf{F}_{cable} = k_c(\Delta l) \Delta l \hat{\mathbf{v}}_{cable} + c_c \dot{\Delta l} \hat{\mathbf{v}}_{cable}. \quad (4-2)$$

其中， $k_c(\Delta l)$ 为与线缆形变量相关的等效刚度系数， c_c 为等效阻尼系数， $\dot{\Delta l}$ 为长度变化率。式中引入 $(\Delta l, \dot{\Delta l})$ 的关键原因在于：柔性线缆在孔口局部尺度下

的主导作用可由沿拖拽约束方向的伸长/压缩一维坐标刻画；若直接采用线缆高维形变参数将导致控制与强化学习阶段的可辨识性不足，从而增大闭环的不确定性传播。第二章得到的线缆掩膜与线缆方向先验用于确定 $\hat{v}_{cable}$ 的空间一致性，而第三章的规划输出提供末端在插孔邻域的相对位移参考，使该等效坐标能够与几何误差分解结果在同一任务空间中对齐。

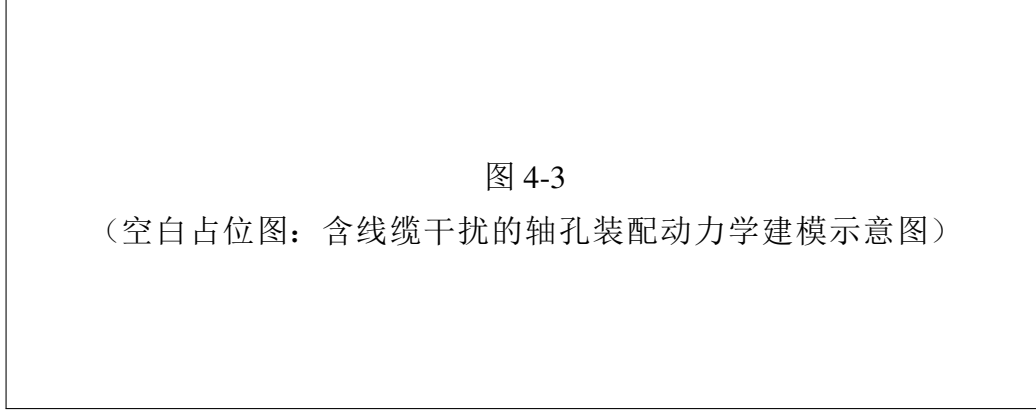


图 4-3
(空白占位图：含线缆干扰的轴孔装配动力学建模示意图)

图 4-3 含线缆干扰的轴孔装配动力学建模示意图（接触作用与柔性线缆等效弹性—阻尼扰动的作用关系示意）

图 4-3 将接触作用与等效线缆弹簧—阻尼元件的作用关系进行示意：当线缆在拖拽主方向 $\hat{v}_{cable}$ 上发生有效约束与回复，其等效弹性—阻尼会向末端注入与 Δl 对应的扰动加速度。该物理对应使后续阻抗控制器中通过通道刚度矩阵 K_c 与阻尼矩阵 D_c 的配置，能够以可解释的方式改变等效线缆扰动注入强度，从而抑制柔性线缆诱发的横向耦合放大。

为保证等效方向单位向量 $\hat{v}_{cable}$ 与轴孔装配任务坐标的一致性，需要将第二章由线缆掩膜获得的方向先验从视觉坐标系映射至控制任务坐标系。设孔口坐标系为 $\{O\}$ 、机器人基坐标系为 $\{B\}$ 、视觉相机坐标系为 $\{C\}$ ，以及末端坐标系为 $\{E\}$ ，则刚体变换满足

$${}^B T_O = {}^B T_E {}^E T_C {}^C T_O.$$

其中， ${}^B T_E$ 为末端坐标系相对基坐标系的位姿变换， ${}^E T_C$ 为相机坐标系相对末端坐标系的外参变换， ${}^C T_O$ 为孔口坐标系相对相机坐标系的标定变换；该等式的旋转子块用于方向向量变换。记 ${}^C \hat{v}_{cable}$ 为线缆方向先验在相机坐标系下的单位向量表示，则映射到基坐标系下的方向单位向量可写为

$$\hat{v}_{cable} = \frac{{}^B R_C {}^C \hat{v}_{cable}}{\|{}^B R_C {}^C \hat{v}_{cable}\|},$$

其中， ${}^B R_C$ 为相机到基坐标系的旋转矩阵。由于插接阶段的规划视域限定在孔

口局部邻域，等效方向在短时窗内可近似为常向量，从而保证后续 Δl 的一维坐标化表达能够与 $\mathbf{e}_{xy}$ 与 e_z 的几何投影保持确定性耦合。




图 4-4

(空白占位图：视觉线缆方向映射与 Δl 投影几何示意)

图 4-4 视觉线缆方向映射与 Δl 投影几何示意 (给出 ${}^B T_E {}^E T_C {}^C T_O$ 下方向向量变换及 $\Delta \mathbf{p}$ 分解到 e_z 与 $\mathbf{e}_{xy}$ 后形成 $\Delta l = \hat{\mathbf{v}}_{cable}^T \Delta \mathbf{p}$ 的投影关系)

图 4-4 将视觉获得的线缆方向先验转化为控制任务空间中的等效方向单位向量，并在孔口局部几何中完成投影分解：平移误差 $\Delta \mathbf{p}$ 被分解为沿插孔轴线的标量分量 e_z 与垂直平面的向量分量 $\mathbf{e}_{xy}$ ，同时将等效方向 $\hat{\mathbf{v}}_{cable}$ 与该误差分量进行内积得到一维伸长坐标 Δl 。该图示关系使 Δl 不仅有物理含义，也与后续线缆等效弹性—阻尼力 $\mathbf{F}_{cable}$ 的注入幅值建立了直接可计算通道。

为了给出 Δl 的几何计算依据，记末端参考点与插孔参考点之间的平移误差为 $\Delta \mathbf{p} = \mathbf{p}_c - \mathbf{p}_h$ 。由 4.2.1 的误差分解可得

$$\Delta \mathbf{p} = z_h e_z + \mathbf{e}_{xy},$$

其中， z_h 为插孔轴线方向单位向量。进一步定义线缆等效伸长量为沿主方向的投影

$$\Delta l = \hat{\mathbf{v}}_{cable}^T \Delta \mathbf{p} = (\hat{\mathbf{v}}_{cable}^T z_h) e_z + \hat{\mathbf{v}}_{cable}^T \mathbf{e}_{xy},$$

由此可见线缆扰动与 $\mathbf{e}_{xy}$ 、 e_z 存在方向耦合：横向偏移会等效改变一维伸长坐标 Δl ，进而影响 $\mathbf{F}_{cable}$ 的注入强度。该耦合结构可由下一节通过通道刚度矩阵 K_c 与阻尼矩阵 D_c 重塑，从而抑制柔性线缆诱发的横向耦合放大。

由 $\Delta l = \hat{\mathbf{v}}_{cable}^T \Delta \mathbf{p}$ 可进一步得到长度变化率。考虑 $\hat{\mathbf{v}}_{cable}$ 的时间变化，长度变化率为

$$\dot{\Delta l} = \dot{\hat{\mathbf{v}}}_{cable}^T \Delta \mathbf{p} + \hat{\mathbf{v}}_{cable}^T (\dot{\mathbf{p}}_c - \dot{\mathbf{p}}_h),$$

其中， $\mathbf{p}_c$ 与 $\mathbf{p}_h$ 分别为连接器末端参考点与孔口参考点的位置； $\dot{\hat{\mathbf{v}}}_{cable}$ 为方向单位向量变化率。由于第二章的线缆方向先验在孔口局部邻域内具有较高一致性，

并且规划阶段给定了有限速度范围，短时窗内可令 $\dot{\hat{v}}_{cable} \approx 0$ ，从而得到

$$\dot{\Delta l} \approx \hat{v}_{cable}^T (\dot{\mathbf{p}}_c - \dot{\mathbf{p}}_h).$$

结合 4.2.1 的几何分解 $\Delta \mathbf{p} = z_h \mathbf{e}_z + \mathbf{e}_{xy}$ ，进一步有

$$\dot{\Delta l} \approx (\hat{v}_{cable}^T z_h) \dot{e}_z + \hat{v}_{cable}^T \dot{\mathbf{e}}_{xy}.$$

将上述结果代入线缆等效弹性—阻尼力表达式，可得线缆扰动力对误差通道的显式依赖关系：

$$\mathbf{F}_{cable} = (k_c(\Delta l)\Delta l + c_c \dot{\Delta l}) \hat{v}_{cable} = (k_c(\Delta l) ((\hat{v}_{cable}^T z_h) e_z + \hat{v}_{cable}^T \mathbf{e}_{xy}) c_c ((\hat{v}_{cable}^T z_h) \dot{e}_z + \hat{v}_{cable}^T \dot{\mathbf{e}}_{xy})) \hat{v}_{cable}$$

该式表明线缆等效扰动力注入幅值由 $\mathbf{e}_{xy}$ 与 e_z 的投影决定，且可通过通道刚度矩阵 K_c 与阻尼矩阵 D_c 的配置抑制其横向耦合效应。

为保证等效能量与耗散一致，线缆等效弹性—阻尼力由保守弹性项与等效粘性耗散项构造。以伸长坐标 Δl 构造弹性势能

$$U_c(\Delta l) = \int_0^{\Delta l} k_c(s) s ds,$$

则沿主方向的弹性力分量为 $F_e = \frac{\partial U_c}{\partial \Delta l} = k_c(\Delta l)\Delta l$ 。再叠加耗散项 $F_d = c_c \dot{\Delta l}$ ，得到

$$\mathbf{F}_{cable} = (k_c(\Delta l)\Delta l + c_c \dot{\Delta l}) \hat{v}_{cable}.$$

该构造使等效线缆弹簧—阻尼力可由几何误差通道计算得到，并作为下一节 K_c 与 D_c 通道整定的物理依据。

4.2.3 视觉前馈变刚度阻抗控制器设计

由 4.2.2 可知，线缆等效扰动力沿 $\hat{v}_{cable}$ 注入，且其幅值由等效伸长坐标 Δl 表征。为实现线缆方向扰动与通道柔顺调节的一致交互，本文采用笛卡尔空间变刚度阻抗控制，将位姿误差 $\mathbf{e}$ 通过通道相关的 K_c 与 D_c 映射为任务空间恢复力并输出关节力矩指令。

在时刻 t ，强化学习智能体输出归一化动作向量 $\mathbf{a}_t \in [-1, 1]^6$ ，其各分量分别对应末端在笛卡尔空间沿 x, y, z 轴的平移增量以及绕各轴的旋转增量。为满足装配工艺与安全约束，本文依据末端允许的最大线速度与角速度，将归一化动作线性缩放为期望位姿偏移量 $\Delta \mathbf{X}_{RL}$ 。当前实际位姿记为 $\mathbf{X}_c = [\mathbf{P}_c^T, \mathbf{Q}_c^T]^T$ ，则强化学习给出的目标位姿为

$$\mathbf{X}_{target} = \mathbf{X}_c + \Delta \mathbf{X}_{RL}. \quad (4-3)$$

其中, $\mathbf{P}$ 表示位置向量, $\mathbf{Q}$ 表示四元数姿态表示。

由于强化学习推理频率为 10-20 Hz, 而底层力矩控制频率为 1000 Hz, 若将离散的 $\mathbf{X}_{target}$ 直接映射到 1 kHz 阻抗误差, 将造成目标突变并诱发峰值力矩。为保证目标位姿在控制环内连续可实现, 本文在阻抗内环引入指数移动平均滤波器 (Exponential Moving Average, EMA) 对目标位姿进行低通平滑。记第 k 个 1 ms 控制周期内的期望位姿为 $\mathbf{X}_d^{(k)} = [\mathbf{P}_d^{(k)}, \mathbf{Q}_d^{(k)}]$, 其更新形式为

$$\mathbf{P}_d^{(k)} = \alpha \mathbf{P}_{target} + (1 - \alpha) \mathbf{P}_d^{(k-1)}, \quad (4-4)$$

$$\mathbf{Q}_d^{(k)} = \text{Slerp}(\mathbf{Q}_d^{(k-1)}, \mathbf{Q}_{target}, \alpha). \quad (4-5)$$

其中, $\alpha \in (0, 1)$ 为滤波系数, Slerp 表示四元数球面插值算子。通过选取较小的 α 使目标位姿变化连续, 从而限制冲击力矩峰值。

记实际末端平移向量为 $\mathbf{P}_c$ 、期望平移向量为 $\mathbf{P}_d^{(k)}$, 则平移误差为

$$\mathbf{e}_p = \mathbf{P}_c - \mathbf{P}_d^{(k)}. \quad (4-6)$$

姿态误差采用单位四元数描述。记实际姿态为 $\mathbf{Q}_c$ 、期望姿态为 $\mathbf{Q}_d^{(k)}$, 通过四元数乘积构造相对姿态

$$\mathbf{Q}_e = \mathbf{Q}_c^{-1} * \mathbf{Q}_d^{(k)}, \quad (4-7)$$

再提取其向量部分作为姿态误差

$$\mathbf{e}_o = \mathcal{R}(\mathbf{Q}_e)_{vec}. \quad (4-8)$$

其中, $\mathcal{R}(\cdot)_{vec}$ 表示取四元数的虚部向量。将平移与姿态误差合并, 可得广义位姿误差

$$\mathbf{e} = \begin{bmatrix} \mathbf{e}_p^\top \\ \mathbf{e}_o^\top \end{bmatrix}^\top. \quad (4-9)$$

在静力学等效与雅可比转置映射基础上, 可将期望的笛卡尔阻抗特性映射为关节空间任务力矩

$$\hat{\mathbf{F}}_{cable} = (k_c(\Delta l)\Delta l + c_c\dot{\Delta l}) \hat{\mathbf{v}}_{cable}, \quad \mathbf{f}_{ff} = \hat{\mathbf{F}}_{cable}, \quad \mathbf{f}_d = f_d \mathbf{z}_h, \quad \mathbf{f}_{ref} = \mathbf{f}_d + \mathbf{f}_{ff}, \quad (4-10)$$

其中, $\mathbf{f}_{ff}$ 为视觉前馈补偿力, 采用 4.2.2 的线缆等效弹性—阻尼模型估计; $\mathbf{f}_d$ 为插入推进参考力 (z_h 方向), $\mathbf{f}_{ref}$ 为合成参考交互力。等效伸长坐标 Δl 与其变化率 $\dot{\Delta l}$ 由 4.2.1 的几何分解与 4.2.2 的短时窗近似确定。

$$\boldsymbol{\tau}_{task} = \mathbf{J}^\top (\mathbf{f}_{ref} - \mathbf{K}_c \mathbf{e} - \mathbf{D}_c \mathbf{J} \dot{\mathbf{q}}), \quad (4-11)$$

在静力学等效与局部线性化假设下, 可将末端等效交互力写为期望阻抗动力学

$$\mathbf{M}_d \ddot{\mathbf{e}} + \mathbf{D}_c \dot{\mathbf{e}} + \mathbf{K}_c \mathbf{e} = \mathbf{f}_{ref} - \mathbf{f}_{ext},$$

其中, $\mathbf{M}_d$ 为等效期望惯性矩阵, $\mathbf{f}_{ref}$ 为合成参考交互力; $\mathbf{f}_{ext}$ 为外界等效交互力 (含插接接触力与线缆扰动等效分量), $\mathbf{e}$ 为广义位姿误差 (由平移误差与姿态误差构造)。其中, $\mathbf{J} \in \mathbb{R}^{6 \times 7}$ 为当前构型下末端雅可比矩阵, $\dot{\mathbf{q}}$ 为关节角速度向量, $\mathbf{K}_c, \mathbf{D}_c \in \mathbb{R}^{6 \times 6}$ 分别为笛卡尔空间的对角刚度和阻尼矩阵。

本文采用方向相关变刚度: 由 4.2.2 的等效伸长坐标 $\Delta l = (\hat{\mathbf{v}}_{cable}^\top z_h) \mathbf{e}_z + \hat{\mathbf{v}}_{cable}^\top \mathbf{e}_{xy}$ 可知线缆扰动主要通过 $\mathbf{e}_z$ 与 $\mathbf{e}_{xy}$ 通道注入交互能量; 视觉前馈补偿 $\mathbf{f}_{ff}$ 取自线缆等效弹性—阻尼模型, 可在等效方向上抵消主要扰动分量, 因此变刚度主要约束残余横向与姿态耦合。由此插入轴向相关通道取高刚度、横向对齐与姿态通道取低刚度, 并令 $\mathbf{D}_i = 2\mathbf{K}_i$ 以维持接触切换阶段的阻尼裕度。

Franka 机械臂具有 7 个关节自由度, 在六维任务空间下存在冗余。为约束肘部内部构型并避免奇异位形与线缆/结构件干涉, 控制器在任务空间阻抗控制基础上引入零空间姿态优化项。

对雅可比矩阵 $\mathbf{J}$ 进行伪逆计算得到 $\mathbf{J}^+$, 可构造零空间投影矩阵

$$\mathbf{P}_{null} = \mathbf{I} - \mathbf{J}^\top (\mathbf{J}^+)^{\top}. \quad (4-12)$$

其中, $\mathbf{I}$ 为单位矩阵。将预先规划的安全肘部构型记为 $\mathbf{q}_{null}$, 零空间优化力矩设计为

$$\boldsymbol{\tau}_{null} = \mathbf{P}_{null} [\mathbf{K}_{null} (\mathbf{q}_{null} - \mathbf{q}) - \mathbf{D}_{null} \dot{\mathbf{q}}], \quad (4-13)$$

其中, $\mathbf{K}_{null}$ 为零空间刚度系数, $\mathbf{D}_{null} = 2\mathbf{K}_{null}$ 为其临界阻尼系数。该项力矩通过零空间投影被约束在冗余自由度内, 用于稳定肘部构型并减少非期望内部运动。

结合机械臂刚体动力学模型, 最终下发的关节力矩指令采用动力学前馈补偿

$$\boldsymbol{\tau}_{cmd} = \boldsymbol{\tau}_{task} + \boldsymbol{\tau}_{null} + \boldsymbol{\tau}_{coriolis}. \quad (4-14)$$

其中, $\tau_{coriolis}$ 表示科里奥利力与离心力等非线性动力学项, 由底层软件接口计算; 前馈补偿用于提升模型一致性与力矩响应稳定性。

为保证硬件在强化学习早期探索阶段的执行安全, 本文在理论力矩叠加后加入基于物理阈值的力矩限幅器。对于每个关节 i , 最终指令力矩在软件层面被逐元素裁剪为

$$\tau_{cmd,i} = \min(\tau_{limit,i}, \max(-\tau_{limit,i}, \tau_{cmd,i})), \quad (4-15)$$

其中, $\tau_{limit,i}$ 为对应关节的额定安全力矩范围, 结合厂家手册与实验经验设定。

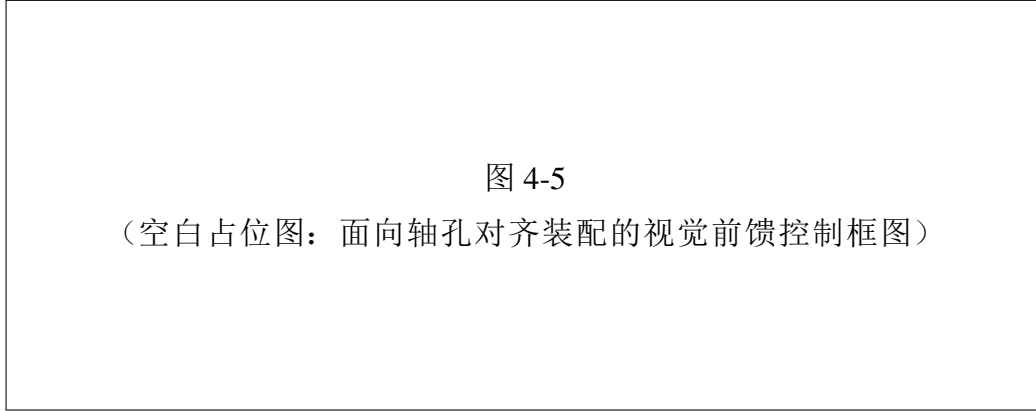


图 4-5 面向轴孔对齐装配的视觉前馈控制框图(线缆方向先验经视觉前馈补偿注入力位混合控制的数据流示意)




图 4-6 控制器关键响应曲线示意图(位姿误差收敛、接触阶段力响应及线缆扰动下阻尼衰减过程)

4.3 面向轴孔对齐插接任务的强化学习环境构建

仅依赖解析模型和固定控制律能够缓解装配过程中的刚性冲击, 但面对孔口搜索、姿态微调与柔性扰动耦合的复杂工况, 传统方法仍可能出现调节迟滞、收敛缓慢与鲁棒性不足等问题。为提升系统在复杂接触过程中的自主调节能力,

本节将电连接器装配问题表述为强化学习框架下的序贯决策过程，并分别设计状态空间、动作空间与奖励函数，使智能体能够在交互中学习搜索、修正与推进的策略，使系统在保证接触安全性的同时获得更强环境适应性与策略优化能力。

本节同时体现与第三章的接口约束：第三章规划阶段得到的抓取姿态与插接方向相容性作为插入阶段初始对准的几何先验，使环境状态在马尔可夫意义下包含对下一步装配演化具有充分统计量的信息，从源头上减少无效探索。

4.3.1 任务形式化与状态空间设计

设单次装配回合刻画从预装配结束到插装完成的插入阶段，包含最多 T 个决策步。初始状态 s_0 对应连接器已被机械臂夹持并处于插座附近预对位区域的位置姿态，其概率分布记为 $\rho(s_0)$ 。在任意时刻 t ，机器人根据当前状态 s_t 选择动作 a_t ，并由机舱环境依据几何约束、机器人动力学与接触力学转移到下一状态 s_{t+1} ，即

$$s_{t+1} \sim \mathcal{P}(\cdot | s_t, a_t), \quad (4-16)$$

并返回即时奖励 r_t 。

在给定策略 $\pi(a|s)$ 的情况下，插入阶段的性能可用折扣累计回报表示为

$$J(\pi) = \mathbb{E}_{s_0 \sim \rho} \mathbb{E}_{a_t \sim \pi, s_{t+1} \sim \mathcal{P}} \left[\sum_{t=0}^T \gamma^t r(s_t, a_t) \right], \quad (4-17)$$

其中， $\gamma \in (0, 1)$ 为折扣因子。

本文采用结果导向的稀疏奖励结构：仅在插入成功时给出一次性正奖励，在失败或非期望行为时给出零或惩罚。在回合长度与终止规则给定的条件下，最大化 $J(\pi)$ 与提高成功插入回合占比具有一致的优化方向，因而可作为预装配后插入工序产率与合格率的代理目标。对于每条插入轨迹 $\tau = \{s_0, a_0, \dots, s_T\}$ ，其不仅是动作序列，更是具有明确工程含义的插装过程样本：状态演化反映从预对位到完全插入的几何进展，动作序列体现连接器轴向推进与姿态微调的控制策略，累计回报刻画该插入过程的安全性 with 成功质量。

面向航空非结构化环境与带柔性线缆的电连接器自主装配任务，插入阶段策略需在孔口邻域同时感知几何对准与接触力学演化。为完整描述预装配结束后连接器与插座之间的局部几何关系及接触状态，本文将状态 s_t 分解为视觉观测与本体观测两部分：

$$s_t = [o_t^{img}, o_t^{pro}]. \quad (4-18)$$

其中, o_t^{img} 承载插座邻域及拖缆相关的可见几何线索 (与第二章视觉输出在接口上相容), o_t^{pro} 承载机器人内部运动与力觉信息, 使 s_t 在马尔可夫决策过程意义下能够同时覆盖宏观对准态势与微观接触趋势。

视觉观测采用多视角 RGB 图像。原始图像 $I_t^{(k)}$ 经 ROI 裁剪、分辨率缩放与像素归一化后得到

$$o_t^{img} = \left\{ \text{Norm} \left(\text{Resize} \left(\text{Crop} \left(I_t^{(k)} \right) \right) \right) \right\}_{k=1}^{N_c}, \quad (4-19)$$

其中, N_c 为相机数量, Crop 表示 ROI 提取算子, Resize 表示分辨率变换算子, Norm 表示像素归一化算子。该观测支路为策略提供连接器—插孔—线缆在图像域的共现场景表达, 用于区分未对准、轻微错位与接触建立后的阶段性差异。

本体观测以预装配初值为参考, 定义为

$$o_t^{pro} = [{}^B\mathbf{x}_t - {}^B\mathbf{x}_0, \mathbf{q}_t - \mathbf{q}_0, \dot{\mathbf{q}}_t, \mathbf{f}_t, g_t]. \quad (4-20)$$

其中, ${}^B\mathbf{x}_t \in \mathbb{R}^6$ 为末端在基准坐标系下的位姿参数化表示, $\mathbf{q}_t$ 与 $\dot{\mathbf{q}}_t$ 分别为关节角与关节角速度, $\mathbf{f}_t$ 为末端六维力/力矩, g_t 为夹爪开度。相对量构造使状态对插入推进与姿态微调的局部变化更敏感, 并与六维力/力矩趋势共同反映接触载荷演化及末端振荡风险, 从而与视觉支路形成互补。

图 4-7

(空白占位图: 强化学习状态空间观测信息示意图)

图 4-7 强化学习状态空间观测信息示意图 (多视角图像与本体观测共同构成状态向量的组织示意)

4.3.2 动作空间与下位控制约束

插入阶段需在任务空间完成孔口搜索、轴向推进与必要的姿态微调, 并伴随夹爪保持或释放等离散切换。相较在关节力矩空间直接决策, 连续末端笛卡尔增量与离散夹爪动作并用的混合空间维数可控, 且便于将接触柔顺与安全约

束下沉至下位控制器。据此定义

$$\mathbf{a}_t = [\mathbf{a}_t^{eff}, \mathbf{a}_t^{grip}], \quad (4-21)$$

其中, $\mathbf{a}_t^{eff} \in \mathbb{R}^6$, $\mathbf{a}_t^{grip} \in \mathcal{A}_{grip}$ 。

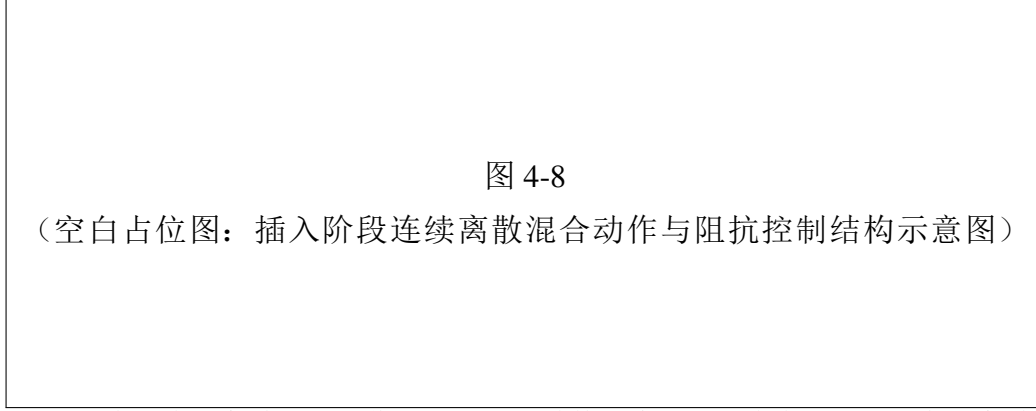


图 4-8
(空白占位图：插入阶段连续离散混合动作与阻抗控制结构示意图)

图 4-8 插入阶段连续离散混合动作与阻抗控制结构示意图（末端连续增量与夹爪离散动作映射至下位阻抗控制结构的关系示意）

策略输出至可执行关节力矩呈分层结构： $\mathbf{a}_t^{eff}$ 与 $\mathbf{a}_t^{grip}$ 分别进入任务空间映射与夹爪通道，经阻抗结构生成 $\boldsymbol{\tau}_t$ ，在插入力一位移约束下形成关节空间轨迹；强化学习层给出平滑任务空间增量，关节级高速力学调节由环境与控制器承担。末端增量在末端坐标系下写为

$$\mathbf{a}_t^{eff} = [\Delta x_t, \Delta y_t, \Delta z_t, \Delta \phi_t, \Delta \theta_t, \Delta \psi_t]^\top. \quad (4-22)$$

环境通过 ${}^E T_B(\cdot)$ 将其映射至基准坐标系并与当前 ${}^B \mathbf{x}_t$ 叠加得到期望位姿

$${}^B \mathbf{x}_{t+1}^* = {}^B \mathbf{x}_t + {}^E T_B(\mathbf{a}_t^{eff}), \quad (4-23)$$

其中, ${}^E T_B(\cdot)$ 表示末端坐标系增量到基准坐标系增量的映射（在微量近似下由旋转与微分运动学关系确定）。下位关节空间阻抗控制律为

$$\boldsymbol{\tau}_t = \mathbf{J}_t^\top (\mathbf{K}_p \mathbf{e}_x + \mathbf{K}_d \dot{\mathbf{e}}_x) + \boldsymbol{\tau}_{grav}, \quad (4-24)$$

其中, $\mathbf{J}_t$ 为雅可比矩阵, $\mathbf{e}_x = {}^B \mathbf{x}_{t+1}^* - {}^B \mathbf{x}_t$ 为任务空间跟踪误差, $\dot{\mathbf{e}}_x$ 为其数值差分, $\mathbf{K}_p, \mathbf{K}_d$ 为刚度与阻尼参数, $\boldsymbol{\tau}_{grav}$ 为重力补偿项。

环境在状态一动作层面定义安全集合

$$\mathcal{X}_{safe} = \{\mathbf{x} \mid \mathbf{x}_{min} \leq \mathbf{x} \leq \mathbf{x}_{max}, \mathbf{f}_{min} \leq \mathbf{f} \leq \mathbf{f}_{max}\}, \quad (4-25)$$

其中, $\mathbf{x}$ 为末端任务空间状态量, $\mathbf{f}$ 为相关力/力矩分量；若预测越界则对末端增量裁剪：

$$\tilde{a}_t^{eff} = \text{clip}\left(a_t^{eff}, \mathbf{a}_{min}, \mathbf{a}_{max}\right). \quad (4-26)$$

夹爪离散集合为

$$\mathcal{A}_{grip} = \{\text{open}, \text{close}, \text{stay}\}, \quad (4-27)$$

环境据 a_t^{grip} 更新开度与接触状态，以支持保持插入、插入后保持与释放等阶段切换。

4.3.3 稀疏奖励与成功判定机制

预装配后的插入阶段以工艺结果为准：电连接器是否在轴孔公差内完全插入且无损伤。航空非结构化环境中，柔性线缆遮挡与光照变化使中间位姿、深度与力信号不足以唯一对应“插妥”语义；若强行构造稠密奖励，易引入与工艺不一致的 *shaping*。环境采用结果导向稀疏奖励，使策略优化目标与插入合格率一致：

$$r(s_t, a_t) = \begin{cases} 1, & s_t \in \mathcal{S}_{succ}, \\ -\lambda_{fail}, & s_t \in \mathcal{S}_{unsafe}, \\ -\lambda_{grip} \mathbb{I}[a_t^{grip} \neq \text{stay}], & \text{otherwise.} \end{cases} \quad (4-28)$$

其中， $\lambda_{fail} > 0$ 为失败惩罚权重， $\lambda_{grip} > 0$ 为夹爪动作惩罚权重， $\mathbb{I}[\cdot]$ 为指示函数；中间步无正回报，仅通过夹爪项抑制无效开合。

成功由几何、力学与视觉联合判定：

$$\mathcal{S}_{succ} = \{s \mid d_{pose}(s) \leq \varepsilon_p, \Delta z_{ins}(s) \geq z_{min}, F_{ins}(s) \leq F_{max}, C_{img}(s) \geq \tau\}. \quad (4-29)$$

其中， $d_{pose}(s)$ 为连接器壳体相对插座的位姿偏差度量， $\Delta z_{ins}(s)$ 为沿插入方向的插入深度， $F_{ins}(s)$ 为插入力峰值； $C_{img}(s) \in [0, 1]$ 表示将状态 s 所含末端视野图像输入二分类网络得到的成功置信度，与几何、力学量共同构成联合判据。阈值 $\varepsilon_p, z_{min}, F_{max}, \tau$ 由轴孔装配公差与离线标定确定。

在稀疏奖励仅在终态给出一次正回报的设置下，若成功条件仅由 d_{pose} 、 Δz_{ins} 与 F_{ins} 等可测标量构成，在航空非结构化环境中受柔性线缆遮挡、相近外观与照度变化影响，终态边界可能与工艺定义的“插妥”语义产生偏差。为此，本文另行训练基于末端视野图像的二分类成功判别器：训练样本为人工判定的成功/未成功插入终态图像 $\{(I_i, y_i)\}_{i=1}^N$ ， $y_i \in \{0, 1\}$ ，网络输出 $\hat{p}_i = C_{img}(I_i)$ ，与式 (4-29) 中 $C_{img}(s)$ 在部署时一致（ I_i 与状态 s 的图像观测分支同源）。成功判定仍以式 (4-29) 的联合条件为准：视觉置信度与几何、力学量同时满足逻辑

与关系，不以单一图像输出替代 d_{pose} 、 Δz_{ins} 或 F_{ins} 约束，用于降低“几何接近但插针未到底或锁壳未啮合”等单靠标量阈值易出现的漏检。损失函数取交叉熵形式：

$$\mathcal{L}_{cls} = -\frac{1}{N} \sum_{i=1}^N (y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)). \quad (4-30)$$

失败终止由越界、力超限与步数上限共同定义：

$$\mathcal{S}_{unsafe} = \{s \mid \mathbf{x} \notin X_{safe} \vee \|\mathbf{f}\| > F_{safe} \vee t \geq T_{max}\}. \quad (4-31)$$

若 $s_t \in \mathcal{S}_{unsafe}$ ，回合立即终止并回报 $-\lambda_{fail}$ 。在该映射下， $\mathcal{S}_{succ}$ 对应一次性正回报， $\mathcal{S}_{unsafe}$ 对应失败惩罚，其余步仅受夹爪项约束，使优化搜索集中于满足公差与损伤约束的终态边界。




图 4-9

（空白占位图：插入阶段奖励与成功失败判定机制示意图）

图 4-9 插入阶段奖励与成功失败判定机制示意图（几何—力学—视觉联合成功判定与失败终止条件的奖励映射示意）

4.3.4 人在回路交互与数据记录机制

面向航空非结构化环境下带柔性线缆的电连接器插入任务，纯随机探索难以在柔顺接触与孔口搜索并存的状态—动作空间中稳定产生成功样本；实机训练还须将末端工作空间约束、接触力趋势与插针/壳体损伤风险纳入同一闭环。人在回路数据获取上，先由操作员完成若干条完整插入示教，再在策略在线执行过程中于异常工况下短时接管纠正；训练所用经验按来源分池存储，更新时与自主探索样本联合采样。上层路径规划已将机械臂引导至插座邻域的预对准位姿，且抓取姿态与插入轴向相容，示教起点因而落在可插入通道内，有利于缩短无效探索。

训练初期进入示教阶段：操作员自该预对准位姿起，通过示教设备输出末端任务空间增量及夹爪开闭指令，完成孔口搜索、轴向推进与保持或释放等阶

段。第 k 条示例轨迹记为

$$\tau_k^{demo} = \{(s_t^{(k)}, a_t^{(k)})\}_{t=0}^{T_k}, \quad k = 1, \dots, N_{demo}, \quad (4-32)$$

汇总为 $\mathcal{D}_{human} = \bigcup_{k=1}^{N_{demo}} \tau_k^{demo}$ 。与仅记录末端位姿的抓取示教不同，插入示教同步记录六维力/力矩与夹爪事件时间轴，使每条 transition 的即时奖励与环境内稀疏回报及联合成功/失败判定一致，避免示教标签与回报接口脱节。

策略具备初步执行能力后转入在线交互：机器人按当前策略 π 在仿真或实机上滚动，操作员依据末端位姿相对 $\mathcal{X}_{safe}$ 的裕度、插入力突变与视觉上的孔轴偏离进行监视；一旦出现越界趋势、力异常或明显错向，即短时接管并输出长度为 Δ 的纠正动作片段 $\{\bar{a}_t, \dots, \bar{a}_{t+\Delta}\}$ 。整条回合可写为

$$\tau = \tau_{pre} \oplus \tau_{human} \oplus \tau_{post}, \quad (4-33)$$

其中 τ_{pre} 、 τ_{post} 为策略片段， τ_{human} 为人工片段。环境对每个 transition 记录来源标签（策略/人工），并标注该步是否属于落入 $\mathcal{S}_{unsafe}$ 前的人工纠正序列，使后续学习能够区分“探索失败—纠正—再尝试”与“连续自主成功”两类时间结构；纠正片段与成功示教一并写入 $\mathcal{D}_{human}$ ，用于抬高关键状态处的行为质量估计并抑制重复性危险动作。

环境维护自主回放缓冲 $\mathcal{B}_{self}$ 与含示教及人工片段的 $\mathcal{B}_{human}$ ，统一写为

$$\mathcal{B} = \mathcal{B}_{self} \cup \mathcal{B}_{human}. \quad (4-34)$$

两池分别承接不同来源的状态—动作—回报转移，训练时汇入同一集合 $\mathcal{B}$ 供离策略更新读取。如图 4-10 所示，多视角与本体观测经环境动力学与内嵌的回报、终止判定形成逐步标量反馈；策略与环境交互产生的转移进入 $\mathcal{B}_{self}$ ，示教与人工纠正片段进入 $\mathcal{B}_{human}$ ，学习端自 $\mathcal{B}$ 采样并向策略与价值网络回传梯度，图中给出了示范缓冲与在线经验缓冲的来源组织、汇入 $\mathcal{B}$ 的路径及环境与回放接口边界。在此基础上，离策略更新按设定比例自 $\mathcal{B}_{self}$ 抽取当前策略在真实工况下的交互样本，以跟踪摩擦、线缆姿态与初始偏置等时变因素；自 $\mathcal{B}_{human}$ 抽取高质量片段，用于值函数在专家支撑集附近的监督约束与对危险状态—动作对的抑制。二者联合等价于在固定 MDP 上对回放分布做质量加权：提高高回报、低干预轨迹的采样权重，降低无效失败片段对值估计的稀释作用，从而在样本量受限时兼顾安全性与收敛速度；学习端仅经统一的 $\mathcal{B}$ 访问经验，环境与回放的数据面约定不因具体优化实现而改动。上述分池与统一采样使示范、纠正与自主探索在训练更新中按权重汇合，有利于抑制失败轨迹对关键状态价值估计

的过度稀释，并与后续装配策略学习模块保持经验接口一致。

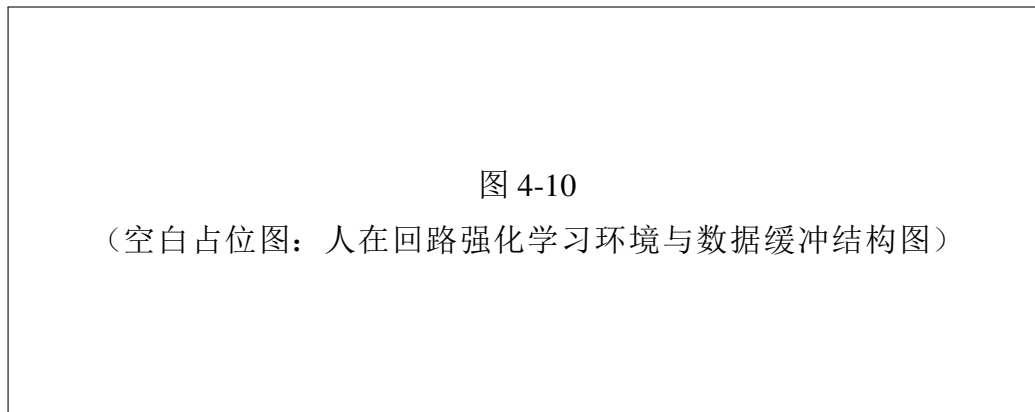


图 4-10
(空白占位图：人在回路强化学习环境与数据缓冲结构图)

图 4-10 人在回路强化学习环境与数据缓冲结构图（示范缓冲与在线经验缓冲的来源组织及策略更新数据流示意）

4.4 人在回路强化学习装配策略学习与虚实迁移方法

由于装配动作表现为连续位姿微调与力控修正，并且训练过程对样本利用效率与策略稳定性要求较高，算法选择直接影响策略收敛效果与实机部署可行性。本文选用 SoftActor-Critic 作为装配策略学习核心算法。该算法基于最大熵强化学习框架，适用于连续动作空间，并在策略探索能力与训练稳定性之间取得平衡。在此基础上进一步讨论策略网络与价值网络结构设计、训练参数设置以及面向真实平台的 Sim-to-Real 迁移策略。

4.4.1 人在回路装配策略学习框架

面向航空非结构化环境下带柔性线缆的电连接器轴孔插入任务，孔口相对位姿受装配偏差、线缆姿态扰动与视觉测量噪声共同影响；柔顺接触阶段的成功回报具有显著稀疏性，而失败样本往往伴随接触力突变与拖缆偏拉。装配系统需在底层阻抗控制与安全裁剪保证稳定性的前提下，学习能够输出任务空间残差微调（连续末端增量）与夹爪开闭决策（离散动作）的混合策略，使策略在有限交互轮次内形成可收敛的“对准—接触—推进/保持—脱开”行为序列。

承接前述分池与统一回放接口，学习端以同一 $\mathcal{B}$ 为训练数据源。面向“装配策略”这一高层决策对象，本文将人在回路装配策略学习表述为闭环：机器人以当前 π_θ 在孔口邻域内执行插入相关子任务，操作员在示教阶段提供可复用的对准—推进先验，在在线阶段于偏孔、卡滞、力异常或柔性线缆拖曳等工况下短时接管；学习端在同一 $\mathcal{B}$ 上开展策略更新，并以 RLDP (Reinforcement Learning with Policy-Dependent Value Function Distillation) 组织 Critic/Actor 的协同，

使人工提供的专家支撑与自主交互转移在优化目标上可区分、可汇合，而非混为单一模仿目标。

设高层策略为 $\pi_\theta(a|s)$ ，软状态动作值函数为 $Q_\phi(s, a)$ ，目标网络为 $Q_{\bar{\phi}}$ 。在温度系数 $\alpha > 0$ 下，最大熵强化学习目标可写为折扣累计回报与熵增广项之和的期望最大化：

$$\mathcal{J}_{\text{ME}}(\theta) = \mathbb{E}_{\rho, \pi_\theta, \mathcal{P}} \left[\sum_{t=0}^T \gamma^t (r(s_t, a_t) + \alpha \mathcal{H}(\pi_\theta(\cdot|s_t))) \right], \quad (4-35)$$

式中， $\mathcal{H}(\pi_\theta(\cdot|s)) = -\mathbb{E}_{a \sim \pi_\theta} [\log \pi_\theta(a|s)]$ 为策略熵； $r(s_t, a_t)$ 与环境内稀疏奖励及底层映射一致； $\gamma \in (0, 1)$ 为折扣因子。

专家支撑集 $\mathcal{D}_{\text{exp}}$ 与人在回路记录规则对齐：由完整示教轨迹、插入成功终止邻域转移（与稀疏奖励及成功/失败判定一致）以及在线接管纠正片段汇总得到，用于标记“应当被策略优先复现”的装配行为片段。训练更新时，Critic 一方面对 $\mathcal{B}$ 中转移执行软贝尔曼 TD 备份以跟踪摩擦、线缆姿态与初始偏置等时变因素；另一方面对 $\mathcal{D}_{\text{exp}}$ 施行价值蒸馏，使孔口搜索、轴孔对准与柔顺推进等插入子阶段在 Q_ϕ 上形成相对清晰的价值排序，从而降低高失败率滚动对装配成功路径的压制。Actor 以最大熵形式输出任务空间残差动作并经 $C(\cdot)$ 映射为底层阻抗控制指令；熵项用于在孔口局部可行域保留必要的微调探索，以应对柔性线缆干扰与接触不确定性，同时避免策略退化为仅复述示教轨迹而缺乏在线纠错余量。上述机制直接对应本节标题中“人在回路”与“装配策略学习”的分工：人工提供可记录、可汇入 $\mathcal{B}$ 的纠正与高质量片段，学习端将其转化为可自主滚动的 π_θ 。损失函数显式形式与蒸馏/行为克隆权重调度在下一小节给出。

执行端、学习端与人工操作员在装配策略学习框架中的接口关系如图 4-11 所示：执行端输出 π_θ 的任务空间指令并经 $C(\cdot)$ 进入阻抗与安全约束闭环；学习端从 $\mathcal{B}$ 采样并交替更新 Q_ϕ 与 π_θ ，其中 RLPD 蒸馏支路读取 $\mathcal{D}_{\text{exp}}$ ；操作员通过示教与接管为 $\mathcal{D}_{\text{exp}}$ 提供样本支撑。图中同时给出最大熵策略支路与蒸馏支路在学习端的汇合位置。

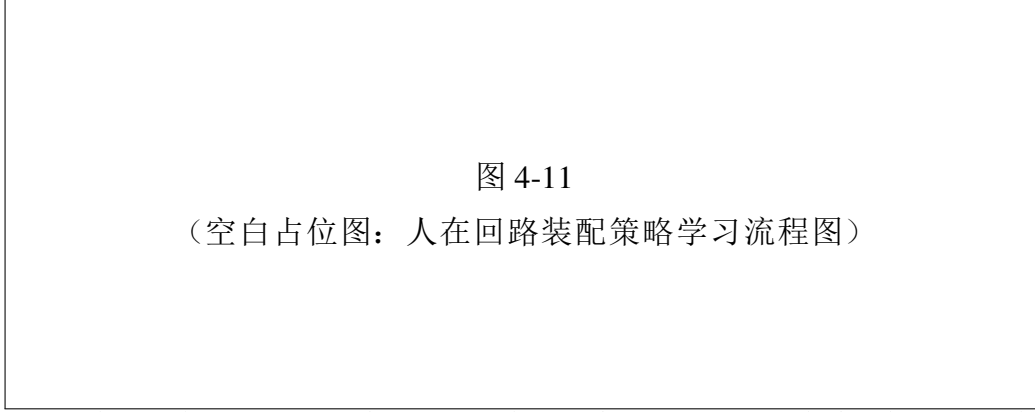


图 4-11
(空白占位图：人在回路装配策略学习流程图)

图 4-11 人在回路装配策略学习流程图（人在回路交互与 RLDP/最大熵目标驱动的整体学习流程示意）

在上述框架下，考虑底层阻抗与安全裁剪后，高层策略所优化的期望回报可写为

$$J(\theta) = \mathbb{E}_{s_0 \sim \rho} \mathbb{E}_{a_t \sim \pi_\theta, s_{t+1} \sim \mathcal{P}} \left[\sum_{t=0}^T \gamma^t r(s_t, C(s_t, a_t)) \right], \quad (4-36)$$

式中， C 表示由任务空间动作到底层阻抗控制器与安全约束的复合映射，与插入阶段任务空间—阻抗分层结构一致。式 (4-36) 与式 (4-35) 在工程上通过熵项权重 α 与最大熵机制联结，用于与仿真—实机实验中的评价指标（成功率、接触力峰值、干预次数等）对照。

4.4.2 装配策略网络结构与在线优化训练方法

在前述 RLDP 学习框架与人在回路数据接口基础上，本节给出策略与价值网络的具体结构以及训练阶段的优化目标。面向航空非结构化环境下带柔性线缆的电连接器插入任务，网络需同时处理多路视觉图像与本体力觉信号，并在连续末端增量与离散夹爪指令共存的混合动作空间上完成高效推理。本节依次从视觉编码与网络结构设计、价值函数与策略的联合优化模型以及人在回路在线训练流程三方面展开。

4.4.2.1 基于预训练视觉编码的策略与价值网络结构

高层策略与动作值函数网络基于状态 $s_t = [o_t^{img}, o_t^{pro}]$ 与动作 $a_t = [a_t^{eff}, a_t^{grip}]$ 建模。视觉编码部分采用在 ImageNet 上预训练的 ResNet-10 作为共享特征提取骨干，多路相机图像（腕部与侧方）经裁剪至感兴趣区域并缩放至 128×128 后，由同一骨干网络输出各路嵌入向量。设第 i 路图像的嵌入为 $\mathbf{e}_i \in \mathbb{R}^{d_e}$ ，本体观测经独立全连接层映射为 $\mathbf{h}_{pro} \in \mathbb{R}^{d_p}$ ，拼接后的状态特征为

$$\mathbf{z}_s = \text{MLP}_{enc}([\mathbf{e}_1; \dots; \mathbf{e}_K; \mathbf{h}_{pro}]), \quad (4-37)$$

式中, K 为相机数量, $[\cdot; \cdot]$ 表示向量拼接, MLP_{enc} 为两层全连接编码器。预训练骨干在训练过程中冻结参数, 以保持优化稳定性并降低真实平台上的梯度计算开销。

连续末端增量动作 a_t^{eff} 与离散夹爪指令 a_t^{grip} 分属两套不同性质的决策空间, 统一建模易导致连续高斯尾部对离散开/闭/保持三态的拟合模糊。为此本文将装配任务拆分为共享状态观测的两个并行子问题 $\mathcal{M}_1 = \{\mathcal{S}, \mathcal{A}_1, \mathcal{P}_1, r, \gamma\}$ 与 $\mathcal{M}_2 = \{\mathcal{S}, \mathcal{A}_2, \mathcal{P}_2, r, \gamma\}$, 其中 $\mathcal{A}_1$ 为连续末端增量空间, $\mathcal{A}_2 = \{\text{开}, \text{闭}, \text{保持}\}$ 为离散夹爪空间。对 $\mathcal{M}_1$, 策略网络 $\pi_\theta(a^{eff}|s)$ 以 z_s 为输入, 通过两层全连接隐层 (256 维) 输出高斯分布的均值 $\mu_\theta(s)$ 与对数标准差 $\log \sigma_\theta(s)$; 动作值函数 $Q_\phi(s, a^{eff})$ 以 $[z_s, a^{eff}]$ 为输入, 经同规模隐层输出标量软 Q 值。对 $\mathcal{M}_2$, 单独训练夹爪值网络 $Q_\psi(s, a^{grip})$, 以 z_s 为输入对三个离散动作分别输出 Q 值。推理时先由 π_θ 采样 a_t^{eff} , 再由 $\arg \max_{a^{grip}} Q_\psi(s_t, a^{grip})$ 选取夹爪指令, 两者拼合后经 $C(\cdot)$ 映射至底层阻抗控制器。该设计使策略与夹爪网络可独立优化, 如图 4-12 所示给出了上述网络中各模块的信息流与输入输出关系。

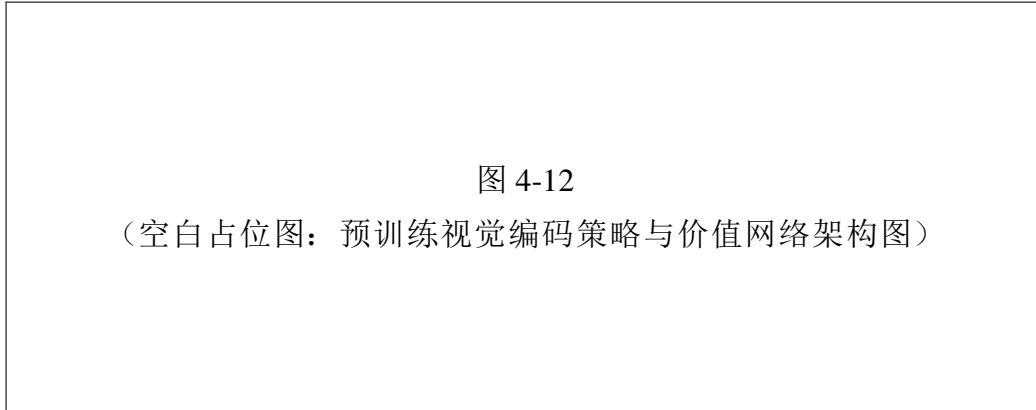


图 4-12 预训练视觉编码策略与价值网络架构图 (共享 ResNet 骨干编码多路图像并与本体信息拼接, 分别输入策略、连续动作值与夹爪值网络的信息流示意)

4.4.2.2 基于异质回放均衡采样的联合优化模型

RLPD 的核心采样策略为: 每个训练批次从示范缓冲 $\mathcal{B}_{human}$ 与在线经验缓冲 $\mathcal{B}_{self}$ 中各抽取等量转移拼合为训练批, 使高质量示范与当前策略探索在梯度更新中获得均衡权重。在此基础上, 连续动作值函数 Q_ϕ 的软贝尔曼 TD 备份目标定义为

$$y_t = r_t + \gamma \mathbb{E}_{a_{t+1} \sim \pi_\theta(\cdot|s_{t+1})} [Q_{\bar{\phi}}(s_{t+1}, a_{t+1}) - \alpha \log \pi_\theta(a_{t+1}|s_{t+1})], \quad (4-38)$$

式中, $\bar{\phi}$ 为目标网络参数, 由 Polyak 平滑更新 $\bar{\phi} \leftarrow \tau \phi + (1 - \tau) \bar{\phi}$ 得到; $\alpha > 0$ 为自适应熵权重。连续动作值函数损失为

$$\mathcal{L}_Q(\phi) = \mathbb{E}_{(s_t, a_t, r_t, s_{t+1}) \sim \mathcal{B}} \left[(Q_\phi(s_t, a_t) - y_t)^2 \right] + \lambda_{dist} \mathbb{E}_{(s, a) \sim \mathcal{D}_{exp}} \left[(Q_\phi(s, a) - Q^{exp}(s, a))^2 \right], \quad (4-39)$$

式中，第一项在来自 $\mathcal{B}$ 的均衡采样批上强制软贝尔曼一致性； λ_{dist} 为蒸馏权重， $Q^{exp}(s, a)$ 为沿专家轨迹的折扣回报估计，第二项在成功装配片段附近抬升 Q_ϕ 以形成对偏孔与力超限动作的抑制梯度。策略网络在更新后的 Q_ϕ 上执行最大熵改进：

$$\mathcal{L}_\pi(\theta) = -\mathbb{E}_{s_t \sim \mathcal{B}} \left[\mathbb{E}_{a_t \sim \pi_\theta} (Q_\phi(s_t, a_t) - \alpha \log \pi_\theta(a_t | s_t)) \right]. \quad (4-40)$$

对离散夹爪子问题 $\mathcal{M}_2$ ，值网络 Q_ψ 按 DQN 形式更新，备份目标为

$$\mathcal{L}_{grip}(\psi) = \mathbb{E}_{(s_t, a_t^{grip}, r_t, s_{t+1}) \sim \mathcal{B}} \left[\left(r_t + \gamma Q_{\bar{\psi}}(s_{t+1}, \arg \max_{a'} Q_\psi(s_{t+1}, a')) - Q_\psi(s_t, a_t^{grip}) \right)^2 \right], \quad (4-41)$$

式中， $\bar{\psi}$ 为夹爪目标网络参数。该分离式设计避免连续与离散动作在同一网络头中产生梯度冲突。

为在训练早期约束策略靠近示教分布，附加行为克隆辅助损失

$$\mathcal{L}_{BC}(\theta) = \mathbb{E}_{(s, a^{exp}) \sim \mathcal{D}_{exp}} \left[\|\mu_\theta(s) - a^{exp}\|_2^2 \right], \quad (4-42)$$

式中， $\mu_\theta(s)$ 为策略高斯均值输出。策略总损失为

$$\mathcal{L}_{\pi, total}(\theta) = \mathcal{L}_\pi(\theta) + \lambda_{BC} \mathcal{L}_{BC}(\theta). \quad (4-43)$$

λ_{BC} 在训练初期取较大值以使策略快速覆盖孔口对准与柔顺推进的关键动作模式，随插入成功率提升逐渐递减，使优化由模仿主导平滑过渡到以 $\mathcal{L}_Q$ 与最大熵目标主导的自主强化。

4.4.2.3 执行-学习异步架构与人在回路训练流程

训练阶段采用执行进程与学习进程异步通信的分布式架构。执行进程在真实机器人上按当前 π_θ 与 Q_ψ 输出装配动作，并将每步转移写入 $\mathcal{B}_{self}$ ；学习进程从 $\mathcal{B}$ 中均衡采样并交替计算式 (4-39)、式 (4-40) 与式 (4-41) 的梯度以更新 Q_ϕ 、 π_θ 与 Q_ψ ，完成后将新参数同步至执行进程。两进程异步运行使策略推理与梯度计算在时间上重叠，有利于在真实平台有限交互速率下提高数据利用率。

在在线执行阶段，若当前策略动作为 a_t^{RL} ，人工接管动作为 a_t^H ，人工接管标志为 $m_t \in \{0, 1\}$ ，则实际执行动作为

$$a_t^{exec} = (1 - m_t) a_t^{RL} + m_t a_t^H. \quad (4-44)$$

当操作员观察到偏孔、接触力突增或柔性线缆拖曳导致轴线偏离时令 $m_t = 1$,

人工动作经阻抗控制器直接作用于机器人以避免对插座与连接器造成损伤，同时将 (s_t, a_t^H) 写入 $\mathcal{D}_{exp}$ 与 $\mathcal{B}_{human}$ 用于后续蒸馏与行为克隆更新。随训练轮次推进，接管频率逐步下降，标志策略已从示范先验过渡到以强化回报为主导的自主执行阶段。图 4-13 给出了示范引导、在线人工纠正与异步参数更新在训练各阶段的协同关系。




图 4-13
(空白占位图：执行-学习异步架构与人在回路训练流程图)

图 4-13 执行-学习异步架构与人在回路训练流程图（执行进程与学习进程异步通信、示范引导到在线人工纠正再到自主强化的阶段性训练流程示意）

4.4.3 基于 IsaacSim 的仿真预训练与虚实迁移方法

直接在真实平台从零训练装配策略面临两方面约束：电连接器插针与孔壁间隙极小，训练早期随机探索易产生过大接触力而损伤插针或壳体；真实平台单次交互周期受限，冷启动阶段获取足量转移样本耗时较长。为此，本文采用“仿真预训练—真实精化”两阶段虚实迁移策略：在 IsaacSim 中以与真实平台一致的网络结构与 RLDP 算法预训练，获取具备初步轴孔对准能力的策略参数 $(\theta_{sim}^*, \phi_{sim}^*, \psi_{sim}^*)$ 作为先验；随后将该检查点加载至真实平台执行-学习异步架构，以人在回路方式在线精化至最终收敛。

仿真环境包含 Franka 机械臂、Robotiq 2F-85 夹爪、电连接器公头、底座插孔与柔性线缆的刚柔耦合模型。仿真侧的动作空间、阻抗控制器参数与观测空间均与真实平台严格对齐， π_θ 、 Q_ϕ 与 Q_ψ 的输入输出接口无需修改即可在两端复用。如图 4-14 所示，迁移时仅需加载仿真末期检查点作为真实平台的初始参数。

仿真与真实环境在接触动力学、摩擦、视觉渲染及线缆柔性响应方面存在域差异。为提升迁移鲁棒性，本文对多项物理与感知参数施加域随机化，设随机化参数集合为

$$\Xi = \{\delta_p, \delta_R, \delta_c, \delta_l, k_l, c_l, \mu, \eta_f\}, \quad (4-45)$$

式中, $\delta_p \in \mathbb{R}^3$ 与 $\delta_R \in \mathbb{R}^3$ 分别为预装配位置偏差与姿态偏差, δ_c 为相机视角微扰, δ_l 为线缆方向偏置角, k_l 、 c_l 为线缆等效刚度与阻尼, μ 为接触摩擦系数, η_f 为力觉噪声标准差。每条轨迹起始时独立采样一组 Ξ , 仿真预训练目标为

$$J_{sim}(\theta, \phi) = \mathbb{E}_{\Xi \sim p(\Xi)} \mathbb{E}_{\tau \sim \pi_{\theta, \Xi}} \left[\sum_{t=0}^T \gamma^t r_t \right], \quad (4-46)$$

式中, r_t 为与真实平台一致的稀疏成功/失败回报。该目标促使策略在多变摩擦、线缆姿态与视觉偏差下学习鲁棒的孔口搜索与对准行为, 避免在单一名义参数下过拟合。

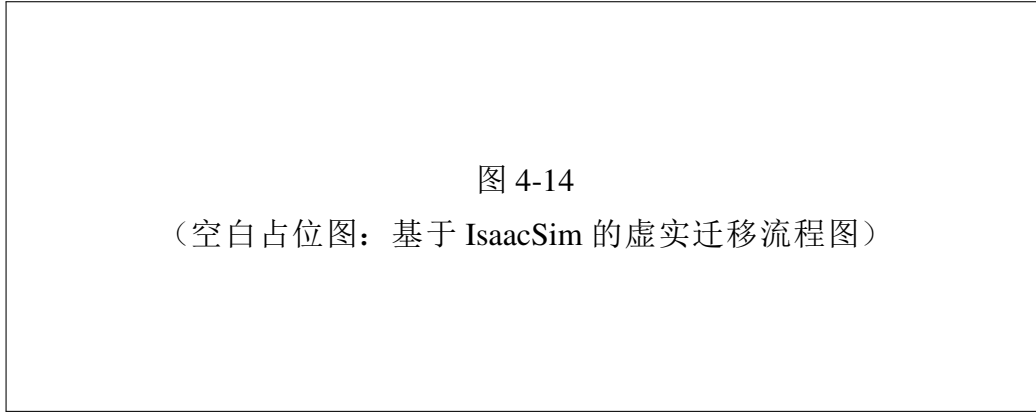


图 4-14 基于 IsaacSim 的虚实迁移流程图 (仿真预训练与真实精化共享网络结构与优化算法的两阶段迁移机制示意)

迁移流程分两阶段执行。第一阶段在 IsaacSim 中按式 (4-46) 以 RLPD 均衡采样交替更新 π_{θ} 、 Q_{ϕ} 与 Q_{ψ} , 直至装配成功率收敛并趋于稳定; 该阶段同时完成动作边界验证与奖励逻辑检查。第二阶段将检查点加载至真实平台学习进程, 在同一 RLPD 框架下以人在回路方式继续在线训练; 由于策略已具备基本对准与推进能力, 冷启动碰撞风险与干预频率显著降低, 策略在真实接触摩擦、线缆刚度与渲染差异下逐步适应并完成最终收敛。如图 4-15 所示, 两阶段回报曲线的对照可表明仿真预训练提供了有效参数先验, 域随机化赋予的分布鲁棒性有助于缩短真实平台适应周期。

4.5 装配实验与结果分析

为验证本章所提装配控制与策略学习方法对带柔性线缆电连接器插入任务的有效性, 分别在 IsaacSim 仿真环境与真实机器人平台上进行实验。实验按本章方法的递进关系组织: 首先在仿真中验证底层阻抗控制与高层残差策略的协同效果及域随机化预训练的收敛性, 随后将仿真所得策略参数迁移至真实平台, 验证人在回路在线精化的训练过程与最终装配性能。实验平台参数如表 4-1 所

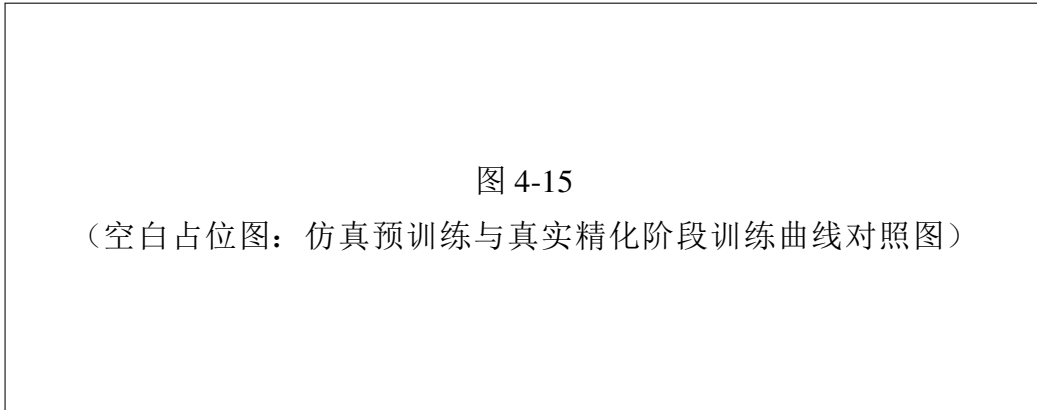


图 4-15 仿真预训练与真实精化阶段训练曲线对照图（域随机化条件下的回报收敛与迁移后在线适应趋势对照）示。

表 4-1 装配实验平台参数

参数	配置
机械臂	Franka Emika Panda 七自由度
夹爪	Robotiq 2F-85 二指平行夹爪
力/力矩传感器	末端六维力/力矩传感器
视觉	腕部 + 侧方相机（128 × 128 裁剪）
仿真平台	NVIDIA IsaacSim
学习端 GPU	NVIDIA RTX 3090
视觉骨干	ResNet-10（ImageNet 预训练，冻结）
策略/值网络 MLP	256 × 256 两层全连接
本体编码器	64 维全连接
折扣因子 γ	0.97
示范轨迹数	20–30 条

4.5.1 IsaacSim 仿真预训练验证

仿真预训练用于验证底层阻抗控制器与高层残差策略接口的协同性、奖励函数与成功/失败判定逻辑的有效性以及域随机化参数范围的合理性。在 IsaacSim 中，对预装配位置偏差、姿态偏差、线缆等效刚度与接触摩擦系数分别施加域随机化，以 RLPD 均衡采样方式训练策略网络与价值网络至收敛。

如图 4-16 所示，以训练轮次为横轴、累计回报为纵轴绘制仿真阶段训练曲线。训练初期回报波动较大，反映策略在域随机化参数空间内的探索过程；随训练推进，回报曲线逐渐上升并趋于稳定，表明策略在多种摩擦、线缆姿态与

位姿偏差组合下均能完成孔口搜索与轴孔对准。底层阻抗控制器有效限制了接触初期的碰撞力峰值，高层残差策略在此基础上输出横向与姿态修正增量，使对准收敛速度相较于仅依赖底层控制显著提升。仿真训练末期保存的策略检查点作为真实平台训练的初始参数。

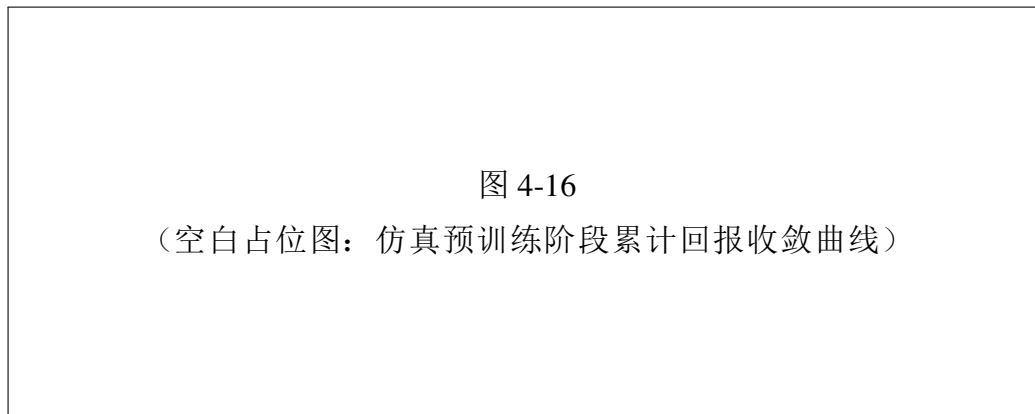


图 4-16
(空白占位图：仿真预训练阶段累计回报收敛曲线)

图 4-16 仿真预训练阶段累计回报收敛曲线

4.5.2 真实平台人在回路训练与装配验证

将仿真检查点加载至真实平台后，按以下流程开展人在回路在线训练：首先采集正负样本训练二值奖励分类器；随后由操作员完成 20–30 条示范轨迹并写入示范缓冲；最后启动在线训练，策略在执行-学习异步架构下滚动，操作员在偏孔、卡滞、力异常或拖缆偏拉等工况下短时接管纠正。

如图 4-17 所示，以训练轮次为横轴、装配成功率与人工干预次数为纵轴绘制真实平台训练曲线。由于策略从仿真预训练检查点出发而非随机初始化，训练起始阶段即具备基本的孔口搜索与轴向推进能力，初始成功率高于零且干预频率处于可控水平。随在线轮次增加，成功率逐步提升，干预次数逐步下降，表明策略在真实接触摩擦、线缆实际刚度与视觉渲染差异下完成了有效适应。训练后期干预趋近于零，标志策略已过渡至以强化回报为主导的自主执行阶段。

为验证底层阻抗控制在接触阶段的柔顺性与高层策略动作的阶段性，选取训练收敛后的典型成功插入回合，记录六维接触力/力矩的时域响应。如图 4-18 所示，对准阶段横向力分量 F_x 、 F_y 在策略修正增量驱动下振幅逐渐衰减；进入轴向推进阶段后 F_z 平稳上升至插入完成并回落，全程未出现超出安全阈值的力冲击。该结果表明底层阻抗控制器有效抑制了接触瞬态冲击，高层策略的“先对准、后推进”动作模式在真实平台上得到复现。

如图 4-19 所示，给出训练收敛后一次完整装配过程的关键帧序列，依次覆盖预对位、孔口搜索、轴孔对准、柔顺推进与插装完成五个阶段。策略在孔口

图 4-17

(空白占位图：真实平台训练过程成功率与干预次数曲线)

图 4-17 真实平台训练过程成功率与干预次数曲线

图 4-18

(空白占位图：典型成功插入回合六维接触力时域响应曲线)

图 4-18 典型成功插入回合六维接触力时域响应曲线

搜索阶段输出横向微调使连接器逐步趋近插孔轴线，在柔顺推进阶段沿插入方向平稳前进直至公头完全就位。在存在柔性线缆侧向拖拽的工况下，策略仍能通过连续修正维持轴线对准，验证了本章所提方法对航空非结构化环境下带柔性线缆电连接器插入任务的有效性。

图 4-19

(空白占位图：训练收敛后完整装配过程关键帧序列图)

图 4-19 训练收敛后完整装配过程关键帧序列图

4.6 本章小结

本章围绕预装配结果基础上的最终装配任务，建立了含线缆附加扰动的轴孔装配动力学模型，并将装配误差分解为横向对齐误差、轴向推进误差和姿态误差。设计了融合视觉前馈补偿的导纳/阻抗控制器，使线缆方向信息能够直接参与装配控制律构造，为接触过程中的柔顺执行与抗扰补偿提供基础。构建了面向轴孔对齐插接任务的多模态强化学习环境，通过示范样本、在线经验与人工纠正机制提升真实平台策略学习的样本效率和稳定性。引入基于 IsaacSim 的虚实迁移训练流程，在统一的 Franka 机械臂与 Robotiq 二指夹爪接口下完成仿真预验证、策略初始化与真实平台在线精化，形成可用于装配系统集成的柔顺控制与学习策略组合。

第5章 电连接器机器人自主装配系统集成与综合实验研究

5.1 引言

本章针对电连接器机器人自主抓取与装配系统的工程实现问题,开展系统集成与综合实验研究。首先搭建缩比航空机舱实验平台,完成机械臂、视觉传感器、力/力矩传感器和连接器工装的硬件集成,并建立相机、末端执行器与机器人基坐标系之间的标定关系;随后开展感知—规划子系统联合实验,验证输出的目标身份、精位姿和 *CableMask* 对抓取规划的支撑作用;进一步开展装配过程力控实验,分析在柔性拖缆干扰下的接触响应特性;最后通过连续作业实验,对系统在作业节拍、装配一致性、成功率和人工干预次数等方面的综合性能进行评估。

5.2 实验平台搭建与系统集成

系统级实验首先依赖稳定可靠的平台条件。若硬件布局不统一、坐标关系不准确或软件接口不稳定,感知结果就无法可靠传递给规划与控制模块,后续实验也难以具有重复性和可比性。狭窄空间、复杂遮挡和柔性拖缆并存的任务特点要求实验平台尽可能贴近真实航空机舱作业条件。本节围绕实验平台构建、系统标定和软件集成展开研究,建立硬件环境、坐标变换关系和 ROS 数据流。

5.2.1 航空机舱模拟环境与硬件构成

航空制造现场的狭窄舱段对机器人系统提出“可观测、可到达、可测量且可重复”的工程约束。为在有限空间内实现电连接器自主抓取与装配,实验平台以缩比机舱作为物理载体,集成工业机械臂、RGB-D 视觉传感器、六维力/力矩测量模块、末端夹持机构与连接器工装,使几何边界与柔性线缆干扰能够在同一实验链路中被稳定复现。

如图 5-1 所示,硬件布局围绕“位姿求解—抓取规划—装配力控”的连续链路进行组织。UR5e 机器人提供 850 mm 工作半径与 0.03 mm 重复定位精度,使末端在狭窄通道中完成接近、夹持与插接动作的可重复初始化;Robotiq 2F-85 与 3D 打印 TPU 柔性指尖的组合通过两指自适应夹持降低壳体局部应力集中风



图 5-1 电连接器机器人自主装配实验平台硬件集成结构图

险，从而减小由柔性线缆干扰引发的夹持偏差累积。

表 5-1 实验平台主要硬件参数配置

硬件类别	型号/规格	关键参数
工业机械臂	UR5e	工作半径 850 mm；额定负载 5 kg；重复定位精度 0.03 mm
末端夹持机构	Robotiq 2F-85 + 3D 打印 TPU 柔性指尖	两指自适应夹持；适配电连接器壳体夹持区域
RGB-D 视觉传感器	Intel RealSense D435i	Eye-in-Hand 安装；分辨率 1280×720；有效工作距离 0.2 m~1.0 m
六维力/力矩传感器	ATIGamma	F_x/F_y 量程 130 N； F_z 量程 400 N； $T_x/T_y/T_z$ 量程 10 N·m；分辨率 0.05 N；采样频率 1000 Hz
缩比机舱工装	定制缩比机舱实验平台	工作空间 600 mm×600 mm×500 mm；设置 3 个连接器工位；线缆长度约 1.5 m
连接器样件	D38999/26WC35PN 系列	典型插接尺度约 8 mm
上位计算平台	Intel Core i7-10700K + 32 GB RAM + NVIDIA RTX3070 GPU	支持视觉推理、规划计算与装配控制算法运行

表 5-1 给出了平台关键硬件参数，并反映了传感器精度与时间对齐对闭环实验的支撑作用。ATIGamma 六维力/力矩传感器以 1000 Hz 采样频率对装配阶段的接触载荷与力矩变化进行在线测量；RGB-D 视觉传感器在 Eye-in-Hand 架构下提供彩色图与深度图，为目标身份识别、精位姿估计以及柔性线缆形态感

知提供数据来源。视觉更新与力觉反馈的时间尺度匹配，能够避免插接阶段由于测量延时造成的误差累积，使接触调节过程具有可重复的观测条件。

同时，缩比机舱工作空间尺度（600 mm×600 mm×500 mm）与线缆长度约 1.5 m 使柔性拖缆在抓取抬升、转运与预装配对准过程中形成具有代表性的时变几何约束。柔性线缆形态由深度数据支持的线缆分割结果（*CableMask*）进行三维映射，为抓取与运动规划阶段提供可用于碰撞约束/避障评估的环境先验，从而保证柔性线缆干扰、规划约束与装配控制反馈之间的接口一致性。

5.2.2 系统标定与精度分析

在系统集成完成后，需要建立视觉测量与机器人控制之间的一致坐标映射关系。为确保视觉位姿能够稳定转化为机械臂末端控制目标，系统采用 *Eye-in-Hand* 结构进行手眼标定，求取相机坐标系与末端坐标系的刚体变换，并对整体映射精度进行量化评估。

以校准目标在坐标系 {O} 下的位姿为例，基座系 {B} 下位姿可由下式描述：

$${}^B T_O = {}^B T_E \cdot {}^E T_C \cdot {}^C T_O,$$

其中， ${}^B T_E$ 由机器人正运动学获得， ${}^E T_C$ 为相机与末端之间的固定刚体变换， ${}^C T_O$ 由标定靶的视觉观测得到。




图 5-2
(空白占位图)

图 5-2 末端相机、六维力传感器与夹爪安装关系图

(1) 标定方法过程（Eye-in-Hand + Tsai-Lenz）。本系统采用 Eye-in-Hand 手眼标定结构。相机固定安装于机械臂末端，使相机与末端之间的刚体变换在多次运动中保持不变。标定过程中，机器人在预设末端位姿集合上运动，采集标定靶图像并得到校准目标的相机系观测；同时由每个位姿对应的正运动学计算基座系与末端之间的变换。Tsai-Lenz 方法基于多组位姿约束解算相机与末端的刚体变换，并利用最小二乘意义降低噪声对标定结果的影响。为保证几何条件

与实际装配观测一致，本次标定采样采用 20 组末端位姿，并在相机有效成像范围内完成标定靶采集。




图 5-3
(空白占位图)

图 5-3 系统坐标系关系与手眼标定示意图

(2) 精度分析与误差量化。为验证标定结果的可用性，采用重投影一致性作为误差指标，并将像素级误差映射为空间位置误差。表 5.2.2 汇总了当前实验设置下的量化结果：20 组采样下重投影误差为 0.42 pixels，对应空间位置误差约为 0.35 mm。该误差水平反映视觉位姿到基坐标控制目标的初始映射精度，可为后续抓取与插接对位姿初始化提供亚毫米量级的稳定起点。

同时，力/力矩反馈在装配阶段承担接触载荷检测任务。系统对传感器零点进行载荷重心补偿与零点漂移校正，校正后零漂水平约为 0.2 N。该结果说明接触前的力反馈基线已得到有效抑制，能够减少零漂导致的误判触发，从而保证装配控制过程的可靠性与可重复性。

表 5-3 系统标定结果与精度分析结果

指标	结果	说明
手眼标定方法	Tsai-Lenz	20 组采样数据
重投影误差	0.42 pixels	对应空间位置误差约 0.35 mm
力传感器零漂水平	约 0.2 N	载荷重心补偿与零点漂移校正后

5.2.3 软件体系与数据流闭环

本节的软件集成以 ROS 话题与服务为通信骨架，在缩比机舱的受限空间内建立从视觉观测到装配执行的闭环链路。图 5-4 给出了各节点之间的数据传递关系与阶段触发逻辑，其中视觉输出驱动运动生成，装配执行阶段融合力觉反馈完成稳定过渡。

为了量化该闭环在多时间尺度上的协同一致性，表 5.2.3 给出各传感器与

图 5-4
(空白占位图)

图 5-4 基于 ROS 的系统软件架构与数据流向图

节点的运行频率，并对应识别、规划、执行与复位等阶段的启动与结束条件。视觉链路以 RGB 与深度的更新节奏提供目标位姿与线缆状态刷新，规划端在完成状态切换后生成 `joint_trajectory`，执行端依据指令刷新频率保持末端运动连续性；力觉链路在接触阶段以高采样频率提供力误差输入。

表 5-2 传感器与系统运行频率配置

模块/传感器	运行频率/方式	对应阶段与作用
RGB	30 fps	感知输入与目标实例识别触发
深度图像	30 fps	位姿求解所需深度反投影与障碍表示更新
力/力矩	1000 Hz	装配接触载荷实时反馈与零漂基线校验
vision_node	平均 65 ms/帧 (约 15 Hz)	输出目标位姿量与线缆状态量进入规划准备
planning_node	任务触发	生成阶段轨迹 <code>joint_trajectory</code> 并交付控制执行
control_node	500 Hz	轨迹执行期间融合视觉前馈与力觉反馈输出速度指令
state_manager	事件驱动	管理阶段切换与复位触发条件

从阶段过程看，识别阶段由 `vision_node` 在约 15 Hz 的输出节奏完成 `connector_pose` 与 `cable_vector` 的更新；当状态管理节点触发进入规划生成时，`plan-`

ning_node 使用最新的目标位姿与障碍表示生成 joint_trajectory, 并将其交付给 control_node。控制执行阶段由 control_node 以 500 Hz 发布速度指令, 在单次视觉更新间隔内形成多次控制校正, 使轨迹跟踪误差不会因观测延迟而累积。进入插接/接触阶段后, 力/力矩传感器以 1000 Hz 采样更新接触载荷, 驱动力位混合调节, 使接触非线性出现时仍能维持阻抗控制的收敛性。

在缩比机舱与柔性线缆干扰条件下, 插接接触过程呈现明显的时变非线性, 若感知更新、规划生成与控制发布之间缺乏匹配的时间尺度, 误差会在接口处累积并放大为接触力估计滞后与末端轨迹抖动。表 5.2.3 给出的多速率通信与节点触发机制, 使得视觉观测输出能够按固定节奏进入规划准备, 规划结果在控制执行阶段保持一致的目标更新边界, 同时力觉反馈以高采样率驱动阻抗调节。该时序耦合为后续系统级综合验证提供了可复现的闭环接口条件, 从而保证不同工况下接触调节过程的可比性与稳定性。

5.3 感知—规划子系统联合验证实验

为验证狭窄机舱场景下“感知输出—规划输入”的系统接口有效性, 联合实验以电连接器抓取任务为载体, 将任务难点集中在目标身份混淆、目标位姿受遮挡影响以及尾部柔性线缆形成时变障碍三类问题。实验设计强调分段推进: 首先构建遮挡工况以覆盖不同可见性条件, 其次完成线缆先验从像素表征到三维障碍表征的映射, 再对比基线方法与本文方法在同一接口设置下的联合效果, 并用定量指标与轨迹/耗时/失效模式的联合解释来完成论证闭环。

图 5-5
(空白占位图)

图 5-5 轻度、中度与重度遮挡典型实验场景图

如图 5-5 所示, 实验分别构建轻度、中度与重度遮挡三类典型工况。遮挡等级的变化同时影响目标关键区域可见性与线缆在局部空间中的分布密度, 因此可在同一任务评价框架下检验联合系统对“观测不确定性增加”和“环境可通行域收缩”的鲁棒性。

图 5-6
(空白占位图)

图 5-6 CableMask 到 Octomap 障碍地图的构建过程图

如图 5-6 所示，线缆先验由 CableMask 表征得到三维障碍约束，具体包括深度映射得到相机系点云、点云滤波抑制噪声点与离群点、体素化形成离散占据，再在规划地图结构中以 Octomap 的占据概率形式供碰撞检测调用。该接口映射将线缆由“视觉平面信息”转化为“可验证的碰撞约束”，使规划搜索能够在相同的几何语义下进行。

在对比实验中，Baseline 方法仅采用相对有限的感知输入，而本文方法在同一遮挡工况下引入更完整的目标身份与精位姿信息，并叠加由线缆先验构建的障碍地图，使规划器能够在目标选择、轨迹生成与线缆避障三个环节同时受益。评价指标围绕联合链路输出的可执行性展开，包含识别成功率、误抓次数、线缆接触次数、平均规划时间、预装配位姿误差以及抓取成功率。

表 5-4 给出了联合实验的主要量化结果。随着遮挡等级由轻度增加到重度，Baseline 的抓取成功率由 90% 下降到 15%，而本文方法仍保持 90% 的成功率水平；在重度遮挡下，误抓次数从 2 次下降为 0 次，线缆接触次数从 15 次降至 1 次，预装配位姿误差从 4.5 mm 降低到 1.1 mm，平均规划时间由 8.64 s 收敛至 4.82 s。上述对比表明，联合系统在观测不确定性增强与可通行域收缩条件下，能够通过完整接口输入降低错误目标选择概率，并通过三维线缆约束抑制与线缆的近距离擦碰与缠绕风险。

进一步结合轨迹安全性与耗时稳定性进行解释。图 5-7 给出了本文方法在舱壁与线缆附近的典型规划轨迹形态，轨迹与关键障碍边界保持了更合理的安全间隙，量化上与线缆接触次数的降低趋势一致，说明规划搜索在引入三维线缆障碍约束后能够稳定选择更安全的通行走廊。

图 5-8 从识别与抓取表现角度对遮挡等级变化进行对比：Baseline 在中度与重度遮挡下表现衰减更快，而本文方法的下降幅度相对更小，体现出对目标关键区域可见性下降的鲁棒适应能力。该结论与表 5-4 中识别成功率和抓取成功

表 5-4 不同遮挡工况下感知—规划联合实验结果

方法	遮 挡 工 况	识 别 成 功 率/%	误 抓 次 数/次	线 缆 接 触 次数/次	平 均 规 划 时间/s	预 装 配 位 姿误差/mm	抓 取 成 率/%
Baseline	轻 度 遮 挡	100	0	2	2.15	0.4	90
Ours	轻 度 遮 挡	100	0	0	2.42	0.3	100
Baseline	中 度 遮 挡	85	1	8	3.55	1.2	55
Ours	中 度 遮 挡	95	0	0	3.28	0.8	95
Baseline	重 度 遮 挡	40	2	15	8.64	4.5	15
Ours	重 度 遮 挡	90	0	1	4.82	1.1	90

图 5-8
(空白占位图)

图 5-7 规划轨迹与舱壁/线缆安全间隙示意图

率的差异一致，说明联合链路的稳定性主要来自目标身份锁定与预抓取位姿初始化的接口质量。



图 5-8 不同遮挡程度下识别与抓取表现对比示意图

针对规划耗时，图 5-9 以箱线统计方式比较不同方法的规划时间分布。相较于 **Baseline** 的更宽分布，本文方法的中位数与离散程度更小，说明在统一实验平台与相同任务触发逻辑下，完整感知先验能够减少无效搜索迭代，并稳定搜索过程。图 5-10 进一步从分布视角验证该趋势，规划耗时在本文方法中表现出更集中的统计特征。




图 5-9 不同方法规划耗时箱线图

如图 5-10 所示，本文方法在规划耗时上的分布更加集中，体现出感知先验的语义约束不仅改善成功率，也降低了搜索过程对噪声与遮挡误差的敏感性。

最后，从失效模式角度解释联合系统为何在重遮挡工况下仍能维持可执行性。图 5-11 给出了典型失败案例：当精位姿估计与线缆三维障碍约束缺失或不一致时，系统更容易出现目标误锁定、轨迹擦碰以及线缆缠绕等问题。该失效形态与表 5-4 中误抓次数与线缆接触次数的变化规律相互印证，说明线缆先验的三维化与目标位姿的接口质量能够共同作用于“选对目标—走对路径—避开线缆”的可执行性链路。

图 5-10
(空白占位图)

图 5-10 规划耗时分布统计图

图 5-11
(空白占位图)

图 5-11 典型失败案例分析图

综上，5.3 节实验表明，在狭窄机舱与柔性线缆干扰条件下，通过完整的感知输出一三维障碍映射—规划生成接口输入，联合系统能够在遮挡等级提升时保持更高的抓取成功率，并在重度遮挡下显著降低误抓与线缆接触风险。该结论为后续装配过程的稳定预装配位姿初始化提供了直接实验依据。

5.4 面向航空制造的全流程综合验证

5.4.1 实验流程设计

为验证前述子系统方案在完整系统尺度上的可用性，本节开展端到端综合实验，重点检验：在狭窄机舱几何约束与柔性线缆干扰并存条件下，感知输出是否能够稳定驱动抓取规划；规划轨迹是否能够在时变线缆约束下安全执行；装配控制是否能够在接触非线性出现时维持力响应稳定性，并完成连续任务链闭环。

实验以缩比机舱的多实例混叠为输入场景，同时叠加狭窄通道约束与柔性拖缆干扰。四个连续阶段按动作链组织并形成可重复的接口边界：第一阶段由感知模块完成目标身份锁定、精位姿估计与线缆状态量输出；第二阶段由抓取

与规划模块完成接近、夹持、避障搬运以及预对准，并将线缆三维约束纳入可行域评估；第三阶段由装配控制模块完成接触调节、搜孔与插接动作，在力觉闭环下实现误差收敛；第四阶段由状态管理逻辑触发复位与下一目标实例处理，从而考察连续作业能力与阶段切换的稳定性。




图 5-11
(空白占位图)

图 5-12 全流程综合验证实验流程

在评价指标选择上，本节以作业节拍与装配力响应一致性为核心量化指标，并以线缆干扰下的成功率检验工程可用性。人工装配用于提供现实工艺条件下的参考上界，用于解释自主系统在效率与稳定性之间的综合权衡。

5.4.2 综合效能评估与结果分析

全流程综合验证在缩比机舱平台上按图 5-12 所示的动作链组织执行。每次任务以相同的初始状态触发系统：先完成目标身份锁定与预对准初始化，再进入抓取搬运与基于线缆三维约束的安全轨迹生成，随后进入插接接触阶段并由力觉闭环驱动阻抗调节，最后通过状态管理切换至下一目标实例处理流程。实验过程中记录每次作业节拍、接触阶段的力响应波动形态，并统计线缆干扰条件下的任务完成情况。基于上述采集数据，表 5-5 汇总了人工装配（熟练工）与本文自主系统在典型作业工况下的统计结果。

表 5-5 全流程综合性能统计结果

评估指标	人工装配（熟练工）	本文自主系统
单次作业节拍 / s	15.5	22.8
装配力峰值方差 / N	2.5	0.4
线缆干扰下成功率 / %	98	96.7

从统计指标可见，本文自主系统在节拍上存在一定成本（22.8 s 相比人工的 15.5 s），该成本主要来源于全流程链路中对安全间隙与接触稳定性的冗余校验与力觉闭环调节时间。更关键的是，装配力峰值方差由人工装配的 2.5 N 降至 0.4 N，表明在插接与搜孔接触非线性阶段，自主系统能够将力响应波动限制在更小范围内，从而减少由接触力突变引发的对准漂移与二次调整次数。在线缆干扰下的插接成功率达到 96.7%，与人工装配的 98% 保持接近，说明本文方案能够在刚柔耦合场景中维持可执行的连续动作链。

从时间尺度匹配角度看，全流程节拍差异并不意味着插接过程的误差积累，而更偏向体现在“插接前的安全准备阶段”。在节点触发机制约束下，视觉侧以约 15 Hz 刷新目标位姿与线缆状态量；规划侧在任务触发条件下生成阶段轨迹并交付执行；控制执行侧以 500 Hz 输出速度指令，在单次视觉更新间隔内形成多轮闭环校正；进入插接/接触阶段后，力/力矩传感器以 1000 Hz 采样接触载荷并驱动力觉闭环调节。该多速率协同使得“感知更新—轨迹约束—力觉校正”在同一工况窗口内保持稳定对应关系，从而抑制非线性接触引起的末端轨迹抖动。

图 5-12
(空白占位图)

图 5-13 全流程自主装配实验关键帧序列图

如图 5-13 所示，全流程自主装配的关键帧序列可划分为预对准、搬运避障与插接接触三个动作段。预对准阶段的末端姿态连续性由上游抓取规划输出保证，使接近过程能够在不破坏线缆空间约束的前提下完成姿态导入；搬运与避障阶段通过将线缆状态量转化为规划可行域约束，降低末端轨迹对线缆附近几何边界的扰动概率；插接阶段进入接触非线性后，力觉反馈驱动控制律对接触误差进行实时校正，并在阻抗调节框架下抑制力波动的传播。上述三个阶段的动作边界与时序衔接方式与图 5-12 所示流程设计一致，因此关键帧序列形态与力峰值方差统计能够相互印证。

接触阶段的力响应稳定性可从阻抗调节的等效动力学关系得到解释。末端

在约束环境下的期望位移误差可由阻抗模型对应到外载荷响应，其典型形式为

$$M\ddot{x} + B\dot{x} + Kx = f_{ext}$$

其中， x 为末端等效位移（相对插接参考路径）， M 表示等效质量， B 表示等效阻尼， K 表示等效刚度， f_{ext} 为外部接触力/力矩通过坐标映射得到的等效外载荷。该模型将插接过程中外载荷引起的扰动映射为阻抗系统的动态响应，从而在控制过程中抑制接触非线性导致的力峰值突变，进而降低装配力峰值方差并提升收敛性。

如图 5-15 所示，极端打结工况会同时改变线缆受力方向并重构局部几何约束，使原有线缆方向先验与可通行域引导的可靠性降低，规划阶段需要更多依赖接触阶段的力觉闭环来实现误差收敛。图 5-14 的综合效能结果表明，即便线缆约束一致性下降，自主系统仍保持较高成功率与力响应稳定性，其原因在于：接触阶段的力觉闭环能够对接触调节误差进行在线修正，而阻抗调节机制能够限制力波动在末端与接触界面的扩散范围，从而避免由几何先验失配引发的插接失稳。

在极端打结场景下，主要失效风险来源于两类误差耦合：其一，线缆三维约束的局部形态变化会导致规划可行域边界的估计偏移；其二，线缆受力方向变化会改变接触界面的摩擦与支撑条件，使得插接几何约束更易出现非理想偏转。力觉闭环通过对接触误差进行在线修正，把上述偏移从“开环几何导向”转化为“闭环动力响应”，因此仍能够在不稳定先验条件下维持插接过程的可收敛性。



图 5-18
(空白占位图)

图 5-14 极端打结工况下综合效能对比示意图

为进一步说明全流程结果的可重复性，本节将前述感知—规划联合验证的定量支撑作为接口质量背景。表 5-4 中，本文在轻度、中度与重度遮挡工况下

图 5-19
(空白占位图)

图 5-15 极端打结工况下线缆受力方向与局部几何约束变化示意图

的抓取成功率分别为 100%、95% 与 90%，并且在重度遮挡下平均规划时间由 2.42 s 增长至 4.82 s。该上游接口表现表明，即便观测不确定性增强，系统仍能维持足够稳定的预对准初始化质量，从而使插接阶段的力闭环在更接近目标姿态的起始条件下收敛。因此，全流程实验中的力响应稳定性与高成功率不仅由控制策略保证，也由前端感知与规划链路共同提供了可控的起始误差边界。

5.5 本章小结

本章围绕系统集成、联合验证与全流程评估展开，构建了面向航空制造场景的缩比机舱实验平台，完成手眼标定与 ROS 集成，重投影误差为 0.42 pixels、空间误差约为 0.35 mm，感知链路平均耗时约 65 ms，可支撑系统闭环运行。感知—规划联合实验表明，目标身份、精位姿与 CableMask 先验能够有效提升抓取锁定、预抓取初始化与线缆避障建图效果；装配实验中，本文方法的峰值接触力降至 6.5 ± 1.2 N，成功率达 100%。全流程综合验证表明，本文系统单次节拍为 22.8 s，线缆干扰下成功率为 96.7%，并在狭窄空间与柔性线缆约束条件下表现出较高一致性、自主性与鲁棒性。

结 论

结论内容待结合全文研究结果进一步整理与补充。当前工程已完成正文主体的初步迁移,可在后续写作中对创新点、实验结论与工程价值进行系统归纳。

参考文献

- [1] Lepetit V, Moreno-Noguer F, Fua P. EPnP: An Accurate $O(n)$ Solution to the PnP Problem[J]. International Journal of Computer Vision, 2009, 81(2): 155-166.
- [2] Fischler M A, Bolles R C. Random Sample Consensus: A Paradigm for Model Fitting with Applications to Image Analysis and Automated Cartography[J]. Communications of the ACM, 1981, 24(6): 381-395.
- [3] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks[C] // Advances in Neural Information Processing Systems: Vol 28. 2015.
- [4] Redmon J, Divvala S, Girshick R, et al. You Only Look Once: Unified, Real-Time Object Detection[C] // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 779-788.
- [5] Wang C-Y, Bochkovskiy A, Liao H-Y M. YOLOv7: Trainable Bag-of-Freebies Sets New State-of-the-Art for Real-Time Object Detectors[C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 7464-7475.
- [6] He K, Gkioxari G, Dollár P, et al. Mask R-CNN[C] // Proceedings of the IEEE International Conference on Computer Vision. 2017: 2961-2969.
- [7] Chen L-C, Zhu Y, Papandreou G, et al. Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation[C] // Proceedings of the European Conference on Computer Vision. 2018: 801-818.
- [8] Xiang Y, Schmidt T, Narayanan V, et al. PoseCNN: A Convolutional Neural Network for 6D Object Pose Estimation in Cluttered Scenes[C] // Robotics: Science and Systems. 2018.
- [9] Peng S, Liu Y, Huang Q, et al. PVNet: Pixel-wise Voting Network for 6DoF Pose Estimation[C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 4561-4570.
- [10] Wang C, Xu D, Zhu Y, et al. DenseFusion: 6D Object Pose Estimation by Iterative Dense Fusion[C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 3343-3352.

- [11] He Y, Sun W, Huang H, et al. PVN3D: A Deep Point-wise 3D Keypoints Voting Network for 6DoF Pose Estimation[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 11632-11641.
- [12] Song C, Song J, Huang Q. HybridPose: 6D Object Pose Estimation under Hybrid Representations[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 431-440.
- [13] He Y, Huang H, Fan H, et al. FFB6D: A Full Flow Bidirectional Fusion Network for 6D Pose Estimation[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 3003-3013.
- [14] Labbé Y, Carpentier J, Aubry M, et al. CosyPose: Consistent Multi-view Multi-object 6D Pose Estimation[C] //Proceedings of the European Conference on Computer Vision. 2020: 574-591.
- [15] Su Y, Salber M, Gnanapragasam T, et al. ZebraPose: Coarse to Fine Surface Encoding for 6DoF Object Pose Estimation[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 6738-6748.
- [16] Tang C, Lin H-C, Tomizuka M. A Framework for Manipulating Deformable Linear Objects by Coherent Point Drift[J]. IEEE Robotics and Automation Letters, 2018, 3(4): 3426-3433.
- [17] Caporali A, Galassi K, Zanella R, et al. DLO3DS: Deformable Linear Objects 3D Shape Estimation in Cluttered Environments[J]. IEEE Robotics and Automation Letters, 2023, 8(6): 3310-3317.
- [18] Mou F, Gao J, Chen W, et al. A Learning-Based Cable Coupling Effect Modeling for Robot Manipulation with Heavy Industrial Cables[J]. IEEE Transactions on Industrial Electronics, 2022, 69(12): 13363-13373.
- [19] Kuffner J J, LaValle S M. RRT-Connect: An Efficient Approach to Single-Query Path Planning[C] //Proceedings of the IEEE International Conference on Robotics and Automation. 2000: 995-1001.
- [20] Hsu D, Jiang T, Reif J, et al. The Bridge Test for Sampling Narrow Passages with Probabilistic Roadmap Planners[C] //Proceedings of the IEEE International Conference on Robotics and Automation. 2003: 4420-4426.
- [21] Karaman S, Frazzoli E. Sampling-based Algorithms for Optimal Motion Planning[J]. International Journal of Robotics Research, 2011, 30(7): 846-894.

- [22] Gammell J D, Srinivasa S S, Barfoot T D. Informed RRT*: Optimal Sampling-based Path Planning Focused via Direct Sampling of an Admissible Ellipsoidal Heuristic[C] // Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems. 2014: 2997-3004.
- [23] Gammell J D, Srinivasa S S, Barfoot T D. Batch Informed Trees (BIT*): Sampling-based Optimal Planning via the Heuristically Guided Search of Implicit Random Geometric Graphs[C] // Proceedings of the IEEE International Conference on Robotics and Automation. 2015: 3067-3074.
- [24] Zucker M, Ratliff N, Dragan A D, et al. CHOMP: Covariant Hamiltonian Optimization for Motion Planning[J]. International Journal of Robotics Research, 2013, 32(9-10): 1164-1193.
- [25] Mousavian A, Eppner C, Fox D. 6-DOF GraspNet: Variational Grasp Generation for Object Manipulation[C] // Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 2901-2910.
- [26] Fang H-S, Wang C, Gou M, et al. GraspNet-1Billion: A Large-Scale Benchmark for General Object Grasping[C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 11444-11453.
- [27] Sundermeyer M, Mousavian A, Triebel R, et al. Contact-GraspNet: Efficient 6-DoF Grasp Generation in Cluttered Scenes[C] // Proceedings of the IEEE International Conference on Robotics and Automation. 2021: 13438-13444.
- [28] Whitney D E. Quasi-Static Assembly of Compliantly Supported Rigid Parts[J]. ASME Journal of Dynamic Systems, Measurement, and Control, 1982, 104(1): 65-77.
- [29] Hogan N. Impedance Control: An Approach to Manipulation: Part I—Theory[J]. ASME Journal of Dynamic Systems, Measurement, and Control, 1985, 107(1): 1-7.
- [30] Inoue T, De Magistris G, Munawar A, et al. Deep Reinforcement Learning for High Precision Assembly Tasks[C] // Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems. 2017: 819-825.
- [31] Vecerik M, Hester T, Scholz J, et al. Leveraging Demonstrations for Deep Reinforcement Learning on Robotics Problems with Sparse Rewards[J]. arXiv preprint arXiv:1707.08817, 2017.

- [32] Beltran-Hernandez C C, Petit D, Ramirez-Alpizar I G, et al. Variable Compliance Control for Robotic Peg-in-Hole Assembly: A Deep-Reinforcement-Learning Approach[J]. Applied Sciences, 2020, 10(19): 6923.
- [33] Tobin J, Fong R, Ray A, et al. Domain Randomization for Transferring Deep Neural Networks from Simulation to the Real World[C] // Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems. 2017: 23-30.
- [34] Narang Y, Storey K, Akinola I, et al. Factory: Fast Contact for Robotic Assembly[C] // Robotics: Science and Systems. 2022.
- [35] Schoettler G, Nair A, Ojea J A, et al. Meta-Reinforcement Learning for Robotic Industrial Insertion Tasks[C] // Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems. 2020: 9728-9735.
- [36] Luo J, Solowjow E, Wen C, et al. Robust Multi-Modal Policies for Industrial Assembly via Reinforcement Learning[C] // Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems. 2021: 6380-6387.
- [37] Jiang Z, Chen X. A Robotic Assembly Strategy of Large-Diameter Peg-in-Hole Based on Deep Reinforcement Learning with Fuzzy Action Generator[J]. Assembly Automation, 2023, 43(3): 353-365.